

Aprendizado de Máquina

Aula 5: Algoritmos baseados em probabilidade

André C. P. L. F de Carvalho
ICMC/USP

andre@icmc.usp.br



Tópicos

- Métodos baseados em probabilidade
- Métodos discriminativos
 - Regressão Logística
- Métodos generativos
 - Teoria das probabilidades
 - Teorema de Bayes
 - *Naive Bayes*

Introdução

- Muitos problemas de classificação são não determinísticos
 - Relação entre atributos de entrada e classe é probabilística
 - Ruído nos dados
 - Algumas informações importantes não são capturadas pelos atributos preditivos usados
 - Informações capturadas pelos atributos preditivos usados são incompletas ou imprecisas

Exemplo

- Predizer se uma pessoa terá problemas cardíacos
 - Atributos preditivos: peso e frequência de exercício
 - Ignora outras possíveis causas:
 - Bebida
 - Hereditariedade
 - Fumo
 - Alimentação
 - ...

Métodos probabilísticos

- Em várias aplicações é importante ...
 - Estimar a probabilidade de um exemplo pertencer a uma classe
- Modelam relacionamento probabilístico entre atributos preditivos e atributo alvo
- Tipos de modelos induzidos:
 - Modelos discriminativos
 - Modelos generativos

Métodos discriminativos

- Discriminam um objeto entre os possíveis rótulos (classes)
 - Qual a probabilidade de um dado objeto ter um dado rótulo
- Modelam a distribuição de probabilidade a posteriori (condicional) $P(Y/X)$
- Dado X , retornam a probabilidade de Y ocorrer
 - X : atributo(s) preditivo(s)
 - Y : atributo alvo
 - Ex.: Regressão logística

Métodos generativos

- Conhecem a distribuição dos dados
 - Sabe qual a probabilidade de existir um objeto X da classe Y
 - Podem gerar novos objetos
- Modelam a distribuição de probabilidade conjunta $P(X,Y)$ (ou $P(X)$ se não existirem rótulos)
 - Com a distribuição conjunta é possível derivar qualquer distribuição condicional
- Induzidos por algoritmos baseados no teorema de Bayes
 - Algoritmos Bayesianos
 - Ex.: *Naive Bayes*

Discriminativos x Generativos

Modelos Discriminativos

Modelam a fronteira de decisão entre as classes

Sabem se é provável que um objeto x tenha o rótulo y

$P(y/x)$

Discriminam um objeto entre possíveis rótulos (classes)

Modelos Generativos

Modelam a distribuição de cada classe


Sabem se é provável que exista um objeto (x,y)

$P(y, x)$

Podem gerar novos objetos, pois conhecem a distribuição de cada classe

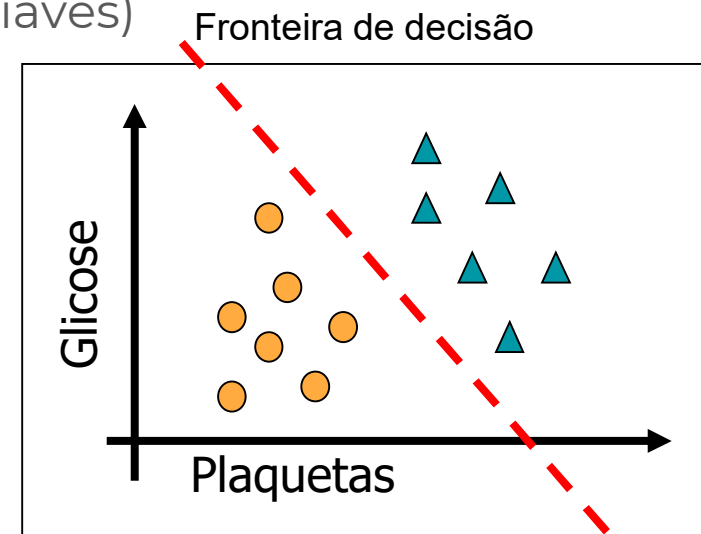
Fronteira de decisão

- Supor um conjunto de objetos, cada um representado por dois atributos preditivos (características, variáveis)
 - Nível de glicose
 - Número de plaquetas no sangue
- Objetos podem ser representados em um espaço de atributos
 - Como classificar novos objetos?
 - Construir uma fronteira de decisão
 - Fácil ver em até 3 dimensões



Fronteira de decisão

- Supor um conjunto de objetos, cada um representado por dois atributos preditivos (características, variáveis)
 - Nível de glicose
 - Número de plaquetas no sangue
- Objetos podem ser representados em um espaço de atributos
 - Como classificar novos objetos?
 - Construir uma fronteira de decisão
 - Fácil ver em até 3 dimensões



$$y = ax + b$$

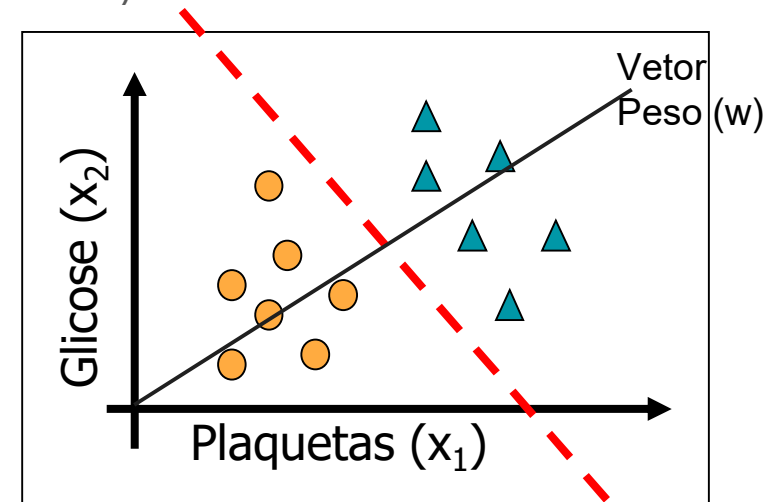
$$\text{Glicose} = a\text{Plaquetas} + b$$

Fronteira de decisão

- Como construir a fronteira de decisão?
- Adicionar um novo vetor de peso, W
 - Cuja orientação será usada para definir a fronteira de decisão

Fronteira de decisão


- Supor um conjunto de objetos, cada um representado por dois atributos preditivos (características, variáveis)
 - Nível de glicose
 - Número de plaquetas no sangue
- Objetos podem ser representados em um espaço de atributos
 - Como classificar novos objetos?
 - Construir uma fronteira de decisão
 - Fácil ver em até 3 dimensões



$$f(x) = \sum_{i=1}^n w_i x_i - \theta$$
$$f(x) = w_1 x_1 + w_2 x_2 - \theta$$
$$f(x) = w_1 x_1 + w_2 x_2 + w_0$$

Discriminante linear

- Fronteira de decisão pode ser representada por uma função linear
 - Função discriminante
 - Discrimina se um novo objeto pertence à classe positiva ou negativa
 - Ajusta parâmetros da função $f(x) = w_0 + w_1x_1 + w_2x_2 + \dots$
 - Valor de $f(x)$
 - $f(x) > 0$ classe positiva
 - $f(x) < 0$ classe negativa
 - Distância de x à fronteira de decisão
- Estima chance de x pertencer à classe positiva (negativa)



Fronteira de decisão

- Quando $f(x) = 0$
- Quando $w_1x_1 + w_2x_2 + w_0 = 0$

$$x_2 = -w_1/w_2 x_1 - w_0/w_2$$
$$y = ax + b$$


- Se temos os valores de w_2 , w_1 e w_0 , temos uma fronteira de decisão
- Problema: encontrar valores de w_2 , w_1 e w_0

Discriminante linear

- Distância de exemplos a fronteira de decisão definida por uma função linear
- Problema:
 - Distância: $-\infty < f(x) < +\infty$
 - Modelos probabilísticos devem retornar uma probabilidade: $0 \leq f(x) \leq 1$
- Solução:
 - Regressão logística

Regressão logística

- Apesar do nome, é usada para tarefas de classificação
- Estima probabilidade que um exemplo x pertencer a uma dada classe y : $P(y/x)$
 - Ajusta uma função logística a um conjunto de dados
 - Utiliza um conjunto de treinamento
 - Gera uma curve sigmoide
 - Produz uma fronteira de decisão
 - Hiperplano de separação




Regressão logística

- Chance de sucesso em relação ao fracasso (odds)
- Ex.: Suponha as seguintes probabilidades:
 - $\text{Probabilidade}_{\text{Sucesso}} = 0,8$
 - $\text{Probabilidade}_{\text{Fracasso}} = 1,0 - 0,8 = 0,2$
 - $\text{Chance}_{\text{Sucesso}} = \frac{P_{\text{Sucesso}}}{P_{\text{Fracasso}}} = 0,8/0,2 = 4:1$
 - $\text{Chance}_{\text{Positiva}} = \frac{P_{\text{Positiva}}}{P_{\text{Negativa}}} = 4:1$

Regressão logística

P_+ :
Probabilidade
de sucesso

$$p_+(x) = \frac{1}{1 + e^{-f(x)}}$$




| Probabilidade (P_+) | Chance ($P_+:(1-P_+)$) | Log(Chance) |
|-------------------------|--------------------------|-------------|
| 0,5 | 50:50 (1:1) = 1 | 0,00 |
| 0,9 | 90:10 (9:1) = 9 | 2,19 |
| 0,999 | 999:1 = 999 | 6,91 |
| 0,01 | 1:99 = 0,0101 | -4,60 |
| 0,001 | 1:999 = 0,001001 | -6,91 |

- Encontrar $f(x)$ que consiga modelar $\log(\text{Chance})$
 - Permite estimar probabilidade usando modelo gerado por discriminante linear

Regressão logística

P_+ :
Probabilidade
de sucesso



| Probabilidade (P_+) | Chance ($P_+ : P_-$) | $\log(\text{Chance})$ |
|-------------------------|------------------------|-----------------------|
| 0,5 | 50:50 (1:1) = 1 | 0,00 |
| 0,9 | 90:10 (9:1) = 9 | 2,19 |
| 0,999 | 999:1 = 999 | 6,91 |
| 0,01 | 1:99 = 0,0101 | -4,60 |
| 0,001 | 1:999 = 0,001001 | -6,91 |

- Encontrar $f(x)$ que consiga modelar $\log(\text{Chance})$
 - Permite estimar probabilidade usando modelo gerado por discriminante linear

Regressão logística

- Probabilidade de exemplo pertencer a classe positiva
 - Evento ocorreu

$$\text{Função logit} \rightarrow \log\left(\frac{p_+(x)}{1-p_+(x)}\right) = f(x) = w_0 + w_1x_1 + w_2x_2 + \dots$$


$$p_+(x) = \frac{1}{1+e^{-f(x)}} = \frac{e^{f(x)}}{1+e^{f(x)}}$$

- Treinamento

$$g(x, w) = \begin{cases} p_+(x) & \text{se } x \text{ é } + \\ 1 - p_+(x) & \text{se } x \text{ é } - \end{cases} \quad \text{Função objetivo para ajuste dos pesos}$$

Regressão logística

- Função logit
 - Inversa da função logística



$$\log\left(\frac{p_+(x)}{1-p_+(x)}\right)$$

Treinamento

- Encontrar valores de w_i que minimizem erro no conjunto de treinamento
 - Faz aproximação numérica utilizando método de máxima verossimilhança
 - Gradiente descendente estocástica
 - Para grandes conjuntos de dados
 - Exemplo para 1 atributo preditivo
 - w_0 : posição da função logística
 - w_1 : inclinação da função logística

Teoria das probabilidades

- Espaço amostral (Ω) : todos as possíveis observações de um experimento
- Evento (A): subconjunto de possíveis observações em Ω
- Ex.: Valores de um dado de 6 faces
 - $\Omega = \{1, 2, 3, 4, 5, 6\}$
 - $A = \text{valor do dado} < 3 = \{1, 2\}$
 - $A = \text{valor do dado é par} = \{2, 4, 6\}$
 - $P(A)$: probabilidade de um evento ocorrer

Teoria das probabilidades

- $P(A)$ satisfaz axiomas de Kolmogorov
 - $P(A) \geq 0$
 - $P(\Omega) = 1$
 - $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
 - Se A e B são eventos mutuamente exclusivos
 - $(A \cap B) = \emptyset$
 - $P(A \cap B) = 0$
 - $P(A \cup B) = P(A) + P(B)$

Teoria das probabilidades

- Probabilidade conjunta
 - Probabilidade de dois eventos ocorrerem simultaneamente
 - $P(A \cap B)$ ou $P(A,B)$
 - Se eventos são eventos independentes
 - A ocorrência de um não afeta a probabilidade de ocorrência do outro
 - $P(A \cap B) = P(A) * P(B)$

Probabilidade e AM

- Tarefa: dado o resultado de um exame, prever se paciente está doente
- Atributo preditivo
 - Resultado de exame
- Atributo alvo
 - Diagnóstico do paciente
 - Predição (classificação)

Probabilidade e AM

- Sejam dois eventos A e B
 - A: atributo alvo (presença de uma doença)
 - Variável aleatória com dois valores: presença e ausência
 - B: atributo de entrada (resultado de um exame)
 - Variável aleatória com dois valores: positivo e negativo
 - $P(A)$: probabilidade do evento A ocorrer (presença da doença)
 - $P(A) = 1 - P(\neg A)$
 - $P(B)$: probabilidade do evento B ocorrer (exame positivo)
 - $P(B) = 1 - P(\neg B)$

Probabilidade condicional

- Probabilidade de ocorrência de um evento dada a ocorrência de outro
 - $P(A/B)$
 - Probabilidade de ocorrência de um evento A dada a ocorrência de um evento B
 - Ex.: Probabilidade de estar doente (A) dado que um exame (B) deu positivo
 - Se os atributos (eventos) forem independentes: $P(A/B) = P(A)$
 - Caso não sejam, usar lei de probabilidade condicional

Probabilidade e AM

- $P(A)$: probabilidade a priori do paciente está doente
- $P(B)$: distribuição da variável preditiva B ser verdade (exame deu resultado positivo)
 - Evidência
- $P(B/A)$: probabilidade de verosimilhança
 - Para um valor fixo de A, define verosimilhança (plausibilidade) de cada um dos possíveis valores de B
 - Verossímil: similar a verdade, provável
 - Verosimilhança: possui a qualidade de ser verossímil

Probabilidade e AM

| Paciente | Exame | Doença |
|----------|----------|----------|
| 001 | positivo | presente |
| 002 | negativo | presente |
| 003 | negativo | ausente |
| 004 | positivo | presente |
| 005 | positivo | ausente |
| 006 | positivo | presente |
| 007 | negativo | ausente |
| 008 | negativo | presente |
| 009 | positivo | ausente |
| 010 | positivo | presente |

Probabilidade da variável preditiva e probabilidade *a priori do atributo alvo* podem ser estimadas pela frequência

$P(\text{negativo}) =$

$P(\text{positivo}) =$

$P(\text{presente}) =$

$P(\text{ausente}) =$

O que se deseja em AM é a probabilidade *a posteriori*

Probabilidade e AM

| Paciente | Exame | Doença |
|----------|----------|----------|
| 001 | positivo | presente |
| 002 | negativo | presente |
| 003 | negativo | ausente |
| 004 | positivo | presente |
| 005 | positivo | ausente |
| 006 | positivo | presente |
| 007 | negativo | ausente |
| 008 | negativo | presente |
| 009 | positivo | ausente |
| 010 | positivo | presente |

Probabilidade da variável preditiva e probabilidade *a priori do atributo alvo* podem ser estimadas pela frequência

$$P(\text{negativo}) = 4/10 = 0,4$$

$$P(\text{positivo}) = 6/10 = 0,6$$

$$P(\text{presente}) = 6/10 = 0,6$$

$$P(\text{ausente}) = 4/10 = 0,4$$

O que se deseja em AM é a probabilidade *a posteriori*

Probabilidade e AM

| Paciente | Exame | Doença |
|----------|----------|----------|
| 001 | positivo | presente |
| 002 | negativo | presente |
| 003 | negativo | ausente |
| 004 | positivo | presente |
| 005 | positivo | ausente |
| 006 | positivo | presente |
| 007 | negativo | ausente |
| 008 | negativo | presente |
| 009 | positivo | ausente |
| 010 | positivo | presente |

De forma similar, é possível estimar a probabilidade de que um evento ocorra para cada classe (probabilidade de verossimilhança)

$P(\text{negativo/presente}) =$

$P(\text{positivo/presente}) =$

$P(\text{negativo/ausente}) =$

$P(\text{positivo/ausente}) =$

O que se deseja em AM é a probabilidade *a posteriori*

Probabilidade e AM

| Paciente | Exame | Doença |
|----------|----------|----------|
| 001 | positivo | presente |
| 002 | negativo | presente |
| 003 | negativo | ausente |
| 004 | positivo | presente |
| 005 | positivo | ausente |
| 006 | positivo | presente |
| 007 | negativo | ausente |
| 008 | negativo | presente |
| 009 | positivo | ausente |
| 010 | positivo | presente |

De forma similar, é possível estimar a probabilidade de que um evento ocorra para cada classe (probabilidade de verossimilhança)

$$P(\text{negativo/presente}) = 2/6 = 0.33$$

$$P(\text{positivo/presente}) = 4/6 = 0,66$$

$$P(\text{negativo/ausente}) = 2/4 = 0,5$$

$$P(\text{positivo/ausente}) = 2/4 = 0,5$$

O que se deseja em AM é a probabilidade *a posteriori*

Probabilidade a posteriori

- Fácil estimar pela frequência das probabilidades *a priori*
 - $P(B)$: probabilidade do resultado do exame ser positivo
 - $P(A)$: probabilidade do do paciente estar doente
 - $P(B/A)$: probabilidade do resultado do exame ser positivo dado que o paciente está doente
- Difícil estimar probabilidade *a posteriori*
 - $P(A/B)$: probabilidade do paciente estar doente dado que seu exame deu positivo
 - Teorema (regra) de Bayes

Probabilidade a posteriori

- Lei da probabilidade condicional
 - $P(A/B) = P(A \cap B) / P(B)$
- Teorema de Bayes
 - Permite calcular probabilidade *a posteriori* de um evento
 - $P(A \cap B) = P(A/B)P(B) = P(B/A)P(A)$
 - $P(A/B) = P(B/A)P(A)/P(B)$
 - $Posteriori = (\text{verossimilhança} \times \text{priori}) / \text{evidência}$
 - $P(B)$: lei da probabilidade total

Probabilidade a posteriori

- Lei da probabilidade total
 - Evento A pode ter 2 possíveis resultados, A (A_1) e $\neg A$ (A_2), que formam uma partição em Ω

$$P(B) = P(B \cap A_1) + P(B \cap A_2)$$

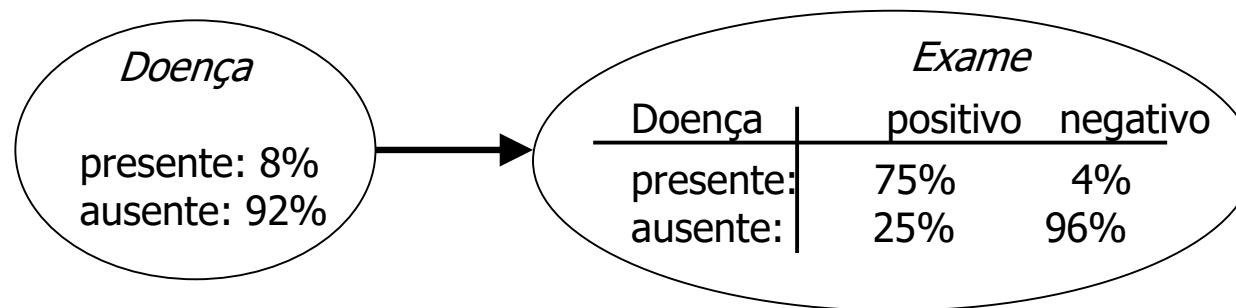
$$P(B) = P(B / A_1)P(A_1) + P(B / A_2)P(A_2)$$

- Evento A pode ter n possíveis resultados mutuamente exclusivos, A_1, A_2, \dots, A_n , que formam uma partição em Ω

$$P(B) = \sum_{i=1}^n P(B / A_i)P(A_i)$$

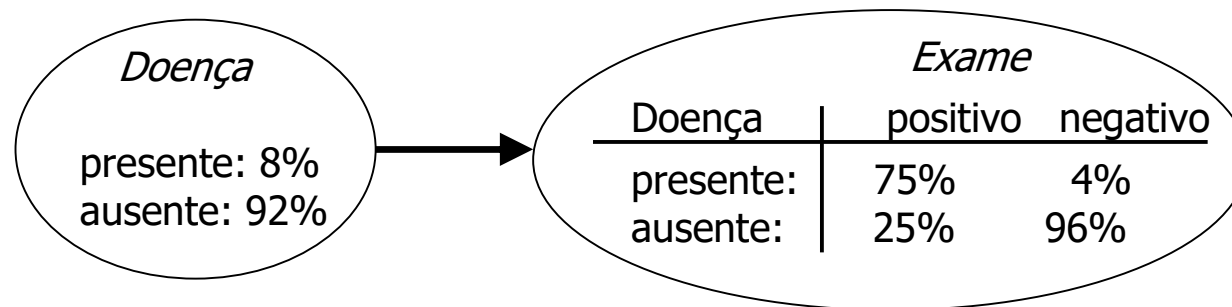
Modelo probabilístico gráfico

- Mostra os valores das probabilidades a priori e os valores das probabilidades condicionais
 - Modelo qualitativo: grafo cujos nós representam variáveis
 - Modelo quantitativo: tabelas com a distribuição das variáveis



Probabilidade a posteriori

De acordo com experiências passadas



$$P(\text{Exame}/\text{Doença}) = 0,75$$

$$P(\neg \text{Exame}/\neg \text{Doença}) = 0,96$$

$$P(\text{Exame}) = P(\text{Exame}/\text{Doença})P(\text{Doença}) + P(\text{Exame}/\neg \text{Doença})P(\neg \text{Doença})$$

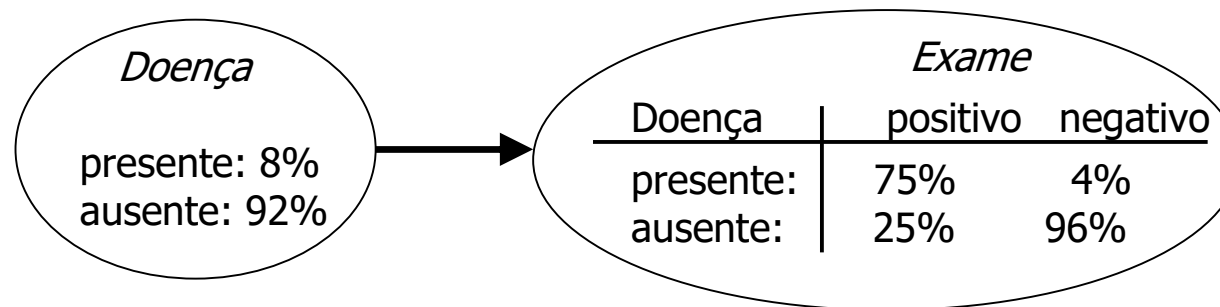
$$P(\text{Exame}) = 0,75 \times 0,08 + 0,25 \times 0,92 = 0,29$$

...

$$P(\text{Doença}/\text{Exame}) = ?$$

Probabilidade condicional

De acordo com experiências passadas



$$P(\text{Exame}/\text{Doença}) = 0,75$$

$$P(\neg \text{Exame}/\neg \text{Doença}) = 0,96$$

$$P(\text{Exame}) = P(\text{Exame}/\text{Doença})P(\text{Doença}) + P(\text{Exame}/\neg \text{Doença})P(\neg \text{Doença})$$

$$P(\text{Exame}) = 0,75 \times 0,08 + 0,25 \times 0,92 = 0,29$$

...

$$P(\text{Doença}/\text{Exame}) = P(\text{Exame}/\text{Doença})P(\text{Doença})/P(\text{Exame}) = 0,75 \times 0,08 / 0,29$$

=

Classificação Bayesiana

- Sejam y_i , $i = 1, 2, \dots, m$, as possíveis classes
 - Novo exemplo pertence à classe que tiver probabilidade *a posteriori* máxima
 - $Y_{\text{MAP}} = \arg \max_i P(y_i/X)$ (maior valor obtido variando i)
- Definição de $P(y_i/X)$
 - $P(y_i/X) = P(X/y_i) P(y_i) / P(X)$ (Teorema de Bayes)

Classificação Bayesiana

- Expressão $P(X/y_i) P(y_i) / P(X)$ pode ser simplificada
 - $P(X)$ é comum a todas as classes
 - Considerar as classes equiprováveis ($P(y_i) = P(y_j)$)
- Exemplo x pertence a classe com máxima verossimilhança
 - $h_{MV} = \arg \max_i P(X/y_i)$
- Difícil calcular valores
 - Precisa de um número de exemplos muito grande

Classificação Bayesiana

- Inferência Bayesiana
 - Cálculo da probabilidade *a posteriori* a partir da probabilidade *a priori*
- Várias alternativas para estimar $P(X/y_i)$
 - Produzem diferentes funções de classificação
 - Ex.: Classificador Naive Bayes

Naive Bayes

- Classificador Bayesiano mais simples
- Assume que os atributos são independentes

- $P(X/y_i) = P(x_1/y_i) * \dots * P(x_d/y_i)$

$$P(y_i / X) \propto P(y_i) \prod_{j=1}^d P(x_j / y_i)$$

$$\log P(y_i / X) \propto \log P(y_i) + \sum_{j=1}^d \log P(x_j / y_i)$$

Naive Bayes

- Para duas classes

$$\log \frac{P(y_1 / X)}{P(y_2 / X)} \propto \log \frac{P(y_1)}{P(y_2)} + \sum_{j=1}^d \log \frac{P(x_j / y_1)}{P(x_j / y_2)}$$

- Sinal do primeiro log indica a classe
- Sinal de cada termo do somatório indica contribuição de cada atributo

Naive Bayes


- Como é implementado
 - Todas as probabilidades necessárias são calculadas a partir do conjunto de dados de treinamento
 - Cálculo da probabilidade a priori de cada classe
 - Usar um contador para cada classe
 - Cálculo da probabilidade condicional de observar um valor de um atributo, dado que o exemplo pertence a uma dada classe
 - Necessário distinguir entre atributos nominais e atributos contínuos

Naive Bayes

- Cálculo da probabilidade condicional
 - Atributos preditivos nominais
 - Usar um contador para cada valor
 - Atributos preditivos contínuos (número de possíveis valores é infinito)
 - Assumir uma distribuição de probabilidade para os valores do atributo
 - Em geral é assumida a distribuição normal
 - Discretizar o atributo em uma fase de pré-processamento
 - Geralmente produz resultados melhores

Exemplo

- Conjunto de dados da UCI *Balance Scale*
 - Classe é o maior valor entre $Distância_{esq} \times Peso_{esq}$ e $Distância_{dir} \times Peso_{dir}$
 - 4 atributos preditivos



Exemplo

- Conjunto tem 625 exemplos em 3 classes
 - Esquerda, direita e equilíbrio
 - Domínio de valores para atributos preditivos = {1, 2, 3, 4, 5}
 - Definir $P(\text{Classe}/\text{Atributos})$

$$P(y_i / X) \propto P(y_i) \prod_{j=1}^d P(x_j / y_i)$$

| | Equilíbrio | Esquerda | Direita |
|----------------|------------|----------|---------|
| Freq. (classe) | 49 | 288 | 288 |
| P(classe) | 0,0784 | 0,4608 | 0,4608 |

$P(\text{Distancia}_{\text{Esq}}/\text{Equilíbrio}) P(\text{Peso}_{\text{Esq}}/\text{Equilíbrio}) P(\text{Distancia}_{\text{Dir}}/\text{Equilíbrio})...$
 $P(\text{Distancia}_{\text{Esq}}/\text{Esquerda}) P(\text{Peso}_{\text{Esq}}/\text{Esquerda}) P(\text{Distancia}_{\text{Dir}}/\text{Esquerda})...$
...

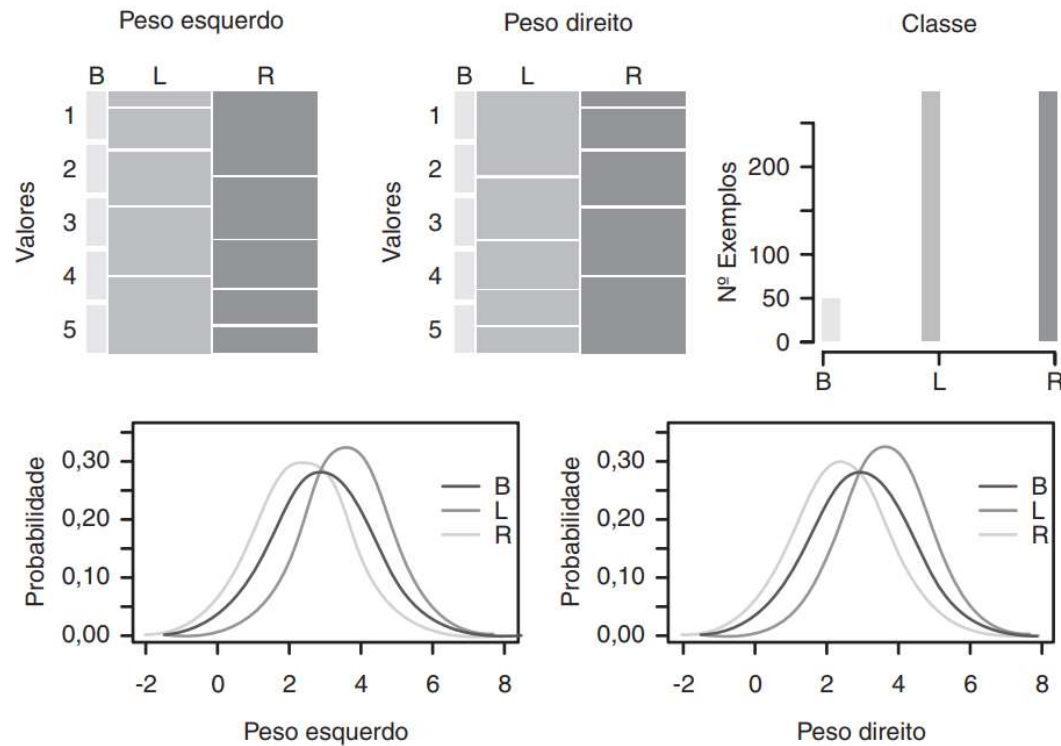
Discretização de valores

- Transformar valores numéricos em intervalos ou categorias
- Sub-tarefas
 - Definição de número de categorias
 - Geralmente feito pelo usuário
 - Definição de como mapear valores dos atributos contínuos para essas categorias
 - Definição do frequência/largura dos intervalos
 - Geralmente feito pelo algoritmo
 - Exemplo: distribuir valores 1, 3, 4, 5, 6, 7, 9, 12 em dois intervalos
 - Por largura: {1, 3, 4, 5, 6} e {7, 9, 12}
 - Por frequência: {1, 3, 4, 5} e {6, 7, 9, 12}

Distribuição dos valores dos atributos

| | Distribuição normal | | Discretização | | | | |
|--------------------------------|---------------------|---------------|---------------|----|----|----|----|
| <i>Peso_{Esq}</i> | Média | Desvio padrão | V1 | V2 | V3 | V4 | V5 |
| Equilibrado | 2,938 | 1,42 | 10 | 11 | 9 | 10 | 9 |
| Esquerda | 3,611 | 1,23 | 17 | 43 | 63 | 77 | 88 |
| Direita | 2,399 | 1,33 | 98 | 71 | 53 | 38 | 28 |
| <i>Distância_{Esq}</i> | Média | Desvio padrão | V1 | V2 | V3 | V4 | V5 |
| Equilibrado | 2,938 | 1,42 | 10 | 11 | 9 | 10 | 9 |
| Esquerda | 3,611 | 1,22 | 17 | 43 | 63 | 77 | 88 |
| Direita | 2,399 | 1,33 | 98 | 71 | 53 | 38 | 28 |
| <i>Peso_{Dir}</i> | Média | Desvio padrão | V1 | V2 | V3 | V4 | V5 |
| Equilibrado | 2,938 | 1,42 | 10 | 11 | 9 | 10 | 9 |
| Esquerda | 2,399 | 1,33 | 98 | 71 | 53 | 38 | 28 |
| Direita | 3,611 | 1,22 | 17 | 43 | 63 | 77 | 88 |
| <i>Distância_{Dir}</i> | Média | Desvio padrão | V1 | V2 | V3 | V4 | V5 |
| Equilibrado | 2,938 | 1,42 | 10 | 11 | 9 | 10 | 9 |
| Esquerda | 2,399 | 1,33 | 98 | 71 | 53 | 38 | 28 |
| Direita | 3,611 | 1,22 | 17 | 43 | 63 | 77 | 88 |

Distribuição dos valores dos atributos



Conclusão

- Métodos baseados em probabilidade
- Discriminante linear
- Regressão logística
- Teorema de Bayes
- Naive Bayes

Fim do
apresentação