
Um algoritmo genético híbrido para supressão de ruídos em imagens

Jônatas Lopes de Paiva

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Jônatas Lopes de Paiva

Um algoritmo genético híbrido para supressão de ruídos em imagens

Dissertação apresentada ao Instituto de Ciências Matemáticas e de Computação – ICMC-USP, como parte dos requisitos para obtenção do título de Mestre em Ciências – Ciências de Computação e Matemática Computacional. *VERSÃO REVISADA*

Área de Concentração: Ciências de Computação e Matemática Computacional

Orientador: Prof. Dr. Claudio Fabiano Motta Toledo

USP – São Carlos
Janeiro de 2016

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados fornecidos pelo(a) autor(a)

P142u Paiva, Jônatas Lopes de
Um algoritmo genético híbrido para supressão
de ruídos em imagens / Jônatas Lopes de Paiva;
orientador Claudio Fabiano Motta Toledo. - São
Carlos - SP, 2016.
[123](#) p.

Dissertação (Mestrado - Programa de Pós-Graduação
em Ciências de Computação e Matemática Computacional)
- Instituto de Ciências Matemáticas e de Computação,
Universidade de São Paulo, 2016.

1. Atenuação de ruídos em imagens.
 2. Algoritmos genéticos.
 3. Preservação de características.
 4. Processamento de imagens.
 5. Otimização.
- I. Toledo, Claudio Fabiano Motta, orient. II. Título.

Jônatas Lopes de Paiva

A hybrid genetic algorithm for image denoising

Master dissertation submitted to the Instituto de Ciências Matemáticas e de Computação – ICMC-USP, in partial fulfillment of the requirements for the degree of the Master Program in Computer Science and Computational Mathematics. *FINAL VERSION*

Concentration Area: Computer Science and Computational Mathematics

Advisor: Prof. Dr. Claudio Fabiano Motta Toledo

USP – São Carlos
January 2016

*Este trabalho é dedicado à minha mãe, Alcione, que
acreditou em mim quando nem eu mesmo acreditava.*

Obrigado, mãe.

AGRADECIMENTOS

Enquanto apenas o meu nome vai na capa desse trabalho, muitas pessoas são responsáveis por ele. São a elas que eu devo meus agradecimentos.

Ao Professor Claudio, que confiou em mim e me deu uma chance de trabalhar com ele. Ele ensinou e exigiu em medidas iguais, não apenas me incentivando a fazer um bom trabalho, mas também nunca se esquecendo do lado humano, dando um exemplo de como um educador deve se portar.

Ao Professor Hélio, que foi fundamental para a condução deste trabalho e que, sempre muito solícito, nunca se importou em ajudar, conversar e ensinar um aluno que nem sempre sabia muito do que estava falando.

Aos colegas, funcionários e demais professores do ICMC, em especial os membros do LCR que foram companheiros de estudo nesta jornada. Aqui também vão os meus agradecimentos.

Um abraço aos meus amigos de São Carlos, Jaime e Amanda, que tornaram a minha estadia aqui menos solitária e mais divertida.

Um salve para toda a família da República Taverna em Lavras-MG, que é, sem sombra de dúvidas, a melhor república do universo.

Gostaria de agradecer especialmente a todos os meus amigos de São Paulo que, fossem eles de longa data ou mais recentes, me ajudaram a viver na selva de pedra e fizeram eu me sentir em casa mesmo estando distante da família. Ferreira, Foguinho, Luluba, Rafael, Paty, Luíza, Brunão, Jú, Raíssa e Nayara, obrigado por toda amizade durante esses anos e este mestrado é de todos nós.

Aos meus familiares e amigos que são responsáveis diretos por fazer de mim quem eu sou e que me apoiaram de todas as maneiras desde sempre para que eu pudesse estar aqui. Especialmente ao Edvaldo, Edmilson, Rita, Gabriel, Stella, João, Tia Maria (in memoriam) e Vó Therezinha (in memoriam), obrigado por tudo.

A minha namorada Agnes. Você que me deu forças para enfrentar os desafios até os últimos dias deste trabalho. Você que me faz querer ser sempre uma pessoa melhor. Você que me dá amor. Você que me faz feliz. Eu só consegui fazer este trabalho porque você está comigo. Obrigado por existir na minha vida e por permitir que eu faça parte da sua.

Ao meu pai José Heitor, que sempre apoiou e se preocupou comigo, me incentivando no

que eu quisesse fazer. Você também é responsável direto por este trabalho.

À minha irmã Lara, que é a minha mais antiga amiga e que nunca me deu nada que não fosse amor e apoio. Mana, este mestrado também é seu, obrigado por ser essa pessoa especial que você é.

Agradeço a minha mãe, Alcione, que sempre foi o meu porto seguro. Que nos momentos mais difíceis da minha vida esteve lá por mim. Que literalmente acreditou em mim quando nem eu mesmo pensava que fosse capaz. Que sempre coloca a mim antes dela mesma e que só pediu em troca a minha felicidade. Mãe, obrigado por tudo.

À vó Maura. A senhora trabalhou uma vida toda, desde criança pequena, sempre humilde, nunca parando. A senhora que nos acolheu. A senhora que enfrentou diversas adversidades na vida. A senhora que nunca reclamou. A senhora que até hoje ainda pergunta se eu estou agasalhado, comendo direito e se eu quero alguma coisa. Só o carinho que a senhora sempre deu já foi muito mais que o suficiente. Obrigado, vó.

Por fim, eu gostaria de fazer um agradecimento especial ao meu avô David. Mesmo não estando entre nós há um bom tempo, ele sempre está presente comigo em todos os momentos. Infelizmente a saudade fica, mas, felizmente, o amor também.

“Happiness Is a Warm Gun”
(John Lennon)

RESUMO

PAIVA, J. L.. **Um algoritmo genético híbrido para supressão de ruídos em imagens.** 2016. 123 f. Dissertação (Mestrado em Ciências – Ciências de Computação e Matemática Computacional) – Instituto de Ciências Matemáticas e de Computação (ICMC/USP), São Carlos – SP.

Imagens digitais são utilizadas para diversas finalidades, variando de uma simples foto com os amigos até a identificação de doenças em exames médicos. Por mais que as tecnologias de captura de imagens tenham evoluído, toda imagem adquirida digitalmente possui um ruído intrínseco a ela que normalmente é adquirido durante o processo de captura ou transmissão da imagem. O grande desafio neste tipo de problema consiste em recuperar a imagem perdendo o mínimo possível de características importantes da imagem, como cantos, bordas e texturas. Este trabalho propõe uma abordagem baseada em um Algoritmo Genético Híbrido (AGH) para lidar com este tipo de problema. O AGH combina um algoritmo genético com alguns dos melhores métodos de supressão de ruídos em imagens encontrados na literatura, utilizando-os como operadores de busca local. O AGH foi testado em imagens normalmente utilizadas como *benchmark* corrompidas com um ruído branco aditivo Gaussiano ($N, 0$), com diversos níveis de desvio padrão para o ruído. Seus resultados, medidos pelas métricas PSNR e SSIM, são comparados com os resultados obtidos por diferentes métodos. O AGH também foi testado para recuperar imagens SAR (*Synthetic Aperture Radar*), corrompidas com um ruído *Speckle* multiplicativo, e também teve seus resultados comparados com métodos especializados em recuperar imagens SAR. Através dessa abordagem híbrida, o AGH foi capaz de obter resultados competitivos em ambos os tipos de testes, chegando inclusive a obter melhores resultados em diversos casos em relação aos métodos da literatura.

Palavras-chave: Atenuação de ruídos em imagens, Algoritmos genéticos, Preservação de características, Processamento de imagens, Otimização.

ABSTRACT

PAIVA, J. L.. **Um algoritmo genético híbrido para supressão de ruídos em imagens.** 2016. 123 f. Dissertação (Mestrado em Ciências – Ciências de Computação e Matemática Computacional) – Instituto de Ciências Matemáticas e de Computação (ICMC/USP), São Carlos – SP.

Digital images are used for many purposes, ranging from a simple picture with friends to the identification of diseases in medical exams. Even though the technology for acquiring pictures has been evolving, every image digitally acquired has a noise intrinsic to it that is normally gotten during the processes of transmission or capture of the image. A big challenge in this kind of problem consists in recovering the image while losing the minimum amount of important features of the image, such as corners, borders and textures. This work proposes an approach based on a Hybrid Genetic Algorithm (HGA) to deal with this kind of problem. The HGA combines a genetic algorithm with some of the best image denoising methods found in literature, using them as local search operators. The HGA was tested on benchmark images corrupted with an additive white Gaussian noise ($N, 0$) with many levels of standard deviation for the noise. The HGA's results, which were measured by the PSNR and SSIM metrics, were compared to the results obtained by different methods. The HGA was also tested to recover SAR (Synthetic Aperture Radar) images that were corrupted by a multiplicative Speckle noise and had its results compared against the results by other methods specialized in recovering with SAR images. Through this hybrid approach, the HGA was able to obtain results competitive in both types of tests, even being able to obtain the best results in many cases, when compared to the other methods found in the literature.

Key-words: Image denoising, Genetic Algorithms, Feature preservation, Image processing, Optimization.

LISTA DE ILUSTRAÇÕES

Figura 1 – A figura mostra uma imagem na qual houve movimento no instante da captura, tornando-a borrada.	35
Figura 2 – Imagem original.	37
Figura 3 – O resultado de diferentes ruídos aplicados à imagem 2..	38
Figura 4 – Ilustração do problema de corte mínimo da proposta de Ishikawa (ISHIKAWA, 2000).	40
Figura 5 – Crossover de 1-ponto.	43
Figura 6 – Crossover de n-pontos ($n = 4$).	44
Figura 7 – Crossover uniforme.	44
Figura 8 – Exemplos de mutação aplicados a uma cadeia binária.	44
Figura 9 – Inicialização da população do AGH.	47
Figura 10 – Exemplos dos operadores de cruzamento de um-ponto linha e coluna.	49
Figura 11 – Exemplo do operador de crossover uniforme como utilizado pelo AGH.	50
Figura 12 – Fluxograma básico do funcionamento do AGH.	51
Figura 13 – Boat image.	54
Figura 14 – Comparação entre as médias dos resultados mínimo, médio e máximo dos diferentes tamanhos de torneio.	56
Figura 15 – Comparação entre as médias dos resultados mínimo, médio e máximo das diferentes taxas de busca local.	58
Figura 16 – Comparação entre as médias dos resultados mínimo, médio e máximo dos diferentes tamanhos de população.	60
Figura 17 – Comparação entre as médias dos resultados mínimo, médio e máximo dos diferentes valores para o parâmetro β	62
Figura 18 – Comparação entre as médias dos resultados mínimo, médio e máximo dos diferentes tempos de execução.	64
Figura 19 – Imagens utilizadas nos testes do AGH em comparação com outros métodos de supressão de ruídos.	72
Figura 20 – Imagem SAR <i>San Francisco</i>	82
Figura 21 – Imagem SAR <i>Mississippi</i>	83
Figura 22 – Imagem SAR <i>Washington</i>	83
Figura 23 – Imagem <i>Glasses</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 10$ tratada pelos diversos métodos comparados.	96

Figura 24 – Imagem <i>Couple</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 15$ tratada pelos diversos métodos comparados.	97
Figura 25 – Imagem <i>Fingerprint</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 20$ tratada pelos diversos métodos comparados.	98
Figura 26 – Imagem <i>Lenna</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 25$ tratada pelos diversos métodos comparados.	99
Figura 27 – Imagem <i>Boat</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 30$ tratada pelos diversos métodos comparados.	100
Figura 28 – Imagem <i>Barbara</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 35$ tratada pelos diversos métodos comparados.	101
Figura 29 – Imagem <i>Lightning</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 40$ tratada pelos diversos métodos comparados.	102
Figura 30 – Imagem <i>Peppers</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 45$ tratada pelos diversos métodos comparados.	103
Figura 31 – Imagem <i>Man</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 50$ tratada pelos diversos métodos comparados.	104
Figura 32 – Imagem <i>Hill</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 55$ tratada pelos diversos métodos comparados.	105
Figura 33 – Imagem <i>Cameraman</i> corrompida por um ruído branco aditivo Gaussiano com $\sigma = 60$ tratada pelos diversos métodos comparados.	106
Figura 34 – Imagem <i>Washington</i> corrompida por um ruído Speckle multiplicativo com $L = 1$ tratada pelos diversos métodos comparados.	107
Figura 35 – Imagem <i>San Francisco</i> corrompida por um ruído Speckle multiplicativo com $L = 2$ tratada pelos diversos métodos comparados.	108
Figura 36 – Imagem <i>Mississippi</i> corrompida por um ruído Speckle multiplicativo com $L = 3$ tratada pelos diversos métodos comparados.	108
Figura 37 – Imagem <i>San Francisco</i> corrompida por um ruído Speckle multiplicativo com $L = 5$ tratada pelos diversos métodos comparados.	109
Figura 38 – Imagem <i>Washington</i> corrompida por um ruído Speckle multiplicativo com $L = 6$ tratada pelos diversos métodos comparados.	109
Figura 39 – Imagem <i>San Francisco</i> corrompida por um ruído Speckle multiplicativo com $L = 8$ tratada pelos diversos métodos comparados.	110
Figura 40 – Imagem <i>Mississippi</i> corrompida por um ruído Speckle multiplicativo com $L = 12$ tratada pelos diversos métodos comparados.	110

LISTA DE ALGORITMOS

Algoritmo 1 – Algoritmo Genético clássico.	42
Algoritmo 2 – Algoritmo Genético Híbrido(Imagen <i>Img</i>)	46

LISTA DE TABELAS

Tabela 1 – PSNR para diferentes tamanhos de torneio.	55
Tabela 2 – SSIM para diferentes tamanhos de torneio.	55
Tabela 3 – PSNR para diferentes taxas de busca local.	57
Tabela 4 – SSIM para diferentes taxas de busca local.	57
Tabela 5 – PSNR para diferentes tamanhos de população.	59
Tabela 6 – SSIM para diferentes tamanhos de população.	59
Tabela 7 – PSNR para diferentes β .	61
Tabela 8 – SSIM results para diferentes β .	61
Tabela 9 – PSNR para diferentes tempos de execução.	63
Tabela 10 – SSIM para diferentes tempos de execução.	63
Tabela 11 – Teste de Kruskal-Wallis para os valores de PSNR do Teste 1.	66
Tabela 12 – Teste de Dunn para os valores de PSNR encontrados para o teste 1.	67
Tabela 13 – Teste de Kruskal-Wallis para os valores de SSIM do Teste 1.	67
Tabela 14 – Teste de Dunn para os valores de SSIM encontrados para o teste 1.	67
Tabela 15 – Teste de Kruskal-Wallis para os valores de PSNR do Teste 2.	68
Tabela 16 – Teste de Dunn para os valores de PSNR encontrados para o teste 2.	68
Tabela 17 – Teste de Kruskal-Wallis para os valores de SSIM do Teste 2.	69
Tabela 18 – Teste de Dunn para os valores de SSIM encontrados para o teste 2.	69
Tabela 19 – Teste de Kruskal-Wallis para os valores de PSNR do Teste 3.	70
Tabela 20 – Teste de Dunn para os valores de PSNR encontrados para o teste 3.	70
Tabela 21 – Teste de Kruskal-Wallis para os valores de SSIM do Teste 3.	71
Tabela 22 – Teste de Dunn para os valores de SSIM encontrados para o teste 3.	71
Tabela 23 – Métodos e suas respectivas abreviaturas.	73
Tabela 24 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Lightning</i> .	74
Tabela 25 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Lightning</i> .	74
Tabela 26 – Teste de Kruskal-Wallis para os desvios entre os PSNR de cada método e o melhor PSNR para cada σ .	75
Tabela 27 – Teste de Dunn para os desvios do PSNR em relação ao melhor PSNR obtido para cada σ .	76
Tabela 28 – Teste de Kruskal-Wallis para os desvios entre os SSIM de cada método e o melhor SSIM para cada σ .	77

Tabela 29 – Teste de Dunn para os desvios do SSIM em relação ao melhor SSIM obtido para cada σ	78
Tabela 30 – Número de vezes em que o AGH foi melhor que os outros métodos para as métricas PSNR e SSIM.	79
Tabela 31 – Número de vezes nas quais o AGH foi melhor que os outros métodos para cada nível de ruído de acordo com a métrica PSNR.	80
Tabela 32 – Número de vezes nas quais o AGH foi melhor que os outros métodos para cada nível de ruído de acordo com a métrica SSIM.	81
Tabela 33 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>San Francisco</i>	84
Tabela 34 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>San Francisco</i>	84
Tabela 35 – Teste de Kruskal-Wallis para os desvios entre os PSNR de cada método e o melhor PSNR para cada L	84
Tabela 36 – Teste de Dunn para os desvios do PSNR em relação ao melhor PSNR obtido para cada L	85
Tabela 37 – Teste de Kruskal-Wallis para os desvios entre os SSIM de cada método e o melhor SSIM para cada L	85
Tabela 38 – Teste de Dunn para os desvios do SSIM em relação ao melhor SSIM obtido para cada L	85
Tabela 39 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Barbara</i>	112
Tabela 40 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Barbara</i>	112
Tabela 41 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Boat</i>	113
Tabela 42 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Boat</i>	113
Tabela 43 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Cameraman</i>	114
Tabela 44 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Cameraman</i>	114
Tabela 45 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Couple</i>	115
Tabela 46 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Couple</i>	115
Tabela 47 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Fingerprint</i>	116
Tabela 48 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Fingerprint</i>	116
Tabela 49 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Glasses</i>	117
Tabela 50 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Glasses</i>	117

Tabela 51 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Hill</i> .	118
Tabela 52 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Hill</i> .	118
Tabela 53 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Lenna</i> .	119
Tabela 54 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Lenna</i> .	119
Tabela 55 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Man</i> .	120
Tabela 56 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Man</i> .	120
Tabela 57 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Peppers</i> .	121
Tabela 58 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Peppers</i> .	121
Tabela 59 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Mississippi</i> .	122
Tabela 60 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Mississippi</i> .	122
Tabela 61 – Resultados de PSNR dos diversos métodos testados aplicados à imagem <i>Washington</i> .	123
Tabela 62 – Resultados de SSIM dos diversos métodos testados aplicados à imagem <i>Washington</i> .	123

LISTA DE ABREVIATURAS E SIGLAS

- AD Anisotropic Diffusion
AG Algoritmo Genético
AGH Algoritmo Genético Híbrido
BM3D ... Block-matching and 3D filtering
FDP Função Densidade de Probabilidade
GR Genetic Restoration
HGA Hybrid Genetic Algorithm
MRF Markov Random Field
MSE Mean Squared Error
PPB Probabilistic Patch-Based filter
PSNR Peak Signal-to-Noise Ratio
PSO Particle Swarm Optimization
SAR Synthetic Aperture Radar
SARBM3D Synthetic Aperture Radar Block-matching and 3D filtering
SSIM Structural Similarity Index
SVD Singular Value Decomposition
TV Total Variation

SUMÁRIO

1	INTRODUÇÃO	27
1.1	Motivação, objetivos e hipótese do trabalho	28
1.2	Organização do trabalho	29
2	REFERENCIAL TEÓRICO	31
2.1	Revisão Bibliográfica	31
2.2	Supressão de ruídos em imagens	35
2.2.1	<i>Ruído</i>	35
2.2.2	<i>Atenuação de ruídos como um Problema de Otimização</i>	37
2.2.2.1	Atenuação através de MRF	37
2.2.2.2	Atenuação através da minimização da variação total	39
2.3	Computação Evolutiva	41
2.3.1	<i>Algoritmos Genéticos</i>	42
3	ALGORITMO GENÉTICO HÍBRIDO	45
4	RESULTADOS COMPUTACIONAIS	53
4.1	Sintonizando o AGH	54
4.2	Avaliando diferentes abordagens a partir do AGH	65
4.2.1	<i>Primeiro Teste - Mudanças nos operadores de mutação e busca local</i>	65
4.2.2	<i>Segundo Teste - Avaliando os operadores de busca local</i>	68
4.2.3	<i>Terceiro Teste - Avaliando uma função objetivo diferente</i>	70
4.3	Comparação do AGH com métodos da literatura	71
4.4	Testando o AGH para suprimir ruídos em imagens SAR	79
5	CONCLUSÕES	87
	REFERÊNCIAS	89
	APÊNDICE A	
	IMAGENS RESULTANTES DOS TESTES COMPUTACIONAIS	95
A.1	Imagens da comparação do AGH com métodos da literatura	96
A.2	Imagens SAR resultantes da comparação do AGH com métodos da literatura	107

APÊNDICE B	TABELAS DE RESULTADOS COMPUTACIONAIS	. 111
B.1	Resultados da comparação do AGH com métodos da literatura	. 111
B.2	Resultados dos testes do AGH para suprimir ruídos em imagens SAR	122



INTRODUÇÃO

Há muito tempo as imagens deixaram de ser apenas algo para guardar recordações e se tornaram indispensáveis em diversas áreas. Medicina (JAMES; DASARATHY, 2014), astronomia (BERRY; BURNELL, 2000), física (CHRYSOCHOOS; LOUCHE, 2000), biologia (CROWTHER; HENDERSON; SMITH, 1996) entre outras são apenas algumas das áreas onde a utilização de imagens possibilitou grandes avanços. O uso e mesmo a popularização das imagens digitais em diversas áreas acabou por criar novos desafios em sua utilização. Por exemplo, apenas uma rede social, o *Facebook*, estimou que até o mês de setembro de 2013 seus usuários fizeram em média *upload* de 350 milhões de imagens por dia (FACEBOOK; ERICSSON; QUALCOMM, 2013).

Apesar de diversos avanços tecnológicos, as imagens digitais possuem um ruído intríngueco a elas que pode ser causado por diversos fatores, como a limitação dos sensores utilizados para a aquisição da imagem, imperfeições nas lentes utilizadas, problemas durante os processos de transmissão e compressão entre outros. O problema de supressão ou atenuação de ruídos em imagens lida com estes casos, procurando reduzir a quantidade de ruído presente na imagem enquanto preserva características importantes como bordas, cantos e texturas. As técnicas de supressão de ruídos foram pesquisadas intensamente na literatura (MOTWANI *et al.*, 2004; REEVES, 2014) e aplicadas em diversos problemas reais (MOHAN; KRISHNAVENI; GUO, 2014), entretanto, ainda não existe nenhuma solução definitiva para este problema.

O processo de degradação de uma imagem pode ser descrito pela equação 1.1 no domínio espacial, onde $g(x,y)$ é a imagem degradada, $h(x,y)$ é a função de degradação, $f(x,y)$ é a imagem perfeita e $\eta(x,y)$ o ruído adicionado à imagem. O símbolo $*$ representa a operação de convolução (GONZALEZ; WOODS, 2006).

$$g(x,y) = h(x,y) * f(x,y) + \eta(x,y) \quad (1.1)$$

Algoritmos Genéticos (AG) são metaheurísticas baseadas nos conceitos de seleção natural,

onde o indivíduo mais apto tende a sobreviver e se reproduzir com maior probabilidade (GOLDBERG, 1989). Nesse contexto, um indivíduo é uma representação da solução do problema tratado. A robustez na exploração do espaço de busca das possíveis soluções, tornam os AGs uma opção para aplicações em diversas áreas (GONDRO; KINGHORN, 2007; GEORGE; RAJAKUMAR; BINU, 2012; SCHULTZ, 1994; ISHIBUCHI; MURATA; TÜRKŞEN, 1997; GREFENSTETTE *et al.*, 1985).

Este trabalho propõe um Algoritmo Genético Híbrido (AGH) para atenuação de ruídos em imagens. Ele combina uma metaheurística baseada em populações com três métodos de supressão de ruídos: BM3D (DABOV *et al.*, 2006), Anisotropic Diffusion (BLACK *et al.*, 1998) and Wiener-chop (GHAEL *et al.*, 1997). A força da abordagem evolutiva é utilizada para explorar o espaço de soluções, enquanto os métodos de recuperação de imagens são utilizados para melhorar as soluções criadas. O AGH é comparado com outros métodos da literatura, utilizando imagens de *benchmark* corrompidas com diferentes níveis de desvio padrão para um ruído branco aditivo Gaussiano. Também são avaliadas imagens SAR (*Synthetic Aperture Radar*) corrompidas com um ruído *Speckle* multiplicativo. Os resultados obtidos mostram que o AGH foi capaz de gerar imagens restauradas com melhor qualidade que os outros métodos da literatura em diversos casos.

No decorrer do trabalho, um resultado parcial descrevendo a metodologia utilizada para os ajustes dos parâmetros do AGH foi aceito em conferência internacional, um segundo trabalho completo foi aceito em um periódico e uma página web foi desenvolvida exibindo alguns dos principais resultados obtidos até então conforme listado a seguir:

- A Hybrid Genetic Algorithm for Image Denoising, IEEE Congress on Evolutionary Computation (CEC), 2015 (PAIVA; TOLEDO; PEDRINI, 2015a).
- An Approach Based on Hybrid Genetic Algorithm Applied to Image Denoising Problem, Applied Soft Computing, 2015 (PAIVA; TOLEDO; PEDRINI, 2015b), artigo aceito.
- Endereço web <<http://hgacmc.s3-website-sa-east-1.amazonaws.com/>>.

1.1 Motivação, objetivos e hipótese do trabalho

A partir das premissas já atestadas anteriormente, que indicam a capacidade dos algoritmos genéticos de percorrer um espaço de busca a procura de boas soluções para determinado problema, espera-se que uma abordagem com esta inspiração apresente bons resultados no auxílio à resolução de um problema tão importante quanto a atenuação de ruídos. Para isso, a presente dissertação de mestrado propõe o uso de um Algoritmo Genético Híbrido (AGH) para solucionar o problema de supressão de ruídos em imagens. Os principais pontos a serem abordados são:

1. Estudo do problema de supressão de ruído em imagens digitais.
2. Proposição e aplicação de um AGH que combina AG com métodos de supressão de ruídos.
3. Avaliação da relação custo/benefício no uso de AGH quando comparado aos métodos existentes na literatura.

Como consequência do desenvolvimento deste trabalho e já mencionado previamente, os resultados obtidos foram publicados em um evento e uma revista internacional.

A hipótese a ser verificada durante este trabalho é a de que a técnica proposta é capaz de encontrar soluções de boa qualidade — quando comparadas com outros métodos conhecidos — para a supressão de ruídos em imagens em tons de cinza.

1.2 Organização do trabalho

Este trabalho está organizado da seguinte maneira:

- Capítulo 2 apresenta o referencial teórico utilizado como base do método proposto, bem como uma revisão bibliográfica apresentando o estado da arte dos métodos de supressão de ruídos em imagens.
- Capítulo 3 mostra o AGH proposto e detalha as suas principais características e seu modo de funcionamento.
- Capítulo 4 mostra os resultados obtidos pelo AGH em diversos testes realizados.
- Capítulo 5 apresenta as conclusões tiradas neste trabalho
- Apêndice A mostra algumas das imagens resultantes dos diversos testes realizados durante este trabalho.
- Apêndice B mostra tabelas com diversos resultados obtidos durante este trabalho.



REFERENCIAL TEÓRICO

Este capítulo apresenta um referencial teórico com as bases nas técnicas utilizadas neste trabalho e o estado da arte dos métodos de supressão de ruídos em imagens. A Seção 2.1 revisa alguns dos principais métodos de atenuação de ruídos em imagens. A Seção 2.2 apresenta conceitos relativos ao problema de supressão de ruídos em imagens digitais e, por fim, a Seção 2.3 apresenta conceitos de computação evolutiva com foco em algoritmos genéticos.

2.1 Revisão Bibliográfica

Técnicas bastante comuns para supressão de ruídos em imagens utilizam filtros espaciais que procuram suavizar uma imagem de modo a diminuir o ruído. Entretanto, essas técnicas tendem a gerar imagens borradadas e com perda de informações de bordas e texturas (GONZALEZ; WOODS, 2006; SILVA *et al.*, 2013). Os filtros utilizados para supressão de ruídos em imagens são classificados em lineares e não-lineares, onde os lineares podem ser expressos como a convolução de um núcleo (filtro) através de uma imagem. Os filtros não-lineares, por sua vez, não podem ser expressos como uma operação de convolução (GONZALEZ; WOODS, 2006).

Filtros lineares apresentam resultados relevantes para suprimir ruído Gaussiano sem a necessidade de conhecimento prévio a respeito de características específicas das imagens (RUSSO, 2003; RUSSO, 2004). O filtro de Wiener (GONZALEZ; WOODS, 2006), que busca minimizar o erro médio quadrado (*mean square error* - MSE) entre a imagem original e a recuperada, é uma conhecida abordagem linear para tratar imagens ruidosas. Por outro lado, uma famosa abordagem não-linear é o filtro de mediana, que substitui o valor de cada pixel pelo valor da mediana de sua vizinhança (GONZALEZ; WOODS, 2006).

Métodos baseados em equações diferenciais parciais e fluidodinâmica computacional também foram propostos. O método *total variation* (TV) considera que sinais ruidosos possuem alta variação total e procura minimizar essa variação para obter uma imagem próxima da

original (RUDIN; OSHER; FATEMI, 1992; CHAMBOLLE, 2004; DRAPACA, 2009). Métodos de *level set* procuram estimar *levels* (níveis) para as imagens e consideram que os valores que se encontram abaixo de determinado *level* são ruídos e devem ser removidos (SETHIAN, 1999). Métodos de difusão anisotrópica e isotrópica buscam difundir uma imagem sucessivamente, utilizando uma equação que seja capaz de identificar as bordas (função *edge-stopping*). Dessa maneira, a imagem é suavizada enquanto as suas bordas são preservadas (PERONA; MALIK, 1990; KATKOVNIK; EGIAZARIAN; ASTOLA, 2006).

Um exemplo de método que utiliza difusão anisotrópica é o apresentado por Black et. al em (BLACK *et al.*, 1998). A partir da suposição de que a imagem ruidosa é uma função definida em trechos, que foi corrompida por um ruído Gaussiano com média zero e variância pequena, a diferença entre um pixel e seus vizinhos deve ser pequena e também seguir uma distribuição normal com média zero. Quando a diferença entre um pixel e seus vizinhos não segue esse padrão o método entende que uma região de borda foi encontrada. Tomando essas suposições como base e utilizando técnicas de estatística robusta, os autores foram capazes de criar uma nova função *edge-stopping* que possibilita a suavização da imagem com menos perda de informações sobre bordas.

Métodos baseados em decomposição de valores singulares (*singular value decomposition* - SVD) também foram desenvolvidos. Em (ORCHARD; EBRAHIMI; WONG, 2008), o método proposto filtra a imagem utilizando médias não-locais, enquanto procura eliminar os pixels que são muito diferentes de sua vizinhança. Em (WONGSAWAT; RAO; ORAINTARA, 2005), por sua vez, é utilizada uma técnica que transforma a imagem para um sinal no domínio da frequência, dividindo a mesma em blocos e em seguida realiza a decomposição de cada bloco utilizando SVD. Os autovalores obtidos são o ruído estimado da imagem que são descartados e, após as operações inversas, obtém-se uma imagem recuperada.

Assim como a técnica previamente citada, diversos métodos utilizam o domínio da frequência para funcionar. Nestas técnicas, transformadas como a de Fourier e a de wavelet são utilizadas, dessa maneira, a imagem passa a ser representada por suas frequências e não por uma função espacial ($f(x,y)$). Um destes métodos, o BM3D (DABOV *et al.*, 2006), utiliza janelas deslizantes para percorrer a imagem e criar blocos. Após esta fase, os blocos semelhantes são empilhados juntos e transformados para o domínio da frequência 3D, onde as duas primeiras dimensões são as posições dos blocos e a terceira a altura de cada bloco na pilha. Em seguida, os blocos são filtrados segundo um filtro de Wiener adaptado e, por fim, a imagem é reconstruída com os valores de suas intensidades sendo formados a partir da ponderação dos valores dos blocos.

Algumas das técnicas mais eficazes para supressão de ruídos surgiram a partir da possibilidade de se trabalhar com transformadas *wavelet*. Uma das mais comuns consiste em buscar por *thresholds* que limitem os coeficientes *wavelet* que são relacionados às frequências ligadas ao ruído. Este processo, comumente chamado de *wavelet shrinkage*, consiste em, basicamente, três

fases: passar a imagem para o domínio da transformada *wavelet*; estimar os *thresholds* e remover ruído através de uma regra de *shrinkage*; realizar a transformada inversa na imagem ([SILVA et al., 2013](#); [SENDUR; SELESNICK, 2002](#)).

O método apresentado por Silva *et al.* ([SILVA et al., 2013](#)) se baseia em *wavelet shrinkage*. Em um passo inicial, a imagem é dividida em um conjunto de blocos que são transformados para o domínio *wavelet*. Em seguida, um algoritmo de detecção de bordas é utilizado e os *thresholds* de cada sub-banda são estimados. Após isso, os coeficientes *wavelet* tem seus *thresholds* limitados adaptativamente levando suas sub-bandas em conta e uma regra de *shrinkage* é aplicada para identificar e suprimir os coeficientes ruidosos na imagem. Por fim, a transformada inversa é aplicada nos blocos e a imagem é reconstruída.

Ghah et al ([GHAEL et al., 1997](#)) se utilizaram dos conceitos de *wavelet shrinkage* através de uma abordagem diferente. Neste caso, uma estimativa dos coeficientes *wavelet* ruidosos é utilizada para criar um filtro Wiener específico para a imagem no domínio da frequência. Pelo fato deste filtro ser desenvolvido especificamente para tratar estes coeficientes, esta abordagem se mostra capaz de gerar imagens tratadas com alta qualidade.

Além dos trabalhos descritos anteriormente, diversos outras abordagens para realizar o *wavelet shrinkage* foram propostas. Em ([WEYRICH; WARHOLA, 1998](#)), por exemplo, o *shrinkage* é feito a partir da validação cruzada dos parâmetros para o cálculo dos *thresholds*. Enquanto isso, abordagens Bayesianas se utilizam de conhecimento a priori para procurar estimar os parâmetros do cálculo dos *threshold* ([CHIPMAN; KOLACZYK; MCCULLOCH, 1997](#); [RUGGERI; VIDAKOVIC, 1998](#); [VIDAKOVIC, 1998](#); [CHANG; YU; VETTERLI, 2000a](#)). Além destas, outras técnicas foram apresentadas, como em ([KAZUBEK, 2003](#)), onde são utilizados filtros Wiener; em ([FAN; XIA, 2001](#); [ROMBERG; CHOI; BARANIUK, 1999](#)), onde são utilizados modelos ocultos de Markov e diversas outras ([CHANG; YU; VETTERLI, 2000b](#); [LIU; MOULIN, 2001](#); [MIHCAK et al., 1999](#); [SENDUR; SELESNICK, 2002](#)).

Enquanto boa parte das técnicas de supressão de ruídos considera que as imagens foram corrompidas por um ruído Gaussiano aditivo, alguns métodos foram propostos especificamente para tratar de ruídos não-Gaussianos ou não-aditivos. O trabalho apresentado por Deledalle *et al.* ([DELEDALLE; DENIS; TUPIN, 2009](#)) mostra uma abordagens através de médias não-locais onde, ao invés de realizar o simples cálculo da distância euclidiana para definir as médias de pixels similares, ele provê uma base estatística para definir um estimador ponderado de máxima probabilidade. Para realizar esta estimativa, o método leva em conta a distribuição do ruído, apresentando bons resultados para imagens obtidas através de SAR (*Synthetic-aperture radar*) que foram corrompidas com um ruído Speckle multiplicativo.

Em ([ISHIKAWA, 2000](#)) foi proposta a representação de uma imagem como um campo aleatório de Markov (*Markov Random Field - MRF*), onde cada pixel da imagem é um vértice de um grafo e cada aresta representa uma vizinhança. Um MRF pode ser descrito como um conjunto de variáveis aleatórias (vértices) que são representadas por um grafo não-direcionado.

Neste caso, os pixels são os vértices e a vizinhança entre dois pixels é definida por uma aresta. Cada vértice do grafo pode assumir um conjunto L de valores, onde a possibilidade de um vértice assumir determinado valor é dada por $P(X)$, onde X representa um estado do grafo. O problema de supressão de ruídos é, então, modelado como um problema de corte mínimo, onde é esperado que o custo do corte do grafo seja o mesmo da função de energia do MRF. Dessa maneira, minimizar a energia seria o mesmo que encontrar o corte mínimo do grafo (ISHIKAWA, 2000).

Uma outra abordagem para atenuação de ruídos em imagens com MRF foi apresentada em (CAO; LUO; YANG, 2011), onde a imagem é representada como três MRFs dispostos em camadas. Uma camada representa a imagem separada em regiões de acordo com sua textura enquanto as camadas seguintes representam a imagem sem ruído e a ruidosa, respectivamente. Assim, cada região apresenta diferentes parâmetros para o MRF, um para cada textura diferente.

Algumas abordagens meta-heurísticas foram desenvolvidas para minimizar a quantidade de ruídos em imagens. Uma dessas técnicas foi apresentada em (HSU *et al.*, 2013), onde um método híbrido, envolvendo otimização por enxame de partículas (*Particle Swarm Optimization* – PSO) em conjunto com uma filtragem por médias não-locais, é aplicado. Nesta abordagem, a técnica de PSO é utilizada para encontrar os melhores valores para os parâmetros do filtro de médias não-locais. As imagens obtidas a cada iteração do algoritmo têm sua qualidade medida por uma métrica Q que, de acordo com (HSU *et al.*, 2013), mede a quantidade de conteúdo real na imagem. Este algoritmo é executado até que uma solução ótima seja encontrada ou até que o máximo número de iterações seja alcançado.

Outro método meta-heurístico foi proposto por Kockanat *et al.* (KOCKANAT; KARABOGA; KOZA, 2012), onde um algoritmo de colônia artificial de abelhas é utilizado para suprimir ruídos em imagens. Neste caso, o erro médio quadrado (*Mean Squared Error* – MSE) é utilizado como função objetivo do algoritmo. Para tanto, este MSE é calculado entre a imagem avaliada e uma imagem ideal estimada que, nesta abordagem, é definida como o resultado da remoção de um sinal ruidoso estimado da imagem de entrada.

Na literatura, também encontram-se diferentes abordagens evolutivas para lidar com o problema de imagens ruidosas. Alguns destes métodos são utilizados para estimar os *thresholds* em operações de *wavelet shrinkage*, como o método descrito por (GUPTA; CHAN; SIAN, 2007) que aplica uma estratégia de evolução diferencial. Os autores em (THAVAVEL *et al.*, 2012), por sua vez, encontram estes *thresholds* através de um algoritmo genético multi-objetivo. Em uma abordagem diferente, o trabalho proposto por Toledo *et al.* (TOLEDO *et al.*, 2013) se utiliza de um Algoritmo Genético (AG) para recuperar as imagens. Neste método, as próprias imagens são indivíduos e a população evoluí através da aplicação de operadores de mutação e *crossover* específicos para o problema. A criação de novos indivíduos, nesta abordagem, se dá pelo uso de operadores de *crossover* que combinam partes das imagens escolhidas como pais e pelo uso de filtros simples como os de média, mediana e Gaussiano como operadores de mutação.

2.2 Supressão de ruídos em imagens

Por diversas vezes uma imagem digital sofre um processo de degradação que pode ser causado por diversos fatores como movimento no momento da captura da imagem, imperfeições da lente da câmera, limitação no tamanho dos sensores, etc. Além disso problemas também ocorrem durante a compressão e transmissão da imagem. Todas essas situações podem produzir uma imagem fora de foco ou ruidosa como ilustrado na Figura 1.

Figura 1 – A figura mostra uma imagem na qual houve movimento no instante da captura, tornando-a borrada.



Fonte: Imagem obtida na galeria do autor da fotografia.¹

A degradação que ocorre em uma imagem pode ser descrita no domínio espacial pelo modelo da equação 2.1, onde $f(x,y)$ é a imagem não degradada, $h(x,y)$ é a função de degradação, $\eta(x,y)$ o ruído adicionado à imagem e "*" representa a operação de convolução. Ao final, a imagem degradada é representada pela função $g(x,y)$.

$$g(x,y) = h(x,y) * f(x,y) + \eta(x,y) \quad (2.1)$$

Se os valores para $h(x,y)$ e $\eta(x,y)$ forem conhecidos, então será possível estimar $f(x,y)$ e recuperar a imagem (GONZALEZ; WOODS, 2006). Na grande maioria das vezes, $h(x,y)$ e $\eta(x,y)$ são desconhecidos.

2.2.1 Ruído

Agora consideremos que o único tipo de degradação sofrida por uma imagem digital seja o ruído (Equação 2.2). Neste caso, a recuperação da imagem depende apenas de estimar $\eta(x,y)$.

$$g(x,y) = f(x,y) + \eta(x,y) \quad (2.2)$$

¹ Disponível em <<https://www.flickr.com/photos/9976163@N03/4038490884/>>. Acesso em jun. 2015.

Enquanto é difícil, na maioria dos casos, simular ruídos reais em uma imagem, é possível gerar aproximações para ruídos causados por problemas reais através de funções densidade de probabilidade (FDP). Algumas das funções mais comumente utilizadas para geração de ruídos em imagens são:

- Ruido Gaussiano: Definido pela Equação 2.3, onde z é o tom de cinza, \bar{z} é a média e σ o desvio padrão (GONZALEZ; WOODS, 2006).

$$p(z) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(z-\bar{z})^2}{2\sigma^2}} \quad (2.3)$$

- Ruído Rayleigh: Definido pela Equação 2.4, onde a é um valor real e b um real maior que zero (GONZALEZ; WOODS, 2006).

$$p(z) = \begin{cases} \frac{2}{b}(z-a)e^{-(z-a)^2/b} & z \geq a \\ 0 & z < a \end{cases} \quad (2.4)$$

- Ruído Erlang: Definido pela Equação 2.5, onde a é um real maior que zero e b um inteiro positivo (GONZALEZ; WOODS, 2006).

$$p(z) = \begin{cases} \frac{a^b z^{b-1}}{(b-1)!} e^{-az} & z \geq a \\ 0 & z < a \end{cases} \quad (2.5)$$

- Ruído exponencial: Definido pela Equação 2.6. Trata-se de um caso específico do ruído Erlang para $b = 1$ (GONZALEZ; WOODS, 2006).

$$p(z) = \begin{cases} ae^{-az} & z \geq a \\ 0 & z < a \end{cases} \quad (2.6)$$

- Ruído uniforme: Definido pela Equação 2.7 (GONZALEZ; WOODS, 2006).

$$p(z) = \begin{cases} \frac{1}{b-a} & a \leq z \leq b \\ 0 & \text{outros casos} \end{cases} \quad (2.7)$$

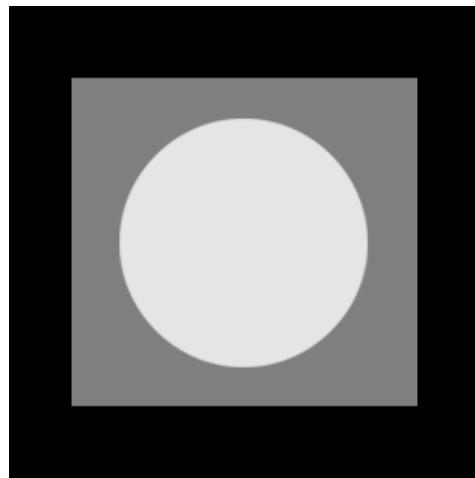
- Ruído impulsivo: Definido pela Equação 2.8. Também chamado de ruído sal-e-pimenta (*salt-and-pepper*); caso $b > a$, a intensidade b será um ponto claro na imagem e a um ponto escuro, desde que P_a e P_b não sejam iguais a zero. Usualmente, em um modelo onde os valores dos pixels se situam no intervalo $[0, 255]$, $P_a = 0$ e $P_b = 255$ (GONZALEZ; WOODS, 2006).

$$p(z) = \begin{cases} P_a & z = a \\ P_b & z = b \\ 0 & \text{outros casos} \end{cases} \quad (2.8)$$

Um exemplo do efeito que cada um desses diferentes ruídos causa, ao ser aplicado na imagem da Figura 2, pode ser visto na Figura 3.

Neste trabalho, nós utilizamos o ruído Gaussiano branco aditivo para a maioria dos experimentos realizados. Este tipo de ruído — que segue uma distribuição normal e afeta as bandas de frequência de maneira uniforme — é o mais utilizado em diversos casos da literatura, isso se deve a facilidade de manipulação matemática que ele fornece tanto no domínio espacial quanto no domínio da frequência (GONZALEZ; WOODS, 2006).

Figura 2 – Imagem original.



Fonte: [Gonzalez, Woods e Eddins \(2005\)](#).

Todas as FDPs apresentadas até aqui nos dão uma estimativa para o cálculo de $\eta(x, y)$ (como definido em 2.2) e não resolvem o problema completamente, porém elas servem como um norte para guiar os estudos a respeito de atenuação de ruídos em imagens.

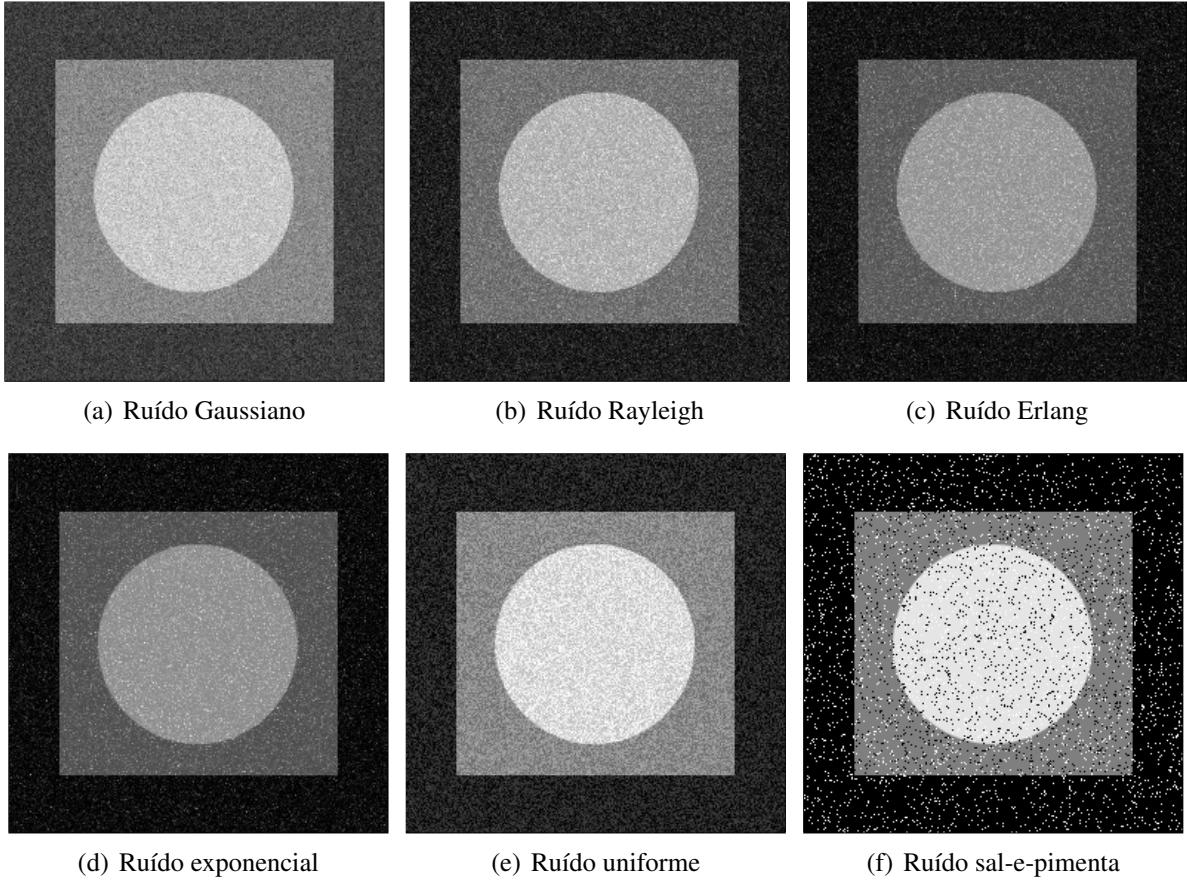
2.2.2 Atenuação de ruídos como um Problema de Otimização

2.2.2.1 Atenuação através de MRF

A abordagem feita por Ishikawa (ISHIKAWA, 2000) utiliza o *Bayesian Framework* em conjunto com o MRF para tratar a atenuação de ruídos como um problema de otimização. Neste problema, é criado um modelo dividido em duas partes, o *Prior Model*, que é uma expectativa de como seria a imagem original, e o *Image Formation Model*, que é a imagem ruidosa da maneira como ela é formada, ou seja, o ruído adicionado à imagem original.

Um MRF pode ser descrito como um conjunto de variáveis aleatórias (vértices) que são representadas por um grafo não-direcionado. Os vértices são associados a um conjunto de valores possíveis L e uma função de probabilidade $P(X)$, onde X é um estado do grafo. Um valor de L é associado a cada vértice e cada aresta possui um peso representando a probabilidade condicional entre dois vértices adjacentes. Quando não há aresta entre vértices, eles representam variáveis independentes.

Figura 3 – O resultado de diferentes ruídos aplicados à imagem 2..



Fonte: [Gonzalez, Woods e Eddins \(2005\)](#).

A partir destas suposições, o problema passa a ser estimar a imagem original a partir da ruidosa. Neste caso, o *Prior Model* dá a probabilidade $P(X)$ da imagem X ser uma imagem original, enquanto o *Image Formation Model* dá a probabilidade $P(I|X)$ de que a imagem ruidosa I tenha sido formada a partir da original X . Neste ponto, queremos buscar a imagem X com maior probabilidade de se tornar a imagem I após a adição do ruído, ou seja, de um ponto de vista matemático, queremos maximizar $P(I|X)$ (equação 2.9).

$$P(X|I) = \frac{P(I|X)P(X)}{P(I)} \quad (2.9)$$

Na equação 2.9, $P(I)$ é conhecido e constante, pois I é a imagem de entrada do problema. Os outros termos foram calculados em ([ISHIKAWA, 2000](#)) como sendo

$$P(X) \sim \prod_{x,y} \prod_{x',y'} e^{-\mu |X(x,y) - X(x+x',y+y')|} \quad (2.10)$$

$$P(I|X) \sim \prod_{x,y} e^{-\left(I(x,y) - X(x,y)\right)^2} \quad (2.11)$$

onde μ é um parâmetro que depende da intensidade do ruído, (x, y) são os pixels das imagens e (x', y') são seus pixels vizinhos.

A maximização de $P(X|Y)$ pode ser tratada como um problema de minimização $\log P(X|Y)$, o que pode ser interpretado como a minimização da energia do sistema ([ISHIKAWA, 2000](#)) (equação 2.12), onde $R(X)$ é a energia da imagem.

$$\arg \min_X \|X - I\|^2 + \mu R(X) \quad (2.12)$$

Tratando a imagem como um MRF ([ISHIKAWA, 2000](#)) o problema passa a ser a minimização da equação de energia 2.13

$$\min E(X) = \mu \sum_{(u,v) \in E} |X_u - X_v| + \sum_{v \in V} (I_v - X_v)^2 \quad (2.13)$$

onde X é o indivíduo avaliado, I a imagem ruidosa, X_v é o v -iésimo pixel de X e dois pixels $(u, v) \in N$ se, e somente se, u pertence à vizinhança-4 de v . Por fim, μ é uma constante que visa balancear a suavização de X .

A partir da representação da imagem como um MRF, o problema de *image denoising* passa a ser tratado como um problema de corte mínimo em ([ISHIKAWA, 2000](#)), de maneira que seja possível obter um grafo cuja relação entre seus cortes e as configurações do MRF original seja de um para um. Neste modelo, os vértices do grafo são dispostos em formato de cubo, onde duas dimensões representam a localização do pixel e a terceira representa intensidade do pixel, fazendo com que haja um vértice por valor possível de intensidade. A altura do cubo onde ocorre o corte representa qual será a intensidade para o pixel correspondente. Desta maneira, espera-se que o custo do corte do grafo seja igual ao valor da função de energia do MRF. Ou seja, ao minimizar a função de energia do MRF, o corte mínimo do grafo também será feito. Este processo, ilustrado na figura 4, foi solucionado por Ishikawa com um algoritmo chamado *standard push-relabel method with global relabeling* ([ISHIKAWA, 2000](#)).

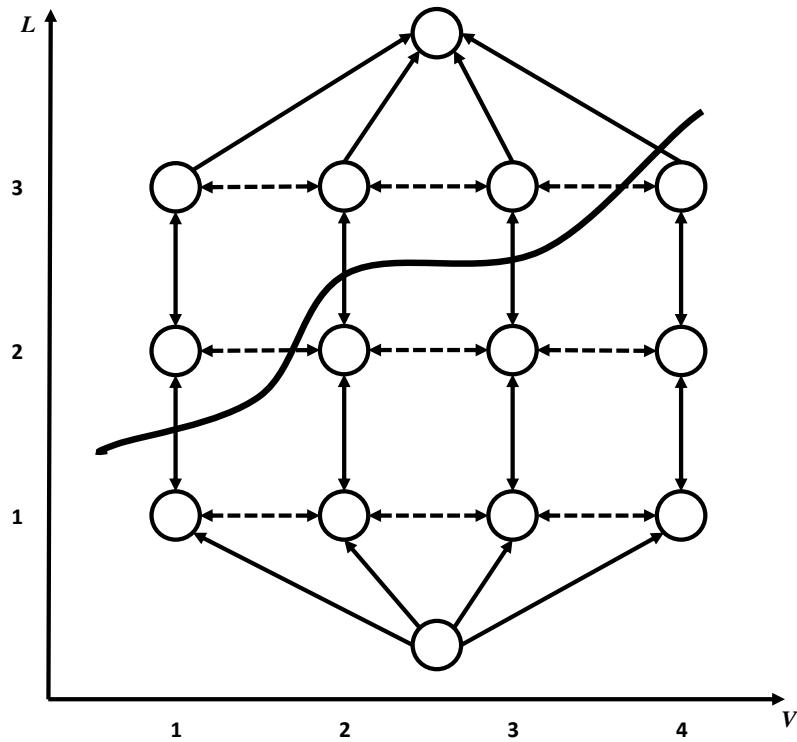
2.2.2.2 Atenuação através da minimização da variação total

Um modo particularmente eficaz e bem utilizado de supressão de ruídos em imagens consiste em minimizar a variação total presente na mesma. Desta forma, um modelo matemático que descreva essa variação pode ser utilizado como guia para diversos métodos de otimização ([ZOSSO; BUSTIN, 2014](#)).

Com base nisso, um modelo foi proposto em ([RUDIN; OSHER; FATEMI, 1992](#)) visando minimizar esta variação total através da seguinte equação:

$$\min_X \left\{ \int_{\Omega} |\nabla X| + \frac{\lambda}{2} \int_{\Omega} (X - I)^2 \right\} \quad (2.14)$$

Figura 4 – Ilustração do problema de corte mínimo da proposta de Ishikawa (ISHIKAWA, 2000).



Fonte: Elaborada pelo autor.

para um parâmetro de balanceamento $\lambda > 0$. Nessa proposta, X é a imagem avaliada e I é a imagem ruidosa, ∇X é o gradiente de X (norma de variação total) e Ω é o conjunto de pontos da imagem.

A partir da equação 2.14, diferentes propostas foram realizadas, buscando tornar a função de minimização ciente de características importantes da imagem, como bordas, e mais adaptável dentro do espaço. Por este motivo, a norma de variação total passou a também ser ponderada por um parâmetro β (equação 2.15) (SOCHEN; KIMMEL; MALLADI, 1998; KIMMEL; SOCHEH; MALLADI, 1997).

$$\min_X \left\{ \int_{\Omega} \sqrt{1 + \beta^2 |\nabla X|^2} + \frac{\lambda}{2} \int_{\Omega} (X - I)^2 \right\} \quad (2.15)$$

Para o desenvolvimento do trabalho apresentado em (ZOSSO; BUSTIN, 2014), o *Beltrami Framework* é utilizado. Este *framework* geométrico — apresentado em (SOCHEN; KIMMEL; MALLADI, 1998) — se baseia no conceito de Ação de Polyakov, introduzida inicialmente na teoria das cordas no campo da física. O *framework* consiste em dois aspectos principais: primeiro, descrever uma imagem como mapas entre duas variedades de Riemann; segundo, uma ação funcional que permita medições nos espaços destes mapas.

A partir das possibilidades produzidas pela utilização deste *framework*, Zosso e Bustin propuseram uma formulação em um modelo primal-dual da função descrita na Equação 2.15 — utilizada neste trabalho, em sua forma discreta, como função de *fitness* do AGH. Através de um algoritmo de otimização de gradientes projetados, eles conseguiram atingir resultados melhores do que utilizando a função originalmente proposta em (RUDIN; OSHER; FATEMI, 1992).

2.3 Computação Evolutiva

Os métodos evolutivos se caracterizam por criar populações, onde cada indivíduo é uma representação para a solução do problema tratado. Estes indivíduos então passam a competir e a população se atualiza, onde os que se apresentam como mais adequados (melhor *fitness*) ao problema possuem mais chances de sobreviver e reproduzir, fazendo com que suas principais características passem aos seus filhos.

Uma população inicial de indivíduos é construída de forma aleatória ou com certo grau de aleatoriedade. Em seguida, alguns indivíduos são selecionados como pais cujas características serão recombinadas para gerar novos indivíduos. Os elementos da nova geração podem ou não passar por um processo de mutação que muitas vezes traz diversidade para a população. Uma população intermediária é formada a partir dos novos indivíduos e daqueles que já existiam na população. Os mais aptos tendem a ser escolhidos para formar a população na próxima geração. Este método é repetido até que algum critério de parada seja atendido (EIBEN; SMITH, 2003).

A partir destes conceitos básicos, surgiram diferentes correntes de desenvolvimento dessas técnicas:

- **Programação Evolutiva** – Proposta por Fogel, Owens e Walsh (EIBEN; SMITH, 2003), possui algumas características particulares como a não existência de recombinação e mutação a ser realizada através de uma perturbação gaussiana nos cromossomos.
- **Estratégia Evolutiva** – Proposta por Rechenberg e Schwefel (EIBEN; SMITH, 2003). Algumas características originais específicas são a existência de recombinação, mutação por perturbação gaussiana e a seleção aleatória de pais.
- **Programação Genética** – A mais recente das quatro, foi proposta por Koza (EIBEN; SMITH, 2003) no início dos 1990. Nesta técnica, os cromossomos são representados como árvores, a recombinação é feita através da troca de sub-árvores e a mutação através de mudanças aleatórias nas árvores.
- **Algoritmos Genéticos** – Proposto por Holland (EIBEN; SMITH, 2003; HOLLAND, 1973; HOLLAND, 1992). Algumas de suas características originais são a codificação dos cromossomos como strings binárias, recombinação dos cromossomos através do método

de um ponto ou de n-pontos e mutação definida através da inversão do valor dos bits com certa probabilidade.

A subseção 2.3.1 irá apresentar os Algoritmos Genéticos (AG) de maneira mais detalhada, mostrando as suas principais características de acordo como propostas inicialmente. O Capítulo 3 descreve o Algoritmo Genético Híbrido (AGH), um algoritmo genético desenvolvido especificamente para lidar o problema de supressão de ruídos em imagens.

2.3.1 Algoritmos Genéticos

O algoritmo genético clássico ou canônico como propostos por Holland pode ser descritos pelo algoritmo 1 (HOLLAND, 1973; HOLLAND, 1992). Os indivíduos são gerados aleatoriamente e possuem seus cromossomos codificados como strings binárias. A partir das operações de recombinação e mutação os novos indivíduos são criados e podem ser inseridos na população. Os operadores utilizados, bem como a seleção dos pais, serão explicados a seguir.

Algoritmo 1: Algoritmo Genético clássico.

- 1 $ger \leftarrow 0;$
 - 2 Gerar população inicial aleatoriamente;
 - 3 Calcular o *fitness* dos indivíduos da população;
 - 4 **while** $ger < maxGer$ **do**
 - 5 Selecionar os pais para reprodução;
 - 6 Realizar *crossover* com os pais selecionados;
 - 7 Aplicar mutação sobre os filhos gerados na operação anterior;
 - 8 Calcular o *fitness* dos filhos;
 - 9 Substituir todos os indivíduos da população atual pelos filhos;
 - 10 $ger \leftarrow ger + 1;$
-

Seleção dos Pais

Os principais métodos para seleção dos pais levam em conta o *fitness* de cada indivíduo da população. As principais formas são a seleção por *ranking*, *torneio* e *roleta* (JONG, 2008; EIBEN; SMITH, 2003):

- Na seleção por ranking, todos os indivíduos da população são ordenados de acordo com seu *fitness* e a probabilidade de seleção de cada indivíduo se dá pela sua colocação dentro deste ranking.

- Na seleção por torneio, um número de indivíduos da população é selecionada aleatoriamente e o de melhor *fitness* entre eles é escolhido para reprodução. Este processo é repetido até que a quantidade de pais necessária seja atingida.
- Na seleção por roleta, todos os indivíduos da população têm chances de serem selecionados para reprodução, mas a probabilidade da seleção varia de acordo com o *fitness* de cada indivíduo.

Recombinação

A recombinação, também chamada de *crossover*, é o método no qual os filhos são gerados a partir dos pais selecionados (EIBEN; SMITH, 2003), ou seja, ocorre a troca de informações para geração de uma nova representação da solução (indivíduo). Existem diferentes formas de realizar a recombinação, mas o objetivo geral é gerar filhos que contenham uma parte de seu cromossomo vinda a partir do primeiro pai e outra parte a partir do segundo pai. Usualmente, a recombinação ocorre de acordo com determinada taxa de probabilidade definida com a necessidade do problema.

Alguns métodos conhecidos de crossover são o *crossover de 1-ponto*, onde uma posição é sorteada e um filho é formado pela sequência inicial do primeiro pai e da sequência final do segundo pai. O segundo filho é formado de maneira análoga a partir da sequência inicial do segundo pai e final do primeiro. O *crossover de n-pontos* funciona de maneira análoga ao de 1-ponto, mas ao invés de sortear um ponto de corte, são sorteados n pontos de corte. O *crossover uniforme* faz com que cada elemento do filho tenha 50% de chances de pertencer ao primeiro pai ou ao segundo pai. Estes três tipos de recombinação estão exemplificados nas figuras 5, 6 e 7 respectivamente.

Figura 5 – Crossover de 1-ponto.

	1	2	3	4	5	6	7	8	9	10	11	12
Pai 1	0	1	0	0	1	1	0	1	0	1	1	0
Pai 2	1	1	1	0	0	1	0	1	0	0	1	1
Filho 1	0	1	0	0	1	1	0	1	0	0	1	1
Filho 2	1	1	1	0	0	1	0	1	0	1	1	0

Fonte: Elaborada pelo autor.

Novas representações foram propostas para AGs, onde indivíduos são representados por números inteiros e reais com operadores de recombinação específicos. Por exemplo, no crossover de média o valor do filho é calculado a partir da média dos valores dos pais. No crossover aritmético, o valor do filho é calculado como um ponto pertencente a reta entre os valores dos pais.

Figura 6 – Crossover de n-pontos ($n = 4$).

	1	2	3	4	5	6	7	8	9	10	11	12
Pai 1	0	1	0	0	1	1	0	1	0	1	1	0
Pai 2	1	1	1	0	0	1	0	1	0	0	1	1
Filho 1	0	1	1	0	1	1	0	1	0	1	1	0
Filho 2	1	1	0	0	0	1	0	1	0	0	1	1

Fonte: Elaborada pelo autor.

Figura 7 – Crossover uniforme.

	1	2	3	4	5	6	7	8	9	10	11	12
Pai 1	0	1	0	0	1	1	0	1	0	1	1	0
Pai 2	1	1	1	0	0	1	0	1	0	0	1	1
Filho 1	0	1	1	0	0	1	0	1	0	1	1	0
Filho 2	1	1	0	0	1	1	0	1	0	0	1	1

Fonte: Elaborada pelo autor.

Mutação

A mutação é um processo que realiza variações no cromossomo de um indivíduo (EIBEN; SMITH, 2003). O objetivo dela é ajudar a manter a diversidade na população. Assim como no caso da recombinação, a mutação também ocorre de acordo com determinada taxa de probabilidade. A figura 8 ilustra o uso de mutação na representação binária.

Figura 8 – Exemplos de mutação aplicados a uma cadeia binária.

0 1 0 0 1 → 0 1 0 **1** 1

(a) Um bit selecionado aleatoriamente é invertido

0 **1** 0 **0** 1 → 0 **0** 0 **1** 1

(b) Dois elementos da sequência são trocados

Fonte: Elaborada pelo autor.

Da mesma maneira que aconteceu com a recombinação, representações diferentes também trazem novas possibilidades para os operadores de mutação. Na *mutação uniforme*, por exemplo, um novo valor (dentro do domínio permitido) é sorteado para substituir um valor do cromossomo; outro caso é a *mutação gaussiana* que sorteia o novo valor a partir de uma distribuição gaussiana $N(\mu, \sigma)$ com média μ e desvio padrão σ .



ALGORITMO GENÉTICO HÍBRIDO

O Algoritmo Genético Híbrido (AGH) apresentado neste trabalho se inspira no método *Genetic Restoration* (GR), um algoritmo genético para supressão de ruídos em imagens proposto em (TOLEDO *et al.*, 2013). Nessa abordagem, podemos destacar que cada indivíduo da população é uma imagem em si, representada por uma matriz de pixels cujos valores são números inteiros dentro do intervalo [0..255]. De maneira análoga ao método no qual o AGH se inspira, uma imagem ruidosa I é utilizada como entrada para o método e a população é criada a partir da aplicação de operadores de mutação em I e, além disso, dos três operadores de *crossover* utilizados pelo AGH, dois haviam sido introduzidos em (TOLEDO *et al.*, 2013).

Entretanto, o AGH possui uma série de diferenças em relação ao GR:

- Cálculo de *fitness* dos indivíduos — enquanto o GR minimiza a função de energia dada por Ishikawa (ISHIKAWA, 2000) (ver subseção 2.2.2.1) o AGH busca minimizar a variação total da imagem (ZOSSO; BUSTIN, 2014) (ver subseção 2.2.2.2).
- Utilização de população intermediária — o GR não utiliza população intermediária, substituindo um dos pais pelo novo filho caso ele seja mais apto (melhor *fitness*); o AGH cria uma população intermediária com todos elementos da população juntamente com os novos filhos gerados
- Uso de busca local — o GR aplica filtros e operações simples como operadores de mutação durante o passo evolutivo do algoritmo, o AGH, por sua vez, utiliza métodos sofisticados de supressão de ruídos como operadores de busca local, e aplica as mutações simples apenas para garantir a diversidade da população durante os processos de inicialização e reinicialização da população. Esta mudança, particularmente, traz uma contribuição relevante para o trabalho, uma vez que métodos conhecidos para supressão de ruídos servem como maneiras do AGH se aprofundar na busca para soluções do problema.

- Critério de parada — o AGH é executado por um tempo determinado, enquanto o GR executa por um número determinado de épocas.

Além das listadas, o AGH possui outras diferenças básicas em relação ao GR, como o tipo de torneio utilizado, o critério de convergência do processo evolutivo e os processos de inicialização e reinicialização do algoritmo. O pseudocódigo do método proposto neste trabalho está detalhado no Algoritmo 2.

Algoritmo 2: Algoritmo Genético Híbrido(Imagen *Img*)

```

1 Pop  $\leftarrow$  CriaPopulação(Img)
2 melhor  $\leftarrow$  Pop.melhor
3 while tempo  $<$  TempoMaximo do
4   contador  $\leftarrow$  0
5   while contador  $<$  MaximoIteracoes do
6     PopIntermediaria  $\leftarrow$  Pop
7     for i  $\leftarrow$  1 to TamanhoPopulacao do
8       ind1, ind2  $\leftarrow$  SelecionaPais(Pop)
9       ind3  $\leftarrow$  crossover(ind1, ind2)
10      if ( $\lambda \in [0, 1]$ )  $\leq$  TaxaBuscaLocal then
11        BuscaLocal(ind3)
12        PopIntermediaria.adiciona(ind3)
13      ordenação(IntermPop)
14      Pop  $\leftarrow$  PopIntermediaria[1..TamanhoPopulacao]
15      if melhor = Pop.melhor then
16        contador  $\leftarrow$  contador + 1
17      else
18        contador  $\leftarrow$  0
19    reinicialização(Pop)
20  return Pop.melhor

```

O início do algoritmo consiste em criar a população em dois passos: primeiro, a imagem ruidosa é utilizada como entrada para três métodos de supressão de ruídos em imagens. No AGH estas técnicas são também utilizadas como operadores de busca local:

- BM3D ([DABOV *et al.*, 2006](#)).
- Anisotropic Diffusion ([BLACK *et al.*, 1998](#)).

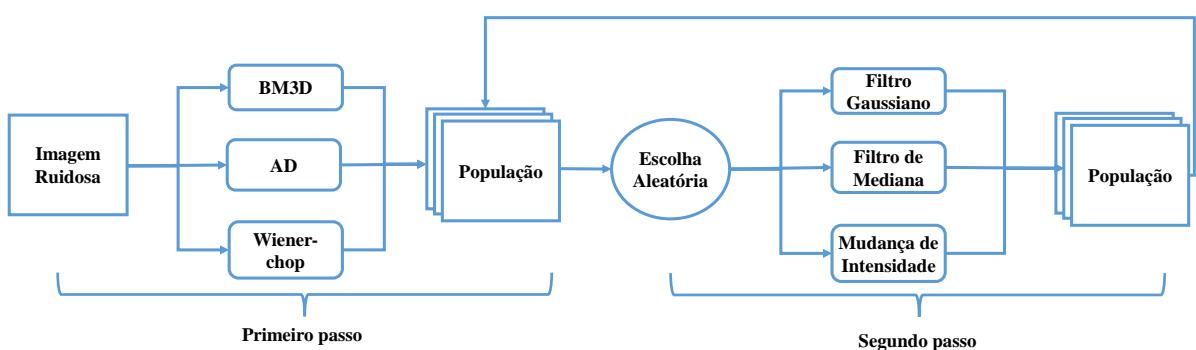
- Wiener-chop ([GHAEL et al., 1997](#)).

Estes métodos foram escolhidos tanto pela sua rapidez computacional quanto pelo fato deles serem responsáveis por alguns dos melhores resultados da literatura. A saída destes métodos é, por padrão, incluída na população inicial. Desta maneira, ao final do primeiro passo a população inicial conta com três indivíduos. No segundo passo, uma das saídas destes três métodos é escolhida aleatoriamente e submetida a um operador de mutação que também é escolhido aleatoriamente. Os operadores utilizados neste passo são os seguintes:

- **Borramento Gaussiano:** filtra a imagem com um filtro Gaussiano. O tamanho do filtro é escolhido aleatoriamente entre 3×3 pixels e 5×5 pixels.
- **Filtro de mediana:** filtra a imagem com um filtro de mediana. O tamanho do filtro é escolhido aleatoriamente entre 3×3 pixels e 5×5 pixels.
- **Mudança de intensidade:** todos os pixels da imagem são multiplicados pelo mesmo fator cujo valor é escolhido aleatoriamente dentro do intervalo $[0.7, 1.3]$.

Estes filtros são chamados de operadores de mutação por realizarem mudanças na imagem previamente recuperada por um dos métodos de supressão de ruídos. A imagem resultante é incluída na população e o segundo passo do método se repete até que a população atinja o tamanho desejado. Ao final deste processo, a população inicial será formada pelas saídas dos três métodos de supressão de ruídos e pelas imagens submetidas à mutação. Este processo de inicialização da população em duas fases está ilustrado na figura 9.

Figura 9 – Inicialização da população do AGH.



Fonte: Elaborada pelo autor.

Uma vez que a população inicial é criada (linha 1, algoritmo 2), o processo evolutivo é executado por um intervalo de tempo definido (linhas 3-19). Durante esta execução, a população continua a evoluir enquanto não houver mudança no melhor indivíduos até um número máximo de iterações (linhas 5-18). Quando este número é alcançado, a população é reiniciada mantendo

apenas o melhor indivíduo encontrado até então (linha 19). Os demais indivíduos da população são criados novamente pelo processo de inicialização já citado anteriormente.

Uma população intermediária é criada durante o processo evolucionário. Essa população, cujo tamanho é duas vezes maior que o da população inicial, é inicializada com os membros da própria população atual do algoritmo e, durante o processo evolutivo, os novos indivíduos gerados vão sendo inseridos nela (linhas 6 e 12).

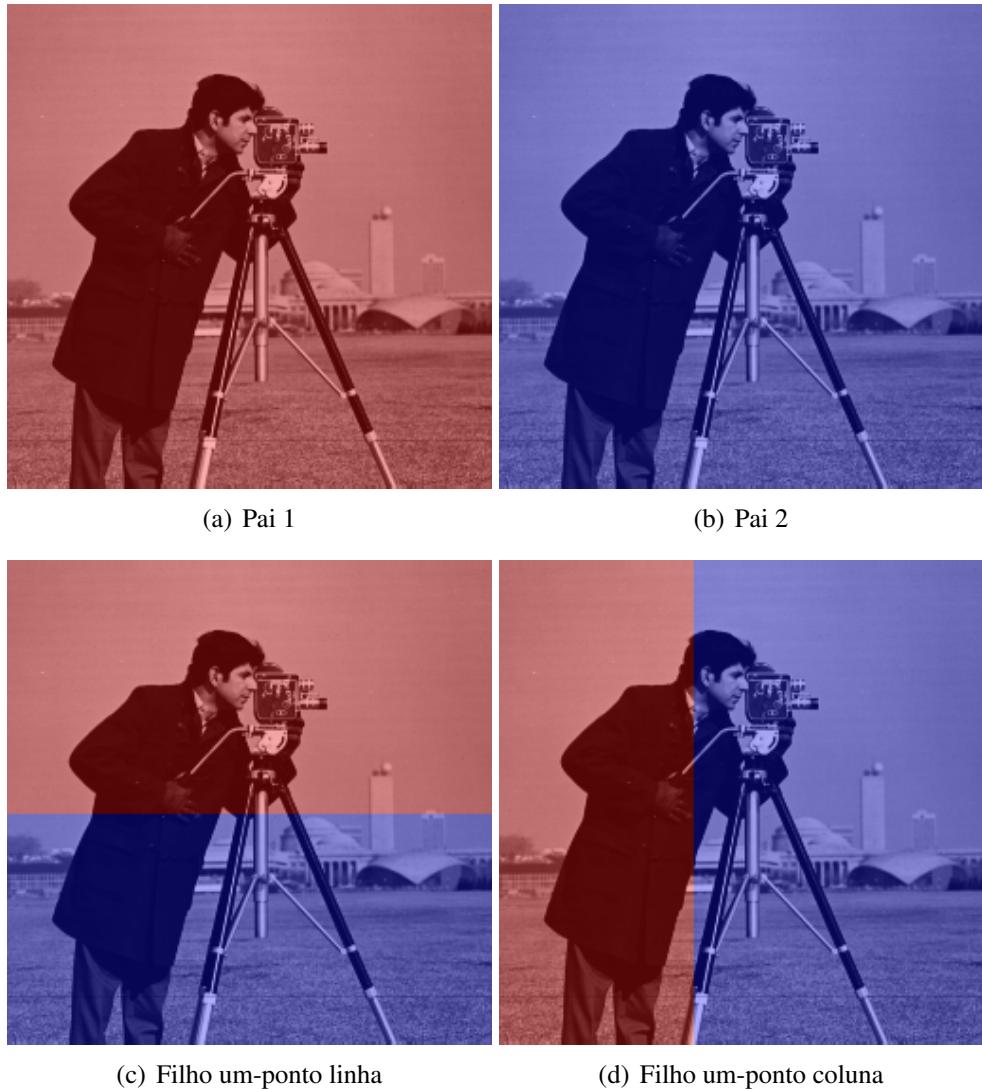
Para atingir a quantidade de membros necessários para completar a população intermediária, os novos indivíduos são gerados através de uma sequência de passos:

1. Seleção dos pais via torneio (linha 8) — três indivíduos são selecionados aleatoriamente dentro da população e o mais apto é escolhido como primeiro pai, em seguida este processo é repetido, tomando cuidado para que o mesmo indivíduo não seja escolhido novamente, na escolha do segundo pai.
2. *Crossover* (linha 9) — um operador de crossover é escolhido aleatoriamente e aplicado nos pais selecionados anteriormente e, a partir desta operação, um novo indivíduo é criado. Os operadores possíveis são:
 - **Operador de um-ponto linha:** Uma linha de pixels dentro da matriz é escolhida aleatoriamente. Todos os pixels acima desta linha virão de um dos pais e todos os pixels abaixo desta linha vêm do outro pai (vide figura 10).
 - **Operador de um-ponto coluna:** Similar ao método anterior, mas uma coluna é escolhida ao invés de uma linha (vide figura 10)
 - **Operador uniforme:** Semelhante ao operador de *crossover* uniforme do AG clássico (ver seção 2.3.1), cada pixel é escolhido aleatoriamente de um dos pais, com 50% de chances do valor escolhido vir de um ou do outro pai (vide figura 11).
3. Busca local (linhas 10-11) — Após a criação, o novo indivíduo também pode passar por uma operação de busca local, caso um valor real escolhido aleatoriamente dentro do intervalo $[0, 1]$ seja menor do que a taxa de busca local do algoritmo (linhas 10-11). Se um indivíduo for escolhido para a busca local, ele será submetido a um operador de supressão de ruídos em imagens escolhido aleatoriamente entre os três métodos descritos anteriormente: BM3D, Anisotropic Diffusion e Wiener-chop.

Todo o fluxo de execução do pseudocódigo está ilustrado no fluxograma da figura 12, onde o passo evolutivo mencionado se refere às linhas 7 a 12 do algoritmo.

Com a população intermediária completa (tamanho duas vezes maior que a população do algoritmo), ela é ordenada de acordo com a aptidão (*fitness*) de seus indivíduos (linha 13). A partir desse ponto, os *TamanhoPopulacao* primeiros elementos dela passam a formar a população do

Figura 10 – Exemplos dos operadores de cruzamento de um-ponto linha e coluna.

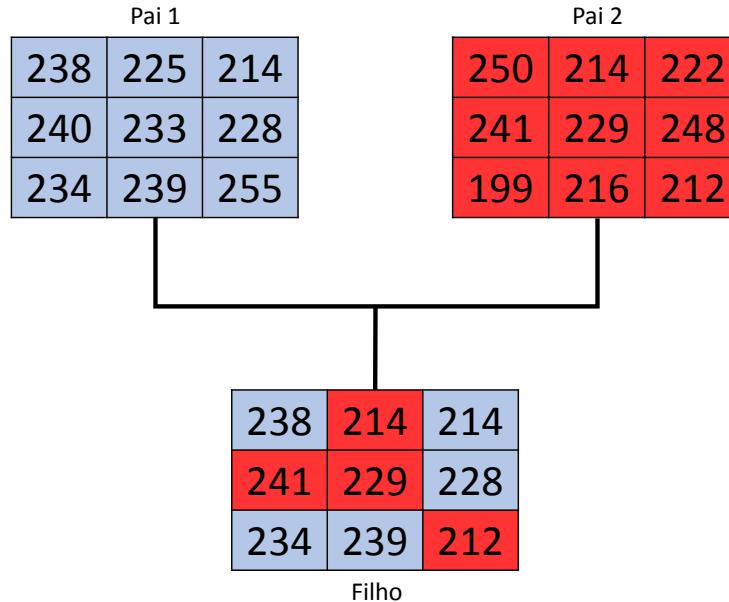


Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

AGH em si para o próximo passo evolutivo do algoritmo (linha 14). Para avaliar se a população deve ser reiniciada, o AGH verifica se não há alterações no melhor indivíduo de sua população por um número determinado de execuções da evolução de sua população. Caso o melhor indivíduo da população não mude depois de *MaximoIteracoes* iterações consecutivas, então a população é reiniciada.

A fim de guiar o AGH, a função objetivo descrita pela equação 3.1 é utilizada. Esta função, detalhada na subseção 2.2.2.2 identifica as regiões de borda enquanto tenta preservar importantes características da imagem (**ZOSO; BUSTIN, 2014**). Nesta equação, X e I são, respectivamente, as imagens avaliadas no momento e a ruidosa (entrada do algoritmo), e o termo $(X - I)^2$ garante certa fidelidade entre ambas. Ainda dentro da função, ∇X é um termo de regularização da variação total (*Total Variation - TV*), β e λ são termos de balanceamento e Ω é o conjunto de todos os pontos da imagem. Ao minimizar a função objetivo, o método busca,

Figura 11 – Exemplo do operador de crossover uniforme como utilizado pelo AGH.

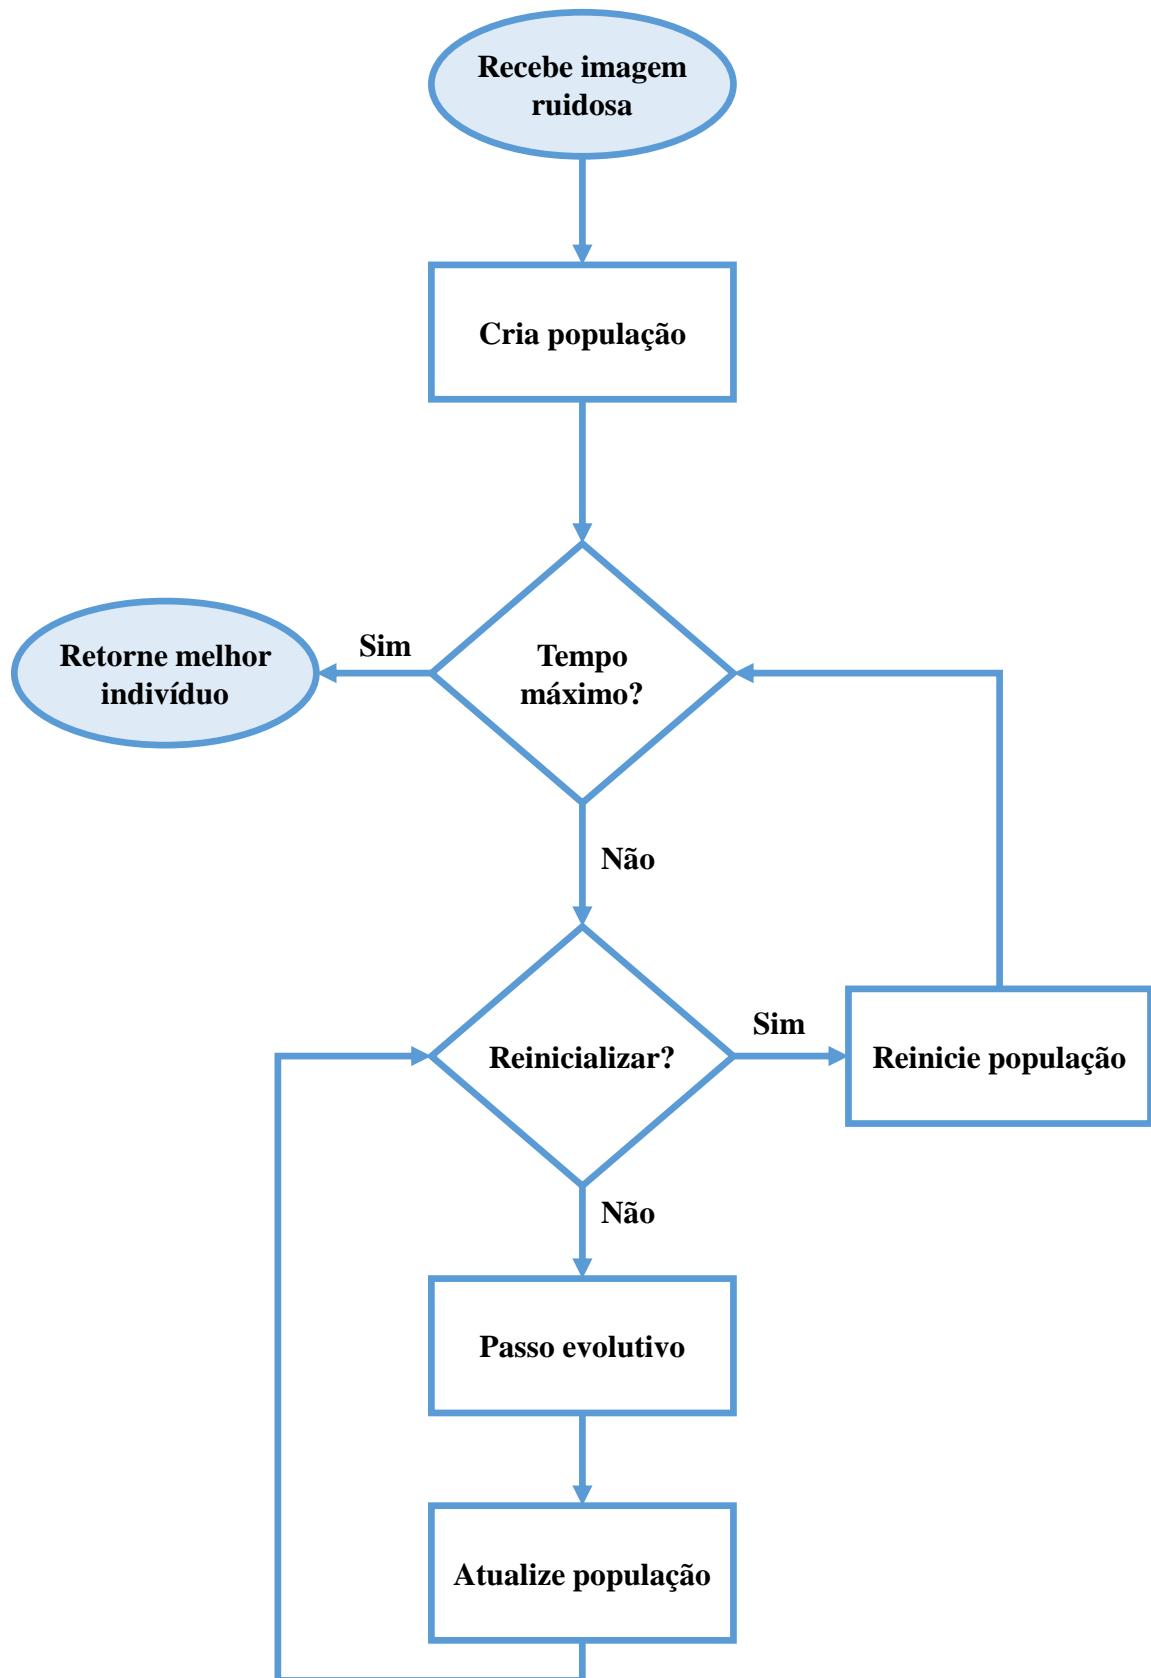


Fonte: Elaborada pelo autor.

basicamente, minimizar a variação total da imagem ao mesmo tempo em que procura preservar a fidelidade da mesma em relação à imagem original ([ZOSSO; BUSTIN, 2014](#)).

$$\text{fitness}(X) = \left(\sum_{\Omega} \sqrt{1 + \beta^2 |\nabla X|^2} \right) + \frac{\lambda}{2} (X - I)^2 \quad (3.1)$$

Figura 12 – Fluxograma básico do funcionamento do AGH.



Fonte: Elaborada pelo autor.



RESULTADOS COMPUTACIONAIS

Este capítulo apresenta os resultados computacionais obtidos pelo AGH. Primeiramente, diversos testes feitos para identificar os melhores valores para os parâmetros do algoritmo (seção 4.1) são apresentados. Em seguida a qualidade do AGH é testada comparando-o com variações de si mesmo (seção 4.2), com alguns dos principais métodos de supressão de ruídos da literatura (seção 4.3) e com métodos especializados em suprimir ruídos de imagens SAR (seção 4.4).

As métricas PSNR (*peak signal-to-noise ratio*) e SSIM (*structural similarity index*) foram utilizadas para comparar os diferentes algoritmos, já que elas são comumente utilizadas para medir a qualidade de imagens restauradas. Elas foram calculadas para as saídas de cada algoritmo e estão descritas a seguir:

- PSNR: descreve a razão entre a potência máxima de um sinal e a potência do ruído (SILVA *et al.*, 2013). É medida em decibéis (dB) e valores mais altos para PSNR normalmente indicam imagens de maior qualidade. Para imagens em tons de cinza (8 bits), a métrica é definida pela equação 4.1:

$$\text{PSNR} = 10 \log_{10} \left(\frac{255^2}{\text{MSE}} \right) \quad (4.1)$$

onde o MSE, definido na equação 4.2, é o erro médio quadrado entre as imagens original (O) e recuperada (R) e as dimensões da imagem são representadas por M e N .

$$\text{MSE} = \frac{1}{MN} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} [O(i, j) - R(i, j)]^2 \quad (4.2)$$

- SSIM: nesta métrica, duas imagens são mapeadas para um intervalo $[-1, 1]$, onde imagens similares contêm valores mais altos (SILVA *et al.*, 2013; WANG *et al.*, 2004). Ela é definida pela equação 4.3, onde μ_A, μ_B, σ_A e σ_B são os valores da média e desvio padrão para A e B ,

σ_{AB} é a covariância entre A e B , $c_1 = (k_1 L)^2$ e $c_2 = (k_2 L)^2$, onde L é o intervalo dinâmico dos valores dos pixels ($2^{bits per pixel} - 1$) e $k_1 = 0,01$ e $k_2 = 0,03$ são constantes (WANG et al., 2004).

$$\text{SSIM}(A, B) = \frac{(2\mu_A\mu_B + c_1)(2\sigma_{AB} + c_2)}{(\mu_A^2 + \mu_B^2 + c_1)(\sigma_A^2 + \sigma_B^2 + c_2)} \quad (4.3)$$

Todos os métodos aqui apresentados foram implementados em Matlab R2013a (8.1.0.604) 64-bit e executados em uma máquina com processador Intel Core i7-2600 3,40 GHz com 24 GB de RAM compartilhadas em um *cluster* com 10 CPUs em Linux Debian 7.6 (versão do núcleo 3.2.0 64 bits). Imagens de comparações de diversos testes deste capítulo encontram-se no apêndice A.

4.1 Sintonizando o AGH

A imagem *boat 13* (512x512 pixels) foi utilizada como padrão para realização dos testes de parâmetros, por se tratar de uma das maiores imagens entre as utilizadas como *benchmark* neste trabalho. Para isso, ela foi deteriorada com um ruído aditivo branco Gaussiano $N(0, \sigma)$ com onze diferentes valores para o desvio padrão $\sigma = 10, 15, 20, 25, 30, 35, 40, 45, 50, 55$ e 60 .

Figura 13 – Boat image.



Fonte: Gonzalez, Woods e Eddins (2005).

A configuração inicial do AGH utiliza um torneio de tamanho 3, taxa de busca local = 0,4, população de tamanho 15, $\beta = 1,5$ e tempo de execução de 20 minutos. Esta configuração se baseou em testes empíricos que levaram em conta o tempo computacional gasto ao executar cada geração do AGH. Por exemplo, não é possível criar uma população muito grande, uma vez que isso faz com que os processos de inicialização e reinicialização da população e de busca local passem a consumir muito tempo, prejudicando a evolução das imagens pelo AG dentro do tempo total de execução do método.

O primeiro parâmetro avaliado a partir da configuração inicial foi o tamanho do torneio para a seleção de pais. Já que o tamanho de população padrão não é muito grande, os valores

utilizados neste experimento foram 3, 6 e 9. Os valores médio (Med), máximo (Max) e mínimo (Min) das dez execuções para essas diferentes configurações são exibidos nas tabelas 1 e 2.

Tabela 1 – PSNR para diferentes tamanhos de torneio.

Ruído	Torneio: 3			Torneio: 6			Torneio: 9		
	Med	Max	Min	Med	Max	Min	Med	Max	Min
10	32,25	32,35	32,15	32,16	32,33	31,40	32,26	32,34	32,11
15	30,37	30,58	29,60	30,47	30,59	30,32	30,39	30,62	29,35
20	29,27	30,04	28,98	29,24	30,03	28,78	29,43	30,05	28,56
25	28,51	29,78	28,01	29,16	29,84	27,86	28,50	29,84	27,20
30	27,65	28,65	27,09	27,76	28,82	26,49	27,86	28,84	26,42
35	26,64	27,45	26,37	26,35	26,60	26,05	26,40	26,67	26,04
40	25,82	26,17	25,35	25,68	25,91	25,27	25,78	26,14	25,49
45	25,41	25,78	25,20	25,05	25,76	24,26	24,97	25,64	24,36
50	24,75	24,99	24,06	24,65	25,06	23,98	24,62	25,30	23,28
55	24,26	24,73	23,69	24,25	24,74	23,53	23,91	24,37	23,13
60	23,84	24,08	23,55	23,78	24,04	23,25	23,52	24,36	22,89
Média	27,16	27,69	26,73	27,14	27,61	26,47	27,06	27,65	26,26

Fonte: Dados da pesquisa.

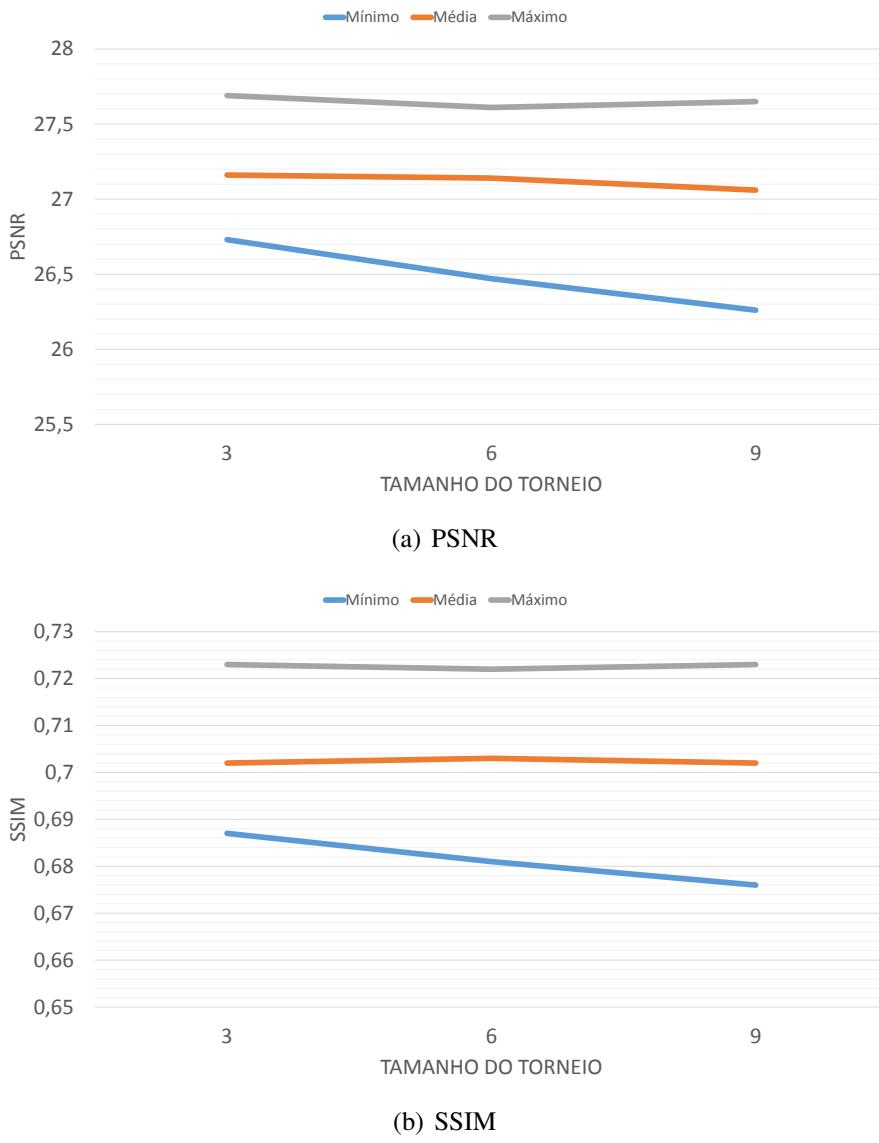
Tabela 2 – SSIM para diferentes tamanhos de torneio.

Ruído	Torneio: 3			Torneio: 6			Torneio: 9		
	Avg	Max	Min	Avg	Max	Min	Avg	Max	Min
10	0,839	0,844	0,836	0,838	0,842	0,834	0,840	0,842	0,835
15	0,800	0,804	0,791	0,801	0,806	0,796	0,801	0,806	0,784
20	0,772	0,802	0,761	0,773	0,799	0,760	0,779	0,801	0,761
25	0,754	0,798	0,733	0,777	0,799	0,735	0,755	0,799	0,697
30	0,728	0,773	0,701	0,735	0,773	0,674	0,742	0,773	0,697
35	0,690	0,712	0,678	0,679	0,697	0,661	0,680	0,692	0,661
40	0,664	0,681	0,652	0,657	0,667	0,645	0,663	0,685	0,651
45	0,646	0,664	0,634	0,640	0,660	0,608	0,640	0,662	0,618
50	0,627	0,639	0,604	0,625	0,649	0,608	0,628	0,657	0,582
55	0,610	0,630	0,588	0,614	0,638	0,591	0,602	0,616	0,578
60	0,597	0,607	0,579	0,597	0,613	0,580	0,592	0,621	0,570
Média	0,702	0,723	0,687	0,703	0,722	0,681	0,702	0,723	0,676

Fonte: Dados da pesquisa.

A figura 14 apresenta um gráfico ilustrando como o tamanho de torneio afeta a qualidade do imagens resultante do AGH. No gráfico estão as médias dos valores mínimo, médio e máximo para os três tamanhos de torneio (valores retirados da última linha das tabelas 1 e 2). Por esta análise, podemos ver que, apesar do resultado médio para todos os tamanhos de torneio serem muito semelhantes, o pior caso do torneio de tamanho 3 tende a ser melhor do que o pior caso dos outros torneios. Uma possível explicação se dá no fato de que um torneio menor diminui a

Figura 14 – Comparação entre as médias dos resultados mínimo, médio e máximo dos diferentes tamanhos de torneio.



Fonte: Elaborada pelo autor.

pressão seletiva, tornando a população mais diversa e aumentando a possibilidade do surgimento de diferentes soluções.

O segundo parâmetro a ser testado foi a taxa de busca local com os valores 0,2, 0,4 e 0,6. Os resultados obtidos com as diferentes taxas são apresentados nas tabelas 3 e 4.

Para o teste das diferentes taxas de busca local, os resultados foram muito próximos, mostrando pouca diferença entre os valores testados. Entretanto, a taxa de busca local 0,6 foi capaz de atingir melhores resultados do que as demais. Este comportamento fica mais perceptível no gráfico ilustrado pela figura 15. Esta tendência se seguiu por todas as diferentes taxas de ruído, inviabilizando a identificação de um padrão onde uma taxa de busca local específica possa funcionar melhor do que as outras taxas em ruídos mais baixos ou mais altos.

Tabela 3 – PSNR para diferentes taxas de busca local.

Ruído	Taxa: 0,2			Taxa: 0,4			Taxa: 0,6		
	Med	Max	Min	Med	Max	Min	Med	Max	Min
10	32,20	32,29	32,11	32,25	32,35	32,15	32,30	32,38	32,08
15	30,46	30,63	30,19	30,37	30,58	29,60	30,48	30,60	30,10
20	29,34	29,80	29,00	29,27	30,04	28,98	29,22	30,05	28,71
25	28,85	29,84	27,95	28,51	29,78	28,01	28,28	29,06	27,78
30	27,44	27,99	26,99	27,65	28,65	27,09	27,59	28,68	27,21
35	26,58	27,64	25,41	26,64	27,45	26,37	26,39	27,39	25,95
40	25,78	26,06	24,73	25,82	26,17	25,35	25,86	26,61	25,53
45	25,37	25,70	24,85	25,41	25,78	25,20	25,39	25,85	24,85
50	24,69	25,13	24,12	24,75	24,99	24,06	24,75	25,43	24,42
55	24,08	24,66	23,01	24,26	24,73	23,69	24,39	25,00	23,87
60	23,99	24,37	23,45	23,84	24,08	23,55	23,91	24,58	23,14
Média	27,16	27,65	26,53	27,16	27,69	26,73	27,14	27,78	26,69

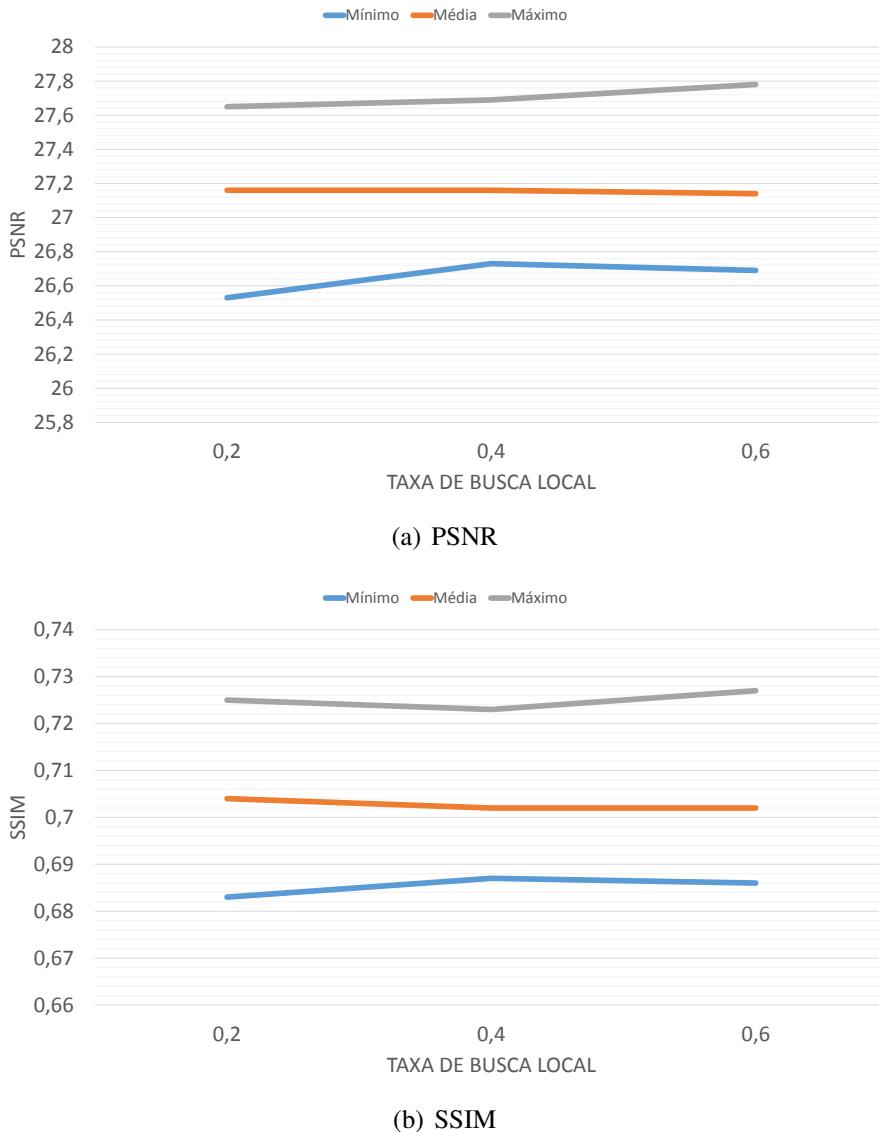
Fonte: Dados da pesquisa.

Tabela 4 – SSIM para diferentes taxas de busca local.

Ruído	Taxa: 0,2			Taxa: 0,4			Taxa: 0,6		
	Med	Max	Min	Med	Max	Min	Med	Max	Min
10	0,838	0,843	0,834	0,839	0,844	0,836	0,841	0,847	0,835
15	0,800	0,811	0,792	0,800	0,804	0,791	0,803	0,810	0,795
20	0,773	0,787	0,760	0,772	0,801	0,761	0,773	0,800	0,762
25	0,766	0,799	0,735	0,754	0,798	0,733	0,745	0,773	0,720
30	0,722	0,763	0,707	0,728	0,773	0,701	0,731	0,772	0,710
35	0,691	0,731	0,646	0,690	0,712	0,678	0,684	0,723	0,664
40	0,662	0,681	0,639	0,664	0,681	0,652	0,660	0,691	0,644
45	0,648	0,668	0,629	0,646	0,664	0,634	0,649	0,669	0,627
50	0,630	0,643	0,614	0,627	0,639	0,604	0,627	0,652	0,614
55	0,611	0,623	0,571	0,610	0,630	0,588	0,615	0,639	0,596
60	0,602	0,621	0,590	0,597	0,607	0,579	0,599	0,628	0,576
Média	0,704	0,725	0,683	0,702	0,723	0,687	0,702	0,727	0,686

Fonte: Dados da pesquisa.

Figura 15 – Comparação entre as médias dos resultados mínimo, médio e máximo das diferentes taxas de busca local.



Fonte: Elaborada pelo autor.

O terceiro teste envolveu a avaliação de diferentes tamanhos de população. Para este teste, foram escolhidos três valores na vizinhança do utilizado inicialmente, por este motivo, foram selecionados os valores: 10, 15 e 20 indivíduos. Os resultados para os diferentes tamanhos estão exibidos nas tabelas 5 e 6.

A diferenciação entre os resultados dos diferentes tamanhos de população é mais clara do que a obtida para a taxa de busca local. Mais uma vez, os médias dos resultados mínimo e médio foram parecidas entre os variados tamanhos de população, entretanto há uma superioridade da população de tamanho 15 para o melhor caso, onde ela consegue o melhor resultado em mais de 70% dos casos tanto para o PSNR quanto para o SSIM. Esta análise pode ser verificada pela figura 16, onde os gráficos atestam a acurácia desta análise.

Tabela 5 – PSNR para diferentes tamanhos de população.

Ruído	Tamanho população: 10			Tamanho população: 15			Tamanho população: 20		
	Med	Max	Min	Med	Max	Min	Med	Max	Min
10	32,20	32,31	32,09	32,30	32,38	32,08	32,11	32,32	31,69
15	30,42	30,59	30,30	30,48	30,60	30,10	30,44	30,59	30,18
20	29,01	29,39	28,44	29,22	30,05	28,71	29,14	29,28	29,00
25	28,66	29,84	27,76	28,28	29,06	27,78	28,21	29,08	27,86
30	27,50	28,30	26,94	27,59	28,68	27,21	27,31	28,27	26,62
35	26,62	26,92	26,36	26,39	27,39	25,95	26,60	27,51	26,36
40	25,75	26,26	25,29	25,86	26,61	25,53	25,71	26,24	25,14
45	25,16	25,86	24,47	25,39	25,85	24,85	25,43	26,08	25,09
50	24,79	25,22	24,57	24,75	25,43	24,42	24,72	25,12	24,39
55	24,32	25,00	23,59	24,39	25,00	23,87	24,32	24,61	23,68
60	23,88	24,31	23,38	23,91	24,58	23,14	23,69	24,23	22,87
Média	27,12	27,64	26,65	27,14	27,78	26,69	27,06	27,58	26,62

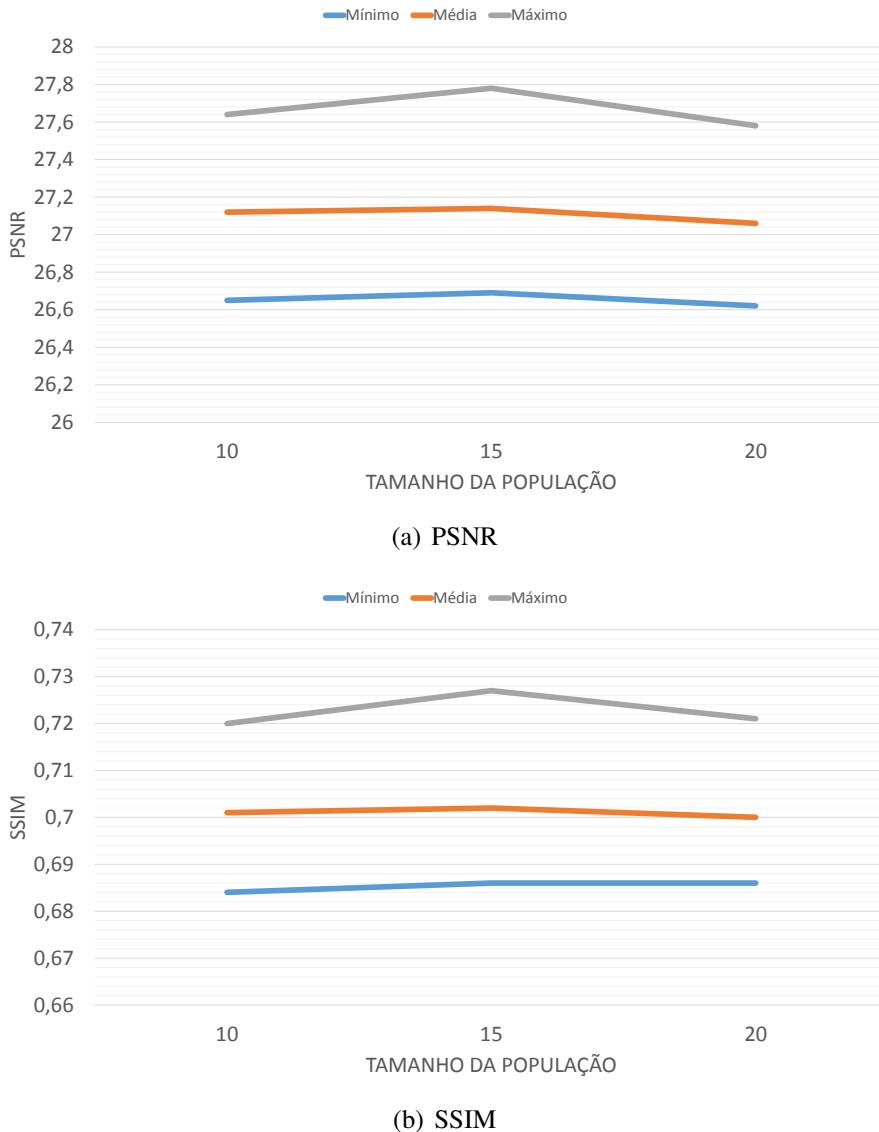
Fonte: Dados da pesquisa.

Tabela 6 – SSIM para diferentes tamanhos de população.

Ruído	Tamanho população: 10			Tamanho população: 15			Tamanho população: 20		
	Med	Max	Min	Med	Max	Min	Med	Max	Min
10	0,839	0,842	0,834	0,841	0,847	0,835	0,839	0,842	0,834
15	0,799	0,806	0,794	0,803	0,810	0,795	0,801	0,805	0,794
20	0,764	0,776	0,745	0,773	0,800	0,762	0,768	0,771	0,763
25	0,759	0,799	0,727	0,745	0,773	0,720	0,746	0,785	0,729
30	0,724	0,754	0,702	0,731	0,772	0,710	0,716	0,768	0,695
35	0,689	0,701	0,678	0,684	0,723	0,664	0,688	0,726	0,676
40	0,656	0,676	0,637	0,660	0,691	0,644	0,660	0,678	0,637
45	0,641	0,664	0,615	0,649	0,669	0,627	0,651	0,675	0,638
50	0,628	0,650	0,615	0,627	0,652	0,614	0,627	0,641	0,613
55	0,613	0,638	0,595	0,615	0,639	0,596	0,610	0,624	0,598
60	0,598	0,616	0,585	0,599	0,628	0,576	0,591	0,613	0,569
Média	0,701	0,720	0,684	0,702	0,727	0,686	0,700	0,721	0,686

Fonte: Dados da pesquisa.

Figura 16 – Comparação entre as médias dos resultados mínimo, médio e máximo dos diferentes tamanhos de população.



Fonte: Elaborada pelo autor.

Conforme descrito em (ZOSSO; BUSTIN, 2014), os melhores valores para parâmetro β da função objetivo se situam dentro do intervalo [1, 3], por este motivo o teste deste fator foi realizado com os valores 1, 1,5 e 2. Os resultados obtidos estão apresentados nas tabelas 7 e 8.

Fazendo uma análise entre os diferentes valores possíveis para o parâmetro β , fica bem claro que os resultados obtidos para $\beta = 2$ são muito inferiores em relação aos outros dois testados. Desta maneira, a comparação passa a ser apenas entre $\beta = 1$ e $\beta = 1,5$. Os resultados de ambos são muito parecidos para o caso médio do PSNR e, no pior caso, $\beta = 1$ é a melhor opção. Entretanto, enquanto o PSNR apresenta uma leve diferença no pior caso, no valor máximo desses fatores o resultado obtido pelo $\beta = 1,5$ é muito superior aos outros. Além disso, os valores obtidos para o SSIM mostram um $\beta = 1,5$ numa vantagem clara em relação aos demais

Tabela 7 – PSNR para diferentes β .

Ruído	$\beta: 1$			$\beta: 1,5$			$\beta: 2$		
	Med	Max	Min	Med	Max	Min	Med	Max	Min
10	32,34	32,34	32,34	32,30	32,38	32,08	31,85	32,30	30,93
15	30,39	30,39	30,39	30,48	30,60	30,10	28,85	29,81	28,31
20	28,99	29,02	28,98	29,22	30,05	28,71	27,97	28,28	27,44
25	27,89	27,90	27,86	28,28	29,06	27,78	27,21	27,57	26,76
30	28,62	28,72	28,60	27,59	28,68	27,21	26,52	27,07	25,78
35	27,00	27,14	26,69	26,39	27,39	25,95	25,74	26,21	25,10
40	25,59	25,91	24,93	25,86	26,61	25,53	24,66	25,26	23,84
45	25,10	25,24	24,72	25,39	25,85	24,85	24,63	25,34	23,84
50	24,59	24,76	23,59	24,75	25,43	24,42	24,06	24,35	23,64
55	24,26	24,29	24,24	24,39	25,00	23,87	23,96	24,36	23,63
60	23,83	24,02	23,40	23,91	24,58	23,14	23,54	23,84	22,56
Média	27,15	27,25	26,89	27,14	27,78	26,69	26,27	26,76	25,62

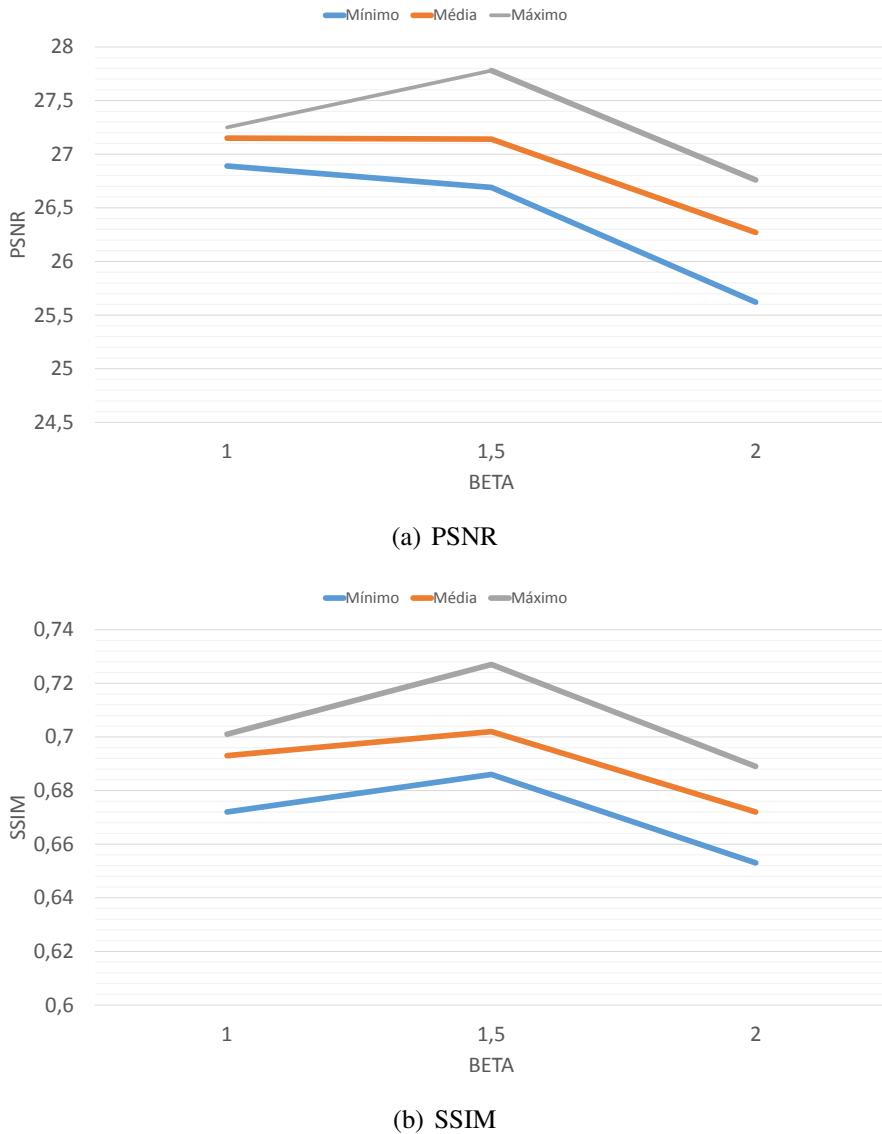
Fonte: Dados da pesquisa.

Tabela 8 – SSIM results para diferentes β .

Ruído	$\beta: 1$			$\beta: 1,5$			$\beta: 2$		
	Med	Max	Min	Med	Max	Min	Med	Max	Min
10	0,852	0,852	0,852	0,841	0,847	0,835	0,833	0,841	0,819
15	0,805	0,805	0,805	0,803	0,810	0,795	0,757	0,784	0,741
20	0,764	0,768	0,763	0,773	0,800	0,762	0,724	0,736	0,714
25	0,725	0,728	0,723	0,745	0,773	0,720	0,715	0,729	0,701
30	0,760	0,765	0,759	0,731	0,772	0,710	0,680	0,700	0,656
35	0,703	0,711	0,682	0,684	0,723	0,664	0,663	0,684	0,642
40	0,643	0,665	0,614	0,660	0,691	0,644	0,625	0,646	0,594
45	0,618	0,631	0,589	0,649	0,669	0,627	0,622	0,644	0,598
50	0,597	0,614	0,516	0,627	0,652	0,614	0,600	0,608	0,593
55	0,589	0,594	0,581	0,615	0,639	0,596	0,596	0,608	0,585
60	0,567	0,582	0,512	0,599	0,628	0,576	0,581	0,595	0,543
Média	0,693	0,701	0,672	0,702	0,727	0,686	0,672	0,689	0,653

Fonte: Dados da pesquisa.

Figura 17 – Comparação entre as médias dos resultados mínimo, médio e máximo dos diferentes valores para o parâmetro β .



Fonte: Elaborada pelo autor.

valores. Estes comportamentos podem ser verificados na figura 17.

Por fim, o último parâmetro testado foi o tempo de execução do algoritmo, com os valores de 10, 20 e 30 minutos. Os resultados obtidos são exibidos nas tabelas 9 (PSNR) e 10 (SSIM).

A escolha do melhor tempo de execução foi feita de maneira diferente das outras análises realizadas. Enquanto nos outros casos a qualidade era o principal fator, para o tempo do algoritmo uma relação custo-benefício foi levada em conta. Colocando de maneira grosseira, não vale a pena uma imagem um pouco melhor se o tempo gasto for muito maior. Obviamente que este tipo de análise é, por vezes, subjetiva, uma vez que determinar quanto tempo deve ser gasto pode variar para cada tipo de aplicação.

Tabela 9 – PSNR para diferentes tempos de execução.

Ruído	Tempo de execução: 10			Tempo de execução: 20			Tempo de execução: 30		
	Med	Max	Min	Med	Max	Min	Med	Max	Min
10	32,03	32,34	31,27	32,30	32,38	32,08	32,25	32,34	32,16
15	30,34	30,58	29,90	30,48	30,60	30,10	30,45	30,58	30,29
20	29,11	29,81	28,40	29,22	30,05	28,71	29,10	29,56	28,63
25	28,14	28,77	27,64	28,28	29,06	27,78	28,45	29,84	27,40
30	27,46	28,22	27,00	27,59	28,68	27,21	27,47	27,98	26,88
35	26,55	27,31	25,95	26,39	27,39	25,95	26,36	26,83	25,95
40	25,96	26,77	25,57	25,86	26,61	25,53	25,90	26,13	25,66
45	25,44	25,86	25,01	25,39	25,85	24,85	25,21	25,55	24,85
50	24,76	25,32	24,18	24,75	25,43	24,42	24,80	24,97	24,68
55	24,24	24,72	23,97	24,39	25,00	23,87	24,17	25,13	23,27
60	23,93	24,34	23,64	23,91	24,58	23,14	23,83	24,09	23,46
Média	27,09	27,64	26,59	27,14	27,78	26,69	27,09	27,55	26,66

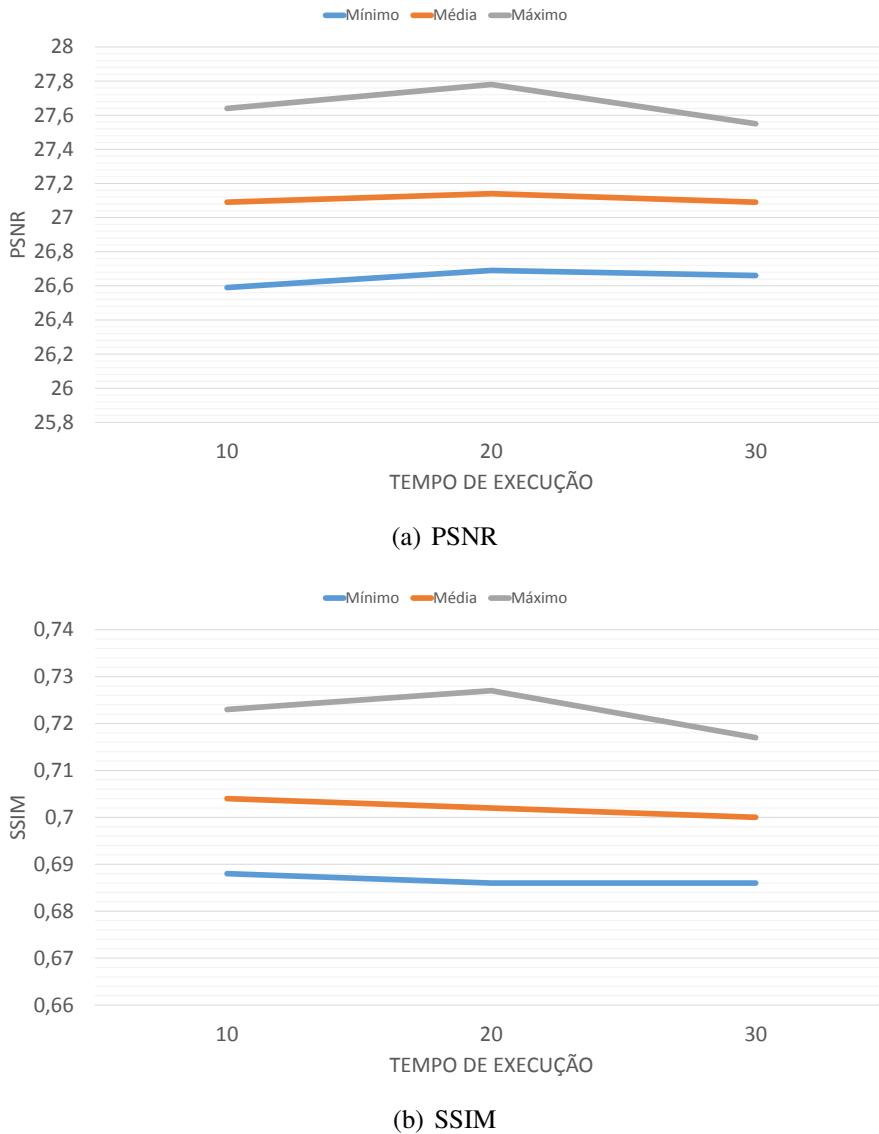
Fonte: Dados da pesquisa.

Tabela 10 – SSIM para diferentes tempos de execução.

Ruído	Tempo de execução: 10			Tempo de execução: 20			Tempo de execução: 30		
	Med	Max	Min	Med	Max	Min	Med	Max	Min
10	0,840	0,845	0,836	0,841	0,847	0,835	0,839	0,843	0,837
15	0,802	0,807	0,799	0,803	0,810	0,795	0,800	0,804	0,793
20	0,771	0,788	0,761	0,773	0,800	0,762	0,768	0,781	0,761
25	0,741	0,760	0,729	0,745	0,773	0,720	0,753	0,799	0,723
30	0,720	0,757	0,698	0,731	0,772	0,710	0,722	0,749	0,702
35	0,693	0,728	0,663	0,684	0,723	0,664	0,681	0,694	0,665
40	0,670	0,707	0,650	0,660	0,691	0,644	0,664	0,674	0,655
45	0,657	0,664	0,644	0,649	0,669	0,627	0,639	0,658	0,628
50	0,627	0,648	0,599	0,627	0,652	0,614	0,625	0,629	0,615
55	0,615	0,628	0,604	0,615	0,639	0,596	0,609	0,648	0,584
60	0,604	0,617	0,591	0,599	0,628	0,576	0,596	0,603	0,585
Média	0,704	0,723	0,688	0,702	0,727	0,686	0,700	0,717	0,686

Fonte: Dados da pesquisa.

Figura 18 – Comparação entre as médias dos resultados mínimo, médio e máximo dos diferentes tempos de execução.



Fonte: Elaborada pelo autor.

Uma vez decididos os tempos que seriam testados, a comparação nos levou a conclusão de que, em geral, o tempo de 20 minutos conseguiu melhores resultados. Como ilustrado nos gráficos da figura 18, este comportamento não é uniforme, mas a vantagem do parâmetro *tempo de execução* = 20 minutos é palpável, uma vez que os valores de PSNR e SSIM em 30 minutos retornam ao mesmo patamar daqueles alcançados em 10 minutos. Testes com maiores intervalos de tempo podem vir a mostrar que não houve melhoria após os vinte minutos por uma eventual estabilização do método. Desta maneira, a escolha do *tempo de execução* = 20 minutos é apropriada.

Após todos estes testes, a configuração básica do AGH ficou a seguinte tamanho do torneio = 3, taxa de busca local = 0,6, tamanho da população = 15, β = 1,5 e tempo de execução

= 20 minutos. Os outros parâmetros do algoritmo foram escolhidos empiricamente: número máximo de iterações antes de reinicializar a população foi definido como 5 e o parâmetro λ da função objetivo foi definido como $1/\sqrt{v}$, onde v é a variância estimada do ruído da imagem (ROUSSEEUW; LEROY, 2005).

4.2 Avaliando diferentes abordagens a partir do AGH

Esta seção avalia o AGH em relação a outras possíveis estratégias baseadas na proposta evolucionária híbrida. Para estes testes, a mesma imagem *boat* [13] foi utilizada, tendo sido corrompida da mesma maneira como descrito na seção 4.1. Testes preliminares indicaram que os resultados não seguiam uma distribuição normal e não apresentavam homogeneidade de variância, por este motivo foram feitas análises estatísticas dos dados através de testes não-paramétricos. Para cada avaliação, foram feitos *Testes de Kruskal-Wallis* nos resultados e, caso uma diferença significativa tenha sido encontrada, o *Teste de Dunn* foi aplicado para as comparações entre as diferentes abordagens.

O teste de Kruskal-Wallis é um teste não-paramétrico que pode ser utilizado para comparar diversas amostras independentes e indicar se há diferença entre elas. O teste, baseado em ranqueamento, indica um resultado significante quando existe diferença entre duas ou mais amostras, entretanto, ele não indica onde a diferença ocorreu (CORDER; FOREMAN, 2014). Para isto, um teste *post hoc* deve ser realizado.

Neste trabalho, o teste de Dunn foi utilizado como método de análise de contraste entre os resultados dos diferentes algoritmos testados, uma vez que ele permite a comparação de múltiplas amostras através da soma de seus postos. O método de Dunn combina os grupos participantes dos testes, ranqueia os resultados do menor para o maior e, finalmente, compara o ranque médio entre os grupos, dois a dois (DUNN, 1964).

4.2.1 Primeiro Teste - Mudanças nos operadores de mutação e busca local

O primeiro teste comparou o AGH proposto contra uma variação de si com duas mudanças importantes. Primeiro, os operadores de mutação, que atualmente são aplicados apenas durante a inicialização e reinicialização do algoritmo [2], substituem os operadores de busca local durante o processo evolucionário. Segundo, os operadores de busca local serão aplicados apenas sobre o melhor indivíduo ao final de cada passo da evolução. Estas mudanças definem versões do AGH onde os filtros são utilizados como operadores de mutação durante a evolução do método e a busca local passa a ocorrer apenas no melhor indivíduo encontrado.

Um total de quatro variantes do AGH foi avaliada, diferindo apenas pelo tipo de busca local aplicada na segunda modificação proposta. Estas variantes são chamadas: AGH-W, para a

versão que utiliza o método Wiener-chop como busca local; AGH-AD, para a que usa o método AD; AGH-B, para a que usa BM3D; AGH-T, para uma versão que aplica os três métodos ao melhor indivíduo e escolhe aquele com melhor *fitness*. Nos três casos, a imagem retornada pelo método de supressão de ruídos substitui o melhor indivíduo da população apenas se ela for considerada mais apta que ele. A tabela 11 mostra os testes de Kruskal-Wallis com valores de PSNR para cada nível de ruído. A coluna σ indica o desvio padrão do ruído do teste específico, a coluna K (*observado*) dá o valor da estatística K do próprio teste, a coluna K (*crítico*) mostra o valor crítico para a estatística K (valor tabelado), GL mostra o número de graus de liberdade. O intervalo de confiança foi selecionado como 95% para todos os testes realizados neste trabalho, implicando que a hipótese nula de que as médias dos resultados obtidos por todos os algoritmos são iguais pode ser rejeitada caso o valor *p-valor* seja menor que 0,05 (α).

Tabela 11 – Teste de Kruskal-Wallis para os valores de PSNR do Teste 1.

σ	K (observado)	K (crítico)	GL	p-valor	α
10	16,514	9,488	4	0,002	0,05
15	12,618	9,488	4	0,013	0,05
20	6,834	9,488	4	0,145	0,05
25	1,329	9,488	4	0,856	0,05
30	1,946	9,488	4	0,746	0,05
35	5,541	9,488	4	0,236	0,05
40	10,440	9,488	4	0,034	0,05
45	14,193	9,488	4	0,007	0,05
50	15,042	9,488	4	0,005	0,05
55	1,210	9,488	4	0,877	0,05
60	10,518	9,488	4	0,033	0,05

Fonte: Dados da pesquisa.

Existe diferença significante entre o AGH proposto e suas variantes para $\sigma = 10, 15, 40, 45, 50$ e 60 . Para cada um destes níveis de ruído o teste de Dunn foi realizado e os resultados estão expostos na tabela 12.

Os resultados da tabela 12 estão ordenados de maneira que os métodos com as melhores médias apareçam primeiro. Assim, os algoritmos no Grupo A possuem um PSNR médio melhor que os dos grupos B e C. Mesmo não existindo diferença significante entre os métodos dentro de um grupo, os resultados também estão ordenados da mesma maneira dentro deles. Nesta análise, nós podemos ver que o AGH está sempre no primeiro grupo e, na vezes em que ele não é o único elemento do grupo, ele possui a melhor média dentre os elementos do grupo.

A mesma análise foi feita para a métrica SSIM (tabela 13). Neste caso, o teste de Kruskal-Wallis mostrou diferença significativa para os níveis de ruído $\sigma = 10$ e 50 . O teste de Dunn para estes dois casos, exibido na tabela 14, também mostra o AGH sempre no primeiro grupo, ou seja, o AGH é ou melhor ou, no mínimo, tão bom quanto as variantes propostas neste teste.

Com base nos resultados obtidos, a estratégia de melhorar os novos indivíduos gerados

Tabela 12 – Teste de Dunn para os valores de PSNR encontrados para o teste 1.

σ	Grupo A	Grupo B	Grupo C
10	AGH, AGH-W	AGH-W, AGH-T, AGH-A, AGH-B	
15	AGH, AGH-T	AGH-T, AGH-W, AGH-A	AGH-W, AGH-A, AGH-B
40	AGH	AGH-A, AGH-B, AGH-W, AGH-T	
45	AGH, AGH-T	AGH-T, AGH-B, AGH-A	AGH-B, AGH-A, AGH-W
50	AGH, AGH-B	AGH-B, AGH-A, AGH-W	AGH-A, AGH-W, AGH-T
60	AGH, AGH-T, AGH-A	AGH-T, AGH-A, AGH-W	AGH-A, AGH-W, AGH-B

Fonte: Dados da pesquisa.

Tabela 13 – Teste de Kruskal-Wallis para os valores de SSIM do Teste 1.

σ	K (observado)	K (crítico)	GL	p-valor	α
10	17,832	9,488	4	0,001	0,05
15	2,059	9,488	4	0,725	0,05
20	5,750	9,488	4	0,219	0,05
25	0,854	9,488	4	0,931	0,05
30	2,474	9,488	4	0,649	0,05
35	1,153	9,488	4	0,886	0,05
40	4,098	9,488	4	0,393	0,05
45	5,781	9,488	4	0,216	0,05
50	10,367	9,488	4	0,035	0,05
55	0,922	9,488	4	0,921	0,05
60	7,829	9,488	4	0,098	0,05

Fonte: Dados da pesquisa.

Tabela 14 – Teste de Dunn para os valores de SSIM encontrados para o teste 1.

σ	Grupo A	Grupo B	Grupo C
10	AGH, AGH-W, AGH-T	AGH-W, AGH-T, AGH-B	AGH-B, AGH-A
50	AGH, AGH-B, AGH-A, AGH-W	AGH-B, AGH-A, AGH-W, AGH-T	

Fonte: Dados da pesquisa.

através de recombinação (processo evolutivo) utilizando técnicas de supressão de ruído como busca local aplicada já aos novos indivíduos, mostra-se mais efetiva do que aplicando-as apenas ao melhor indivíduo. Esta busca local também se mostra mais apropriada do que aplicar os simples filtros como operadores de mutação.

4.2.2 Segundo Teste - Avaliando os operadores de busca local

Neste teste, o AGH é comparado com outras três variações de si mesmo, onde apenas um tipo de busca local é aplicado durante o processo evolucionário do método (linha 11 do algoritmo 2): AGH-W aplica apenas Wiener-chop, AGH-A aplica apenas AD e AGH-B aplica apenas o método BM3D. A tabela 15 apresenta os resultados do teste de Kruskal-Wallis para o PSNR e mostra que há significância para $\sigma = 10, 15, 20, 40, 55$ e 60 .

Tabela 15 – Teste de Kruskal-Wallis para os valores de PSNR do Teste 2.

σ	K (observado)	K (crítico)	GL	p-valor	α
10	24,253	7,815	3	< 0,0001	0,05
15	17,046	7,815	3	0,001	0,05
20	14,249	7,815	3	0,003	0,05
25	4,573	7,815	3	0,206	0,05
30	7,180	7,815	3	0,066	0,05
35	4,418	7,815	3	0,220	0,05
40	10,304	7,815	3	0,016	0,05
45	3,105	7,815	3	0,376	0,05
50	1,942	7,815	3	0,585	0,05
55	8,141	7,815	3	0,043	0,05
60	17,274	7,815	3	0,001	0,05

Fonte: Dados da pesquisa.

Tabela 16 – Teste de Dunn para os valores de PSNR encontrados para o teste 2.

σ	Grupo A	Grupo B	Grupo C
10	AGH-W, AGH	AGH-A, AGH-B	
15	AGH-W, AGH	AGH , AGH-A, AGH-B	
20	AGH-W, AGH	AGH , AGH-A	AGH-A, AGH-B
40	AGH-W, AGH-B, AGH	AGH-B, AGH , AGH-A	
55	AGH-B, AGH-W	AGH-W, AGH-A, AGH	
60	AGH-B	AGH , AGH-W, AGH-A	

Fonte: Dados da pesquisa.

O AGH-W e AGH estão nos grupos A e/ou B para todos os ruídos na tabela 16. Mesmo o AGH não apresentando o melhor PSNR médio no grupo A, ele é estável quando comparado

com os outros algoritmos. Por exemplo, o AGH-B é o melhor método para $\sigma = 60$, mas está no grupo C para $\sigma = 20$. As tabelas 17 e 18 mostram, respectivamente, os testes de Kruskal-Wallis e de Dunn para a métrica SSIM.

Tabela 17 – Teste de Kruskal-Wallis para os valores de SSIM do Teste 2.

σ	K (observado)	K (crítico)	GL	p-valor	α
10	10,739	7,815	3	0,013	0,05
15	16,575	7,815	3	0,001	0,05
20	16,740	7,815	3	0,001	0,05
25	4,434	7,815	3	0,218	0,05
30	12,786	7,815	3	0,005	0,05
35	6,888	7,815	3	0,076	0,05
40	8,903	7,815	3	0,031	0,05
45	6,186	7,815	3	0,103	0,05
50	10,550	7,815	3	0,014	0,05
55	9,481	7,815	3	0,024	0,05
60	9,455	7,815	3	0,024	0,05

Fonte: Dados da pesquisa.

Tabela 18 – Teste de Dunn para os valores de SSIM encontrados para o teste 2.

σ	Grupo A	Grupo B	Grupo C
10	AGH-W	AGH , AGH-A, AGH-B	
15	AGH-W	AGH , AGH-B, AGH-A	
20	AGH-W, AGH	AGH , AGH-A	AGH-A, AGH-B
30	AGH , AGH-W, AGH-A	AGH-A, AGH-B	
40	AGH-W, AGH	AGH, AGH-B, AGH-A	
50	AGH-W, AGH , AGH-B	AGH-B, AGH-A	
55	AGH-B	AGH , AGH-W, AGH-A	
60	AGH-B, AGH	AGH , AGH-W, AGH-A	

Fonte: Dados da pesquisa.

Os resultados obtidos para SSIM são similares aos obtidos para PSNR. O AGH não se mostrou como a melhor média no grupo A, mas ele sempre pertence aos grupos A ou B. Apenas o método AGH-W também apresentou tal comportamento, enquanto as outras variantes se mostraram inferiores. Para estes testes, a estratégia de escolher aleatoriamente e aplicar um método de supressão de ruídos como busca local, durante o processo evolutivo, apresentou resultados mais consistentes do que utilizando apenas um método com exceção do Wiener-chop.

4.2.3 Terceiro Teste - Avaliando uma função objetivo diferente

Este teste compara o AGH com uma variação de si próprio que utiliza a mesma função objetivo usada por Toledo *et al.* em (TOLEDO *et al.*, 2013). A função foi proposta por Ishikawa (ISHIKAWA, 2000) e transforma o problema de supressão de ruídos em imagens em um problema de otimização através de Campos Aleatórios de Markov (ver seção 2.2.2.1). Neste caso, a função de energia da equação 4.4 deve ser minimizada, onde X é a imagem sendo avaliada, I a imagem ruidosa, X_v e X_u são, respectivamente, os v-ésimo e u-ésimo pixels de X com $(u, v) \in N$ se, e somente se, u pertence à vizinhança-4 de v . Além disso, μ é uma constante que balanceia a suavização de X .

$$\text{fitness}(X) = \mu \sum_{(u,v) \in N} |X_u - X_v| + \sum_{v \in V} (I_v - X_v)^2 \quad (4.4)$$

O AGH executado com a função objetivo descrita pela equação 4.4 aqui será tratado por AGH-I, onde a constante μ foi definida como descrito em (TOLEDO *et al.*, 2013). As tabelas 19 e 20 mostram, respectivamente, os resultados dos testes de Kruskal-Wallis e de Dunn para o PSNR.

Tabela 19 – Teste de Kruskal-Wallis para os valores de PSNR do Teste 3.

σ	K (observado)	K (crítico)	GL	p-valor	α
10	4,480	3,841	1	0,034	0,05
15	1,653	3,841	1	0,199	0,05
20	2,286	3,841	1	0,131	0,05
25	1,287	3,841	1	0,257	0,05
30	0,051	3,841	1	0,821	0,05
35	3,025	3,841	1	0,082	0,05
40	12,091	3,841	1	0,001	0,05
45	13,720	3,841	1	0,000	0,05
50	14,296	3,841	1	0,000	0,05
55	14,286	3,841	1	0,000	0,05
60	14,286	3,841	1	0,000	0,05

Fonte: Dados da pesquisa.

Tabela 20 – Teste de Dunn para os valores de PSNR encontrados para o teste 3.

Noise	Grupo A	Grupo B
10	AGH	AGH-I
40	AGH	AGH-I
45	AGH	AGH-I
50	AGH	AGH-I
55	AGH	AGH-I
60	AGH	AGH-I

Fonte: Dados da pesquisa.

Para o PSNR, existe diferença significativa em seis níveis de ruído e o AGH é sempre melhor do que o AGH-I nestes casos. As tabelas 21 e 22 mostram os mesmos testes para a métrica SSIM.

Tabela 21 – Teste de Kruskal-Wallis para os valores de SSIM do Teste 3.

σ	K (observado)	K (crítico)	GL	p-valor	α
10	0,571	3,841	1	0,450	0,05
15	13,730	3,841	1	0,000	0,05
20	0,206	3,841	1	0,650	0,05
25	0,966	3,841	1	0,326	0,05
30	0,006	3,841	1	0,940	0,05
35	7,005	3,841	1	0,008	0,05
40	14,286	3,841	1	0,000	0,05
45	14,286	3,841	1	0,000	0,05
50	14,296	3,841	1	0,000	0,05
55	14,286	3,841	1	0,000	0,05
60	14,286	3,841	1	0,000	0,05

Fonte: Dados da pesquisa.

Tabela 22 – Teste de Dunn para os valores de SSIM encontrados para o teste 3.

Noise	Grupo A	Grupo B
15	AGH-I	AGH
35	AGH	AGH-I
40	AGH	AGH-I
45	AGH	AGH-I
50	AGH	AGH-I
55	AGH	AGH-I
60	AGH	AGH-I

Fonte: Dados da pesquisa.

Os resultados para o SSIM nos levam as mesmas conclusões que as obtidas com o PSNR. O AGH apresentou melhores valores de SSIM para quase todos os níveis de ruído com diferença significativa, exceto $\sigma = 15$. Além disso, ainda se pode notar que o AGH se sobressai especialmente nos valores mais altos de σ .

4.3 Comparação do AGH com métodos da literatura

Nesta seção, o AGH foi comparado contra diferentes métodos de supressão de ruídos encontrados na literatura. Um conjunto de 11 imagens foi selecionado (figura 19) e todas elas foram corrompidas com um ruído aditivo branco Gaussiano $N(0, \sigma)$ com $\sigma = 10, 15, 20, 25, 30, 35, 40, 45, 50, 55$ e 60 .

Os métodos utilizados nas comparações e suas respectivas abreviaturas utilizadas neste trabalho estão descritos na tabela 23. O AGH foi executado dez vezes para cada imagem e para

Figura 19 – Imagens utilizadas nos testes do AGH em comparação com outros métodos de supressão de ruídos.



(a) Barbara



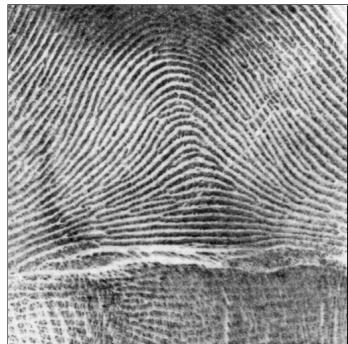
(b) Boat



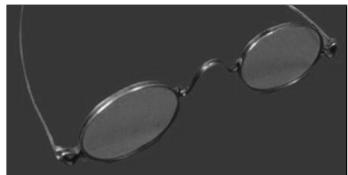
(c) Cameraman



(d) Couple



(e) Fingerprint



(f) Glasses



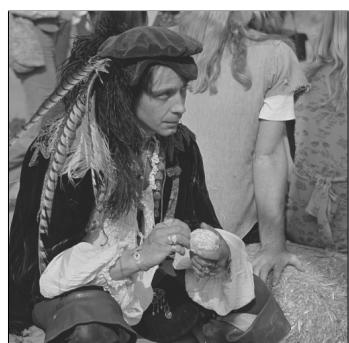
(g) Hill



(h) Lenna



(i) Lightning



(j) Man



(k) Peppers

Fonte: [Gonzalez, Woods e Eddins \(2005\)](#).

cada nível de ruído. O melhor (AGH Max) e o pior (AGH Min) resultados do AGH, após as dez execuções foram comparados contra as abordagens da literatura.

Tabela 23 – Métodos e suas respectivas abreviaturas.

Método	Abreviatura
Silva <i>et al.</i> (SILVA <i>et al.</i> , 2013)	Wav
Bivariate (SENDUR; SELESNICK, 2002)	Biv
Median (GONZALEZ; WOODS, 2006)	Med
AD (KATKOVNIK; EGIAZARIAN; ASTOLA, 2006)	AD
TV (RUDIN; OSHER; FATEMI, 1992)	TV
Bayes (CHANG; YU; VETTERLI, 2000a)	Bay
Wiener-chop (GHAEL <i>et al.</i> , 1997)	WiC
Wiener (GONZALEZ; WOODS, 2006)	Wie
BM3D (DABOV <i>et al.</i> , 2006)	BM

Fonte: Elaborada pelo autor.

Os testes de Kruskal-Wallis e de Dunn foram aplicados para avaliar a diferença significativa entre estes métodos para ambas as métricas PSNR e SSIM. Entretanto, para a realização destes testes, a diferença de escala entre os resultados é um aspecto que deve ser levado em conta. Por exemplo, o método BM3D retorna um PSNR de 32,262 para o ruído $\sigma = 10$ quando testado com a imagem *Barbara*, obtendo neste caso o melhor resultado entre os métodos. Entretanto, ele obteve o pior PSNR entre as abordagens para $\sigma = 45$ (PSNR= 19,768). Para evitar a influência dessas discrepâncias nas análises, os valores obtidos para PSNR e SSIM foram transformados em seus desvios relativos entre cada resultado e o valor ótimo, como definido pela equação 4.5.

$$d(i) = \frac{r(i) - r_{opt}}{r_{worst} - r_{opt}} \quad (4.5)$$

O parâmetro d é o desvio calculado e r é o resultado obtido pelo algoritmo i , onde r_{opt} e r_{worst} representam, respectivamente, o valor ótimo e o pior valor possível atingido por tal métrica. Uma vez que as soluções ótima e a pior possível nem sempre são conhecidas ou não podem ser calculadas, nós podemos considerar que o melhor e pior resultado de um grupo representam substitutos razoáveis para tais valores (CHIARANDINI; BASSO; STÜTZLE, 2005). Por este motivo, para cada σ , o melhor resultado dentro dos obtidos pelos algoritmos testados foi ajustado como r_{opt} e o pior resultado dentre os métodos foi utilizado como r_{worst} . Estes desvios foram calculados para cada imagem e para ambas as métricas. Tais resultados são exemplificados nas tabelas 24 e 25 para a imagem *Lightning*. Baseado nestes valores, os testes de Kruskal-Wallis e de Dunn foram realizados. Os resultados completos tanto para PSNR quanto para SSIM para todas os métodos e imagens estão disponíveis no apêndice B.

Na análise estatística feita aqui, o desvio $d(i)$ do algoritmo i associado com cada σ é uma amostra, dessa maneira, o tamanho da amostra de cada método é onze. Os resultados do teste de

Tabela 24 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Lightning*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Lightning	10	38,26	33,59	30,54	37,53	33,73	36,01	38,36	37,75	37,48	39,06	38,69
Lightning	15	36,32	31,62	29,93	35,20	31,15	33,85	36,11	37,27	35,99	37,27	36,59
Lightning	20	34,91	30,30	29,08	33,30	28,99	31,90	34,37	36,46	32,76	36,46	35,22
Lightning	25	34,17	29,44	28,25	32,13	27,30	30,45	33,06	35,54	29,81	35,54	34,93
Lightning	30	33,41	28,87	27,33	31,12	25,82	29,11	32,01	33,46	27,21	34,62	33,04
Lightning	35	32,69	28,52	26,40	30,15	24,58	27,96	31,06	28,60	25,14	32,55	31,61
Lightning	40	32,06	27,73	25,60	29,41	23,54	26,90	30,18	24,27	23,45	31,81	29,93
Lightning	45	31,43	27,10	24,85	28,69	22,59	26,10	29,48	20,84	22,01	31,21	29,40
Lightning	50	30,74	26,46	23,98	27,93	21,66	25,16	28,48	18,45	20,77	30,42	28,78
Lightning	55	30,19	25,91	23,45	27,46	20,99	24,65	28,08	17,03	19,79	30,08	28,43
Lightning	60	29,16	25,64	22,67	26,61	20,23	23,87	27,11	15,81	18,81	29,02	27,41

Fonte: Dados da pesquisa.

Tabela 25 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Lightning*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Lightning	10	0,953	0,945	0,893	0,947	0,824	0,930	0,948	0,959	0,956	0,962	0,959
Lightning	15	0,939	0,927	0,835	0,917	0,700	0,891	0,921	0,955	0,936	0,955	0,943
Lightning	20	0,927	0,915	0,759	0,881	0,583	0,835	0,890	0,950	0,836	0,950	0,932
Lightning	25	0,919	0,906	0,689	0,847	0,489	0,770	0,858	0,938	0,677	0,938	0,934
Lightning	30	0,911	0,899	0,615	0,809	0,408	0,700	0,825	0,854	0,515	0,930	0,901
Lightning	35	0,906	0,894	0,549	0,770	0,346	0,634	0,792	0,561	0,394	0,918	0,900
Lightning	40	0,902	0,886	0,504	0,748	0,298	0,578	0,766	0,322	0,307	0,915	0,880
Lightning	45	0,897	0,878	0,457	0,717	0,259	0,531	0,738	0,190	0,242	0,909	0,895
Lightning	50	0,890	0,871	0,411	0,684	0,226	0,484	0,697	0,127	0,198	0,904	0,898
Lightning	55	0,890	0,865	0,389	0,672	0,200	0,455	0,682	0,097	0,165	0,901	0,893
Lightning	60	0,884	0,866	0,342	0,638	0,177	0,416	0,648	0,074	0,138	0,895	0,877

Fonte: Dados da pesquisa.

Kruskal-Wallis para o PSNR encontram-se na tabela 26 que mostra uma diferença significativa entre os métodos em todos os casos, uma vez que o valor de *p-valor* foi sempre menor que 0,05.

Tabela 26 – Teste de Kruskal-Wallis para os desvios entre os PSNR de cada método e o melhor PSNR para cada σ .

Imagen	K (observado)	K (crítico)	GL	p-valor	α
Barbara	38,747	18,307	10	< 0,0001	0,05
Boat	71,702	18,307	10	< 0,0001	0,05
Cameraman	81,159	18,307	10	< 0,0001	0,05
Couple	61,487	18,307	10	< 0,0001	0,05
Fingerprint	70,149	18,307	10	< 0,0001	0,05
Glasses	85,359	18,307	10	< 0,0001	0,05
Hill	73,909	18,307	10	< 0,0001	0,05
Lenna	79,803	18,307	10	< 0,0001	0,05
Lightning	84,970	18,307	10	< 0,0001	0,05
Man	78,971	18,307	10	< 0,0001	0,05
Peppers	73,215	18,307	10	< 0,0001	0,05

Fonte: Dados da pesquisa.

Em seguida, as comparações foram conduzidas e os resultados exibidos na tabela 27. A média dos desvios dentro de um mesmo grupo estão ordenadas do melhor para o pior e, mesmo não havendo diferença significativa dentro do mesmo grupo, o AGH Max (melhor caso do AGH) apresentou o melhor resultado em 8 das 11 imagens. Ele também está no primeiro grupo para quase todas as imagens, o que significa que ele é significantemente diferente, em média, dos métodos nos outros grupos e, o único caso em que o AGH Max não se encontra no primeiro grupo, foi para a imagem *Fingerprint*. Além disso, o AGH Min não apresentou diferença significante em relação ao AGH Max em diversas imagens, indicando que tanto o melhor quanto o pior caso do AGH são competitivos.

Uma possível explicação para a perda de qualidade do AGH com a imagem *Fingerprint* é a função objetivo escolhida. Regiões com alta concentração de texturas possuem alta variação total, característica esta que é semelhante à regiões com alta presença de ruído. Por este motivo, métodos que se valem da minimização da variação total da imagem podem confundir textura com ruído em uma imagem. Em uma imagem como a *Fingerprint*, que é rica em texturas, tanto o AGH quanto o método TV, apresentaram resultados de pior qualidade em relação aos conquistados para as outras imagens.

A mesma análise foi feita para os valores obtidos para SSIM, onde a tabela 28 mostra que existe diferença significativa entre os métodos para todas as imagens. O teste de Dunn para o SSIM (tabela 29) evidencia que o AGH continua a atingir bons resultados. O AGH Max foi o melhor método em 7 dos 11 casos e, além disso, o segundo melhor resultado em quatro dessas ocasiões foi obtido pelo AGH Min, o que só reforça a noção da qualidade do AGH.

Além das análises estatísticas feitas com os testes de Kruskal-Wallis e Dunn, uma forma mais simples e direta também foi utilizada para comparar os métodos. O melhor e pior casos

Tabela 27 – Teste de Dunn para os desvios do PSNR em relação ao melhor PSNR obtido para cada σ .

Image	Grupo A	Grupo B	Grupo C	Grupo D	Grupo E	Grupo F	Grupo G	Grupo H
Barbara	WiC, AGH Max, AD, Wav, BM, Bay, Wie, AGH Min, Biv	Wav, BM, Bay, Wie, AGH Min, Biv	AGH Min, Biv, TV	Biv, TV, Med	-	-	-	-
Boat	AGH Max, Wav, WiC	Wav, WiC, AD	WIC, AD, AGH Min	AD, AGH Min, Bay, BM, Wie, TV, -	Bay, BM, Wie, TV, -	Bay, BM, Wie, TV, Biv, Med	Bay, BM, Wie, TV, -	Bay, BM, Wie, TV, Biv, Med
Cameraman	AGH Max, AD, Wav	AD, Wav, AGH Min, WiC	Wav, AGH Min, WiC, BM	AGH Min, WiC, BM, Bay, Wie	WiC, BM, BM, Bay, Wie, TV, Med			
Couple	Wav, AGH Max, WiC, AD	WIC, AD, AGH Min	AD, AGH Min, BM, Bay, Wie	BM, Bay, Wie, TV, Bay	Bay, Wie, -	Bay, Wie, -	Bay, Wie, -	Bay, Wie, -
Fingerprint	Wav, WiC, Bay	Bay, AGH Max, AD, BM, Med, Biv, AGH Min, TV, Wie	AGH Max, AD, BM, Med, Biv, AGH Min, TV, Wie	-	-	-	-	-
Glasses	AGH Max, Wav	Wav, AGH Min, Bay, WiC, AD	AGH Min, Bay, WiC, AD, BM, Wie	BM, Wie, TV, Med	Wie, Biv, TV, Med	Wie, Biv, TV, Med	Wie, Biv, TV, Med	Wie, Biv, TV, Med
Hill	AGH Max, Wav, WiC, AD	WIC, AD, AGH Min	AD, AGH Min, Bay, Wie, BM	Bay, Wie, BM, TV, Bay	TV, Bay, -	TV, Bay, -	TV, Bay, -	TV, Bay, -
Lenna	AGH Max, Wav, WiC	Wav, WiC, AGH Min, AD	WIC, AGH Min, AD, Bay	AGH Min, AD, Bay, Wie	BM, Wie, Biv, TV	Wie, Biv, TV, Med	Wie, Biv, TV, Med	Wie, Biv, TV, Med
Lightning	AGH Max, Wav, AGH Min	Wav, AGH Min, AD	AGH Min, AD, WiC	AD, WiC, BM	WiC, BM, Wie, Bay, Biv	BM, Wie, Bay, TV, Biv	BM, Wie, Bay, TV, Biv	BM, Wie, Bay, TV, Biv
Man	AGH Max, Wav, WiC	Wav, WiC, AD, AGH Min	WIC, AD, AGH Min, Bay	AD, AGH Min, Bay, Wie, BM	Wie, Bay, TV, Biv	Wie, BM, TV, Biv, Med	Wie, BM, TV, Biv, Med	Wie, BM, TV, Biv, Med
Peppers	AGH Max, AD, Wav	AD, Wav, AGH Min, WiC	Wav, AGH Min, WiC, Wie	AGH Min, WiC, Wie, Wie	Wie, BM, TV, Bay, Med, Biv			

Fonte: Dados da pesquisa.

Tabela 28 – Teste de Kruskal-Wallis para os desvios entre os SSIM de cada método e o melhor SSIM para cada σ .

Imagen	K (observado)	K (crítico)	GL	p-valor	α
Barbara	65,225	18,307	10	< 0,0001	0,05
Boat	87,798	18,307	10	< 0,0001	0,05
Cameraman	87,127	18,307	10	< 0,0001	0,05
Couple	76,130	18,307	10	< 0,0001	0,05
Fingerprint	71,497	18,307	10	< 0,0001	0,05
Glasses	93,116	18,307	10	< 0,0001	0,05
Hill	84,597	18,307	10	< 0,0001	0,05
Lenna	89,203	18,307	10	< 0,0001	0,05
Lightning	90,217	18,307	10	< 0,0001	0,05
Man	88,946	18,307	10	< 0,0001	0,05
Peppers	82,853	18,307	10	< 0,0001	0,05

Fonte: Dados da pesquisa.

das dez execuções do AGH foram comparados com cada resultado dos outros métodos, e foi feita a contagem e ranqueamento do número de vezes nas quais o AGH Max e AGH Min foram melhores que os outros métodos.

Como as comparações foram feitas com nove outros métodos e os 11 níveis de ruído, tanto o AGH Max e o AGH Min foram comparados 99 vezes para cada imagem. A tabela 30 mostra os resultados do AGH para o PSNR. O AGH Min é melhor do que os outros métodos em mais do que 50% dos casos para todas as imagens, com exceção da *Barbara* e *Fingerprint*. Por sua vez, o AGH Max foi capaz de ser o melhor método em mais de 90% dos casos para oito imagens.

A mesma tabela 30 mostra que a comparação é similar para o SSIM. O AGH Min conseguiu ser melhor em mais 69% das comparações para todas as imagens, exceto a imagem *Fingerprint* (14%). O AGH Max, por sua vez, obteve o melhor resultado em mais de 90% das comparações para seis das imagens, sendo o melhor método em quase 100% das comparações para as imagens *Glasses*, *Lightning* e *Peppers*.

Esta análise quantitativa também pode ser feita por níveis de ruído (σ), como demonstrado nas tabelas 31 e 32. Para as métricas PSNR e SSIM, o AGH Max obtém resultados melhores do que os outros métodos em pelo menos 78% dos casos para a maioria dos níveis de ruído, chegando a ser melhor em 100% dos casos para diversos ruídos em diferentes imagens. *Fingerprint* foi a imagem onde o AGH obteve a pior performance nesta análise para ambas as métricas. Para todos os níveis de ruído, o AGH Min consegue seus melhores resultados na imagem *Lightning* sendo o melhor método em pelo menos 78% das comparações. Além dessa, ele também obteve valores expressivos para as imagens *Peppers*, *Cameraman* e *Glasses*.

Para ambas as métricas, podemos apontar a estabilidade nos resultados obtidos pelo AGH nos diferentes níveis de ruído para a maioria dos casos. Em poucos casos o comportamento do AGH Max se distancia muito dentro dos testes feitos para uma mesma imagem. Dois casos

Tabela 29 – Teste de Dunn para os desvios do SSIM em relação ao melhor SSIM obtido para cada σ .

Image	Grupo A	Grupo B	Grupo C	Grupo D	Grupo E	Grupo F	Grupo G
Barbara	AGH Max , Wav, WiC, Bay, AD, BM, <i>AGH Min</i>	Bay, AD, BM, AGH <i>Wie</i> , Biv, TV	Biv, TV, Med	-	-	-	-
Boat	Wav, AGH Max , WiC	WiC, Bay, <i>AGH Min</i> , AD	Bay, <i>AGH Min</i> , AD, BM, BM , Wie, TV, <i>Wie</i> , TV, Biv, Med	-	-	-	-
Cameraman	AGH Max , <i>AGH Min</i>	<i>AGH Min</i> , AD, Wav, Bay, WiC, BM	AD, Wav, Bay, WiC, BM, WiC , BM, Wie	BM, Wie, TV, Biv, -	-	-	-
Couple	Wav, AGH Max , WiC	AGH Max , WiC, <i>AGH Min</i> , AD, Bay	Bay, <i>AGH Min</i> , AD, Bay, BM , Wie, TV	Wie, TV, Biv, Med	-	-	-
Fingerprint	Wav, WiC, Bay	Med, BM, AGH Max , TV, <i>AGH Min</i> , AD, Bay	BM, AGH Max , TV, Biv, AD, Wie, <i>AGH Min</i>	-	-	-	-
Glasses	AGH Max , <i>AGH Min</i> , Bay, Wav	Bay, Wav, AD	AD, WiC, Wie, BM, Biv, <i>Wie</i> , BM, Biv, TV, Med	-	-	-	-
Hill	Wav, AGH Max , WiC	WiC, <i>AGH Min</i> , Bay, AD	AGH Min, Bay, AD, BM, BM , Wie, Biv, TV, <i>Wie</i> , TV, Med	-	-	-	-
Lenna	AGH Max , Wav, Bay, <i>AGH Min</i>	Wav, Bay, <i>AGH Min</i> , WiC	Bay, <i>AGH Min</i> , WiC, WiC , AD, BM	AD, BM, BM , Wie, Wie, Biv	Biv, TV, Biv, TV	-	-
Lightning	AGH Max , <i>AGH Min</i> , Wav	<i>AGH Min</i> , Wav, Bay	Bay, AD, WiC	AD, WiC, BM, <i>Wie</i> , TV, Biv	-	-	-
Man	AGH Max , Wav, WiC	Wav, WiC, Bay, <i>AGH Min</i>	WiC, Bay, <i>AGH Min</i> , AD	AD, BM, Wie	BM, Wie, <i>Wie</i> , Biv, Biv, TV	-	-
Peppers	AGH Max , <i>AGH Min</i>	AGH Min, Bay, WiC, Wav, AD, BM	AD, BM, Wie, <i>BM</i> , Wie, Wie, TV, -	TV	TV, Biv	Biv, Med	-

Fonte: Dados da pesquisa.

Tabela 30 – Número de vezes em que o AGH foi melhor que os outros métodos para as métricas PSNR e SSIM.

Image	PSNR		SSIM	
	AGH Max	AGH Min	AGH Max	AGH Min
Barbara	78%	39%	86%	54%
Boat	91%	54%	87%	63%
Cameraman	96%	75%	97%	95%
Couple	83%	59%	80%	63%
Fingerprint	52%	23%	35%	14%
Glasses	98%	80%	99%	86%
Hill	91%	62%	84%	62%
Lenna	92%	66%	95%	74%
Lightning	93%	87%	98%	90%
Man	95%	65%	94%	69%
Peppers	96%	71%	98%	89%

Fonte: Dados da pesquisa.

onde a quantidade de vitórias obtidas pelo AGH não é estável estão nas imagens *Fingerprint* e *Barbara*, onde ambas as imagens apresentam mais regiões com texturas do que as outras imagens. Para estas situações, o AGH passa a ser mais dependente dos seus métodos de busca local, uma vez que, como já discutido anteriormente, funções que minimizam variação total podem ser prejudicadas nestes casos.

Todos os resultados obtidos pelo AGH, tanto na análise estatística quanto nas comparações baseadas em contagem e ranqueamento, mostram que a abordagem proposta é competitiva quando comparada com alguns dos melhores métodos de supressão de ruídos em imagens disponíveis na literatura. Não apenas isso, as análises mostram que até seus piores resultados (AGH Min) são competitivos. Outro aspecto relevante a ser levado em conta quando analisando os resultados do AGH é o fato de que ele obtém, na maioria dos casos, resultados melhores do que os métodos que ele utiliza como operadores de busca local. Por exemplo, o BM3D é um dos melhores métodos de supressão de ruídos em imagens encontrado na literatura, mas ele não apresenta os melhores resultados em todas as ocasiões, especialmente quando lida com imagens corrompidas com um ruído de desvio padrão muito alto. Isso indica que elementos como a função objetivo e o processo evolutivo do AGH são capazes de guiar o método rumo a bons resultados na grande maioria dos casos. Diversas imagens resultantes dos diversos métodos aqui comparados podem ser encontradas no apêndice A.

4.4 Testando o AGH para suprimir ruídos em imagens SAR

Uma quarta rodada de testes foi feita utilizando o AGH para suprimir ruídos em imagens obtidas através de radares de abertura sintética (*Synthetic Aperture Radar - SAR*). Para estes

Tabela 31 – Número de vezes nas quais o AGH foi melhor que os outros métodos para cada nível de ruído de acordo com a métrica PSNR.

σ	Barbara		Boat		Cameraman		Couple	
	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min
10	56%	56%	89%	67%	89%	56%	100%	78%
15	78%	22%	78%	56%	100%	89%	89%	56%
20	78%	22%	89%	44%	89%	78%	89%	44%
25	89%	22%	89%	56%	89%	89%	67%	44%
30	78%	33%	100%	67%	89%	89%	89%	56%
35	78%	33%	100%	33%	100%	78%	78%	78%
40	78%	44%	100%	44%	100%	67%	78%	44%
45	78%	44%	89%	67%	100%	67%	78%	56%
50	78%	44%	89%	56%	100%	67%	89%	56%
55	78%	56%	89%	44%	100%	78%	78%	67%
60	89%	56%	89%	56%	100%	67%	78%	67%

σ	Fingerprint		Glasses		Hill		Lenna	
	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min
10	56%	56%	89%	67%	89%	67%	100%	67%
15	56%	33%	100%	78%	89%	56%	67%	56%
20	44%	22%	100%	89%	89%	44%	89%	67%
25	44%	22%	89%	89%	89%	67%	89%	67%
30	56%	11%	100%	67%	100%	56%	100%	67%
35	44%	0%	100%	78%	100%	67%	89%	78%
40	56%	22%	100%	78%	89%	67%	100%	78%
45	67%	22%	100%	89%	89%	67%	89%	67%
50	56%	22%	100%	78%	89%	67%	89%	67%
55	44%	22%	100%	89%	89%	67%	100%	56%
60	44%	22%	100%	78%	89%	56%	100%	56%

σ	Lightning		Man		Peppers	
	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min
10	100%	100%	100%	78%	100%	89%
15	100%	89%	100%	67%	100%	44%
20	100%	89%	89%	67%	89%	89%
25	89%	89%	89%	67%	89%	78%
30	100%	78%	100%	56%	89%	56%
35	89%	89%	100%	56%	100%	78%
40	89%	78%	89%	67%	100%	67%
45	89%	78%	89%	67%	100%	78%
50	89%	89%	89%	56%	100%	67%
55	89%	89%	100%	56%	100%	67%
60	89%	89%	100%	78%	89%	67%

Fonte: Dados da pesquisa.

Tabela 32 – Número de vezes nas quais o AGH foi melhor que os outros métodos para cada nível de ruído de acordo com a métrica SSIM.

σ	Barbara		Boat		Cameraman		Couple	
	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min
10	67%	56%	67%	67%	89%	89%	67%	67%
15	67%	22%	67%	33%	100%	89%	56%	56%
20	78%	22%	89%	44%	89%	89%	67%	44%
25	89%	33%	89%	56%	89%	89%	67%	33%
30	89%	44%	100%	67%	100%	89%	100%	67%
35	89%	44%	100%	56%	100%	100%	100%	78%
40	89%	67%	89%	67%	100%	100%	78%	56%
45	89%	67%	89%	78%	100%	100%	78%	67%
50	100%	67%	89%	78%	100%	100%	89%	67%
55	89%	78%	89%	67%	100%	100%	89%	78%
60	100%	89%	89%	78%	100%	100%	89%	78%
σ	Fingerprint		Glasses		Hill		Lenna	
	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min
10	56%	56%	89%	78%	67%	56%	89%	56%
15	56%	22%	100%	89%	56%	33%	78%	56%
20	22%	22%	100%	89%	67%	44%	89%	67%
25	22%	11%	100%	89%	89%	67%	89%	78%
30	56%	0%	100%	78%	100%	44%	100%	67%
35	11%	0%	100%	78%	100%	67%	100%	78%
40	33%	0%	100%	100%	89%	78%	100%	78%
45	33%	11%	100%	100%	89%	67%	100%	89%
50	33%	11%	100%	78%	89%	78%	100%	78%
55	33%	11%	100%	89%	89%	78%	100%	78%
60	33%	11%	100%	78%	89%	67%	100%	89%
σ	Lightning		Man		Peppers			
	AGH Max	AGH Min	AGH Max	AGH Min	AGH Max	AGH Min		
10	100%	89%	78%	56%	100%	78%		
15	100%	89%	89%	44%	100%	78%		
20	89%	89%	89%	56%	89%	89%		
25	89%	89%	89%	67%	89%	89%		
30	100%	89%	100%	67%	100%	89%		
35	100%	89%	100%	67%	100%	100%		
40	100%	78%	89%	67%	100%	67%		
45	100%	89%	100%	89%	100%	100%		
50	100%	100%	100%	78%	100%	100%		
55	100%	100%	100%	78%	100%	100%		
60	100%	89%	100%	89%	100%	89%		

Fonte: Dados da pesquisa.

testes, foram utilizadas três imagens (figuras 20, 21 e 22) que foram corrompidas com um ruído Speckle multiplicativo. Um total de 12 diferentes números de visões equivalentes (*Equivalent Number of Looks - L*) foi avaliada, $L = 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11$ e 12 .

Figura 20 – Imagem SAR San Francisco.



Fonte: [Nozzoli \(2012\)](#).

Os testes compararam o AGH contra dois métodos feitos com intuito de atenuar ruídos em imagens SAR: o SARBM3D ([PARRILLI et al., 2012](#)), que é uma extensão do método BM3D para imagens SAR, e o PPB (*Probabilistic Patch-Based filter*), proposto por Deledalle et al e já descrito na seção [2.1\(DELEDALLE; DENIS; TUPIN, 2009\)](#). O AGH foi executado 10 vezes para cada imagem e para cada valor de L . Os melhores e piores resultados para PSNR e SSIM dentre essas execuções foram comparados com os resultados obtidos pelo PPB e pelo SARBM3D de maneira análoga às comparações feitas na seção anterior, com testes de Kruskal-Wallis e de Dunn. Resultados completos dos testes, como exemplificados nas tabelas [33](#) e [34](#), podem ser encontrados no apêndice [B](#).

Para a realização dos testes estatísticos, os resultados também tiveram que ser ajustados para que todos ficassem dentro da mesma escala (ver equação [4.5](#)), de maneira que as comparações via Kruskal-Wallis e Dunn fossem feitas em cima dos desvios entre os resultados obtidos por cada método, em relação aos melhor e pior valores para cada L .

A tabela [35](#) mostra que, para todas as imagens, houve diferença significativa entre os métodos ($p - \text{valor} < 0,05$). A partir disso, podemos aplicar o teste de Dunn para tais imagens (tabela [36](#)), onde fica clara a superioridade do AGH em relação aos outros métodos. O AGH

Figura 21 – Imagem SAR *Mississippi*.



Fonte: [Baumann \(1996\)](#).

Figura 22 – Imagem SAR *Washington*.



Fonte: [Gonzalez, Woods e Eddins \(2005\)](#).

Tabela 33 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *San Francisco*.

Imagen	<i>L</i>	SARBM3D	PPB	AGH Max	AGH Min
San Francisco	1	22,60	22,80	19,71	18,89
San Francisco	2	19,16	19,66	23,43	22,92
San Francisco	3	14,36	14,62	17,06	16,28
San Francisco	4	11,25	11,36	12,90	12,80
San Francisco	5	9,08	9,08	10,12	9,89
San Francisco	6	7,49	7,45	8,26	8,00
San Francisco	7	6,27	6,22	6,96	6,77
San Francisco	8	5,38	5,33	5,91	5,74
San Francisco	9	4,71	4,67	5,27	4,94
San Francisco	10	4,20	4,18	4,46	4,38
San Francisco	11	3,84	3,82	4,06	3,91
San Francisco	12	3,58	3,56	3,77	3,72

Fonte: Dados da pesquisa.

Tabela 34 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *San Francisco*.

Imagen	<i>L</i>	SARBM3D	PPB	AGH Max	AGH Min
San Francisco	1	0,444	0,523	0,590	0,532
San Francisco	2	0,331	0,504	0,645	0,595
San Francisco	3	0,263	0,420	0,606	0,588
San Francisco	4	0,223	0,341	0,553	0,524
San Francisco	5	0,210	0,291	0,491	0,461
San Francisco	6	0,230	0,272	0,437	0,419
San Francisco	7	0,280	0,271	0,402	0,382
San Francisco	8	0,297	0,283	0,368	0,314
San Francisco	9	0,293	0,287	0,317	0,253
San Francisco	10	0,289	0,286	0,272	0,196
San Francisco	11	0,290	0,284	0,225	0,179
San Francisco	12	0,285	0,279	0,183	0,171

Fonte: Dados da pesquisa.

Max ficou sempre em primeiro lugar nas comparações e, quando não era o representante isolado no Grupo A, ele estava acompanhado apenas pelo AGH Min. Inclusive, é importante ressaltar que o pior caso do AGH também conseguiu excelentes resultados, sendo sempre melhor que os outros métodos. A partir destas análises, podemos afirmar que, em termos de PSNR, o AGH é claramente superior em relação aos outros analisados para as imagens SAR consideradas.

Tabela 35 – Teste de Kruskal-Wallis para os desvios entre os PSNR de cada método e o melhor PSNR para cada *L*.

Imagen	K (observado)	K (crítico)	GL	p-valor	α
Mississippi	32,412	7,815	3	< 0,0001	0,05
San Francisco	30,694	7,815	3	< 0,0001	0,05
Washington	36,090	7,815	3	< 0,0001	0,05

Fonte: Dados da pesquisa.

Tabela 36 – Teste de Dunn para os desvios do PSNR em relação ao melhor PSNR obtido para cada L .

Imagen	Grupo A	Grupo B	Grupo C
Mississippi	AGH Max, AGH Min	SARBM3D	PPB
San Francisco	AGH Max	AGH Min	SARBM3D, PPB
Washington	AGH Max	AGH Min, SARBM3D	PPB

Fonte: Dados da pesquisa.

Em seguida ao teste para o PSNR, a sua versão análoga para o SSIM foi realizada e, como pode ser visto no teste de Kruskal-Wallis da tabela 37, existe diferença significativa entre os métodos para todas as imagens testadas. Com isso, a fim de diferenciar a qualidade dos métodos para essa métrica, o teste de Dunn também foi feito em cima dos dados obtidos. Neste teste (vide tabela 38), não há a predominância total do AGH como no anterior, entretanto o método se mantém sempre entre os melhores e, em duas das três imagens analisadas, ele é o melhor método isolado.

Tabela 37 – Teste de Kruskal-Wallis para os desvios entre os SSIM de cada método e o melhor SSIM para cada L .

Imagen	K (observado)	K (crítico)	GL	p-valor	α
Mississippi	16,126	7,815	3	0,001	0,05
San Francisco	13,446	7,815	3	0,004	0,05
Washington	31,395	7,815	3	< 0,0001	0,05

Fonte: Dados da pesquisa.

Tabela 38 – Teste de Dunn para os desvios do SSIM em relação ao melhor SSIM obtido para cada L .

Imagen	Grupo A	Grupo B	Grupo C
Mississippi	SARBM3D, PPB	PPB, AGH Max	AGH Max, AGH Min
San Francisco	AGH Max	PPB, AGH Min, SARBM3D	-
Washington	AGH Max	SARBM3D	AGH Min, PPB

Fonte: Dados da pesquisa.

É importante mencionar que tanto o método PPB quanto o SARBM3D são especializados para lidar com imagens SAR e eles se utilizam de informação prévia sobre o número de visões equivalentes (L) para serem executados. Por outro lado, o AGH não utiliza nenhuma informação sobre a imagem e não passou por nenhum tipo de especialização para trabalhar com imagens com outro tipo de ruído. Mesmo com essas características diferentes em relação aos métodos comparados, o AGH conseguiu resultados melhores na grande maioria dos casos avaliados. Imagens resultantes das diversas comparações feitas nesta seção encontram-se no apêndice A.



CONCLUSÕES

Este trabalho apresentou um Algoritmo Genético Híbrido (AGH) para supressão de ruídos em imagens. Este método, embora inspirado no algoritmo proposto em ([TOLEDO et al., 2013](#)), possui uma série de mudanças fundamentais em seu núcleo, como a utilização de conhecidos métodos de supressão de ruídos em imagens como operadores de busca local, uso de uma população intermediária e o cálculo do *fitness* dos indivíduos existentes através de uma função baseada no cálculo da variação total na imagem.

Antes de comparar os resultados do AGH com os obtidos por outros métodos encontrados na literatura, ele passou por uma série de testes de parâmetros, buscando realizar uma sintonia fina no método. Estes testes, bem como todos os outros feitos neste trabalho, estão baseados em duas métricas que são amplamente utilizadas para a medição de qualidade de imagens: PSNR e SSIM.

Inicialmente o AGH foi comparado com variações de si próprio, onde partes específicas do algoritmo eram modificadas. Esses testes evidenciam que, em geral, o AGH se mostrou como uma melhor opção evolutiva para um método de supressão de ruídos em imagens, pois ele sempre obteve resultados tão bons quanto ou melhores do que os obtidos pelas outras abordagens testadas. Pode-se concluir que o uso de métodos de supressão de imagem sobre os novos indivíduos gerados é mais eficaz do que a aplicação de filtros, visando diversidade, sobre tais indivíduos ou do que a utilização dos métodos de supressão de ruído apenas sobre os melhores indivíduos.

A bateria de testes seguinte mostrou que o AGH é competitivo com alguns dos principais métodos da literatura para a remoção de ruído aditivo branco Gaussiano em diferentes níveis e em diferentes imagens. Estes testes mostraram um AGH consistente, sendo competitivo em quase todos os casos e, em diversos testes, apresentando bons resultados até em seu pior caso. É importante salientar também que, na maior parte dos casos, o AGH foi capaz de obter resultados melhores do que os métodos que ele utiliza como operadores de busca local. Isso mostra a importância do processo evolutivo e a capacidade da função objetivo de guiar o método para

boas regiões dentro do espaço de busca.

A última avaliação mostrou o comportamento do AGH para imagens SAR com um ruído Speckle multiplicativo. Neste teste, a comparação foi feita com métodos de supressão de ruídos desenvolvidos sob medida para imagens SAR com ruído Speckle, enquanto isso o AGH utilizou a mesma configuração padrão dos testes para ruído Gaussiano. De maneira até surpreendente, o AGH foi capaz de obter resultados relevantes quando comparado com os métodos especialistas, sendo inclusive o melhor método na maior parte das comparações feitas.

Ao fazer uma análise dos resultados obtidos, podemos verificar que a hipótese dada como base deste trabalho — indicando que uma abordagem com algoritmos genéticos é capaz de encontrar soluções de boa qualidade para a supressão de ruídos em imagens — pode ser aceita. Isso se dá principalmente devido a qualidade dos resultados obtidos em comparação com diversos métodos da literatura, bem como nas diferentes situações nas quais o AGH foi testado.

Dentre os diversos aspectos do AGH, dois podem ser revistos: o critério de parada e a função objetivo. O critério de parada atual faz com que o método execute por um tempo pré definido, tornando-o lento quando comparado com outros métodos. Este problema fica mais evidente quando diversas execuções são necessárias. Por este motivo, um critério de parada que consiga reconhecer quando a melhor imagem já foi encontrada é fundamental, caso tempo de execução seja relevante para a aplicação do AGH. A função objetivo foi capaz de guiar bem o AGH pelo espaço de busca e obter bons resultados, mas foi possível verificar nos testes realizados que nem sempre boas imagens foram adequadamente avaliadas. Por exemplo, uma imagem recuperada pelo BM3D pode ter valores altos para PSNR e SSIM, mas a função objetivo não necessariamente irá sempre dar um valor relevante a essa imagem em termos de *fitness*.

O principal objetivo do AGH é viabilizar uma abordagem evolutiva híbrida para o problema de supressão de ruídos em imagens. Entretanto, os resultados mostram que o AGH não é apenas uma opção viável, apesar do gasto de tempo computacional, eles mostram também que ele é estável através de diversas execuções e quando aplicado em diferentes imagens com diferentes níveis de ruído. Uma extensão natural do AGH consiste em adaptá-lo para situações específicas como utilizar métodos especializados em imagens SAR como operadores de busca local. Além disso, uma extensão para tratar de ruídos em imagens médicas 2D e 3D pode ser desenvolvida.

REFERÊNCIAS

- BAUMANN, P. R. **FLOOD ANALYSIS: 1993 Mississippi Flood**. 1996. <<http://rscc.umn.edu/rscc/Volume4/baumann/baumann.html>>. [Acessada em junho de 2015]. Citado 3 vezes nas páginas 83, 108 e 110.
- BERRY, R.; BURNELL, J. Astronomical image processing. **Willman-Bell, Inc**, 2000. Citado na página 27.
- BLACK, M. J.; SAPIRO, G.; MARIMONT, D. H.; HEEGER, D. Robust Anisotropic Diffusion. **IEEE Transactions on Image Processing**, v. 7, n. 3, p. 421–432, mar. 1998. Citado 3 vezes nas páginas 28, 32 e 46.
- CAO, Y.; LUO, Y.; YANG, S. Image denoising based on hierarchical markov random field. **Pattern Recognition Letters**, Elsevier B.V., v. 32, n. 2, p. 368–374, 2011. Disponível em: <<http://linkinghub.elsevier.com/retrieve/pii/S0167865510003211>>. Citado na página 34.
- CHAMBOLLE, A. An Algorithm for Total Variation Minimization and Applications. **Journal of Mathematical Imaging and Vision**, Kluwer Academic Publishers, v. 20, n. 1-2, p. 89–97, 2004. ISSN 0924-9907. Citado na página 32.
- CHANG, S.; YU, B.; VETTERLI, M. Adaptive Wavelet Thresholding for Image Denoising and Compression. **IEEE Transactions on Image Processing**, v. 9, n. 9, p. 1532–1546, set. 2000. Citado 2 vezes nas páginas 33 e 73.
- _____. Spatially Adaptive Wavelet Thresholding Based on Context Modeling for Image Denoising. **IEEE Transactions on Image Processing**, v. 9, n. 9, p. 1522–1531, set. 2000. Citado na página 33.
- CHIARANDINI, M.; BASSO, D.; STÜTZLE, T. Statistical Methods for the Comparison of Stochastic Optimizers. In: **The Sixth Metaheuristics International Conference**. [S.l.: s.n.], 2005. p. 189–196. Citado na página 73.
- CHIPMAN, H.; KOLACZYK, E.; MCCULLOCH, R. Adaptive Bayesian Wavelet Shrinkage. **Journal of the American Statistical Association**, v. 440, n. 92, p. 1413–1421, 1997. Citado na página 33.
- CHRYSOCHOOS, A.; LOUCHE, H. An infrared image processing to analyse the calorific effects accompanying strain localisation. **International Journal of Engineering Science**, v. 38, n. 16, p. 1759 – 1788, 2000. ISSN 0020-7225. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0020722500000021>>. Citado na página 27.
- CORDER, G. W.; FOREMAN, D. I. **Nonparametric Statistics: A Step-by-Step Approach**. second. [S.l.]: John Wiley & Sons, Inc, 2014. Citado na página 65.
- CROWTHER, R.; HENDERSON, R.; SMITH, J. {MRC} image processing programs. **Journal of Structural Biology**, v. 116, n. 1, p. 9 – 16, 1996. ISSN 1047-8477. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S1047847796900039>>. Citado na página 27.

DABOV, K.; FOI, A.; KATKOVNIK, V.; EGIAZARIAN, K. Image Denoising with Block-Matching and 3D Filtering. In: **SPIE Electronic Imaging: Algorithms and Systems**. [S.l.: s.n.], 2006. v. 6064, p. 606414–1–606414–12. Citado 4 vezes nas páginas 28, 32, 46 e 73.

DELEDALLE, C.; DENIS, L.; TUPIN, F. Iterative Weighted Maximum Likelihood Denoising with Probabilistic Patch-Based Weights. **IEEE Transactions on Image Processing**, v. 18, n. 12, p. 2661–2672, 2009. Citado 2 vezes nas páginas 33 e 82.

DRAPACA, C. A Nonlinear Total Variation-based Denoising Method with two Regularization Parameters. **IEEE Transactions on Biomedical Engineering**, v. 56, n. 3, p. 582–586, 2009. Citado na página 32.

DUNN, O. J. Multiple comparisons using rank sums. **Technometrics**, Taylor & Francis, v. 6, n. 3, p. 241–252, 1964. Citado na página 65.

EIBEN, A. E.; SMITH, J. E. **Introduction to evolutionary computing**. [S.l.]: Springer, 2003. Citado 4 vezes nas páginas 41, 42, 43 e 44.

FACEBOOK; ERICSSON; QUALCOMM. **A Focus on Efficiency**. 2013. <<http://internet.org/efficiencypaper>>. Citado na página 27.

FAN, G.; XIA, X. Image Denoising using Local Contextual Hidden Markov Model in the Wavelet Domain. **IEEE Signal Processing Letters**, v. 8, n. 5, p. 125–128, maio 2001. Citado na página 33.

GEORGE, A.; RAJAKUMAR, B. R.; BINU, D. Genetic algorithm based airlines booking terminal open/close decision system. In: **International Conference on Advances in Computing, Communications and Informatics**. New York, NY, USA: ACM, 2012. (ICACCI '12), p. 174–179. ISBN 978-1-4503-1196-0. Disponível em: <<http://doi.acm.org/10.1145/2345396.2345426>>. Citado na página 28.

GHAEL, S.; GHAEL, E. P.; SAYEED, A. M.; BARANIUK, R. G. Improved Wavelet Denoising via Empirical Wiener Filtering. In: **Proceedings of SPIE**. San Diego, CA, USA: [s.n.], 1997. v. 3169, p. 389–399. Citado 4 vezes nas páginas 28, 33, 47 e 73.

GOLDBERG, D. E. **Genetic Algorithms in Search, Optimization and Machine Learning**. 1st. ed. Boston, MA, USA: Addison-Wesley Longman Publishing Co., Inc., 1989. ISBN 0201157675. Citado na página 28.

GONDRO, C.; KINGHORN, B. A simple genetic algorithm for multiple sequence alignment. **Genet. Mol. Res.**, v. 6, n. 4, p. 964–982, 2007. Citado na página 28.

GONZALEZ, R.; WOODS, R.; EDDINS, S. **Image Processing Place**. 2005. <<http://www.imageprocessingplace.com/>>. Accessed: 2016-01-25. Citado 19 vezes nas páginas 37, 38, 49, 54, 72, 83, 96, 97, 98, 99, 100, 101, 102, 103, 104, 105, 106, 107 e 109.

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing (3rd Edition)**. Upper Saddle River, NJ, USA: Prentice-Hall, Inc., 2006. ISBN 013168728X. Citado 6 vezes nas páginas 27, 31, 35, 36, 37 e 73.

GREFENSTETTE, J.; GOPAL, R.; ROSMAITA, B.; GUCHT, D. V. Genetic algorithms for the traveling salesman problem. In: LAWRENCE ERLBAUM, NEW JERSEY (160-168). **First International Conference on Genetic Algorithms and their Applications**. [S.l.], 1985. p. 160–168. Citado na página 28.

- GUPTA, V.; CHAN, C. C.; SIAN, P. T. A Differential Evolution Approach to PET Image Denoising. In: **29th Annual International Conference of the IEEE Engineering in Medicine and Biology Society**. [S.l.: s.n.], 2007. p. 4173–4176. Citado na página 34.
- HOLLAND, J. Genetic algorithms and the optimal allocation of trials. **SIAM Journal on Computing**, v. 2, n. 2, p. 88–105, 1973. Disponível em: <<http://dx.doi.org/10.1137/0202009>>. Citado 2 vezes nas páginas 41 e 42.
- HOLLAND, J. H. Adaptation in natural and artificial systems: An introductory analysis with applications to biology, control, and artific.". A Bradford Book, 1992. Citado 2 vezes nas páginas 41 e 42.
- HSU, L.-Y.; HORNG, S.-J.; FAN, P.; CHOU, H.-H.; WANG, X.; GUO, M. Adaptive Non-Local Means for Image Denoising using Turbulent PSO with No-Reference Measures. In: **International Symposium on Biometrics and Security Technologies**. [S.l.: s.n.], 2013. p. 251–258. Citado na página 34.
- ISHIBUCHI, H.; MURATA, T.; TÜRKŞEN, I. Single-objective and two-objective genetic algorithms for selecting linguistic rules for pattern classification problems. **Fuzzy Sets and Systems**, Elsevier, v. 89, n. 2, p. 135–150, 1997. Citado na página 28.
- ISHIKAWA, H. **Global Optimization Using Embedded Graphs**. Tese (Doutorado) — Department of Computer Science, New York University, 2000. Citado 9 vezes nas páginas 15, 33, 34, 37, 38, 39, 40, 45 e 70.
- JAMES, A. P.; DASARATHY, B. V. Medical image fusion: A survey of the state of the art. **Information Fusion**, v. 19, n. 0, p. 4 – 19, 2014. ISSN 1566-2535. Special Issue on Information Fusion in Medical Image Computing and Systems. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S1566253513001450>>. Citado na página 27.
- JONG, K. D. Evolutionary computation: a unified approach. In: **GECCO conference companion on Genetic and evolutionary computation**. ACM, 2008. p. 2245–2258. ISBN 978-1-60558-131-6. Disponível em: <<http://dx.doi.org/10.1145/1388969.1389054>>. Citado na página 42.
- KATKOVNIK, V.; EGIAZARIAN, K.; ASTOLA, J. **Local Approximation Techniques in Signal and Image Processing**. [S.l.]: SPIE Press, 2006. PM157. Citado 2 vezes nas páginas 32 e 73.
- KAZUBEK, M. Wavelet Domain Image Denoising by Thresholding and Wiener Filtering. **IEEE Signal Processing Letters**, v. 10, n. 11, p. 324–326, 2003. Citado na página 33.
- KIMMEL, R.; SOCHEN, N.; MALLADI, R. From high energy physics to low level vision. In: **Scale-Space Theory in Computer Vision**. [S.l.]: Springer, 1997. p. 236–247. Citado na página 40.
- KOCKANAT, S.; KARABOGA, N.; KOZA, T. Image Denoising with 2-D FIR Filter by using Artificial Bee Colony Algorithm. In: **International Symposium on Innovations in Intelligent Systems and Applications**. [S.l.: s.n.], 2012. p. 1–4. Citado na página 34.
- LIU, J.; MOULIN, P. Complexity-Regularized Image Denoising. **IEEE Transactions on Image Processing**, v. 10, n. 6, p. 841–851, jun. 2001. Citado na página 33.

MIHCAK, M. K.; KOZINTSEV, I.; RAMCHANDRAN, K.; MOULIN, P. Low-complexity Image Denoising based on Statistical Modeling of Wavelet Coefficients. **IEEE Signal Processing Letters**, v. 6, n. 12, p. 300–303, dez. 1999. Citado na página 33.

MOHAN, J.; KRISHNAVENI, V.; GUO, Y. A Survey on the Magnetic Resonance image Denoising Methods. **Biomedical Signal Processing and Control**, v. 9, n. 0, p. 56–69, 2014. Citado na página 27.

MOTWANI, M. C.; GADIYA, M. C.; MOTWANI, R. C.; HARRIS, F. C. Survey of Image Denoising Techniques. In: **Proceedings of GSPX**. [S.l.: s.n.], 2004. p. 27–30. Citado na página 27.

NOZZOLI, A. **Multimedia Forensics Dataset**. 2012. <https://iapp.dinfo.unifi.it/index.php?page=datasets_it>. [Acessada em junho de 2015]. Citado 4 vezes nas páginas 82, 108, 109 e 110.

ORCHARD, J.; EBRAHIMI, M.; WONG, A. Efficient Nonlocal-Means Denoising using the SVD. In: **IEEE International Conference on Image Processing**. San Diego, CA, USA: [s.n.], 2008. p. 1732–1735. Citado na página 32.

PAIVA, J.; TOLEDO, C.; PEDRINI, H. A Hybrid Genetic Algorithm for Image Denoising. In: **IEEE Congress on Evolutionary Computation (CEC)**. Sendai, Japan: [s.n.], 2015. Citado na página 28.

_____. An Approach Based on Hybrid Genetic Algorithm Applied to Image Denoising Problem. In: . [S.l.: s.n.], 2015. Citado na página 28.

PARRILLI, S.; PODERICO, M.; ANGELINO, C.; VERDOLIVA, L. A Nonlocal SAR Image Denoising Algorithm Based on LLMMSE Wavelet Shrinkage. **IEEE Transactions on Geoscience and Remote Sensing**, v. 50, n. 2, p. 606–616, fev. 2012. Citado na página 82.

PERONA, P.; MALIK, J. Scale-Space and Edge Detection using Anisotropic Diffusion. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, IEEE, v. 12, n. 7, p. 629–639, 1990. Citado na página 32.

REEVES, S. J. Image Restoration: Fundamentals of Image Restoration. In: TRUSSELL, J.; SRIVASTAVA, A.; ROY-CHOWDHURY, A. K.; SRIVASTAVA, A.; NAYLOR, P. A.; CHELLAPPA, R.; THEODORIDIS, S. (Ed.). **Academic Press Library in Signal Processing (Chapter 6 - Image, Video Processing and Analysis, Hardware, Audio, Acoustic and Speech Processing)**. [S.l.]: Elsevier, 2014. v. 4, p. 165–192. Citado na página 27.

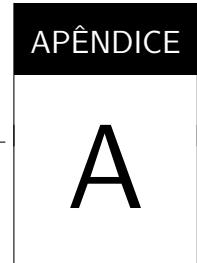
ROMBERG, J. K.; CHOI, H.; BARANIUK, R. G. Shift-Invariant Denoising using Wavelet-domain Hidden Markov Trees. In: **Conference Record of The Thirty-Third Asilomar Conference on Signals, Systems and Computers**. Pacific Grove, CA, USA: [s.n.], 1999. p. 1277–1281. Citado na página 33.

ROUSSEEUW, P. J.; LEROY, A. M. **Robust Regression and Outlier Detection**. [S.l.]: John Wiley & Sons, 2005. v. 589. Citado na página 65.

RUDIN, L.; OSHER, S.; FATEMI, E. Nonlinear Total Variation based Noise Removal Algorithms. **Physica D**, v. 60, p. 259–268, 1992. Citado 4 vezes nas páginas 32, 39, 41 e 73.

- RUGGERI, F.; VIDAKOVIC, B. A Bayesian Decision Theoretic Approach to Wavelet Thresholding. **Journal of The American Statistical Association**, v. 93, p. 173–179, 1998. Citado na página 33.
- RUSSO, F. A Method for Estimation and Filtering of Gaussian Noise in Images. **IEEE Transactions on Instrumentation and Measurement**, v. 52, n. 4, p. 1148–1154, ago. 2003. Citado na página 31.
- _____. Image Filtering based on Piecewise Linear Models. In: **IEEE International Workshop IST**. Stresa, Italy: [s.n.], 2004. p. 7–12. Citado na página 31.
- SCHULTZ, A. C. Learning robot behaviors using genetic algorithms. **Intelligent Automation and Soft Computing: Trends in Research, Development, and Applications**, v. 1, p. 14–17, 1994. Citado na página 28.
- SENDUR, L.; SELESNICK, I. W. Bivariate Shrinkage with Local Variance Estimation. **IEEE Signal Processing Letters**, v. 9, n. 12, p. 439–441, dez. 2002. Citado 2 vezes nas páginas 33 e 73.
- SETHIAN, J. A. **Level Set Methods and Fast Marching Methods: Evolving Interfaces in Computational Geometry, Fluid Mechanics, Computer Vision and Materials Sciences**. [S.l.]: Cambridge University Press, 1999. Citado na página 32.
- SILVA, R. D. da; MINETTO, R.; SCHWARTZ, W. R.; PEDRINI, H. Adaptive Edge-Preserving Image Denoising using Wavelet Transforms. **Pattern Analysis and Applications**, Springer, v. 16, n. 4, p. 567–580, 2013. Citado 4 vezes nas páginas 31, 33, 53 e 73.
- SOCHEN, N.; KIMMEL, R.; MALLADI, R. A general framework for low level vision. **Image Processing, IEEE Transactions on**, v. 7, n. 3, p. 310–318, Mar 1998. ISSN 1057-7149. Citado na página 40.
- THAVAVEL, V.; BASHA, J. J.; KRISHNA, M.; MURUGESAN, R. Heuristic Wavelet Approach for Low-Dose EPR Tomographic Reconstruction: An Applicability Analysis with Phantom and in Vivo Imaging. **Expert Systems with Applications**, v. 39, n. 5, p. 5717–5726, 2012. Citado na página 34.
- TOLEDO, C.; OLIVEIRA, L. de; SILVA, R. Dutra da; PEDRINI, H. Image Denoising based on Genetic Algorithm. In: **IEEE Congress on Evolutionary Computation (CEC)**. [S.l.: s.n.], 2013. p. 1294–1301. Citado 4 vezes nas páginas 34, 45, 70 e 87.
- VIDAKOVIC, B. Nonlinear Wavelet Shrinkage with Bayes Rules and Bayes Factors. **Journal of the American Statistical Association**, v. 93, n. 441, p. 173–179, 1998. Citado na página 33.
- WANG, Z.; BOVIK, A. C.; SHEIKH, H. R.; SIMONCELLI, E. P. Image Quality Assessment: From Error Visibility to Structural Similarity. **IEEE Transactions on Image Processing**, IEEE, v. 13, n. 4, p. 600–612, 2004. Citado 2 vezes nas páginas 53 e 54.
- WEYRICH, N.; WARHOLA, G. T. Wavelet Shrinkage and Generalized Cross Validation for Image Denoising. **IEEE Transactions on Image Processing**, v. 7, n. 1, p. 82–90, jan. 1998. Citado na página 33.
- WONGSAWAT, Y.; RAO, K.; ORAINTARA, S. Multichannel SVD-based Image De-noising. In: **IEEE International Symposium on Circuits and Systems**. [S.l.: s.n.], 2005. v. 6, p. 5990–5993. Citado na página 32.

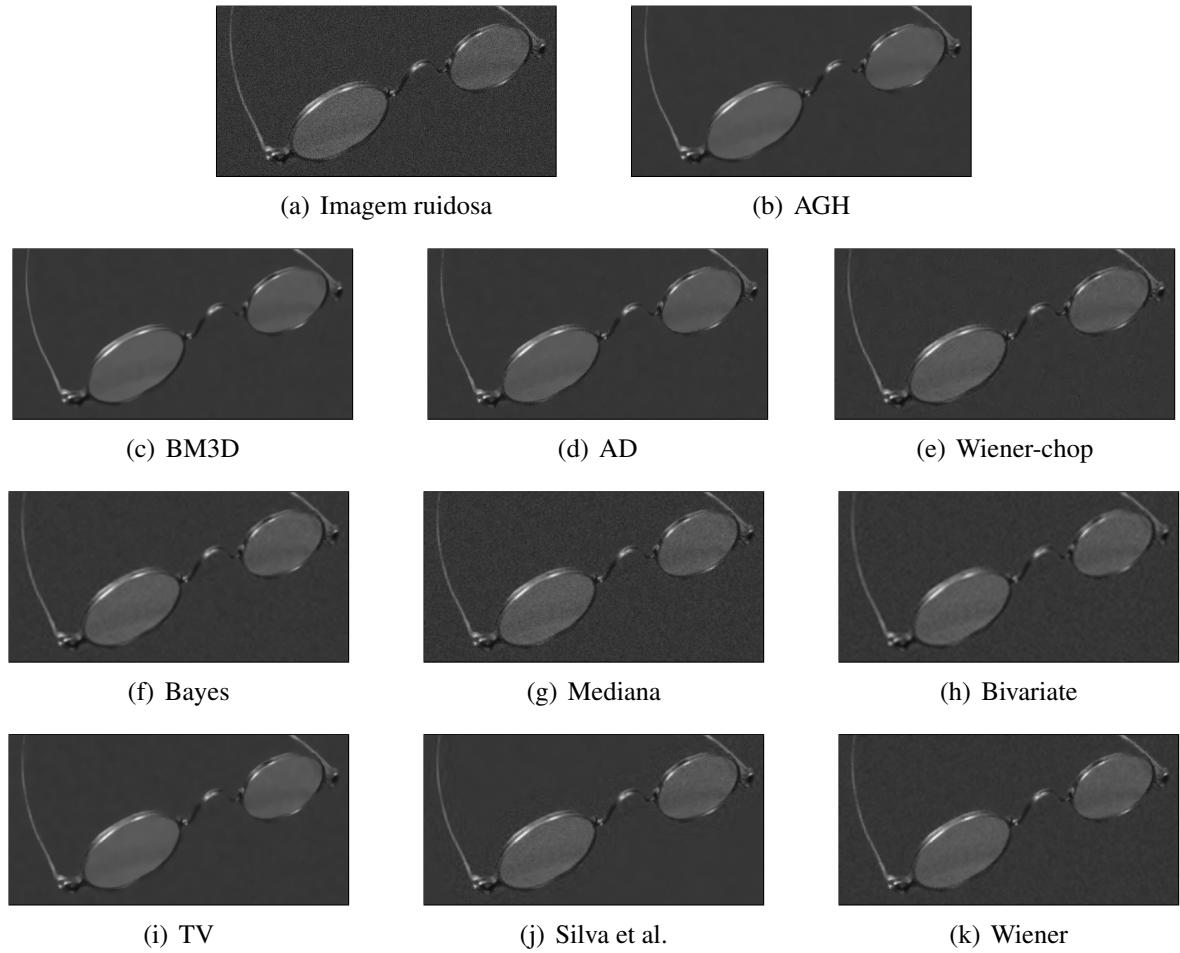
ZOSSO, D.; BUSTIN, A. A Primal-Dual Projected Gradient Algorithm for Efficient Beltrami Regularization. In: **Gordon Research Conference - Image Science**. Stonehill College, Easton, MA, USA: [s.n.], 2014. Citado 6 vezes nas páginas 39, 40, 45, 49, 50 e 60.



IMAGENS RESULTANTES DOS TESTES COMPUTACIONAIS

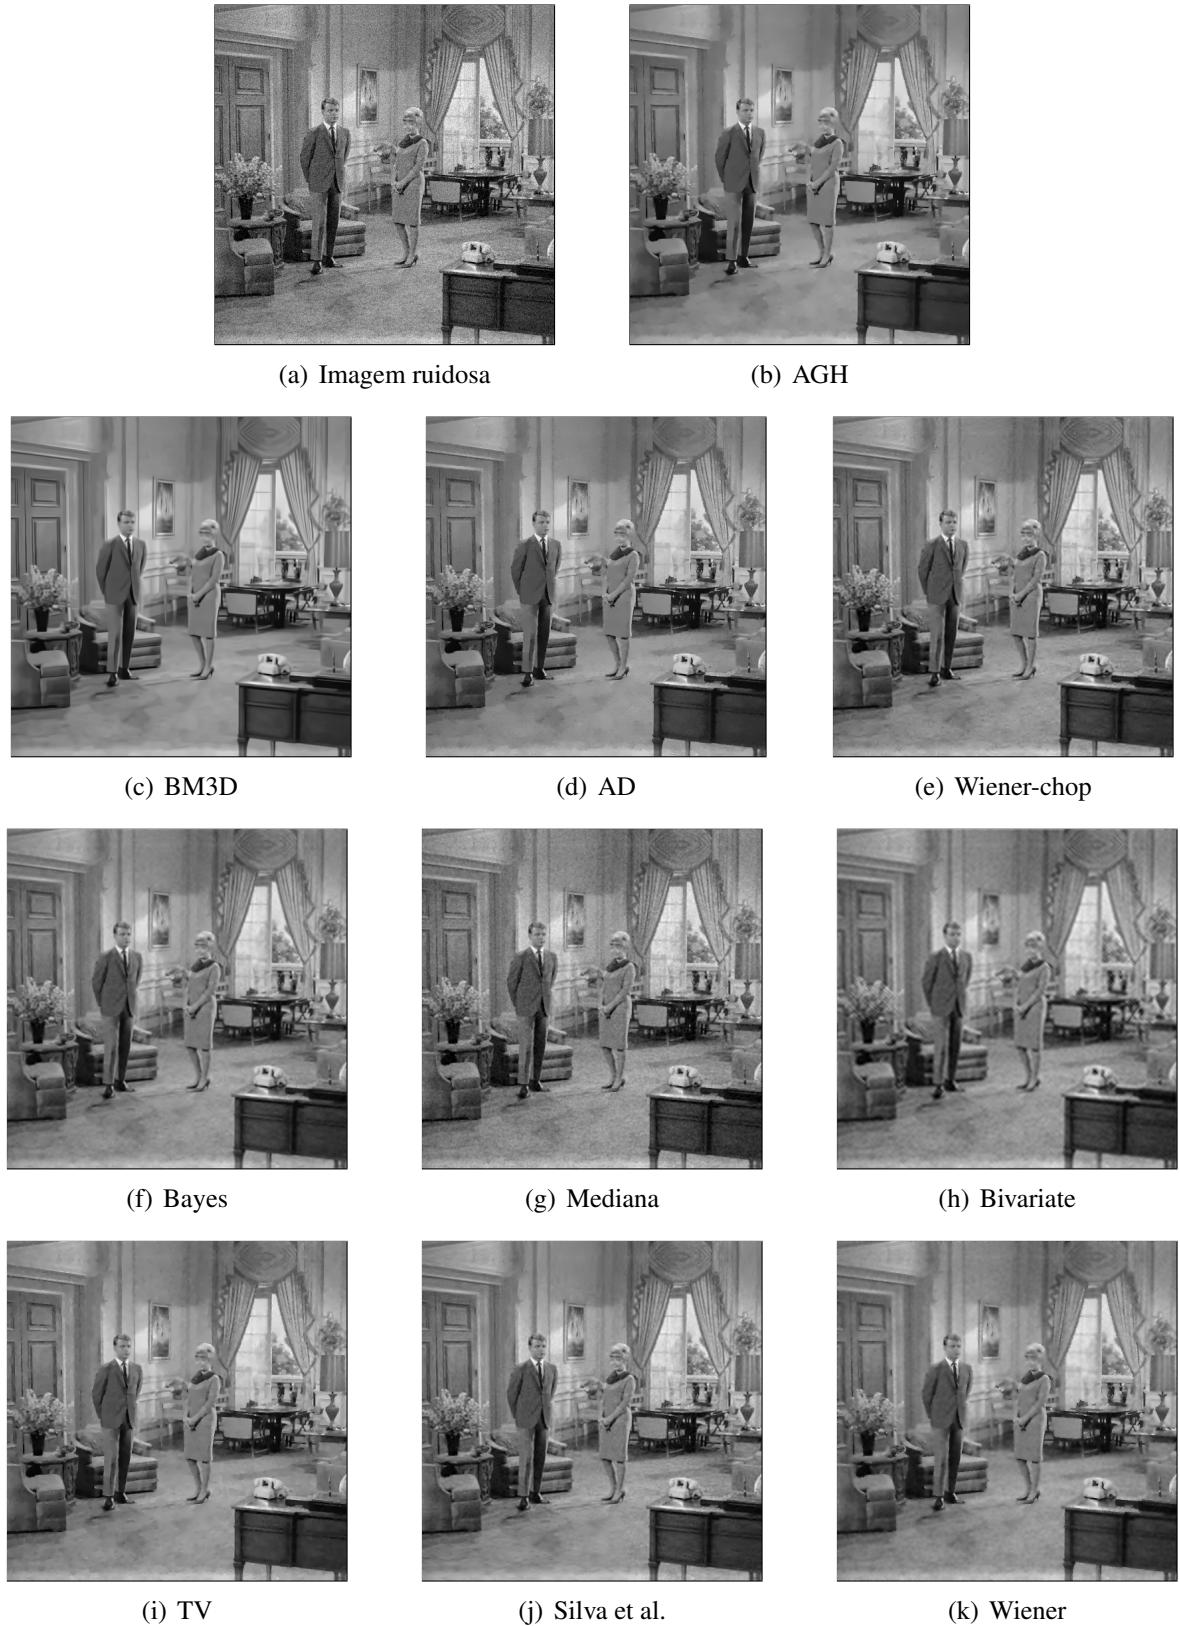
A.1 Imagens da comparação do AGH com métodos da literatura

Figura 23 – Imagem *Glasses* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 10$ tratada pelos diversos métodos comparados.



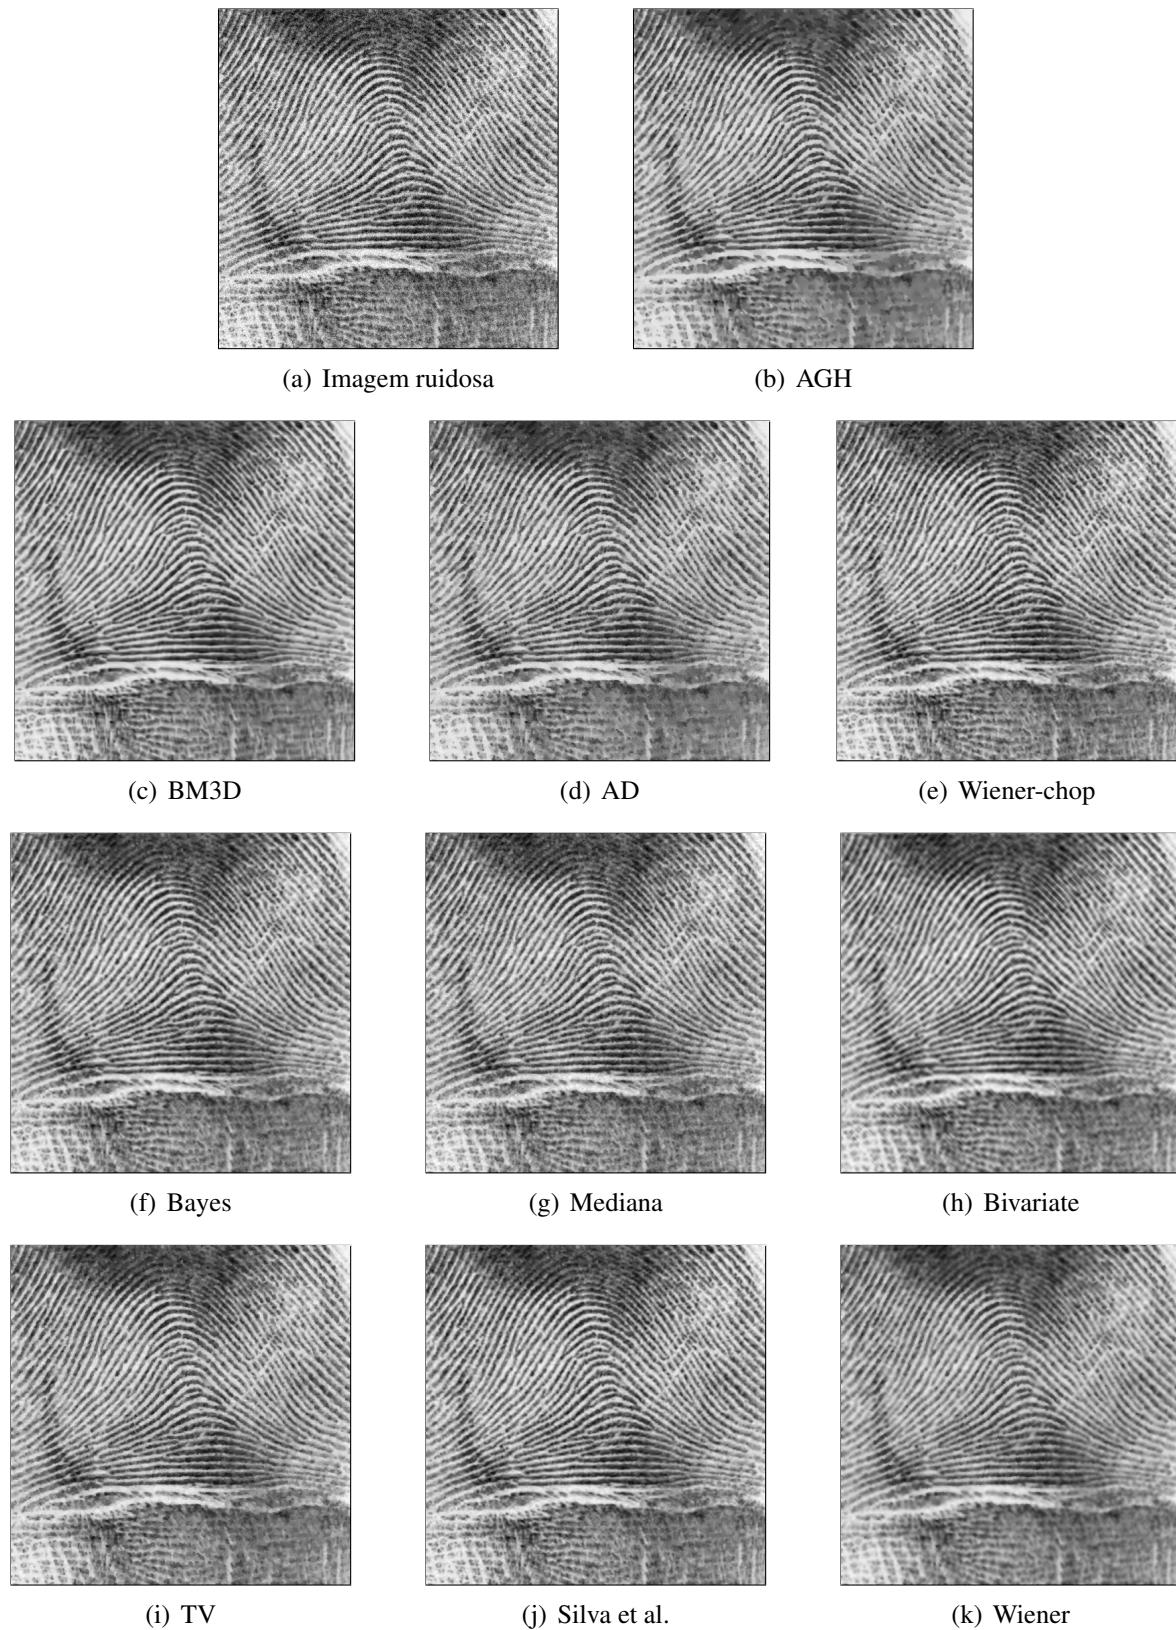
Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 24 – Imagem *Couple* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 15$ tratada pelos diversos métodos comparados.



Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 25 – Imagem *Fingerprint* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 20$ tratada pelos diversos métodos comparados.



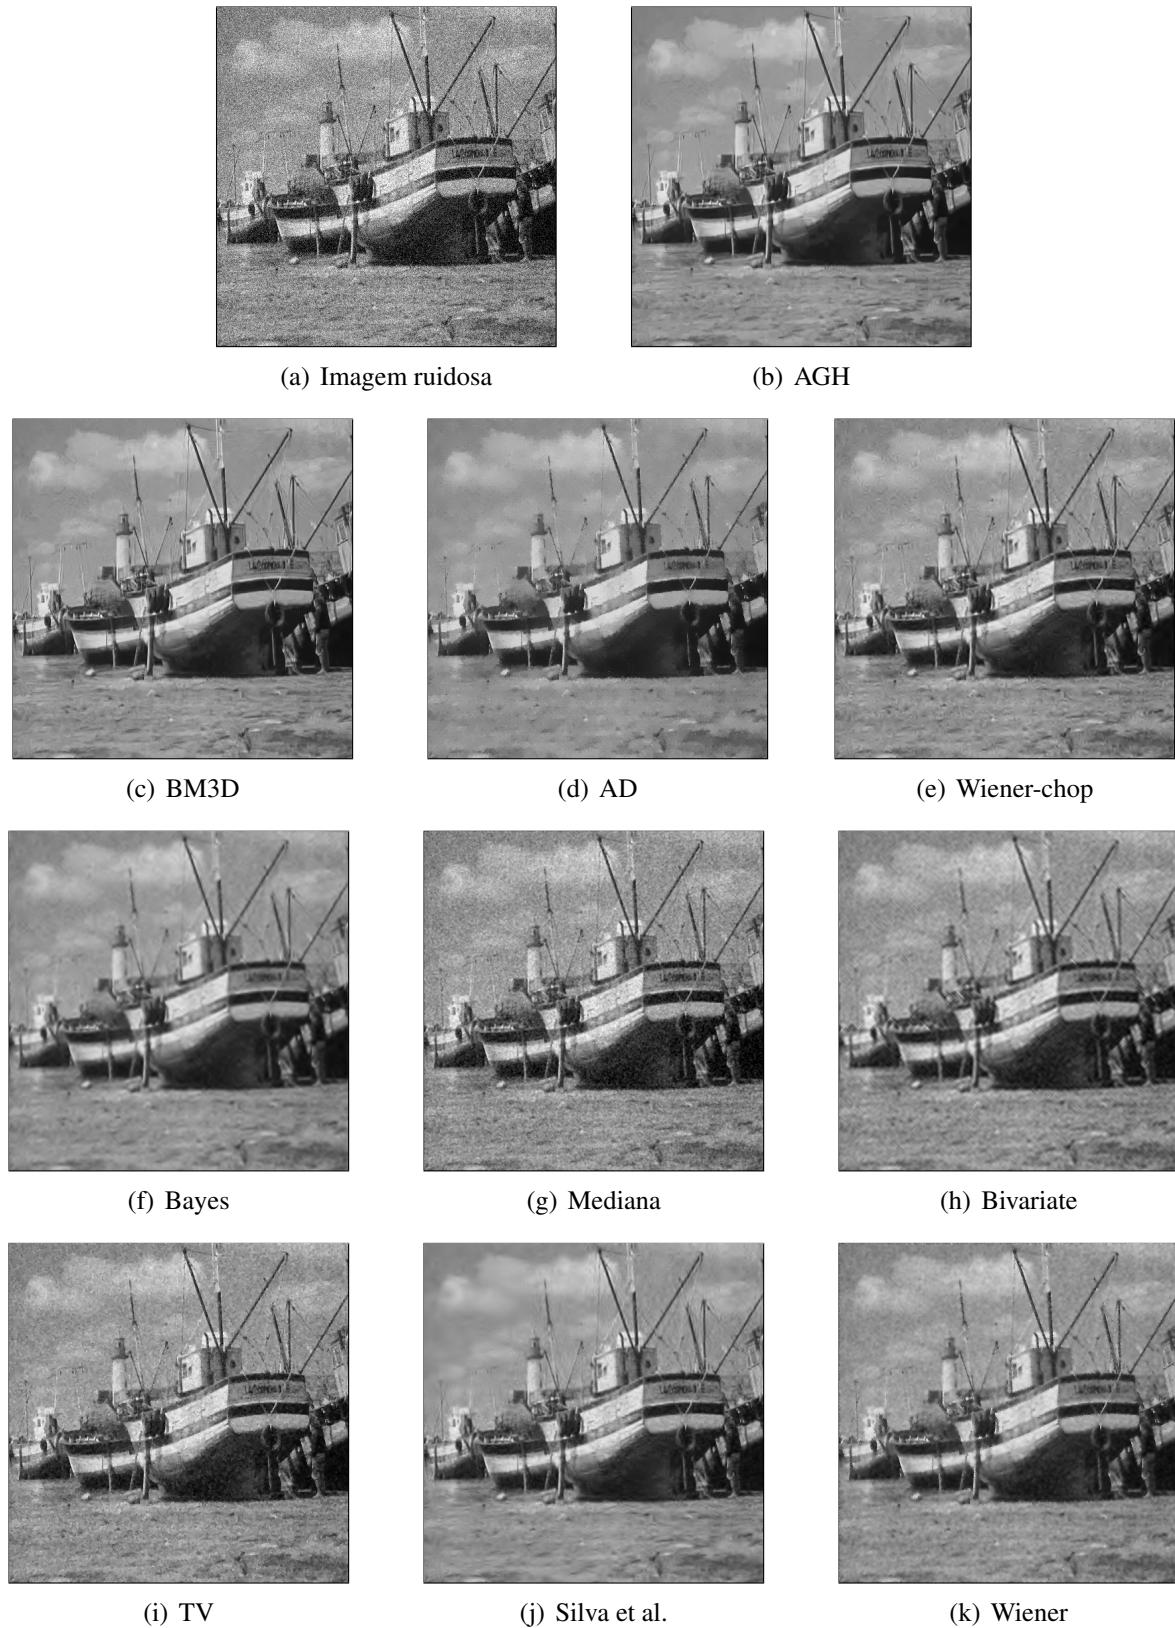
Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 26 – Imagem *Lenna* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 25$ tratada pelos diversos métodos comparados.



Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 27 – Imagem *Boat* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 30$ tratada pelos diversos métodos comparados.



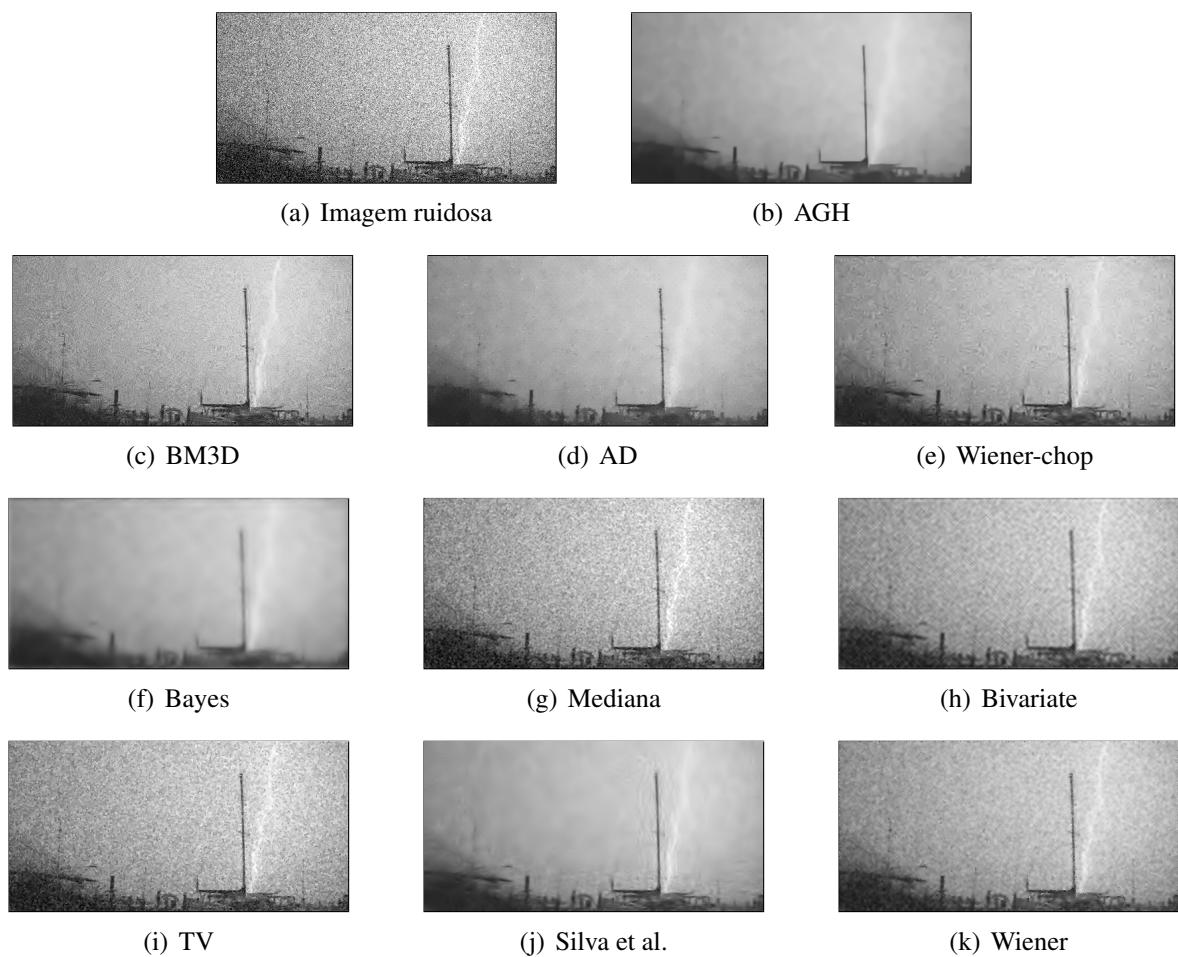
Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 28 – Imagem *Barbara* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 35$ tratada pelos diversos métodos comparados.



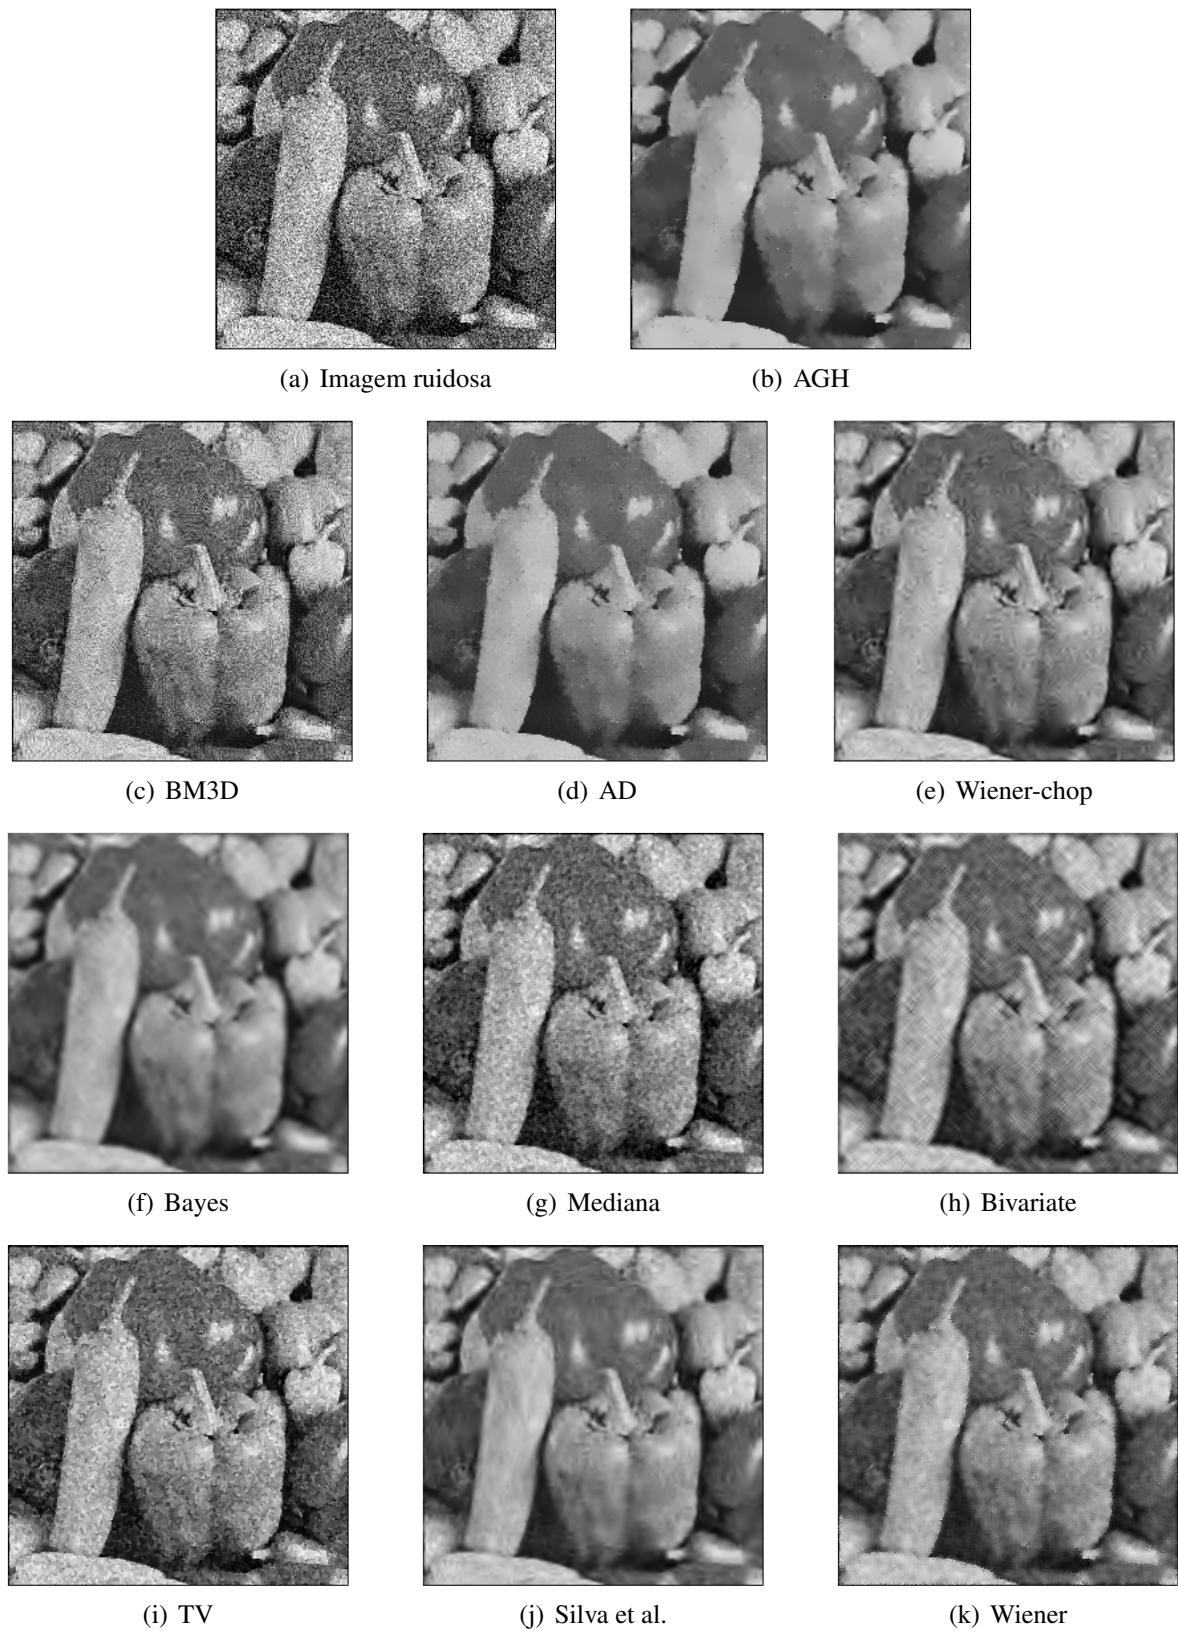
Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 29 – Imagem *Lightning* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 40$ tratada pelos diversos métodos comparados.



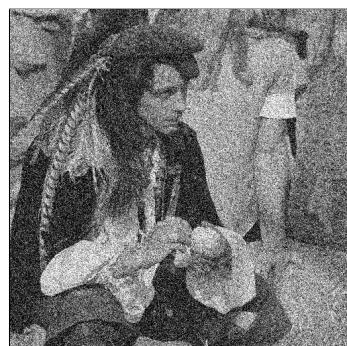
Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 30 – Imagem *Peppers* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 45$ tratada pelos diversos métodos comparados.



Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

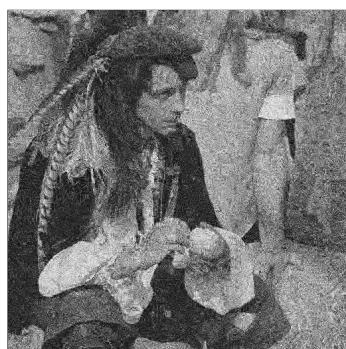
Figura 31 – Imagem *Man* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 50$ tratada pelos diversos métodos comparados.



(a) Imagem ruidosa



(b) AGH



(c) BM3D



(d) AD



(e) Wiener-chop



(f) Bayes



(g) Mediana



(h) Bivariate



(i) TV



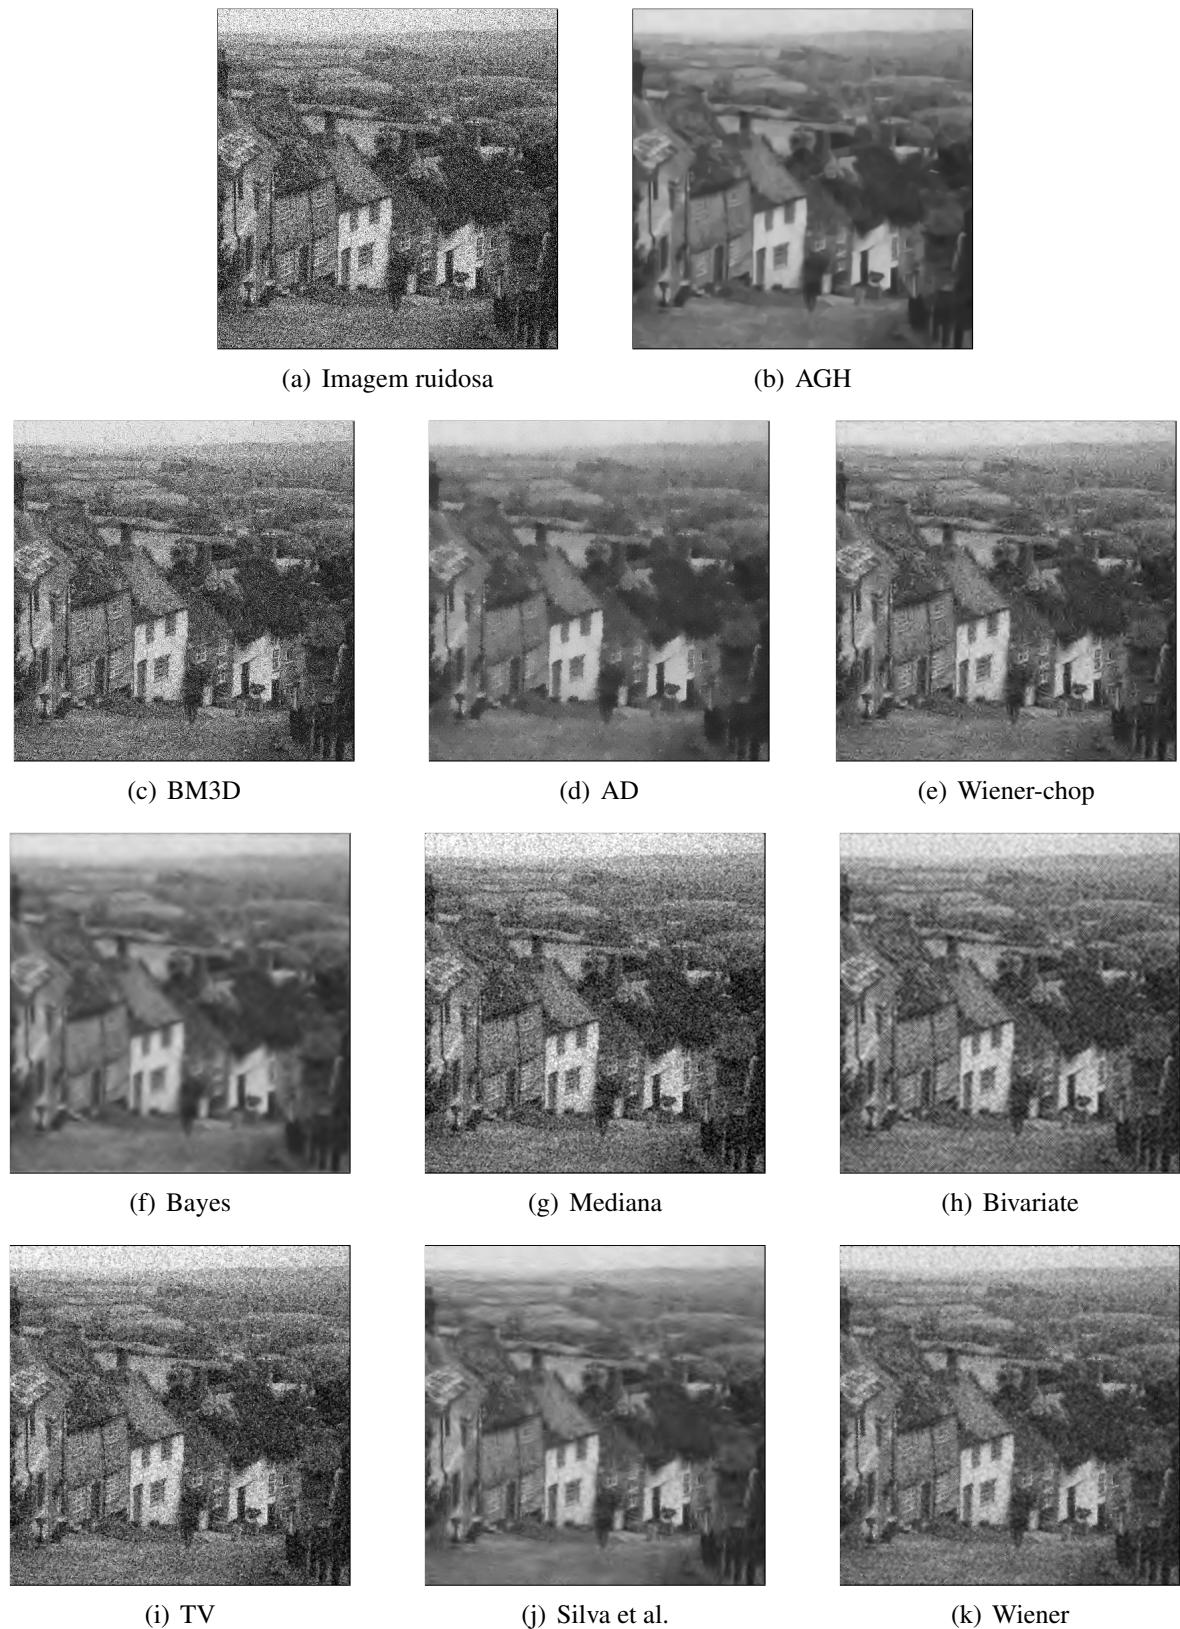
(j) Silva et al.



(k) Wiener

Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 32 – Imagem *Hill* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 55$ tratada pelos diversos métodos comparados.



Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 33 – Imagem *Cameraman* corrompida por um ruído branco aditivo Gaussiano com $\sigma = 60$ tratada pelos diversos métodos comparados.



(a) Imagem ruidosa



(b) AGH



(c) BM3D



(d) AD



(e) Wiener-chop



(f) Bayes



(g) Mediana



(h) Bivariate



(i) TV



(j) Silva et al.

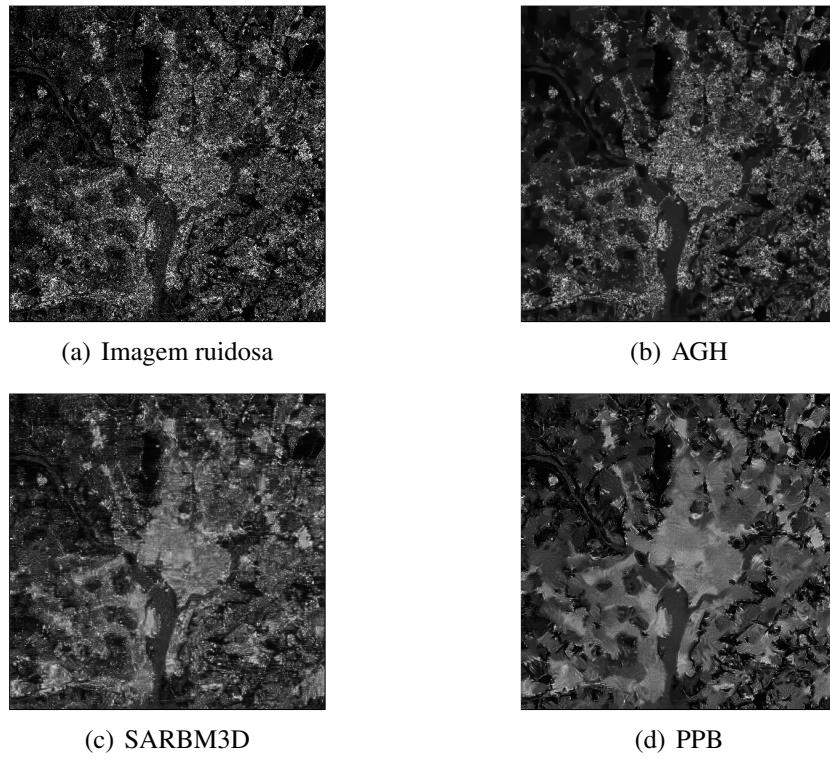


(k) Wiener

Fonte: Adaptada de Gonzalez, Woods e Eddins (2005).

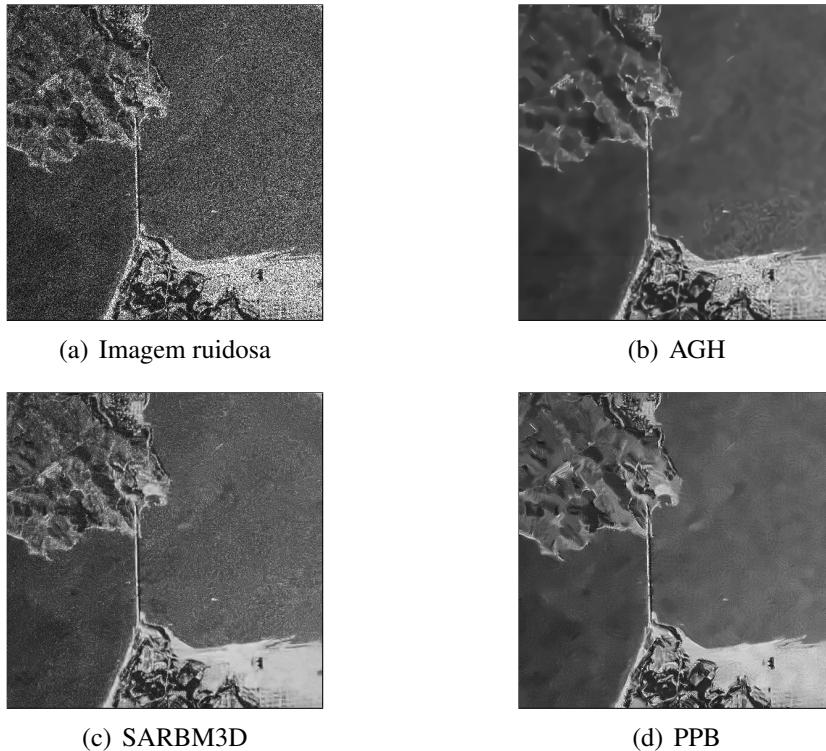
A.2 Imagens SAR resultantes da comparação do AGH com métodos da literatura

Figura 34 – Imagem *Washington* corrompida por um ruído Speckle multiplicativo com $L = 1$ tratada pelos diversos métodos comparados.



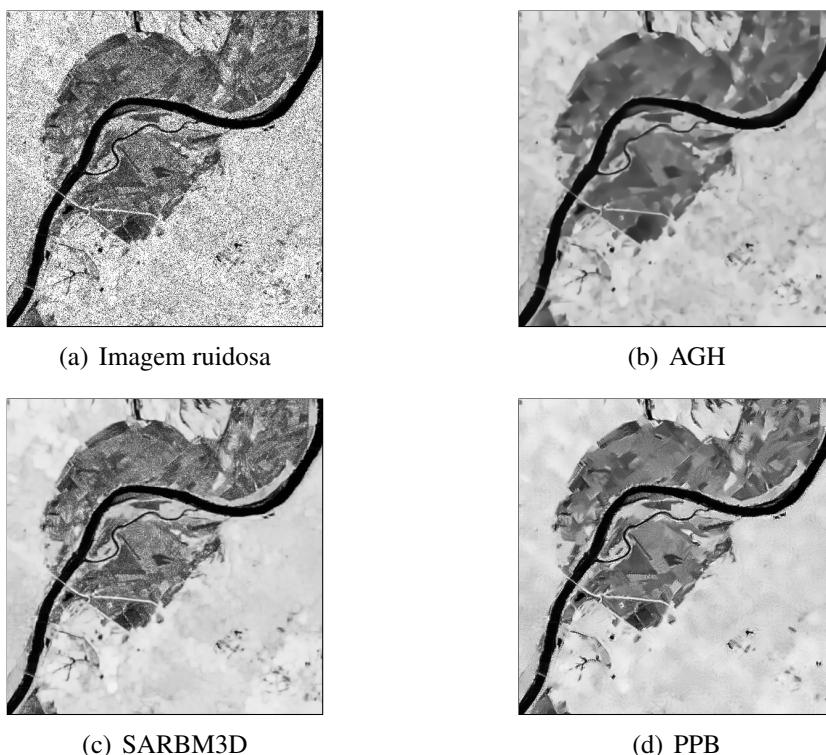
Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 35 – Imagem *San Francisco* corrompida por um ruído Speckle multiplicativo com $L = 2$ tratada pelos diversos métodos comparados.



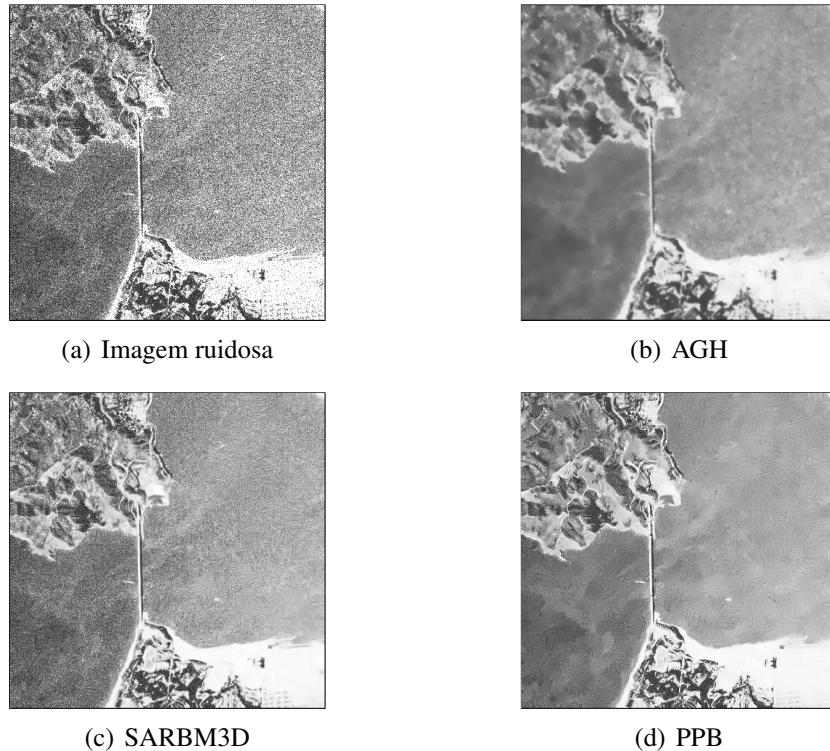
Fonte: Adaptada de [Nozzoli \(2012\)](#).

Figura 36 – Imagem *Mississippi* corrompida por um ruído Speckle multiplicativo com $L = 3$ tratada pelos diversos métodos comparados.



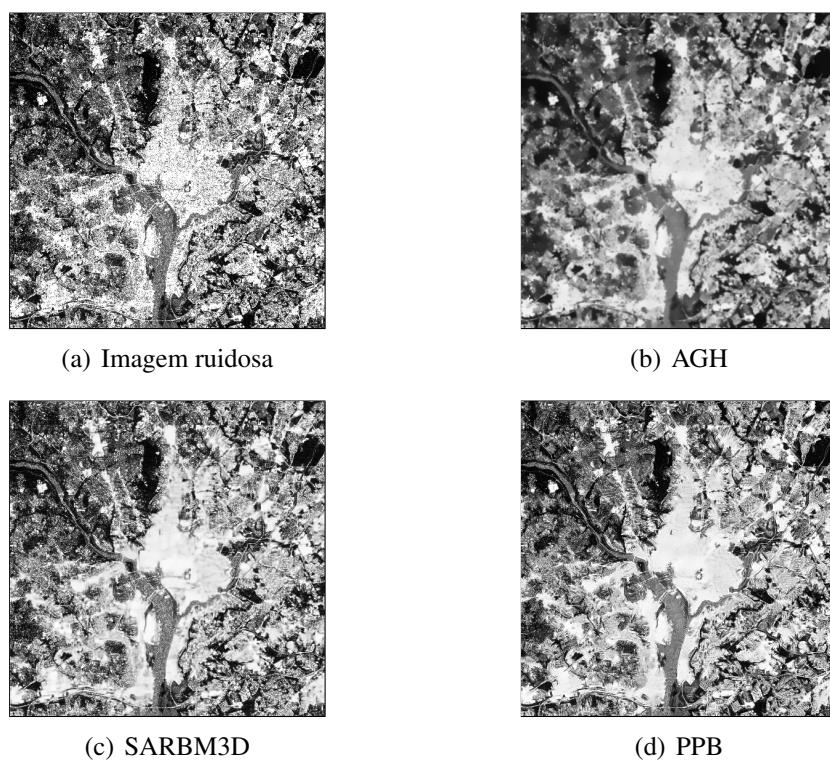
Fonte: Adaptada de [Baumann \(1996\)](#).

Figura 37 – Imagem *San Francisco* corrompida por um ruído Speckle multiplicativo com $L = 5$ tratada pelos diversos métodos comparados.



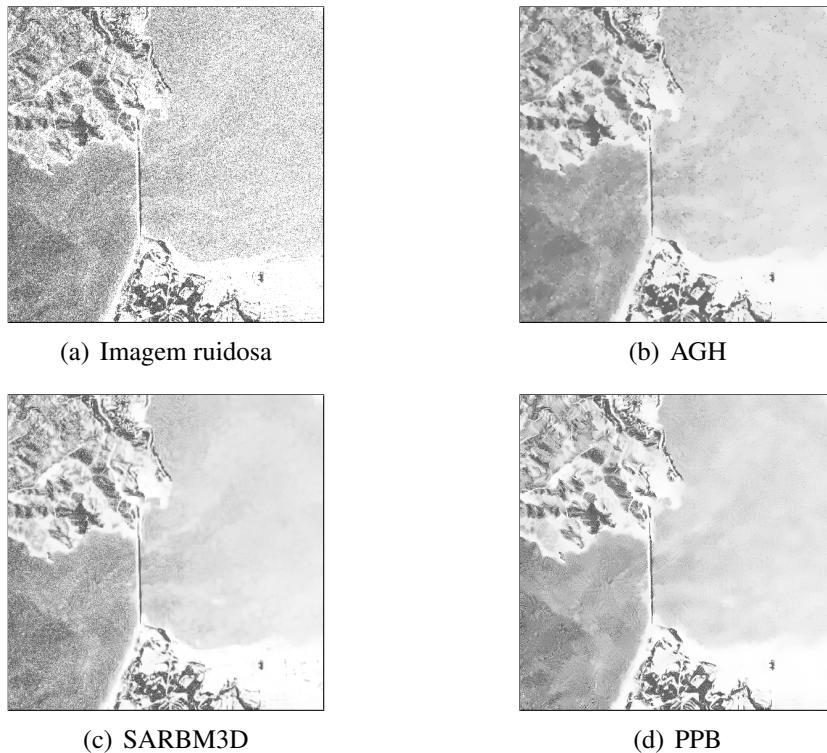
Fonte: Adaptada de [Nozzoli \(2012\)](#).

Figura 38 – Imagem *Washington* corrompida por um ruído Speckle multiplicativo com $L = 6$ tratada pelos diversos métodos comparados.



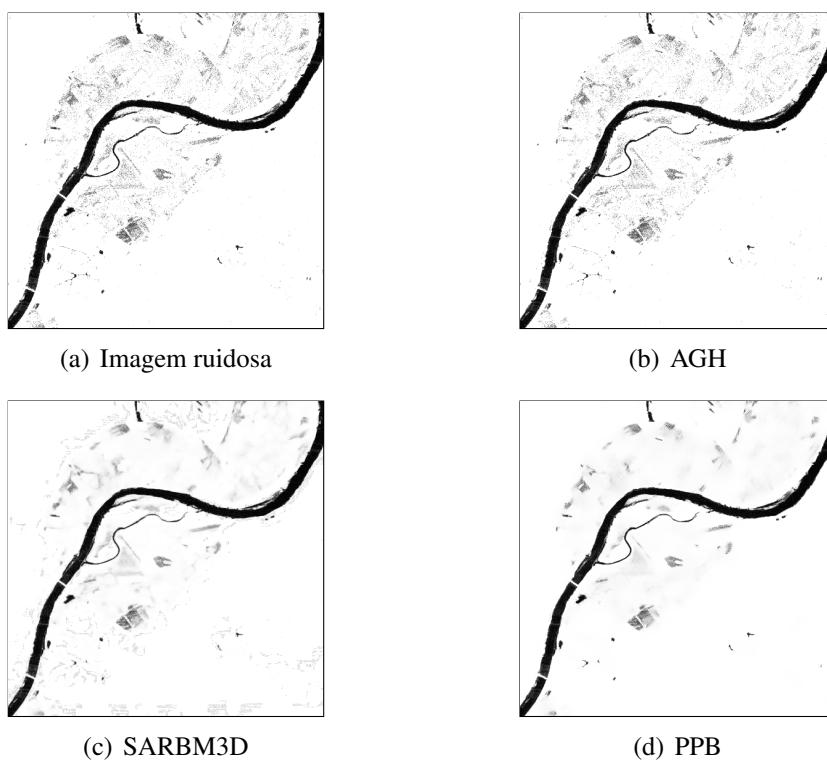
Fonte: Adaptada de [Gonzalez, Woods e Eddins \(2005\)](#).

Figura 39 – Imagem *San Francisco* corrompida por um ruído Speckle multiplicativo com $L = 8$ tratada pelos diversos métodos comparados.

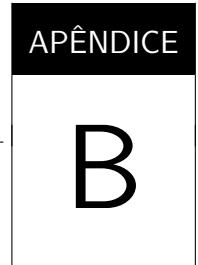


Fonte: Adaptada de [Nozzoli \(2012\)](#).

Figura 40 – Imagem *Mississippi* corrompida por um ruído Speckle multiplicativo com $L = 12$ tratada pelos diversos métodos comparados.



Fonte: Adaptada de [Baumann \(1996\)](#).



TABELAS DE RESULTADOS COMPUTACIONAIS

B.1 Resultados da comparação do AGH com métodos da literatura

Tabela 39 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Barbara*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Barbara	10	26,96	30,92	24,96	30,89	24,88	28,03	31,55	32,26	26,48	30,89	28,47
Barbara	15	26,23	27,51	24,71	28,67	24,39	27,15	29,01	31,91	26,28	28,92	25,61
Barbara	20	25,61	25,54	24,40	27,14	23,83	26,26	27,26	31,41	25,77	27,15	24,67
Barbara	25	25,11	24,81	24,03	26,08	23,22	25,48	26,01	30,66	25,01	26,11	24,14
Barbara	30	24,68	24,35	23,60	25,27	22,58	24,75	25,10	28,95	24,02	25,22	24,19
Barbara	35	24,36	23,99	23,15	24,71	21,98	24,16	24,47	25,91	22,99	24,51	23,59
Barbara	40	24,02	23,56	22,69	24,18	21,34	23,52	23,87	22,46	21,86	24,01	23,27
Barbara	45	23,70	23,25	22,21	23,73	20,72	23,00	23,44	19,77	20,82	23,49	22,80
Barbara	50	23,42	22,85	21,75	23,34	20,14	22,48	23,03	17,87	19,82	23,34	22,39
Barbara	55	23,14	22,56	21,26	22,96	19,59	22,03	22,69	16,49	18,92	22,88	22,13
Barbara	60	22,86	22,30	20,81	22,58	19,05	21,56	22,33	15,49	18,12	22,75	22,19

Fonte: Dados da pesquisa.

Tabela 40 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Barbara*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Barbara	10	0,825	0,888	0,757	0,890	0,734	0,795	0,892	0,909	0,790	0,890	0,851
Barbara	15	0,787	0,811	0,729	0,843	0,671	0,770	0,840	0,905	0,785	0,839	0,761
Barbara	20	0,754	0,745	0,694	0,796	0,605	0,738	0,788	0,897	0,745	0,792	0,717
Barbara	25	0,727	0,712	0,655	0,754	0,545	0,705	0,742	0,886	0,677	0,755	0,679
Barbara	30	0,706	0,692	0,615	0,723	0,493	0,672	0,702	0,838	0,602	0,726	0,678
Barbara	35	0,686	0,669	0,573	0,687	0,446	0,633	0,667	0,693	0,529	0,689	0,643
Barbara	40	0,669	0,649	0,537	0,658	0,405	0,595	0,632	0,514	0,463	0,667	0,637
Barbara	45	0,651	0,632	0,504	0,630	0,369	0,560	0,604	0,385	0,407	0,646	0,610
Barbara	50	0,636	0,613	0,472	0,606	0,338	0,525	0,579	0,303	0,361	0,638	0,599
Barbara	55	0,622	0,600	0,444	0,582	0,311	0,495	0,556	0,250	0,322	0,615	0,584
Barbara	60	0,610	0,586	0,415	0,556	0,287	0,464	0,532	0,216	0,288	0,612	0,588

Fonte: Dados da pesquisa.

Tabela 41 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Boat*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Boat	10	32,61	30,32	26,79	32,24	29,41	30,04	32,34	31,04	30,46	32,38	32,08
Boat	15	30,73	29,05	26,49	30,55	28,18	29,02	30,39	30,66	29,87	30,60	30,10
Boat	20	29,47	27,95	26,09	29,38	26,96	28,12	28,98	30,32	28,88	30,05	28,71
Boat	25	28,42	26,96	25,57	28,40	25,77	27,18	27,86	29,84	27,36	29,06	27,78
Boat	30	27,67	26,19	25,02	27,60	24,67	26,36	26,98	28,60	25,72	28,68	26,99
Boat	35	27,11	25,59	24,43	26,97	23,72	25,63	26,26	25,74	24,12	27,39	25,41
Boat	40	26,55	24,99	23,80	26,36	22,82	24,88	25,59	22,40	22,69	26,61	24,73
Boat	45	26,04	24,58	23,12	25,72	21,96	24,20	25,03	19,57	21,33	25,85	24,85
Boat	50	25,62	24,16	22,63	25,22	21,23	23,63	24,52	17,68	20,23	25,43	24,12
Boat	55	25,10	23,80	22,04	24,67	20,50	23,04	24,01	16,28	19,14	25,00	23,01
Boat	60	24,68	23,37	21,58	24,23	19,87	22,56	23,62	15,23	18,25	24,58	23,14

Fonte: Dados da pesquisa.

Tabela 42 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Boat*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Boat	10	0,862	0,834	0,738	0,857	0,780	0,780	0,852	0,820	0,803	0,847	0,834
Boat	15	0,822	0,794	0,713	0,821	0,715	0,757	0,805	0,811	0,795	0,810	0,792
Boat	20	0,790	0,753	0,677	0,788	0,647	0,733	0,763	0,806	0,761	0,800	0,760
Boat	25	0,759	0,716	0,637	0,754	0,582	0,701	0,723	0,799	0,689	0,773	0,720
Boat	30	0,734	0,687	0,597	0,723	0,525	0,666	0,688	0,759	0,605	0,772	0,707
Boat	35	0,716	0,665	0,557	0,696	0,477	0,630	0,657	0,604	0,519	0,723	0,646
Boat	40	0,697	0,642	0,519	0,672	0,433	0,591	0,628	0,436	0,450	0,691	0,639
Boat	45	0,678	0,626	0,478	0,639	0,392	0,551	0,598	0,318	0,386	0,669	0,627
Boat	50	0,664	0,609	0,452	0,616	0,360	0,521	0,573	0,249	0,338	0,652	0,614
Boat	55	0,644	0,595	0,421	0,588	0,329	0,487	0,546	0,203	0,294	0,639	0,571
Boat	60	0,633	0,579	0,399	0,571	0,304	0,462	0,527	0,171	0,261	0,628	0,576

Fonte: Dados da pesquisa.

Tabela 43 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Cameraman*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Cameraman	10	31,46	31,36	24,01	31,20	26,57	29,15	33,09	30,19	29,18	33,04	31,19
Cameraman	15	29,68	28,55	23,81	29,25	25,84	28,19	30,81	29,97	28,89	30,84	30,13
Cameraman	20	28,30	26,98	23,51	27,88	25,01	27,16	29,24	29,70	27,90	29,59	29,18
Cameraman	25	27,16	25,77	23,16	26,81	24,24	26,17	27,91	29,10	26,77	28,67	27,93
Cameraman	30	26,34	25,04	22,75	26,00	23,49	25,33	26,80	28,25	25,42	27,48	26,92
Cameraman	35	25,46	24,25	22,26	25,19	22,65	24,44	25,82	25,66	23,88	26,29	25,53
Cameraman	40	24,86	23,67	21,85	24,56	21,97	23,69	24,99	22,80	22,64	25,45	24,43
Cameraman	45	24,14	22,99	21,34	23,91	21,25	22,92	24,17	19,92	21,32	24,66	23,36
Cameraman	50	23,57	22,26	20,87	23,29	20,61	22,24	23,39	18,08	20,24	23,84	23,19
Cameraman	55	23,07	21,91	20,39	22,83	19,94	21,65	22,79	16,68	19,23	23,32	22,81
Cameraman	60	22,68	21,54	20,03	22,45	19,48	21,22	22,32	15,74	18,48	22,85	22,19

Fonte: Dados da pesquisa.

Tabela 44 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Cameraman*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Cameraman	10	0,851	0,878	0,761	0,886	0,776	0,817	0,911	0,862	0,857	0,909	0,890
Cameraman	15	0,816	0,823	0,724	0,847	0,690	0,791	0,870	0,856	0,849	0,872	0,860
Cameraman	20	0,785	0,788	0,677	0,810	0,615	0,761	0,832	0,852	0,801	0,851	0,843
Cameraman	25	0,760	0,755	0,623	0,771	0,547	0,726	0,791	0,845	0,711	0,841	0,812
Cameraman	30	0,740	0,734	0,569	0,736	0,495	0,692	0,746	0,807	0,621	0,817	0,781
Cameraman	35	0,714	0,709	0,522	0,697	0,440	0,649	0,711	0,642	0,529	0,773	0,757
Cameraman	40	0,697	0,684	0,475	0,656	0,402	0,604	0,667	0,488	0,458	0,753	0,711
Cameraman	45	0,683	0,669	0,441	0,635	0,371	0,564	0,634	0,384	0,401	0,730	0,702
Cameraman	50	0,665	0,643	0,412	0,603	0,344	0,523	0,600	0,317	0,358	0,710	0,695
Cameraman	55	0,650	0,631	0,379	0,574	0,313	0,481	0,562	0,253	0,312	0,695	0,675
Cameraman	60	0,636	0,621	0,359	0,558	0,293	0,456	0,540	0,221	0,287	0,682	0,661

Fonte: Dados da pesquisa.

Tabela 45 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Couple*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Couple	10	31,93	30,00	26,42	31,62	29,09	29,08	32,31	30,93	30,10	32,40	31,69
Couple	15	30,08	28,78	26,14	29,96	27,95	28,22	30,12	30,58	29,50	30,25	29,61
Couple	20	28,88	27,61	25,73	28,87	26,70	27,36	28,55	30,17	28,49	29,18	27,75
Couple	25	28,02	26,60	25,27	27,98	25,58	26,57	27,34	29,58	27,07	27,93	26,61
Couple	30	27,33	25,80	24,74	27,23	24,53	25,81	26,47	28,30	25,50	28,13	25,85
Couple	35	26,73	25,07	24,18	26,57	23,58	25,14	25,75	25,52	23,97	26,27	25,83
Couple	40	26,16	24,58	23,55	25,94	22,68	24,44	25,10	22,22	22,58	25,43	24,26
Couple	45	25,72	24,18	23,02	25,44	21,88	23,90	24,59	19,44	21,27	25,00	24,02
Couple	50	25,26	23,72	22,46	24,90	21,15	23,34	24,09	17,53	20,11	25,08	23,42
Couple	55	24,89	23,42	21,97	24,50	20,45	22,87	23,72	16,22	19,08	24,20	23,63
Couple	60	24,49	23,13	21,47	24,02	19,77	22,40	23,35	15,15	18,17	23,80	23,13

Fonte: Dados da pesquisa.

Tabela 46 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Couple*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Couple	10	0,871	0,843	0,716	0,867	0,795	0,764	0,867	0,844	0,812	0,862	0,853
Couple	15	0,827	0,798	0,691	0,827	0,733	0,741	0,814	0,834	0,804	0,813	0,804
Couple	20	0,789	0,750	0,656	0,789	0,663	0,712	0,763	0,826	0,767	0,788	0,751
Couple	25	0,760	0,706	0,618	0,756	0,602	0,683	0,716	0,816	0,700	0,747	0,688
Couple	30	0,732	0,667	0,579	0,721	0,546	0,646	0,674	0,767	0,617	0,775	0,676
Couple	35	0,707	0,633	0,541	0,690	0,495	0,610	0,639	0,614	0,535	0,715	0,653
Couple	40	0,685	0,610	0,502	0,660	0,449	0,570	0,605	0,444	0,466	0,643	0,604
Couple	45	0,667	0,591	0,469	0,634	0,411	0,537	0,575	0,325	0,404	0,623	0,589
Couple	50	0,645	0,568	0,438	0,603	0,375	0,500	0,546	0,255	0,351	0,640	0,557
Couple	55	0,632	0,555	0,414	0,587	0,346	0,476	0,526	0,212	0,310	0,604	0,565
Couple	60	0,615	0,542	0,389	0,560	0,318	0,449	0,504	0,180	0,275	0,588	0,550

Fonte: Dados da pesquisa.

Tabela 47 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Fingerprint*.

Imagen	σ	Wav	Bay	Biv	WIC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Fingerprint	10	31,65	31,17	25,84	31,51	29,12	24,88	30,51	29,05	28,78	30,51	29,99
Fingerprint	15	29,87	29,45	25,53	29,78	27,72	24,58	28,17	28,78	27,98	28,58	27,92
Fingerprint	20	28,47	28,00	25,15	28,38	26,46	24,24	26,50	28,37	26,87	26,55	26,27
Fingerprint	25	27,38	26,83	24,73	27,27	25,36	23,89	25,24	27,72	25,64	25,46	24,84
Fingerprint	30	26,44	25,79	24,23	26,30	24,35	23,48	24,11	26,32	24,32	25,35	23,77
Fingerprint	35	25,66	24,97	23,74	25,49	23,41	23,09	23,23	23,80	23,00	23,60	23,00
Fingerprint	40	25,03	24,24	23,25	24,84	22,60	22,72	22,47	21,24	21,85	23,11	22,21
Fingerprint	45	24,32	23,62	22,63	24,08	21,72	22,27	21,77	19,04	20,70	22,66	21,65
Fingerprint	50	23,81	23,13	22,14	23,58	21,04	21,90	21,19	17,41	19,76	21,98	21,00
Fingerprint	55	23,28	22,62	21,61	23,01	20,31	21,51	20,67	16,17	18,81	21,14	20,29
Fingerprint	60	22,76	22,13	21,20	22,49	19,67	21,15	20,18	15,21	18,01	20,51	19,44

Fonte: Dados da pesquisa.

Tabela 48 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Fingerprint*.

Imagen	σ	Wav	Bay	Biv	WIC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Fingerprint	10	0,961	0,960	0,865	0,961	0,935	0,827	0,951	0,925	0,917	0,951	0,939
Fingerprint	15	0,944	0,941	0,856	0,944	0,914	0,821	0,917	0,922	0,910	0,922	0,904
Fingerprint	20	0,926	0,919	0,846	0,926	0,890	0,813	0,881	0,919	0,894	0,874	0,864
Fingerprint	25	0,906	0,895	0,834	0,906	0,864	0,804	0,845	0,912	0,870	0,843	0,816
Fingerprint	30	0,886	0,869	0,817	0,886	0,836	0,792	0,806	0,888	0,837	0,847	0,773
Fingerprint	35	0,868	0,846	0,803	0,867	0,807	0,782	0,772	0,823	0,796	0,775	0,741
Fingerprint	40	0,850	0,823	0,787	0,850	0,778	0,770	0,736	0,728	0,756	0,763	0,706
Fingerprint	45	0,827	0,802	0,764	0,827	0,745	0,752	0,703	0,627	0,707	0,722	0,670
Fingerprint	50	0,810	0,783	0,745	0,810	0,718	0,738	0,669	0,543	0,665	0,702	0,635
Fingerprint	55	0,791	0,765	0,726	0,791	0,686	0,723	0,638	0,478	0,619	0,658	0,586
Fingerprint	60	0,769	0,743	0,709	0,770	0,659	0,707	0,606	0,426	0,579	0,628	0,528

Fonte: Dados da pesquisa.

Tabela 49 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Glasses*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Glasses	10	40,77	39,64	36,57	40,96	35,17	37,74	40,09	41,67	41,30	40,63	
Glasses	15	38,94	37,32	34,56	38,34	31,94	34,90	37,67	40,70	37,93	40,70	38,46
Glasses	20	37,12	35,54	32,38	36,02	29,50	32,55	35,84	39,45	33,69	39,45	37,16
Glasses	25	36,12	34,79	30,85	34,57	27,66	30,98	34,36	38,50	30,21	38,50	38,44
Glasses	30	35,10	34,05	29,49	33,48	26,16	29,80	33,36	35,59	27,57	36,57	33,67
Glasses	35	34,28	33,25	28,27	32,47	24,88	28,77	32,36	30,23	25,49	35,12	32,66
Glasses	40	33,09	32,39	26,97	31,08	23,62	27,63	31,22	25,39	23,62	33,83	31,77
Glasses	45	32,29	31,56	26,15	30,51	22,78	26,87	30,61	21,93	22,34	33,26	32,12
Glasses	50	31,43	30,91	25,20	29,50	21,86	26,05	29,70	19,38	21,16	31,92	30,73
Glasses	55	30,21	29,86	24,35	28,57	21,03	25,15	28,92	17,67	20,12	30,98	30,08
Glasses	60	29,24	28,94	23,58	27,64	20,36	24,50	27,99	16,42	19,21	30,50	28,75

Fonte: Dados da pesquisa.

Tabela 50 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Glasses*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Glasses	10	0,968	0,967	0,927	0,964	0,833	0,946	0,964	0,981	0,976	0,978	0,974
Glasses	15	0,959	0,952	0,865	0,936	0,704	0,888	0,938	0,978	0,956	0,978	0,961
Glasses	20	0,946	0,940	0,781	0,897	0,580	0,809	0,908	0,973	0,846	0,973	0,954
Glasses	25	0,939	0,936	0,709	0,861	0,483	0,738	0,873	0,964	0,674	0,965	0,964
Glasses	30	0,935	0,935	0,644	0,836	0,404	0,675	0,849	0,887	0,518	0,958	0,933
Glasses	35	0,930	0,933	0,582	0,806	0,342	0,621	0,818	0,613	0,392	0,952	0,896
Glasses	40	0,919	0,926	0,517	0,760	0,284	0,565	0,778	0,331	0,292	0,943	0,926
Glasses	45	0,924	0,922	0,481	0,751	0,251	0,529	0,763	0,187	0,235	0,941	0,933
Glasses	50	0,917	0,918	0,433	0,714	0,217	0,487	0,733	0,119	0,191	0,932	0,913
Glasses	55	0,910	0,914	0,402	0,700	0,187	0,450	0,722	0,085	0,157	0,926	0,912
Glasses	60	0,906	0,908	0,370	0,669	0,166	0,421	0,693	0,066	0,131	0,922	0,903

Fonte: Dados da pesquisa.

Tabela 51 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Hill*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Hill	10	32,04	30,58	28,13	31,85	29,93	30,27	32,25	30,73	30,55	32,17	31,30
Hill	15	30,51	29,26	27,72	30,43	28,61	29,40	30,34	30,46	30,11	30,50	30,20
Hill	20	29,52	28,23	27,22	29,37	27,35	28,56	29,08	30,15	29,11	29,72	28,84
Hill	25	28,77	27,42	26,63	28,55	26,07	27,76	28,14	29,79	27,57	29,79	28,30
Hill	30	28,19	26,79	25,96	27,87	24,96	26,98	27,37	28,72	25,95	28,96	27,20
Hill	35	27,67	26,31	25,32	27,26	23,96	26,26	26,80	26,10	24,38	27,72	26,53
Hill	40	27,15	25,82	24,51	26,62	22,97	25,45	26,17	22,48	22,80	27,13	25,99
Hill	45	26,75	25,45	23,89	26,14	22,15	24,83	25,74	19,86	21,58	26,42	25,56
Hill	50	26,23	24,99	23,15	25,54	21,34	24,13	25,18	17,84	20,35	25,73	25,15
Hill	55	25,93	24,68	22,63	25,17	20,65	23,61	24,85	16,51	19,36	25,70	24,84
Hill	60	25,47	24,26	22,07	24,63	19,99	23,10	24,40	15,46	18,45	25,24	24,06

Fonte: Dados da pesquisa.

Tabela 52 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Hill*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Hill	10	0,848	0,823	0,744	0,844	0,780	0,762	0,842	0,791	0,780	0,831	0,821
Hill	15	0,802	0,769	0,717	0,802	0,712	0,741	0,783	0,783	0,777	0,783	0,768
Hill	20	0,767	0,724	0,683	0,767	0,646	0,715	0,736	0,778	0,745	0,756	0,731
Hill	25	0,738	0,690	0,648	0,736	0,578	0,686	0,699	0,775	0,677	0,775	0,710
Hill	30	0,715	0,663	0,608	0,707	0,519	0,652	0,663	0,738	0,596	0,752	0,653
Hill	35	0,691	0,643	0,570	0,678	0,466	0,617	0,636	0,606	0,513	0,700	0,637
Hill	40	0,671	0,623	0,526	0,649	0,417	0,577	0,605	0,421	0,433	0,669	0,629
Hill	45	0,656	0,608	0,496	0,630	0,378	0,545	0,584	0,302	0,375	0,652	0,604
Hill	50	0,638	0,591	0,460	0,603	0,341	0,510	0,559	0,222	0,317	0,631	0,591
Hill	55	0,627	0,578	0,432	0,586	0,310	0,483	0,540	0,178	0,276	0,618	0,586
Hill	60	0,614	0,567	0,406	0,564	0,284	0,458	0,522	0,147	0,242	0,608	0,556

Fonte: Dados da pesquisa.

Tabela 53 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Lenna*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Lenna	10	34,40	33,33	30,14	34,36	32,12	32,66	34,18	33,57	33,06	34,48	34,08
Lenna	15	32,72	31,84	29,51	32,73	30,04	31,22	32,16	33,13	32,23	32,63	32,17
Lenna	20	31,65	30,56	28,74	31,51	28,36	29,99	30,79	32,72	30,59	32,72	31,21
Lenna	25	30,72	29,48	27,88	30,47	26,82	28,84	29,68	32,02	28,46	32,02	30,10
Lenna	30	30,08	28,76	27,02	29,65	25,53	27,86	28,83	30,46	26,48	30,74	29,21
Lenna	35	29,43	27,98	26,24	28,87	24,38	26,99	28,16	27,04	24,63	29,08	28,25
Lenna	40	28,81	27,51	25,36	28,07	23,30	26,09	27,38	23,05	22,99	28,91	27,60
Lenna	45	28,30	27,03	24,52	27,42	22,43	25,37	26,86	19,93	21,63	28,24	27,02
Lenna	50	27,73	26,50	23,76	26,75	21,58	24,64	26,26	17,85	20,39	27,37	26,34
Lenna	55	27,18	25,99	23,15	26,23	20,81	24,04	25,80	16,42	19,36	27,33	25,64
Lenna	60	26,73	25,47	22,55	25,65	20,12	23,49	25,29	15,34	18,44	26,85	25,14

Fonte: Dados da pesquisa.

Tabela 54 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Lenna*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Lenna	10	0,891	0,888	0,843	0,897	0,822	0,860	0,888	0,880	0,870	0,892	0,888
Lenna	15	0,863	0,860	0,804	0,867	0,734	0,832	0,850	0,874	0,857	0,866	0,859
Lenna	20	0,844	0,835	0,755	0,839	0,653	0,798	0,815	0,870	0,800	0,870	0,838
Lenna	25	0,825	0,813	0,702	0,808	0,574	0,756	0,782	0,859	0,696	0,859	0,816
Lenna	30	0,811	0,795	0,649	0,777	0,510	0,707	0,751	0,800	0,586	0,826	0,795
Lenna	35	0,796	0,779	0,603	0,748	0,451	0,661	0,723	0,597	0,483	0,798	0,777
Lenna	40	0,782	0,766	0,553	0,714	0,401	0,609	0,688	0,383	0,399	0,798	0,759
Lenna	45	0,775	0,757	0,512	0,689	0,366	0,570	0,663	0,259	0,338	0,783	0,763
Lenna	50	0,762	0,744	0,469	0,662	0,326	0,529	0,637	0,190	0,285	0,769	0,722
Lenna	55	0,750	0,736	0,443	0,644	0,297	0,498	0,618	0,154	0,247	0,770	0,722
Lenna	60	0,746	0,725	0,416	0,618	0,270	0,469	0,593	0,129	0,217	0,760	0,729

Fonte: Dados da pesquisa.

Tabela 55 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Man*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Man	10	32,37	31,31	28,17	32,11	30,20	30,50	32,57	30,38	30,74	32,66	32,27
Man	15	30,53	29,76	27,71	30,51	28,75	29,48	30,47	30,16	30,26	30,73	30,38
Man	20	29,40	28,70	27,19	29,45	27,40	28,56	29,16	29,94	29,19	29,94	29,22
Man	25	28,55	27,75	26,54	28,57	26,10	27,64	28,13	29,57	27,60	29,57	28,14
Man	30	27,86	26,96	25,89	27,83	24,96	26,81	27,31	28,49	25,89	28,53	27,27
Man	35	27,29	26,42	25,22	27,18	23,88	26,06	26,65	25,75	24,23	27,64	26,40
Man	40	26,80	25,85	24,54	26,61	22,98	25,35	26,12	22,51	22,81	26,69	25,87
Man	45	26,27	25,40	23,85	26,01	22,04	24,64	25,53	19,71	21,41	26,24	25,50
Man	50	25,86	25,00	23,22	25,52	21,30	24,02	25,07	17,80	20,30	25,78	24,98
Man	55	25,40	24,61	22,58	24,99	20,56	23,46	24,63	16,39	19,21	25,53	24,18
Man	60	25,02	24,19	22,07	24,53	19,91	22,96	24,17	15,38	18,39	25,09	24,25

Fonte: Dados da pesquisa.

Tabela 56 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Man*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Man	10	0,875	0,867	0,784	0,878	0,813	0,807	0,873	0,818	0,823	0,873	0,860
Man	15	0,829	0,821	0,752	0,837	0,739	0,782	0,818	0,812	0,818	0,831	0,815
Man	20	0,794	0,783	0,714	0,801	0,668	0,756	0,773	0,809	0,779	0,809	0,779
Man	25	0,764	0,749	0,670	0,767	0,598	0,721	0,733	0,803	0,700	0,803	0,751
Man	30	0,739	0,717	0,630	0,735	0,537	0,683	0,699	0,758	0,608	0,770	0,718
Man	35	0,717	0,695	0,588	0,705	0,479	0,643	0,668	0,599	0,517	0,737	0,686
Man	40	0,696	0,673	0,548	0,677	0,436	0,603	0,640	0,421	0,444	0,693	0,660
Man	45	0,678	0,655	0,511	0,650	0,390	0,565	0,612	0,297	0,377	0,695	0,656
Man	50	0,663	0,641	0,478	0,628	0,357	0,532	0,589	0,227	0,328	0,671	0,635
Man	55	0,646	0,627	0,444	0,601	0,325	0,499	0,566	0,184	0,284	0,657	0,620
Man	60	0,636	0,612	0,419	0,583	0,298	0,473	0,544	0,156	0,252	0,648	0,613

Fonte: Dados da pesquisa.

Tabela 57 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Peppers*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Peppers	10	32,84	30,94	24,32	32,62	30,10	30,64	33,38	31,60	32,10	33,60	33,25
Peppers	15	30,73	28,34	24,14	30,73	28,63	29,55	31,20	31,22	31,16	31,70	30,24
Peppers	20	29,17	26,52	23,89	29,26	27,28	28,42	29,61	30,77	29,65	30,32	29,80
Peppers	25	27,97	24,95	23,54	28,02	25,91	27,33	28,38	30,05	27,67	29,45	28,27
Peppers	30	27,15	24,38	23,22	27,11	24,82	26,49	27,26	28,65	25,99	28,52	27,00
Peppers	35	26,29	23,75	22,81	26,15	23,70	25,61	26,41	25,68	24,27	27,02	26,18
Peppers	40	25,59	23,26	22,38	25,25	22,78	24,85	25,64	22,37	22,71	26,34	25,21
Peppers	45	25,10	23,04	21,97	24,56	21,94	24,19	24,86	19,74	21,40	25,50	24,76
Peppers	50	24,45	22,48	21,50	23,89	21,21	23,55	24,25	17,87	20,37	25,03	23,84
Peppers	55	23,96	22,13	21,10	23,32	20,42	22,94	23,65	16,41	19,23	24,11	23,19
Peppers	60	23,58	21,92	20,71	22,84	19,83	22,44	23,16	15,45	18,38	23,57	22,76

Fonte: Dados da pesquisa.

Tabela 58 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Peppers*.

Imagen	σ	Wav	Bay	Biv	WiC	Med	Wie	AD	BM	TV	AGH Max	AGH Min
Peppers	10	0,888	0,898	0,834	0,908	0,849	0,872	0,907	0,893	0,895	0,912	0,906
Peppers	15	0,854	0,868	0,806	0,878	0,778	0,852	0,870	0,887	0,882	0,889	0,881
Peppers	20	0,826	0,842	0,766	0,847	0,707	0,823	0,834	0,882	0,833	0,871	0,857
Peppers	25	0,801	0,815	0,721	0,816	0,637	0,791	0,801	0,868	0,745	0,858	0,833
Peppers	30	0,783	0,795	0,677	0,790	0,575	0,759	0,764	0,806	0,651	0,837	0,804
Peppers	35	0,762	0,771	0,636	0,758	0,522	0,718	0,737	0,630	0,560	0,809	0,790
Peppers	40	0,738	0,750	0,588	0,723	0,474	0,676	0,703	0,445	0,476	0,796	0,714
Peppers	45	0,732	0,746	0,551	0,702	0,435	0,641	0,671	0,337	0,417	0,786	0,749
Peppers	50	0,720	0,730	0,521	0,684	0,402	0,605	0,651	0,267	0,369	0,774	0,730
Peppers	55	0,712	0,715	0,489	0,661	0,370	0,569	0,624	0,220	0,320	0,751	0,717
Peppers	60	0,697	0,703	0,465	0,631	0,345	0,540	0,597	0,194	0,292	0,744	0,698

Fonte: Dados da pesquisa.

B.2 Resultados dos testes do AGH para suprimir ruídos em imagens SAR

Tabela 59 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Mississippi*.

Imagen	<i>L</i>	SARBM3D	PPB	AGH Max	AGH Min
Mississippi	1	19,84	19,40	15,88	15,43
Mississippi	2	18,62	18,21	21,87	21,00
Mississippi	3	13,55	13,41	16,21	15,45
Mississippi	4	10,79	10,77	12,07	11,78
Mississippi	5	9,19	9,18	9,97	9,72
Mississippi	6	8,22	8,17	8,58	8,44
Mississippi	7	7,55	7,46	7,67	7,67
Mississippi	8	7,06	6,96	7,18	7,18
Mississippi	9	6,71	6,59	6,78	6,78
Mississippi	10	6,44	6,35	6,52	6,52
Mississippi	11	6,24	6,16	6,31	6,31
Mississippi	12	6,10	6,03	6,16	6,16

Fonte: Dados da pesquisa.

Tabela 60 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Mississippi*.

Imagen	<i>L</i>	SARBM3D	PPB	AGH Max	AGH Min
Mississippi	1	0,444	0,396	0,438	0,387
Mississippi	2	0,449	0,432	0,526	0,473
Mississippi	3	0,409	0,401	0,519	0,463
Mississippi	4	0,361	0,358	0,451	0,372
Mississippi	5	0,334	0,323	0,336	0,277
Mississippi	6	0,323	0,301	0,275	0,237
Mississippi	7	0,313	0,287	0,234	0,234
Mississippi	8	0,296	0,277	0,252	0,252
Mississippi	9	0,272	0,266	0,239	0,239
Mississippi	10	0,258	0,257	0,233	0,233
Mississippi	11	0,247	0,248	0,229	0,229
Mississippi	12	0,240	0,241	0,228	0,228

Fonte: Dados da pesquisa.

Tabela 61 – Resultados de PSNR dos diversos métodos testados aplicados à imagem *Washington*.

Imagen	<i>L</i>	SARBM3D	PPB	AGH Max	AGH Min
Washington	1	18,23	17,70	17,18	15,64
Washington	2	17,61	16,72	19,13	18,32
Washington	3	14,61	13,97	16,90	15,91
Washington	4	12,13	11,63	13,95	13,60
Washington	5	10,29	9,90	11,67	11,48
Washington	6	8,92	8,57	9,98	9,88
Washington	7	7,90	7,60	8,88	8,65
Washington	8	7,12	6,85	7,88	7,72
Washington	9	6,49	6,24	7,07	6,93
Washington	10	6,00	5,76	6,59	6,43
Washington	11	5,59	5,38	6,11	5,96
Washington	12	5,26	5,06	5,77	5,53

Fonte: Dados da pesquisa.

Tabela 62 – Resultados de SSIM dos diversos métodos testados aplicados à imagem *Washington*.

Imagen	<i>L</i>	SARBM3D	PPB	AGH Max	AGH Min
Washington	1	0,530	0,460	0,460	0,318
Washington	2	0,623	0,551	0,522	0,423
Washington	3	0,589	0,521	0,625	0,444
Washington	4	0,524	0,463	0,550	0,419
Washington	5	0,460	0,408	0,490	0,391
Washington	6	0,405	0,358	0,455	0,363
Washington	7	0,360	0,319	0,397	0,354
Washington	8	0,321	0,287	0,361	0,319
Washington	9	0,288	0,257	0,336	0,290
Washington	10	0,261	0,234	0,304	0,264
Washington	11	0,239	0,215	0,271	0,241
Washington	12	0,220	0,199	0,258	0,218

Fonte: Dados da pesquisa.