
Reconhecimento de padrões heterogêneos e suas aplicações em biologia e nanotecnologia

Núbia Rosa da Silva

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Núbia Rosa da Silva

**Reconhecimento de padrões heterogêneos e suas
aplicações em biologia e nanotecnologia**

Tese apresentada ao Instituto de Ciências
Matemáticas e de Computação – ICMC-USP,
como parte dos requisitos para obtenção do título
de Doutora em Ciências – Ciências de Computação e
Matemática Computacional. *VERSÃO REVISADA*

Área de Concentração: Ciências de Computação e
Matemática Computacional

Orientador: Prof. Dr. Odemir Martinez Bruno

USP – São Carlos
Dezembro de 2015

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados fornecidos pelo(a) autor(a)

S586r Silva, Núbia Rosa da
 Reconhecimento de padrões heterogêneos e suas
 aplicações em biologia e nanotecnologia / Núbia Rosa
 da Silva; orientador Odemir Martinez Bruno. - São
 Carlos - SP, 2015.
 126 p.

 Tese (Doutorado - Programa de Pós-Graduação em
 Ciências de Computação e Matemática Computacional)
 - Instituto de Ciências Matemáticas e de Computação,
 Universidade de São Paulo, 2015.

 1. Visão computacional. 2. Reconhecimento de
 padrões. 3. Textura Heterogênea. 4. Análise de
 imagens. I. Bruno, Odemir Martinez, orient. II.
 Título.

Núbia Rosa da Silva

**Heterogeneous pattern recognition and its applications in
biology and nanotechnology**

Doctoral dissertation submitted to the Instituto de Ciências Matemáticas e de Computação – ICMC-USP, in partial fulfillment of the requirements for the degree of the Doctorate Program in Computer Science and Computational Mathematics. *FINAL VERSION*

Concentration Area: Computer Science and Computational Mathematics

Advisor: Prof. Dr. Odemir Martinez Bruno

USP – São Carlos
December 2015

AGRADECIMENTOS

A Deus por sempre me surpreender com seu infinito amor;

À minha família amada pelo amor, confiança e dedicação;

Ao meu orientador Prof. Dr. Odemir Martinez Bruno pela orientação, paciência e amizade;

Ao Prof. Dr. Bernard De Baets pela orientação durante o estágio de pesquisa na Universidade de Ghent;

Aos colaboradores dos projetos desenvolvidos durante o doutorado;

Aos meus amigos, de perto e de longe (em tempo e espaço), pelo apoio e compreensão;

Aos amigos e colegas da USP e UGent;

À Fapesp¹, pelo fomento.

¹ Processos 2011/21467-9 e 2014/06208-5.

*“[Eu] Pensava que nós seguíamos caminhos já feitos,
mas parece que não os há. O nosso ir faz o caminho.”*
(C.S. Lewis)

RESUMO

SILVA, N. R.. **Reconhecimento de padrões heterogêneos e suas aplicações em biologia e nanotecnologia.** 2015. 126 f. Tese (Doutorado em Ciências – Ciências de Computação e Matemática Computacional) – Instituto de Ciências Matemáticas e de Computação (ICMC/USP), São Carlos – SP.

O reconhecimento de padrões de textura em imagens tem sido uma importante ferramenta na área de visão computacional. Isso porque o atributo textura pode revelar características intrínsecas, tornando possível a classificação de um conjunto de imagens semelhantes. Embora a textura seja estudada há mais de meio século, ainda não existe um consenso sobre sua definição e nem mesmo um método de extração de características de textura que seja eficiente para todos os tipos de imagens. Além disso, os métodos da literatura analisam os padrões de textura de maneira global, considerando que uma imagem apresente um conjunto de micropadrões que formam um único padrão global ou homogêneo de textura na imagem. No entanto, alguns tipos de imagens apresentam heterogeneidade em sua composição, ou seja, o conjunto de micropadrões na imagem é responsável por formar mais de um padrão de textura dentro da mesma imagem. Esse tipo de imagens levou ao propósito de investigação deste trabalho. Independentemente do método de extração de característica utilizado, considerar a heterogeneidade do padrão de textura em uma imagem leva a uma melhor representação de suas características. Para melhorar a análise de padrões heterogêneos de textura, três abordagens são propostas: (i) *lazy-patch*, (ii) combinação de modelos e (iii) modelagem da textura por meio de autômatos celulares inspirados em corrosão alveolar. Os resultados ao aplicar essas abordagens em diferentes conjuntos de imagens de biologia e nanotecnologia, mostraram que a análise de padrões heterogêneos resulta em melhor representatividade de imagens que possuem padrões heterogêneos de textura em sua composição.

Palavras-chave: Visão computacional, Reconhecimento de padrões, Textura Heterogênea, Análise de imagens.

ABSTRACT

SILVA, N. R.. **Reconhecimento de padrões heterogêneos e suas aplicações em biologia e nanotecnologia.** 2015. 126 f. Tese (Doutorado em Ciências – Ciências de Computação e Matemática Computacional) – Instituto de Ciências Matemáticas e de Computação (ICMC/USP), São Carlos – SP.

Pattern recognition of texture in images has been playing an important role in computer vision area. This is because the texture attribute can reveal intrinsic characteristics, making it possible to classify a set of similar images. Although the texture is studied for over half a century, there is still no consensus on its definition or even a method to extract texture characteristics that is effective for all types of images. Moreover, literature methods globally analyze the texture patterns, whereas a picture displays a number of micropatterns which form a single homogenous global pattern of texture in the image. However, some types of image display heterogeneity in their composition, that is, the set of micropatterns in the image used to form more than one texture pattern within the same image. Such type of image led to the purpose of this research work. Regardless the feature extraction method used, considering the heterogeneity of the texture pattern in an image leads to better representation of its features. To further improve the analysis of heterogeneous texture patterns, three approaches are proposed: (i) *lazy-patch*, (ii) combination of models and (iii) texture modeling using cellular automata inspired by pitting corrosion. The results of applying these approaches in different sets of biology and nanotechnology images showed that the analysis of heterogeneous patterns results in better representation of images that have heterogeneous patterns of texture in your composition.

Key-words: Computer vision, Pattern recognition, Heterogeneous texture, Image analysis.

LISTA DE ILUSTRAÇÕES

Figura 1 – Matriz de co-ocorrência dos níveis de cinza. Imagens (a) e (b) pertencem a um mesmo padrão de textura, enquanto (c) e (d) pertencem a um outro padrão. A primeira linha mostra as imagens originais; a segunda linha mostra as imagens após equalização do histograma e a terceira linha mostra as matrizes de co-ocorrência das respectivas imagens na segunda linha.	29
Figura 2 – Banco de filtros consistindo de 48 filtros com variações de orientação e escala (LEUNG; MALIK, 2001). Os filtros orientados consistem de 6 diferentes orientações em 3 diferentes escalas e 12 filtros isotrópicos em diferentes escalas.	30
Figura 3 – Diferença entre MR8 e <i>Joint classifier</i> . Retirado de (VARMA; ZISSERMAN, 2009).	33
Figura 4 – Análise de primitivas de texturas contendo as mesmas primitivas, no entanto, com diferentes estatísticas para cada uma delas. O número total de primitivas é o mesmo nas duas imagens.	35
Figura 5 – Imagem do ácido oxálico que apresenta diferentes padrões de textura em uma mesma imagem. Os quadros de mesma cor representam textura com os mesmos padrões.	36
Figura 6 – Representação macroscópica e microscópica do composto areia-asfalto, mostrando, respectivamente, sua homogeneidade e heterogeneidade. Adapatado de (SOUZA; ALLEN, 2011).	39
Figura 7 – Cortes transversais de folhas de três espécies diferentes de plantas. Cada corte de folha é dividido em quatro partes: 1 - Cutícula, 2 - Epiderme superior, 3 - Parênquima Paliçádico, 4 - Parênquima Lacunoso.	40
Figura 8 – Esquema de montagem do vetor de características por concatenação simples dos atributos extraídos de cada região do corte transversal da folha (JUNIOR, 2008).	41
Figura 9 – Separação de padrões heterogêneos em diferentes espécies de folhas (A, B e C).	42
Figura 10 – Distinção entre os mesmos tipos de padrões obtidos de diferentes imagens de cortes histológicos de folhas. Os quadros coloridos evidenciam que os padrões contidos nas janelas podem ser agrupados de acordo com a parte da folha de que foram retirados. No entanto, mesmo sendo participantes de um mesmo tipo de padrão é possível verificar que eles são diferenciáveis de acordo com as espécies A, B e C das folhas.	42
Figura 11 – Imagem padrão do ácido oxálico.	42

Figura 12 – Utilizando abordagem multi escala para analisar diferentes padrões em uma mesma imagem. A primeira parte da figura apresenta a abordagem multi-escala, onde são observadas diferentes escalas de uma mesma imagem e na segunda parte da figura é possível observar os padrões heterogêneos da imagem, identificando três diferentes padrões de textura.	43
Figura 13 – <i>Morphogenesis</i> da glândula salivar em estágio embrionário nos tempos T1 a T4. Em vermelho tem-se a actina e em verde a formação dos microtúbulos, revelando a forma da célula. Adaptado de (MAYBECK; RÖPER, 2009).	44
Figura 14 – Atividades para o reconhecimento de padrões por meio da análise de padrões heterogêneos em imagens utilizando abordagem <i>Lazy-Patch</i>	50
Figura 15 – Correspondência de padrões entre imagens da mesma classe. (a) e (b) mostram exemplos de diferentes classes de imagens.	53
Figura 16 – Imagens de diferentes classes não possuem correspondência de padrões.	53
Figura 17 – Mesmo padrão em diferentes classes.	54
Figura 18 – Comparação entre o modelo <i>Lazy-Patch</i> e <i>Bag-of-words</i>	55
Figura 19 – Composição das características de uma imagem. Os vetores de características são obtidos a partir de um descritor de textura para cada uma das texturas que compõem a textura heterogênea da imagem.	58
Figura 20 – Modelo random forest combinado. Características de textura de todos os padrões que compõem a textura heterogênea da imagem são utilizadas para gerar modelos random forest que combinados levam à classificação das amostras. Com estes modelos, as probabilidades <i>oob</i> para o conjunto de treinamento e teste são gerados. Desta forma, os padrões deixam de ser representados por características de textura passando à representação em um espaço de probabilidades. Finalmente, as classes do conjunto de treinamento são preditas utilizando regressão logística. Este procedimento é executado k vezes, variando o conjunto de teste, em um esquema de validação cruzada estratificada k -fold.	59
Figura 21 – Corrosão alveolar: representação esquemática em uma superfície metálica (SILVA <i>et al.</i> , 2015).	60
Figura 22 – Organização de um CA 2D.	62
Figura 23 – Vizinhança de uma célula $c_{i,j}$: (a) vizinhança Moore e (b) vizinhança von Neumann.	62
Figura 24 – Seleção de células a serem atualizadas, com $v = 5$: (a) tesselação 5×5 com o estado inicial de cada célula, (b) diferença $d_{i,j}$ para todas as células de acordo com a Equação 4.8 e (c) níveis de cinza indicando as células a serem atualizadas.	65

Figura 25 – Simulação dos resultados (SILVA <i>et al.</i> , 2015). Primeira coluna: imagens originais. Segunda coluna: resultado em escala de cinza da aplicação do modelo de corrosão alveolar em imagens de textura utilizando $\gamma = 0.05$, $v = 5$ e 90 iterações. Terceira coluna: mesmo que segunda coluna em escala azul-vermelho.	67
Figura 26 – Amostras da base de dados Brodatz (BRODATZ, 1966).	71
Figura 27 – Amostras da base de dados Outex (OJALA <i>et al.</i> , 2002).	71
Figura 28 – Amostras da base de dados Vistex (VISION..., 2009).	72
Figura 29 – Amostras da base de dados Usptex (BACKES; CASANOVA; BRUNO, 2012).	72
Figura 30 – Amostras de imagens do banco de texturas dinâmicas Dytex (PÉTERI; FAZEKAS; HUISKES, 2010).	73
Figura 31 – (a) Imagem original. (b) e (c) Segmentação de textura de uma imagem em dois padrões por meio da divisão de todas as imagens em janelas e posteriormente o seu agrupamento de acordo com suas características obtidas por meio dos descritores de Haralick.	74
Figura 32 – (a) Análise dos parâmetros de poder de corrosão (γ) e rugosidade da superfície (v) para a base de dados Usptex com γ variando de 0,01 a 0,08 e v variando de 0 a 10. (b) Número de iterações para cada configuração de parâmetros em (a).	78
Figura 33 – Amostras de seis modificações da base de dados Vistex adicionando ruído ‘Salt & Pepper’. Cada coluna corresponde a uma intensidade do ruído, com $l = 0,01, 0,05, 0,07, 0,1, 0,5$ and $0,7$, da esquerda para a direita.	79
Figura 34 – Amostras da base de dados Brodatz rotacionada. Cada coluna corresponde a um diferente ângulo de rotação. Da esquerda para a direita: $0^\circ, 45^\circ, 90^\circ, 135^\circ, 180^\circ, 225^\circ$ e 270°	81
Figura 35 – Imagens de FEG-SEM de óxido de titânio anódico galvanostático preparado em solução de ácido oxálico em oito condições diferentes.	86
Figura 36 – Segmentação de padrões. Primeira coluna: imagens originais. Segunda coluna: segmentação dos padrões heterogêneos de textura das imagens da primeira coluna.	87
Figura 37 – Matching de padrões heterogêneos. As janelas com bordas coloridas indicam zoom das janelas menores dentro das imagens.	88
Figura 38 – Vetores de características de dois experimentos.	89
Figura 39 – Comparação dos resultados utilizando métodos da literatura com abordagem homogênea (barras verdes), considerando que exista apenas um padrão de textura na imagem, e a abordagem com padrões heterogêneos de textura (barras vermelhas). As barras em azul e amarelo mostram o número de descritores para cada abordagem, respectivamente.	90

Figura 40 – Matriz de confusão para o método LBPV com análise de padrões heterogêneos de textura com taxa de acerto igual a 84,38%	90
Figura 41 – Cortes microscópicos transversal, tangencial e radial.	95
Figura 42 – Seções transversais de madeira. Cada linha mostra imagens da mesma espécie, de cima para baixo: <i>Leplaea cedrata</i> , <i>Millettia laurentii</i> , <i>Morus mesozygia</i> , <i>Pterocarpus soyauxii</i> and <i>Zanthoxylum gilletii</i>	96
Figura 43 – Seções tangenciais de madeira. Cada linha mostra imagens da mesma espécie, de cima para baixo: <i>Leplaea cedrata</i> , <i>Millettia laurentii</i> , <i>Morus mesozygia</i> , <i>Pterocarpus soyauxii</i> and <i>Zanthoxylum gilletii</i>	97
Figura 44 – Seções radiais de madeira. Cada linha mostra imagens da mesma espécie, de cima para baixo: <i>Leplaea cedrata</i> , <i>Millettia laurentii</i> , <i>Morus mesozygia</i> , <i>Pterocarpus soyauxii</i> and <i>Zanthoxylum gilletii</i>	98
Figura 45 – Imagens de epiderme cujas imagens intra espécies se assemelham. As linhas contém imagens da mesma espécie, de cima para baixo: <i>Ilex affinis</i> , <i>Myrsine guianensis</i> , <i>Tabebuia impetiginosa</i> and <i>Xylopia sericea</i>	103

LISTA DE TABELAS

Tabela 1 – Bases de dados de imagens de textura.	70
Tabela 2 – Resultados da abordagem clássica de análise de padrões de textura e a abordagem utilizando padrões heterogêneos utilizando <i>lazy-patch</i>	75
Tabela 3 – Comparação dos resultados entre os métodos propostos, <i>lazy-patch</i> e random forest combinado, e métodos tradicionais de análise de textura.	76
Tabela 4 – Valores ótimos dos parâmetros.	78
Tabela 5 – Comparação em termos da taxa de acerto da classificação das bases de dados Brodatz e Vistex utilizando o descriptor CITA e métodos da literatura.	78
Tabela 6 – Taxa de acerto para classificação de seis modificações da base Brodatz, obtidas através da adição de ruído ‘Salt & Pepper’ com diferentes intensidades l	80
Tabela 7 – Taxa de acerto para classificação de seis modificações da base Vistex, obtidas através da adição de ruído ‘Salt & Pepper’ com diferentes intensidades l	80
Tabela 8 – Taxa de acerto para classificação da base de dados Brodatz, sendo o conjunto de treinamento formado por imagens originais e o conjunto de teste com adição de diferentes intensidades l do ruído ‘Salt & Pepper’.	80
Tabela 9 – Taxa de acerto para classificação da base de dados Vistex, sendo o conjunto de treinamento formado por imagens originais e o conjunto de teste com adição de diferentes intensidades l do ruído ‘Salt & Pepper’.	81
Tabela 10 – Comparação em termos da taxa de acerto utilizando as bases de dados Brodatz e Vistex rotacionadas.	82
Tabela 11 – Família, gênero e espécies utilizadas para os experimentos de identificação de espécies de madeira.	94
Tabela 12 – Taxa de acerto ao utilizar cada seção separadamente para identificar as espécies de madeira e ao utilizar o modelo Random Forest Combinado.	99
Tabela 13 – Famílias e espécies utilizadas para os experimentos de identificação de espécies utilizando epiderme foliar.	102

Tabela 14 – Taxa de acerto para classificação de 32 espécies de plantas. Os resultados são descritos por meio do número de componentes PCA (#), taxa de acerto e desvio padrão (std) utilizando Fourier, CITA e LBP como descritores de textura e *k*-NN como classificador. A primeira parte dos resultados mostra a taxa de acerto para as 300 imagens, em que as amostras de *Tapirira guianensis* são provenientes somente de mata de galeria. A segunda parte mostra os resultados para 309 imagens, com nove amostras de *Tapirira guianensis* provenientes de vereda. Estes dois resultados fazem uma comparação da taxa de acerto com amostras de uma espécie que cresceu em diferentes ambientes. A taxa de acerto para identificação da espécie *Tapirira guianensis* é mostrada na coluna '% *T. g.*' para 300 e 309 imagens. 105

SUMÁRIO

1	INTRODUÇÃO	21
1.1	<i>Justificativa e Motivação</i>	21
1.2	<i>Objetivos</i>	23
1.3	<i>Contribuições</i>	23
1.4	<i>Organização</i>	24
2	TEXTURA	25
2.1	<i>Percepção da Textura</i>	26
2.1.1	<i>Estatísticas de primeira ordem</i>	27
2.1.2	<i>Estatísticas de segunda ordem</i>	28
2.2	<i>Textons</i>	30
2.2.1	<i>Bag-of-Words</i>	33
2.3	<i>Quando a textura não é homogênea</i>	34
3	TEXTURA HETEROGÊNEA	39
3.1	<i>Modelagem do Problema</i>	44
4	ANÁLISE DE PADRÕES HETEROGÊNEOS	49
4.1	<i>Lazy-Patch</i>	50
4.1.1	<i>Segmentação de Padrões Heterogêneos</i>	50
4.1.1.1	<i>Teste de Grubbs</i>	51
4.1.2	<i>Extração de Características dos Padrões Heterogêneos</i>	51
4.1.3	<i>Correspondência de Padrões Heterogêneos</i>	52
4.1.4	<i>Reconhecimento de Padrões</i>	52
4.2	<i>Combinação de modelos</i>	56
4.2.1	<i>Random Forest</i>	56
4.2.2	<i>Rregressão logística</i>	57
4.2.3	<i>Modelo Random Forest Combinado</i>	57
4.3	<i>CITA: Autômatos celulares, corrosão e textura</i>	60
4.3.1	<i>Autômatos celulares</i>	61
4.3.1.1	<i>Tesselação \mathcal{T}</i>	62
4.3.1.2	<i>Função de vizinhança N</i>	62
4.3.1.3	<i>Estados discretos</i>	62
4.3.1.4	<i>Função de transição Φ</i>	63

4.3.2	Análise de textura	63
5	EXPERIMENTOS E RESULTADOS	69
5.1	Bases de Dados	69
5.2	Descritores de Características de Textura	73
5.3	Experimentos e Resultados	74
5.3.1	<i>Lazy-patch e Random Forest Combinado</i>	74
5.3.2	<i>CITA</i>	76
5.3.2.1	<i>Avaliação dos Parâmetros</i>	76
5.3.2.1.1	Número de iterações	76
5.3.2.1.2	Rugosidade da superfície ν	77
5.3.2.1.3	Poder de corrosão γ	77
5.3.2.2	<i>Experimentos</i>	77
5.3.2.2.1	Bases de Dados sem Modificações	77
5.3.2.2.2	Invariância a Ruído	78
5.3.2.2.3	Invariância à Rotação	80
6	APLICAÇÕES EM BIOLOGIA E NANOTECNOLOGIA	83
6.1	Óxido de Titânio Anódico Galvanostático	83
6.1.1	<i>Aquisição de Imagens</i>	85
6.1.2	<i>Análise de Padrões Heterogêneos</i>	85
6.2	Identificação de Espécies de Madeira	91
6.2.1	<i>Aquisição de imagens</i>	92
6.2.2	<i>Metodologia para Identificação de Espécies</i>	95
6.3	Identificação de Espécies de Plantas	99
6.3.1	<i>Aquisição de Imagens</i>	100
6.3.2	<i>Metodologia para Identificação de Espécies</i>	101
6.3.2.1	<i>Medidas quantitativas manuais</i>	104
6.3.2.2	<i>Efeito da plasticidade na identificação</i>	104
7	CONCLUSÕES	107
7.1	Artigos gerados durante o doutorado	108
7.1.1	<i>Publicações</i>	108
7.1.2	<i>Artigos Submetidos</i>	109
7.1.3	<i>Artigos em Fase de Submissão</i>	109
	REFERÊNCIAS	111



INTRODUÇÃO

1.1 Justificativa e Motivação

O reconhecimento de padrões quando aplicado à visão computacional, trata da identificação ou interpretação de padrões em imagens, objetivando extrair suas informações relevantes para identificar e classificar o seu conteúdo. Satisfatoriamente, a classificação de padrões pode ser utilizada em uma variedade de aplicações em diferentes áreas, tais como: nanotecnologia (ANNAMPEDU; WAGH, 2007; OH; SONG; PARK, 2011; ZHANG *et al.*, 2005; LEE *et al.*, 2001), biologia (LUZZATI; TARDIEU; TAUPIN, 1972; GALAS; EGGERT; WATERMAN, 1985; ISASI; ZAPIRAIN; ZORRILLA, 2011; RAMIREZ; DINIO; PRIBOR, 1972), química (K.; VARMUZA, 1980; DAGBERT *et al.*, 1975; NATALE; DAVIDE; D'AMICO, 1995; LAVINE *et al.*, 1988), medicina (C.J.D.M.; VERHAGEN, 1975; LANDEWEERD *et al.*, 1981; S. N.; IVANCEVIC, 1974; DUNN; WOOLLISCROFT, 1995), e computação (ESTE; GRINGOLI; SALGARELLI, 2009; J.; MANTAS, 1987; CANALS; MORRO; ROSELLÓ, 2010; NETEA *et al.*, 2011). Dentro do reconhecimento de padrões, a análise automática de imagens de textura tem sido um tópico de extensa pesquisa por mais de meio século, com seus primórdios no trabalhos de Bela Julesz em 1962 (JULESZ, 1962). Numerosos métodos para análise de padrões de textura foram desenvolvidos (GONZALEZ; WOODS, 2002; KOLTSOV, 2011; RANDEN; HUSØY, 1999; MATERKA; STRZELECKI, 1998; HALL *et al.*, 1971; HARALICK, 1979; REED; DUBUF, 1993; WECHSLER, 1980; JÄHNE; HAUSSECKER; GEISSLER, 1999), focando em diferentes técnicas, incluindo espectro de Fourier (LENDARIS; STANLEY, 1970; ROSENFIELD, 1962; COGGINS; JAIN, 1985), detecção de arestas (TROY *et al.*, 1970), autocorrelação (FAUGERAS; PRATT, 1980), co-ocorrência de pixels (HARALICK; SHANMUGAM; DINSTEIN, 1973; HARALICK, 1979), filtros de Gabor (GABOR, 1946; BOVIK; CLARK; GEISLER, 1990; BOVIK, 1991), wavelets (UNSER, 1995), entre outras.

Esses métodos fazem suposições restritivas sobre a natureza das imagens de entrada, considerando que as mesmas apresentem um conjunto de micropadrões que formam um único

padrão global ou homogêneo de textura na imagem. Dessa forma, deixam de lado uma questão crítica, que é a análise de imagens que apresentam padrões heterogêneos de textura em sua composição, onde o conjunto de micropadrões na imagem é responsável por formar mais de um padrão de textura dentro da mesma imagem. O padrão heterogêneo de textura surge quando o objeto em análise apresenta padrões combinados de textura em sua composição. Uma textura heterogênea possui a característica de apresentar uma composição ou aparência diferente, quando analisada em partes.

A ausência de métodos capazes de extrair características de textura de imagens com padrões heterogêneos de maneira satisfatória, apresenta uma limitação relevante para muitas aplicações que envolvem análise de textura heterogênea, englobando análise de cortes histológicos transversais de folhas e madeira ou nanoestruturas, que apresentam heterogeneidade em sua composição. Ao identificar e analisar cada padrão de textura em imagens que apresentam heterogeneidade em sua composição obtém-se melhor representatividade dessas imagens produzindo melhores resultados no reconhecimento de padrões em imagens. Por esta razão, o propósito deste trabalho é investigar a análise de textura com padrões heterogêneos para melhorar a classificação de conjuntos de imagens heterogêneas. Assim, três abordagens foram desenvolvidas nesta tese para extração de características de textura heterogênea: (i) *lazy-patch*, (ii) combinação de modelos e (iii) modelagem da textura por meio de autômatos celulares inspirados em corrosão alveolar.

Lazy-patch é uma metodologia baseada na modelagem dos padrões heterogêneos de textura como uma mistura de distribuições. Para tanto, os padrões de textura da imagem são segmentados por meio da divisão da imagem em janelas, seguido da extração de características de textura de cada janela e posteriormente o agrupamento dessas janelas utilizando k -means, para identificar as regiões com padrões semelhantes na imagem. Finalmente, cada região é caracterizada e a classificação procede comparando os padrões de textura da imagem. A segunda abordagem tem seu foco na combinação das características de cada padrão de textura por meio de modelos gerados por *random forest* para realizar a classificação, independente de como essas características foram extraídas. A terceira e última abordagem utiliza uma metodologia baseada em autômatos celulares com regras inspiradas na corrosão alveolar, enfatizando os padrões heterogêneos de textura e classificando as imagens de acordo com a evolução temporal das modificações causadas nas imagens devido à heterogeneidade de padrões.

A efetividade dessas estratégias foi demonstrada ao aplicá-las em diferentes conjuntos de imagens de biologia e nanotecnologia, sendo possível, mostrar que a análise de padrões heterogêneos resulta em melhor representatividade de imagens que possuem padrões heterogêneos de textura em sua composição. Fato que é comprovado pelas taxas de acerto obtidas ao serem comparadas com métodos da literatura. Espera-se que este trabalho contribua para a área de visão computacional e reconhecimento de padrões, fornecendo uma proposta para a análise e caracterização de texturas heterogêneas.

1.2 Objetivos

A principal motivação desta tese deve-se ao fato de que grande parte dos trabalhos de classificação de textura já desenvolvidos não contemplam conjuntos de imagens de textura com padrões heterogêneos na composição das imagens. Tendo em vista que há uma necessidade de desenvolvimento de metodologias que atinjam este tipo de imagens, pretende-se apresentar as metodologias desenvolvidas para realizar tal tarefa. Portanto, esta tese tem como principal objetivo melhorar a análise de conjuntos de imagens que apresentam padrões heterogêneos de textura na sua composição por meio de três abordagens propostas: (i) *lazy-patch*, (ii) combinação de modelos e (iii) modelagem da textura por meio de autômatos celulares inspirados em corrosão alveolar. Posteriormente, essas propostas serão validadas dentro de contextos específicos de aplicações em biologia e nanotecnologia.

1.3 Contribuições

O trabalho desenvolvido e apresentado nesta tese traz contribuições para a área de reconhecimento de padrões, particularmente em visão computacional. As principais contribuições envolvem o desenvolvimento de métodos para extração de características e análise de padrões heterogêneos em imagens de textura. Desta forma, as principais contribuições são listadas a seguir:

- Formalização do conceito de padrões heterogêneos em imagens para o reconhecimento de padrões em visão computacional, onde a imagem é composta por diferentes padrões de textura e dessa forma, torna-se necessário uma abordagem que contemple essa heterogeneidade de padrões.
- Desenvolvimento de um método de extração de características de textura, que utiliza o formalismo de autômatos celulares e a inspiração no modelo de corrosão alveolar para elucidar os padrões heterogêneos na imagem. A classificação das imagens é realizada ao analisar as modificações no tempo dos padrões heterogêneos de textura. Este método é chamado CITA - *Corrosion-Inspired Cellular Automaton*.
- Desenvolvimento de uma metodologia, denominada *lazy-patch*, para segmentação, extração de características e reconhecimento de padrões heterogêneos. Nesta perspectiva, os padrões heterogêneos de textura são modelados como uma mistura de distribuições.
- Desenvolvimento de uma abordagem que utiliza a combinação de modelos random forest para classificação de imagens que apresentam padrões heterogêneos de textura em sua composição. Sendo o enfoque desta metodologia a classificação das imagens de acordo com os diferentes padrões.

- Aplicações em biologia e nanotecnologia. Foram realizadas duas aplicações em identificação de espécies de plantas, sendo uma delas para a identificação de espécies lenhosas. E uma aplicação consistindo na classificação de experimentos de óxido de titânio anódico galvanostático. Em todas elas a análise de padrões heterogêneos de textura foi indispensável para realizar a classificação das imagens.

1.4 Organização

Esta tese está estruturada da seguinte maneira: o Capítulo 2 traz uma discussão sobre a percepção da textura e como os métodos da literatura analisam este importante atributo de imagens; o Capítulo 3 expõe o problema de analisar a textura de maneira global, apresentando uma nova forma de análise de conjuntos de imagens com padrões heterogêneos, sendo elucidadas no Capítulo 4, as metodologias para análise de conjuntos de imagens com padrões heterogêneos; o Capítulo 5 mostra os experimentos em bases de dados de textura; no Capítulo 6 são apresentadas três aplicações desenvolvidas, sendo o foco principal das aplicações biologia e nanotecnologia. Finalmente, o Capítulo 7 apresenta as conclusões e contribuições geradas no decorrer do desenvolvimento desta tese.



TEXTURA

Durante as últimas décadas, a textura tem sido um importante atributo de estudo para a comunidade de visão computacional e processamento de imagens (GONZALEZ; WOODS, 2002). Devido a complexidade dos estudos de textura e a abrangência das áreas em que a análise dos padrões de textura pode ser explorada, muitos métodos de extração de características de textura têm sido intuitivamente desenvolvidos (GONZALEZ; WOODS, 2002; KOLTSOV, 2011; RANDEN; HUSØY, 1999; MATERKA; STRZELECKI, 1998; HALL *et al.*, 1971; HARALICK, 1979; REED; DUBUF, 1993; WECHSLER, 1980; JÄHNE; HAUSSECKER; GEISSLER, 1999), fazendo uso de diferentes abordagens, tais como, espectro de Fourier (LENDARIS; STANLEY, 1970; ROSENFELD, 1962; COGGINS; JAIN, 1985), detecção de arestas (TROY *et al.*, 1970), autocorrelação (FAUGERAS; PRATT, 1980), co-ocorrência de pixels (HARALICK; SHANMUGAM; DINSTEIN, 1973; HARALICK, 1979), filtros de Gabor (GABOR, 1946; BOVIK; CLARK; GEISLER, 1990; BOVIK, 1991), wavelets (UNSER, 1995), entre outras. Embora seja um atributo importante, não há um método de extração de características de textura que seja eficiente para todos os tipos de imagens (PAGET, 2008). Apesar dos inúmeros estudos nesta área, não existe uma definição consensual e satisfatória para textura entre os pesquisadores de visão computacional (MANDELBROT, 1977; HARALICK, 1979; TUCERYAN; JAIN, 1998). Dentre as várias definições encontradas na literatura, podem ser citadas:

“A noção de textura parece depender de três ingredientes: (i) alguma ordem local é repetida sobre a região que é maior em comparação ao tamanho da ordem, (ii) a ordem consiste em uma organização não aleatória das partes elementares, e (iii) as partes são entidades aproximadamente uniformes, tendo aproximadamente as mesmas dimensões em todos os lugares na região de textura.” (HAWKINS, 1969)

“A textura pode ser considerada como o que constitui uma região macroscópica. Sua estrutura é simplesmente atribuída aos repetitivos padrões em que os elementos ou primitivas estão organizados de acordo com uma regra de localização.” (TAMURA; MORI; YAMAWAKI, 1978)

“Uma região em uma imagem tem uma textura constante se o conjunto de estatísticas locais ou outras propriedades locais da função da imagem são constantes, tem pouca variação ou é aproximadamente periódica.” ([SKLANSKY, 1978](#))

“Uma imagem de textura é descrita pelo número e tipos de suas primitivas e a organização espacial ou disposição de suas primitivas.” ([HARALICK, 1979](#))

“A textura é gerada por um ou mais padrões básicos locais que se repetem de maneira periódica em alguma região da imagem.” ([WECHSLER, 1980](#))

“A textura é composta por padrões visuais complexos organizados espacialmente, sendo entidades com brilho, cor, forma e tamanho característicos. Esses sub-padrões locais são caracterizados por sua aspereza, finura, regularidade e lisura. Sendo a textura homogênea para o sistema visual humano.” ([HÁJEK; BENOIT-CATTIN, 2006](#)).

“A textura é uma repetição regular de um elemento ou padrão em uma superfície. Imagens de textura são padrões visuais compostos por entidades com sub-padrões com brilho, cor, forma e tamanho característicos.” ([SRINIVASAN; SHOBHA, 2008](#)).

2.1 Percepção da Textura

Do ponto de vista da visão humana ou psicofísica, a percepção da textura, ou seja, o processo de reconhecer, organizar e interpretar a informação sensorial da textura, pode ser realizada de forma pré-atentiva e atentiva ([JULESZ, 1986](#)). O processo pré-atentivo, ou não controlado, é rápido, paralelo e inconsciente. Rápido porque responde quase que instantaneamente sem uma análise minuciosa; paralelo, por não depender do número de elementos; e inconsciente, pois cobre um campo amplo de visão. De uma maneira geral, o sistema pré-atentivo tem uma visão do todo, do que seria a textura, no entanto, não é capaz de distinguir quais primitivas formam a textura. Por outro lado, o sistema atentivo, ou controlado, é mais lento, embora seja bem mais rápido que o movimento de escaneamento dos olhos, sequencial, onde uma análise minuciosa dos elementos é realizada, e consciente, devido a uma pequena abertura de atenção focal. O sistema atentivo é então capaz de perceber as primitivas que formam a textura.

A organização perceptiva confere ao indivíduo um mundo visual coerente e organizado em objetos com significado ([WILSON; KEIL, 1999](#)). A aparência e identidade de um determinado estímulo são determinadas a partir de um arranjo particular ou organização das partes em todos perceptivos ([KOFFKA, 1922](#)). Quanto menor a possibilidade de variação das partes, melhor será a interpretação, uma vez que ela torna-se mais simples ([GARNER; LEE, 1962](#)). Essas afirmações vão de encontro com a teoria da Gestalt que defende que o todo é maior que a soma das partes, sendo a percepção baseada numa organização de eventos no cérebro ([WERTHEIMER, 1938](#)). Os padrões locais são responsáveis por compor uma imagem unitária homogênea ou uma

imensa articulada com diferentes partes, assim, as condições do todo podem determinar quais são as influências sobre as partes (BENARY, 1938).

Julesz (1986) afirma que as descrições texturais são feitas com maior rapidez quando há diferença em certas características texturais primitivas denominadas *textons*. Eles possuem características semelhantes àquelas cujas células do córtex visual estão preparadas para responder. Estímulos primitivos como barras, bordas, pontos, entre outros são percebidas pelas células do córtex visual em diferentes frequências e orientações. Dessa forma, os textons possuem características específicas e distinguíveis dos elementos compreendidos em uma textura. De fato, experimentos em cérebros de macacos mostraram que as células do córtex fazem uma análise espacial de frequências e orientações das imagens formadas na retina respondendo à determinada frequência e orientação (VALOIS; ALBRECHT; THORELL, 1982). Essas afirmações motivaram a descrição da textura baseada em estatísticas de textons e na resposta a filtros (MALIK; PERONA, 1990).

Julesz verificou que a discriminação entre duas imagens de textura depende principalmente da diferença da estatística de segunda ordem da textura. Isso significa que, para duas imagens com estatísticas de segunda ordem diferentes, identifica-se de forma preatentiva que elas possuem texturas diferentes, enquanto para texturas com mesma estatística de segunda ordem é necessário maior esforço para identificar que elas são diferentes.

2.1.1 Estatísticas de primeira ordem

Estimam propriedades dos valores individuais dos pixels, ignorando sua interação espacial com a vizinhança. A informação de textura é extraída do histograma de intensidades da imagem, definido por:

$$H(l) = \frac{n_l}{N}; l = 0, 1, \dots, L - 1, \quad (2.1)$$

onde N é o número de pixels na imagem, L é o número de níveis de cinza e n_l é o número de pixels com valor l na imagem. Em geral sete características são utilizadas para descrever as propriedades do histograma e, portanto, a textura da imagem. Sendo elas: média, variância, suavidade, assimetria, curtose, energia e entropia.

Desta forma, estatísticas de primeira ordem analisam a distribuição dos níveis de cinza, mas não proveem nenhuma informação sobre as posições relativas dos vários níveis de cinza na imagem. Desta forma, com esta análise não é possível saber, por exemplo, se os níveis de cinza mais baixos estão aglomerados em determinada região ou, se eles estão intercalados com altas intensidades dos níveis de cinza.

2.1.2 Estatísticas de segunda ordem

Estimam propriedades do relacionamento espacial entre dois pixels, baseando-se na probabilidade de encontrar um par de níveis de cinza na imagem que estejam a uma distância d e orientação $\theta = \{0^\circ, 45^\circ, 90^\circ, 135^\circ, 180^\circ, 225^\circ, 270^\circ \text{ e } 315^\circ\}$. Esta probabilidade de distribuição conjunta é também chamada de matriz de co-ocorrência, pois calcula a co-ocorrência de dois pixels. A matrix de co-ocorrência é dada por:

$$P_d(i, j) = Pr(I(p_1) = i \wedge I(p_2) = j \wedge \|p_1 - p_2\| = d), \quad (2.2)$$

onde I é a imagem, Pr é a probabilidade, p_1 e p_2 são pixels vizinhos de acordo com a distância d e orientação θ e i e j são intensidades dos níveis de cinza.

A Figura 1 mostra quatro imagens de textura de dois diferentes padrões e suas respectivas matrizes de co-ocorrência. Para gerar essas matrizes de co-ocorrência foram utilizadas distâncias iguais a 1 pixel na direção horizontal. Texturas com padrões semelhantes tendem a gerar matrizes de co-ocorrência semelhantes demonstrando a relação espacial entre os pixels da imagem. As matrizes da Figura 1 (i) e (j) parecem muito mais similares uma à outra do que as matrizes de (j) e (k), por exemplo, que pertencem a diferentes padrões de textura. [Haralick, Shanmugam e Dinstein \(1973\)](#) e [Haralick \(1979\)](#) propuseram o uso de medidas escalares simples, tais como energia, entropia, contraste, correlação e homogeneidade extraídas da matriz de co-ocorrência ao invés de utilizá-la diretamente para a caracterização de imagens de textura. Algumas dessas características são apresentadas a seguir:

Energia:

$$\sum_{i=0}^{G-1} \sum_{j=0}^{G-1} p(i, j)^2. \quad (2.3)$$

Entropia:

$$\sum_{i=0}^{G-1} \sum_{j=0}^{G-1} p(i, j) \log_2[p(i, j)]. \quad (2.4)$$

Contraste:

$$\sum_{i=0}^{G-1} \sum_{j=0}^{G-1} (i - j)^2 p(i, j). \quad (2.5)$$

Correlação:

$$\sum_{i=0}^{G-1} \sum_{j=0}^{G-1} \frac{ijp(i, j) - \mu_x \mu_y}{\sigma_x \sigma_y}. \quad (2.6)$$

As variáveis μ_x , μ_y , σ_x e σ_y são, respectivamente, média e desvio padrão da soma dos elementos de cada linha e coluna da matriz de co-ocorrência. Outras características calculadas a partir das matrizes de co-ocorrência podem ser obtidas em [\(GONZALEZ; WOODS, 1992\)](#).

A diferença entre texturas com a mesma estatística de segunda ordem, ou estatística global, pode ser analisada observando as diferenças em características locais, os textons ([JULESZ](#),

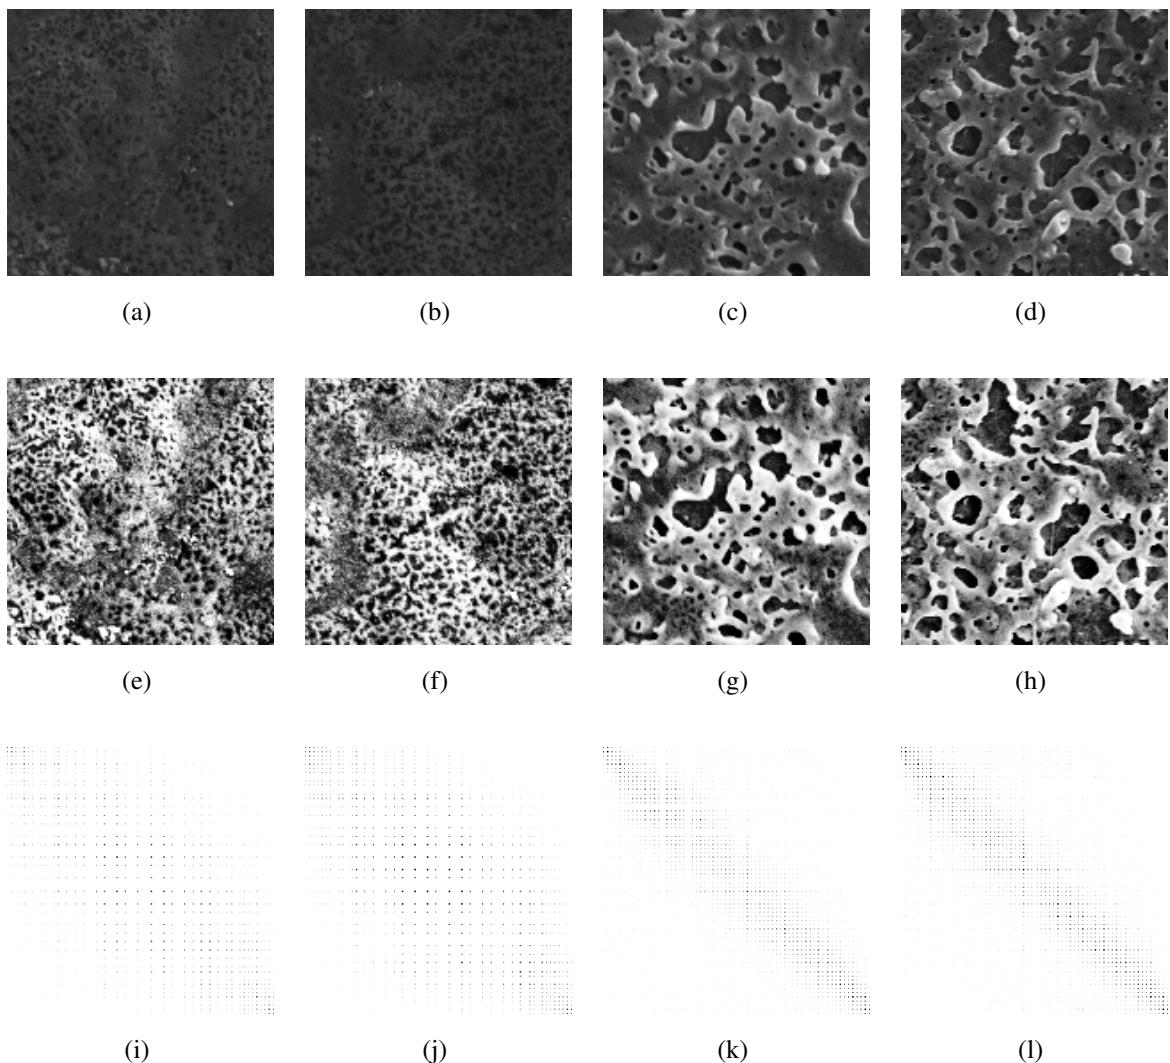


Figura 1 – Matriz de co-ocorrência dos níveis de cinza. Imagens (a) e (b) pertencem a um mesmo padrão de textura, enquanto (c) e (d) pertencem a um outro padrão. A primeira linha mostra as imagens originais; a segunda linha mostra as imagens após equalização do histograma e a terceira linha mostra as matrizes de co-ocorrência das respectivas imagens na segunda linha.

1986). Ao fazer o relacionamento com a análise de textura de acordo com a visão atentiva e pré-atentiva, chega-se às abordagens de textura local e global, respectivamente. A informação de textura local é dada pelos padrões de níveis de cinza ao redor de um dado pixel, por outro lado, a textura também é representada por características globais obtidas pela análise da repetição e relacionamento entre esses padrões locais (LIU; FIEGUTH, 2012). Esse vislumbre motiva métodos tais como *Local Binary Patterns* e *Bag-of-words*, que utilizam estatísticas de propriedades locais para realizar a análise global ou macroscópica da textura da imagem.

2.2 Textons

O termo texton foi definido por [Julesz \(1981\)](#) como as micro-estruturas fundamentais em uma imagem natural, sendo a unidade elementar de percepção humana da textura. Embora esse trabalho tenha fornecido importantes contribuições para a teoria da percepção visual humana da textura, ele não forneceu uma definição precisa para imagens em níveis de cinza. Posteriormente [Leung e Malik \(1999\)](#) incluíram a análise de níveis de cinza introduzindo o termo *texton 3D*.

[Leung e Malik \(1999\)](#) e [Leung e Malik \(2001\)](#) introduziram um modelo descritivo capaz de encapsular características das micro-estruturas locais e atributos de textura natural¹. A principal ideia é construir um vocabulário de textons 3D, representados por um vetor de aparência que compreende propriedades locais geométricas e fotométricas da estrutura da textura em análise. Esta ideia baseia-se na premissa de que na escala local de uma superfície existe somente um pequeno número de micro-estruturas perceptualmente distinguíveis.

O método tem seu início representando cada pixel de uma textura como a convolução de um banco de filtros multi escala e multi orientação com centro nesse dado pixel. As respostas da convolução do filtro centralizado em cada pixel são concatenadas para formar os vetores representativos dos pixels. O banco de filtros utilizado por [Leung e Malik \(1999\)](#) e [Leung e Malik \(2001\)](#) é formado por 48 filtros com diferentes orientações e escalas. Nele existem diferentes tipos de filtros formados por um conjunto de filtros orientados e um conjunto de filtros isotrópicos. O conjunto orientado possui dois grupos, cada um com seis diferentes orientações e três escalas diferentes. O conjunto isotrópico possui doze filtros em diferentes escalas, como mostra a Figura 2.

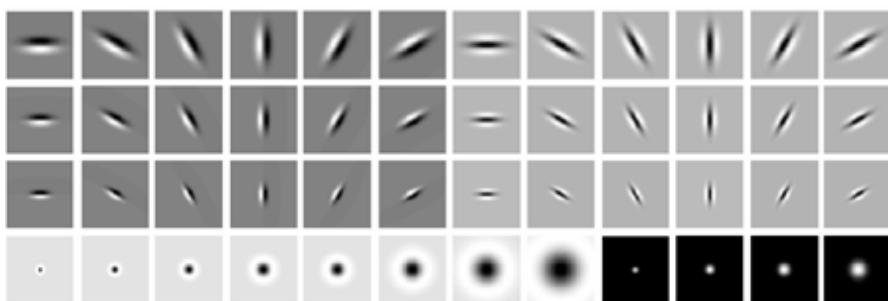


Figura 2 – Banco de filtros consistindo de 48 filtros com variações de orientação e escala ([LEUNG; MALIK, 2001](#)). Os filtros orientados consistem de 6 diferentes orientações em 3 diferentes escalas e 12 filtros isotrópicos em diferentes escalas.

A convolução do banco de filtros com centro em cada pixel gera como resultado um vetor com 48 posições para cada pixel da imagem, tornando o método muito redundante. Devido a natureza repetitiva dos padrões de textura, de acordo com a sua própria definição, muitos vetores possuem valores similares. Para resolver este problema de redundância, os vetores são agrupados

¹ As texturas podem ser classificadas como artificiais ou naturais ([GONZALEZ; WOODS, 2002](#)). Texturas artificiais são formadas por arranjos de símbolos, tais como linhas, segmentos, pontos, entre outros, em um fundo neutro. As texturas naturais dizem respeito a imagens de cenas naturais contendo arranjos semi-repetitivos dos pixels.

utilizando o algoritmo de agrupamento *k-means* (DUDA; HART, 1973). O algoritmo consiste em encontrar k centros, tais que, após rotular todos os vetores de acordo com o centróide mais próximo, a distância quadrada entre os centros seja minimizada. Os centróides encontrados são utilizados para representar características estatísticas dos textons. Leung e Malik (1999) definem o valor de k como 400, depois um mecanismo de poda é utilizado para atingir $k = 100$. Com isso, os vetores concatenados formam uma representação com 4800 posições. A ideia básica é que o processo de modelagem dos textons consiste em aprender um dicionário de textons contendo modelos de todos os elementos de textura representativos no conjunto de treinamento. O vocabulário de textons encapsula características genéricas, ao invés das propriedades específicas das imagens de textura.

Após construir o dicionário de textons, um modelo é gerado para cada imagem a ser classificada. Para a classificação das imagens, cada pixel recebe um rótulo de acordo com o dicionário de 100 textons criado, medindo a distância do vetor de aparência gerado pela convolução com o banco de filtros ao dicionário. A partir da matriz gerada ao colocar rótulos em todos os pixels, o histograma de textons é calculado para cada imagem. Para mensurar a distância entre os histogramas e classificar as imagens de acordo com o tipo de superfície utiliza-se a distância χ^2 . A dissimilaridade χ^2 entre os histogramas p e q é dada por:

$$\chi^2(p, q) = \sum_i \frac{(p_i - q_i)^2}{p_i + q_i}, \quad (2.7)$$

onde p_i e q_i são células de dois histogramas de mapas de textons.

Além dessa deficiência, a metodologia de análise de padrões de textura por textons possui outras dificuldades. A primeira delas é a necessidade de ter um banco de filtros sempre que o método for executado, uma vez que o dicionário de textons é gerado de acordo com um conjunto de imagens de treinamento. A segunda dificuldade ainda relacionada com o banco de filtros, reside no fato de que, mesmo que o pixel não possua todos os padrões definidos pelos filtros, é necessário verificar todos os padrões. A quantidade de padrões é pré-definida, não sendo possível representar características específicas de determinadas texturas e além disso, é necessário ter um conjunto de imagens iniciais para montar o dicionário de textons.

Apesar dessas dificuldades, muitos trabalhos foram desenvolvidos para diferentes aplicações baseando-se em textons (GUO *et al.*, 2012). Varma e Zisserman (2005) modelaram a superfície de texturas utilizando textons 3D, e Varma e Zisserman (2009) desenvolveram uma representação baseada em textons adequadas para modelar a distribuição da vizinhança por modelos de Markov (*Markov random fields*). Leung (2004) utilizou textons para classificação de face, levando em consideração a distribuição condicional de textons. Em Dahme, Ribeiro e Bush (2006) foram utilizados textons para classificação de grãos de pólen, adicionando informações espaciais de co-ocorrência para atingir melhores resultados.

Além disso, informações de cor foram utilizadas para melhorar a análise de imagens

utilizando textons (HARMS; GUNZER; AUS, 1986). Burghouts e Geusebroek (2006), Burghouts e Geusebroek (2009) estenderam um método originalmente proposto para imagens em níveis de cinza incorporando informação de cor aos textons de duas maneiras: (I) eles adicionaram cor diretamente no nível do banco de filtros e (II) propuseram um esquema de ponderação de cor para dar peso aos textons por meio das cores das arestas que geram a textura. Dessa forma, melhoraram o poder de discriminação dos filtros de textura para imagens formadas por muitas arestas. O que não é o caso para imagens com poucas arestas (BURGHOOTS; GEUSEBROEK, 2009).

Os trabalhos de Alvarez *et al.* (2010) e Alvarez e Vanrell (2012) ao invés de utilizarem cor na descrição dos textons, integraram características de cor ao descritor de textura para formar um único descritor. São utilizados dois espaços diferentes: o primeiro, representando a forma dos textons como na abordagem clássica de análise de textons e o segundo, representando a cor dos textons. Para combinar espaços com diferentes características, especificamente cor e forma, o algoritmo de agrupamento *Normalized Cut (N-cut)* (SHI; MALIK, 2000) foi utilizado, agrupando textons com características de cor e forma semelhantes. O agrupamento é realizado por meio do particionamento de grafo, onde os nós são os pontos do espaço de características e as arestas tem um peso igual à semelhança, definida pela distância euclidiana, entre os nós.

O algoritmo apresentado por Varma e Zisserman (2003) e Varma e Zisserman (2009) baseia-se no classificador de textura utilizando textons encontrados por meio de filtros de textura (LEUNG; MALIK, 2001). No entanto, no estágio de filtragem, ao invés de utilizar o banco de filtros para gerar as respostas em cada ponto, utiliza as intensidades dos pixels em uma vizinhança de $p \times p$ ao redor de cada pixel. Os níveis de cinza da vizinhança são reordenados para formar um vetor de características no espaço p^2 dimensional. Todos os demais passos, tanto antes, quanto depois da utilização dos filtros são mantidos. No estágio de treinamento, todas as janelas (vizinhança $p \times p$) do conjunto de treinamento de uma classe de textura são agrupadas e o conjunto dos centróides de cada grupo são utilizados para formar o dicionário de textons. A Figura 3 ilustra a diferença entre o modelo clássico de análise por textons, que utiliza um banco com 38 filtros e 8 respostas (VZ MR8) (VARMA; ZISSEMAN, 2005) e o modelo de análise por janelas/*patches* (*Joint classifier*).

Liu e Yang (2008) e Liu *et al.* (2010) também propuseram um modelo de análise de textons baseado na análise da vizinhança, onde são definidos cinco tipos especiais de templates de textons. Cada um desses templates possui 2×2 pixels, sendo considerados a menor região em análise. Para realizar a classificação das imagens eles utilizaram a distribuição aprendida a partir do conjunto de treinamento representando características de co-ocorrência de cor e textura dos textons por meio de um histograma, diferentemente dos trabalhos citados anteriormente, que utilizam os centróides dos grupos encontrados. A análise de textons por histograma (BATTIATO *et al.*, 2008; SHOTTON; JOHNSON; CIPOLLA, 2008; FEI-FEI; PERONA, 2005) representa uma imagem pela frequência de textons sem levar em consideração onde as características estão

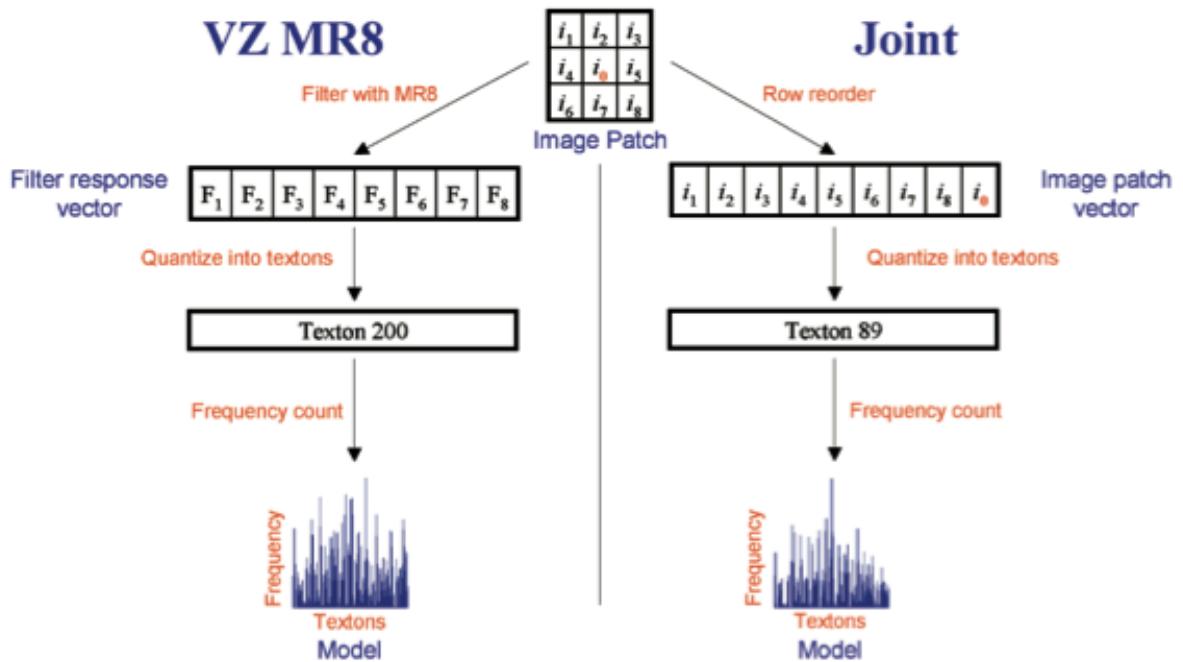


Figura 3 – Diferença entre MR8 e *Joint classifier*. Retirado de (VARMA; ZISSERMAN, 2009).

localizadas, mas dando importância à sua frequência, de maneira similar a estatísticas de primeira ordem.

Além de aplicações destinadas a classificação de textura, aplicações em segmentação e categorização de imagens podem ser obtidas. O trabalho de Shotton, Johnson e Cipolla (2008) propõe o uso de *bag of textons* semânticos para a categorização de imagens, inferindo as categorias de objetos presentes na imagem, fazendo uma segmentação semântica ao dividir a imagem em regiões e simultaneamente categorizando cada uma delas. Para construir o dicionário de textons, árvores de textons semânticos *Semantic Texton Forests (STFs)* foram utilizadas. Essas árvores de decisão aleatórias usam somente a comparação simples de pixels na vizinhança, realizando um agrupamento hierárquico implícito em textons semânticos e uma classificação explícita local da categoria da vizinhança.

2.2.1 Bag-of-Words

No primeiro passo um conjunto de características locais $c_{i,j}$, com $j = 1 \dots N^i$ são detectadas em cada imagem $I^i, i = 1, 2, 3, \dots, M$, onde N^i é o número de características na imagem i e M é o número de imagens. Detectores de Harris, Laplaciano, janelamento da imagem e regiões ao redor de pontos escolhidos aleatoriamente na imagem são ferramentas úteis para encontrar pontos ou regiões de interesse (ZHOU; ZHOU; HU, 2012; CAICEDO; CRUZ; GONZALEZ, 2009; ALVAREZ; VANRELL, 2012; VARMA; ZISSERMAN, 2009; CROSIER; GRIFFIN, 2010).

O segundo passo consiste em descrever ou caracterizar cada região ou ponto de interesse

utilizando descritores locais, gerando um vetor de característica para cada região (OJALA; PIENTIKÄINEN; MÄENPÄÄ, 2002; CROSIER; GRIFFIN, 2010; ZHOU; ZHOU; HU, 2012; NANNI; BRAHNAM; LUMINI, 2012). Khan, Weijer e Vanrell (2012) extraíram características de cor e forma para descrever os objetos de interesse na imagem para realização do reconhecimento de objetos. Alvarez e Vanrell (2012) utilizaram a co-ocorrência de cor e textura para classificação de imagens de textura. Além disso, pode ser utilizada a sequência de níveis de cinza da região selecionada ou as respostas dos bancos de filtros utilizados para obter textons (GALARO *et al.*, 2011).

O último passo é composto pela construção de um dicionário de *palavras visuais* a partir do aprendizado de vetores de característica obtidos a partir de um subconjunto de imagens de treinamento. As *palavras visuais* são vetores representativos resultantes de um procedimento de agrupamento dos vetores de características que representam cada região. Em geral, o algoritmo *k-means* é utilizado para realizar o agrupamento e diversos trabalhos utilizam os centróides de cada grupo para representação dos padrões (BATTIATO *et al.*, 2008; BATTIATO *et al.*, 2010; GALARO *et al.*, 2011; CROSIER; GRIFFIN, 2010). No entanto, alguns trabalhos utilizam uma amostra aleatória de cada grupo afirmando que não há um impacto significante na classificação de texturas naturais quando um algoritmo de agrupamento é utilizado (NOWAK; JURIE; TRIGGS, 2006). Em Winn, Criminisi e Minka (2005), um vocabulário universal de textons coloridos é proposto a partir da combinação de *palavras visuais* que otimizam a caracterização de objetos. Uma discussão sobre a construção de vocabulários construídos a partir da combinação de forma e cor é realizada em Khan, Weijer e Vanrell (2012).

A imagem é então representada por um histograma de tamanho fixo de *palavras visuais* que formam o vocabulário sem referências à localização das características, mas analisando a frequência em que ocorrem (CRUZ-ROA; CAICEDO; GONZÁLEZ, 2011). Quando faz-se necessário analisar a posição das *palavras visuais*, como por exemplo para a caracterização de cenas, são usadas abordagens hierárquicas (LAZEBNIK; SCHMID; PONCE, 2006; BATTIATO *et al.*, 2008). De acordo com trabalhos de caracterização de texturas naturais, quanto maior o tamanho do vocabulário melhor é a identificação (NOWAK; JURIE; TRIGGS, 2006; CSURKA *et al.*, 2004). No entanto, em Tommasi, Orabona e Caputo (2007) mostra-se que o tamanho do vocabulário não influencia na classificação. O objetivo da construção do dicionário é identificar um conjunto de padrões visuais que refletem o conjunto de padrões da imagem. Dessa forma, um classificador é treinado para reconhecer as classes baseando-se nos histogramas que representam as imagens.

2.3 Quando a textura não é homogênea

De maneira geral há um consenso, na literatura, sobre o fato de que imagens contendo somente um tipo de textura, denominadas texturas estacionárias (PETROU; SEVILLA, 2006) ou

homogêneas (ZHU; LIU; WU, 2000), podem ser caracterizadas de forma conveniente por meio da distribuição de probabilidade de uma vizinhança pré-definida ao redor de um pixel (FERNÁNDEZ; ÁLVAREZ; BIANCONI, 2013). No entanto, a limitação desta abordagem é encontrada ao observar imagens com as mesmas primitivas de textura ou primitivas semelhantes, mas com diferentes estatísticas de propriedades locais para cada uma delas (TAMURA; MORI; YAMAWAKI, 1978). A Figura 4 mostra o exemplo de duas imagens, onde diferentes histogramas são gerados para imagens compostas pelas mesmas primitivas, sendo que o número total de primitivas nas duas imagens é o mesmo. Por outro lado, o contrário também pode acontecer, onde duas imagens de texturas diferentes formadas pelas mesmas primitivas geram histogramas semelhantes.

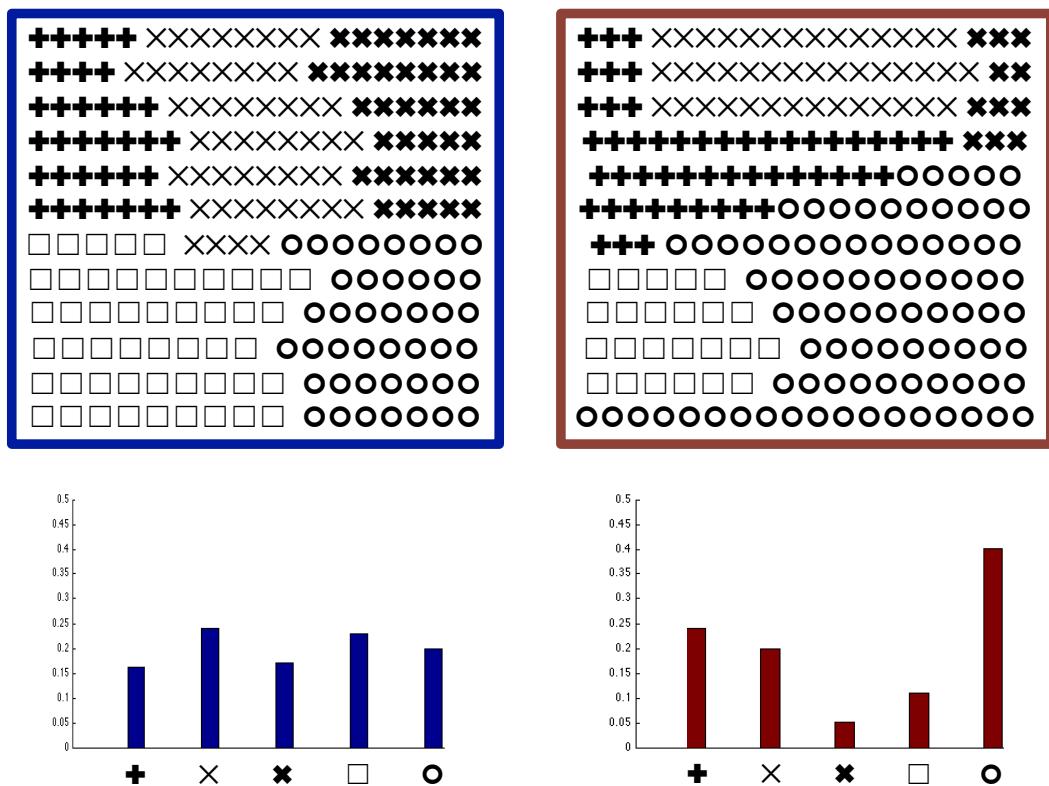


Figura 4 – Análise de primitivas de texturas contendo as mesmas primitivas, no entanto, com diferentes estatísticas para cada uma delas. O número total de primitivas é o mesmo nas duas imagens.

Outro ponto importante a ser observado na Figura 4 é a disposição das primitivas. Ao considerar que o conjunto de cada tipo de primitiva gere um padrão homogêneo de textura, para determinadas aplicações, a disposição das texturas não deve interferir na análise do padrão global da textura. No entanto, métodos que se baseiam no uso de filtros para extração de características sofrem interferência dessa disposição devido às transições entre os padrões homogêneos, resultando em diferentes caracterizações para mesmas texturas. Métodos de extração de características de textura que utilizam filtros são capazes de fornecer características de texturas em diferentes frequências, mas não proveem informação espacial sobre os diferentes tipos de textura que compõem a imagem.

Dadas essas particularidades, algumas questões surgem ao fazer a análise de uma imagem

de textura. A primeira questão é quais características espaciais locais precisam ser modeladas e a segunda, o que é local neste contexto. Essas questões ainda estão em aberto e geralmente o melhor modelo é aquele que fornece o resultado desejado, pois nenhuma abordagem é melhor em todos os casos (PAGET, 2008). A Figura 5, que mostra a imagem de nanoestruturas do ácido oxálico (ácido orgânico saturado) obtida por microscopia eletrônica de varredura por emissão de campo FEG (*Field Emission Gun*), fornece um exemplo onde podem ser encontrados mais de um padrão homogêneo de textura em uma mesma imagem. Neste caso, certamente o melhor método para descrever a textura dessa imagem não seria um método que analisasse de maneira global as características de textura, mas sim um método que fosse capaz de avaliar os padrões de textura da imagem sem considerar a área de abrangência das texturas homogêneas que compõem a imagem.

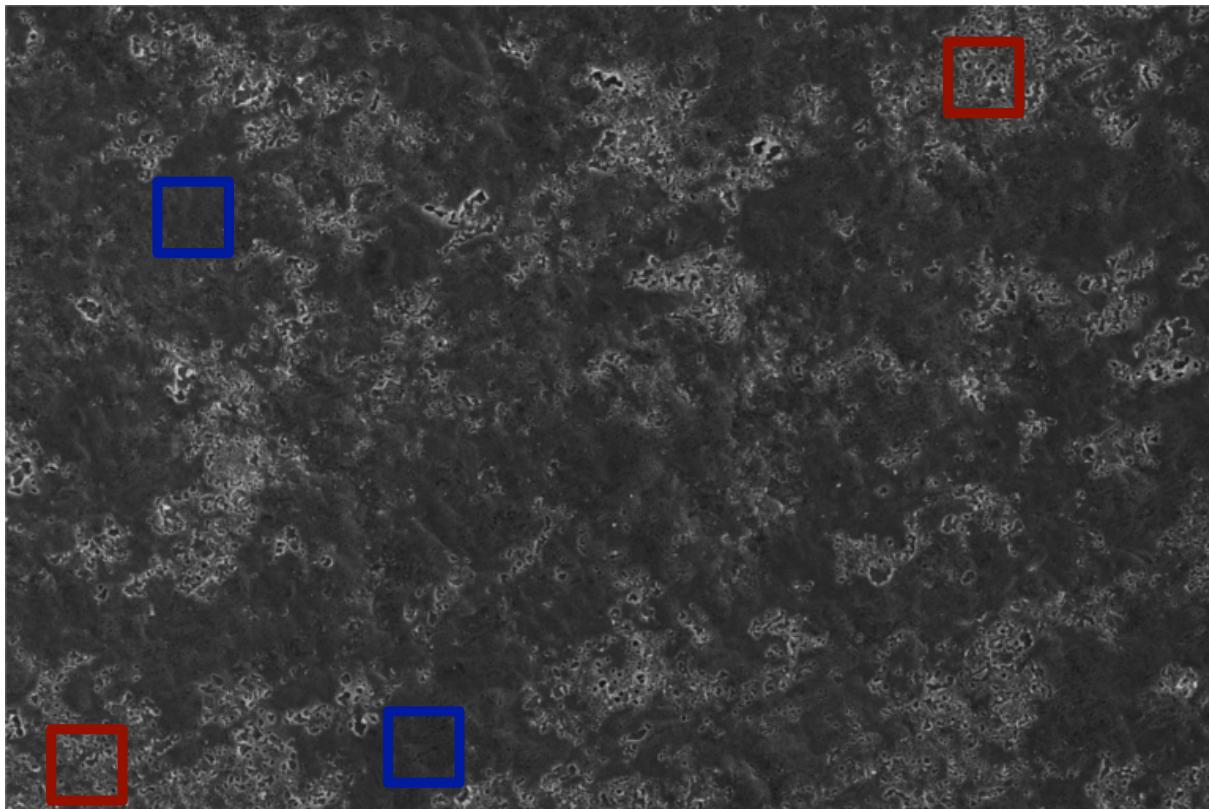


Figura 5 – Imagem do ácido oxálico que apresenta diferentes padrões de textura em uma mesma imagem. Os quadros de mesma cor representam textura com os mesmos padrões.

Métodos globais de análise assumem que toda a imagem é preenchida por uma única textura. Alguns desses métodos podem ser aplicados localmente em texturas não-homogêneas (PETROU; SEVILLA, 2006). No entanto, muitas texturas do mundo real exibem vários padrões, condicionados por fatores ambientais, que são facilmente percebidos por um observador humano (ROSENBERGER; COHEN-OR; LISCHINSKI, 2009), como é o caso da ferrugem ou imagens de sensoriamento remoto. No campo de síntese de imagens e segmentação, texturas que são formadas por mais de um tipo de textura são denominadas texturas não-estacionárias (PETROU; SEVILLA, 2006; ROSENBERGER; COHEN-OR; LISCHINSKI, 2009), não-homogêneas ou

texturas com variação global (WEI *et al.*, 2008; PARK; BYUN; KIM, 2013). Essas texturas são definidas dessa forma pois não é possível descrevê-las de maneira local e estacionária pela definição de *Markov Random Fields* (EFROS; LEUNG, 1999; WEI; LEVOY, 2000).

Neste trabalho, cujo foco é o reconhecimento de padrões de textura, o termo *padrões heterogêneos de textura* é mais adequado, uma vez que as definições de textura utilizadas não estão baseadas em *Markov Random Fields*. O uso da abordagem de análise de padrões heterogêneos torna-se crucial para a classificação de bases de dados de textura que apresentam heterogeneidade em sua composição. Sendo assim, o objetivo deste trabalho é explorar e formalizar o conceito de padrão heterogêneo de textura em diferentes classes de problemas de análise de imagens e reconhecimento de padrões. Pois métodos tradicionais analisam a textura considerando que em uma imagem exista apenas um padrão de textura. Por outro lado, o reconhecimento de texturas que não são homogêneas, ou seja, que incluem múltiplas texturas em uma única imagem, requer a segmentação dos padrões antes de identificar a imagem (PETROU; SEVILLA, 2006). Desta afirmação, surge o questionamento de como extrair informações de texturas heterogêneas. A seguir, o Capítulo 3 trata da motivação de padrões heterogêneos em textura e posteriormente no Capítulo 4 algumas propostas para a classificação de imagens heterogêneas são apresentadas.

CAPÍTULO
3

TEXTURA HETEROGÊNEA

O padrão heterogêneo de textura surge quando o objeto em análise apresenta padrões combinados de textura em sua composição, similar à definição clássica de composições heterogêneas em compostos químicos (STALEY; MATTA; WATERMAN, 2004). Ou seja, uma mistura heterogênea possui a característica de apresentar uma composição ou aparência diferente, quando analisada em partes. Por exemplo, uma sopa é um líquido heterogêneo, porque é possível perceber vários componentes diferentes. No entanto, não são em todos os casos que as substâncias de uma mistura heterogênea podem ser vistas na escala de visualização padrão, sendo necessário utilizar diferentes escalas de observação para análise. A mistura de areia-asfalto pode ser considerada heterogênea a partir de uma determinada escala, pois se observada em macroescala pode ser considerada homogênea, mas ao ser observada microscopicamente é heterogênea (SOUZA; ALLEN; KIM, 2008; SOUZA; ALLEN, 2011), como mostra a Figura 6.

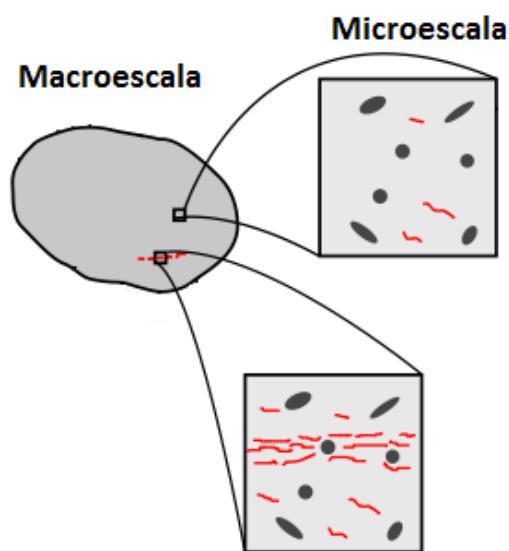


Figura 6 – Representação macroscópica e microscópica do composto areia-asfalto, mostrando, respectivamente, sua homogeneidade e heterogeneidade. Adapatado de (SOUZA; ALLEN, 2011).

Os coloides são exemplos interessantes de análise de padrões heterogêneos em substâncias que são aparentemente homogêneas. Um colóide é um sistema bifásico composto pelo meio disperso (fase dispersa), onde uma ou mais substâncias encontram-se uniformemente disseminadas no meio dispersante (fase contínua), sob a forma de pequenas partículas, formadas por agregados de moléculas. As partículas na fase dispersa tem tamanho entre 1 nm e 1 μm , dessa forma, coloides são intermediários entre misturas homogêneas (soluções com partículas menores que 1 nm) e misturas heterogêneas (suspensão, com partículas maiores que 1 μm). As partículas de um sistema coloidal são, normalmente, invisíveis em microscópios ópticos, mas podem ser vistas em ultramicroscópios ou em microscópios eletrônicos, podendo ser misturas sólidas, líquidas ou gasosas. Alguns exemplos são: o leite, maionese, sangue, gelatina, queijo, pedra-pomes, tintas e ligas metálicas, que quando observadas a olho nu são misturas homogêneas, mas ao serem observadas em escala nanométrica possuem padrões heterogêneos.

Uma analogia de misturas heterogêneas pode ser utilizada no reconhecimento de padrões. Acredita-se que o mesmo fenômeno ocorra em problemas específicos de análise de imagens de textura, onde subpadrões de textura podem ser identificados. A Figura 7 mostra um exemplo da aplicação desta hipótese em imagens de cortes transversais de folhas, onde podem ser analisados três cortes de diferentes espécies e as regiões que a compõem, sendo elas: cutícula, epiderme superior (com presença ou não de camadas subepidérmicas), parênquima paliçádico e parênquima lacunoso.

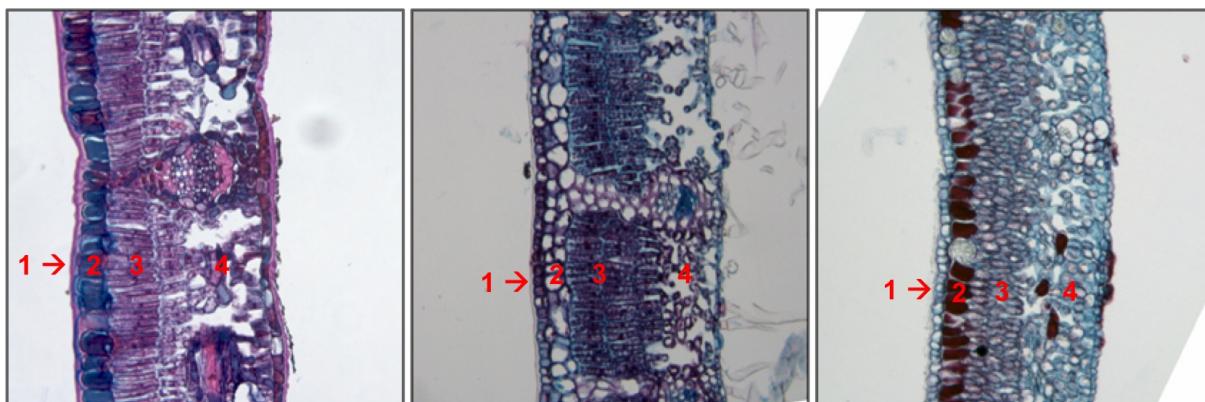


Figura 7 – Cortes transversais de folhas de três espécies diferentes de plantas. Cada corte de folha é dividido em quatro partes: 1 - Cutícula, 2 - Epiderme superior, 3 - Parênquima Paliçádico, 4 - Parênquima Lacunoso.

[Junior \(2008\)](#) realizou a identificação de plantas por meio da análise de imagens de cortes histológicos, inicialmente utilizando a abordagem clássica para realizar a identificação, na qual a imagem como um todo era considerada como uma textura. Os resultados ao empregar diversos métodos de caracterização de textura (Gabor, Fractais, Agentes, Matriz de co-ocorrência entre outros) mostraram que a análise homogênea (método global) não era suficiente para classificar as amostras corretamente. Desta forma, uma metodologia inspirada no estudo anatômico da histologia vegetal foi adotada, levando em consideração as diferentes regiões que constituem a folha (Figura 7). Para cada uma dessas regiões foram obtidos vetores de características que

as representassem e posteriormente esses vetores, após passarem por uma seleção de atributos, foram concatenados para compor o vetor de características de textura da imagem, como mostra a Figura 8.

Nesta Figura, os retângulos em branco correspondem aos métodos de extração de características, as setas simples que apontam para o vetor final indicam um único atributo fornecido pelo método e as setas espessas indicam que houve contribuição de mais de três atributos da região. As letras (X), (Y), (Z) e (W) indicam a quantidade de atributos que o método contém, sendo diferentes para cada região. Ao realizar a análise das diferentes texturas que compunham a imagem, foi possível classificar com sucesso as diferentes espécies, além de caracterizar seu ambiente de crescimento (JUNIOR *et al.*, 2011).

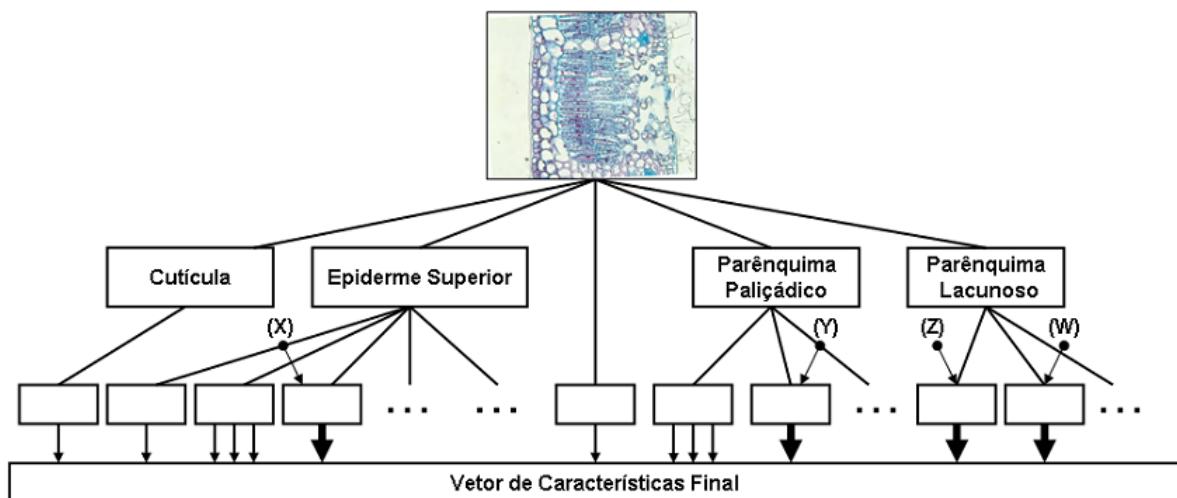


Figura 8 – Esquema de montagem do vetor de características por concatenação simples dos atributos extraídos de cada região do corte transversal da folha (JUNIOR, 2008).

Esta análise baseada na histologia vegetal nos sugere a heterogeneidade dos padrões de textura em uma mesma imagem. Observe na Figura 9, onde as regiões anatômicas são enfatizadas em retângulos amarelos, azuis e verdes, como os padrões distintos entre si na mesma imagem se repetem em diferentes espécies de folhas. Dessa forma, obtém-se amostras para cada sub-padrão de textura (retângulos/regiões) enfatizadas com os quadrados dentro dos retângulos para realizar a classificação de espécies. A Figura 10 mostra a correspondência dos padrões de acordo com cada região do corte histológico. É possível verificar que os padrões correspondentes são diferenciáveis de acordo com cada espécie (A, B e C). Dessa forma, surge a ideia por trás da análise de padrão heterogêneo, de maneira intuitiva, mas ainda não formalizada.

No caso da decomposição das imagens de cortes histológicos transversais de folhas, o reconhecimento de padrões heterogêneos torna-se direto. No entanto, o padrão heterogêneo pode ocorrer em situações onde sua caracterização não seja trivial, podendo ser analisado apenas em algumas escalas de observação (escala espacial ou temporal) ou ainda em espaços de transformações (Fourier, Fractal, Gabor entre outras). A Figura 11 apresenta um exemplo onde os padrões de textura heterogêneos não se encontram organizados de forma específica, mas

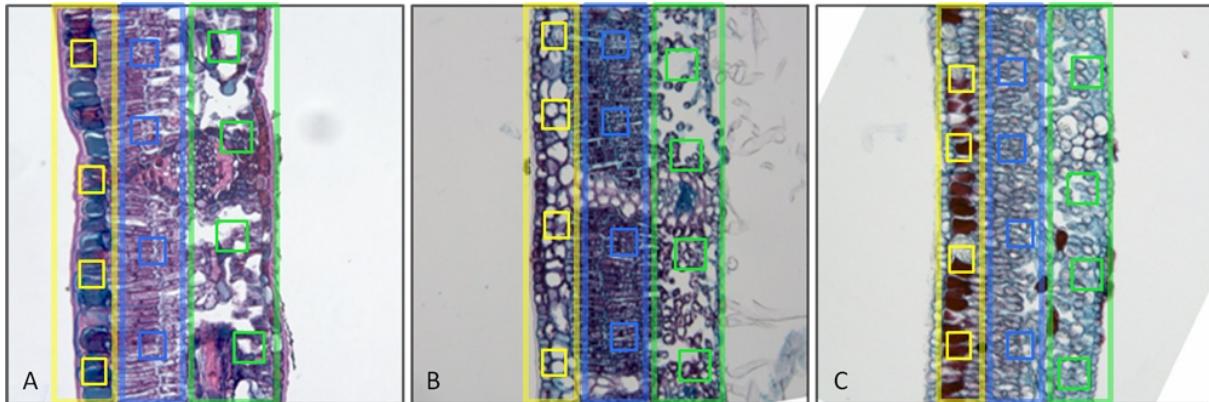


Figura 9 – Separação de padrões heterogêneos em diferentes espécies de folhas (A, B e C).

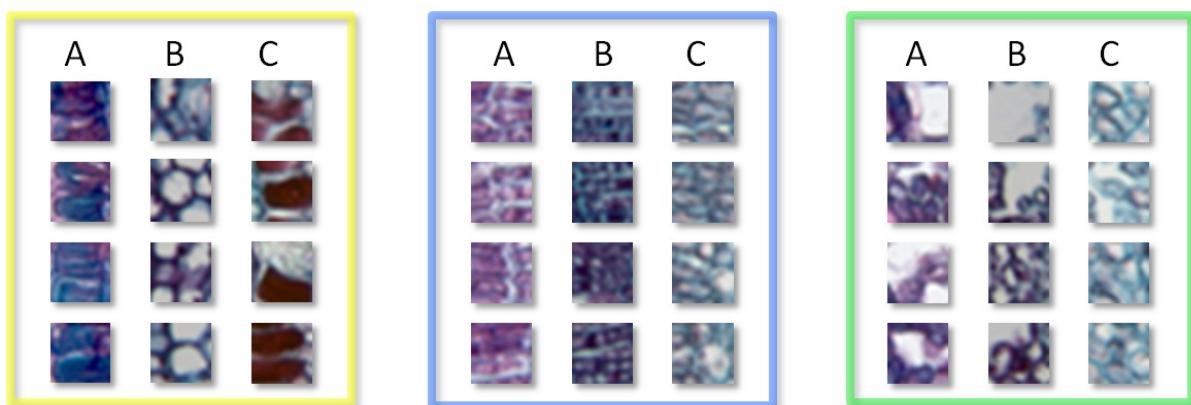


Figura 10 – Distinção entre os mesmos tipos de padrões obtidos de diferentes imagens de cortes histológicos de folhas. Os quadros coloridos evidenciam que os padrões contidos nas janelas podem ser agrupados de acordo com a parte da folha de que foram retirados. No entanto, mesmo sendo participantes de um mesmo tipo de padrão é possível verificar que eles são diferenciáveis de acordo com as espécies A, B e C das folhas.

distribuídos de forma aleatória pela imagem. A Figura 12 enfatiza que ao selecionar uma escala específica, é possível visualizar com maior clareza que a mesma é formada por três padrões distintos que se apresentam distribuídos irregularmente ao longo da imagem.

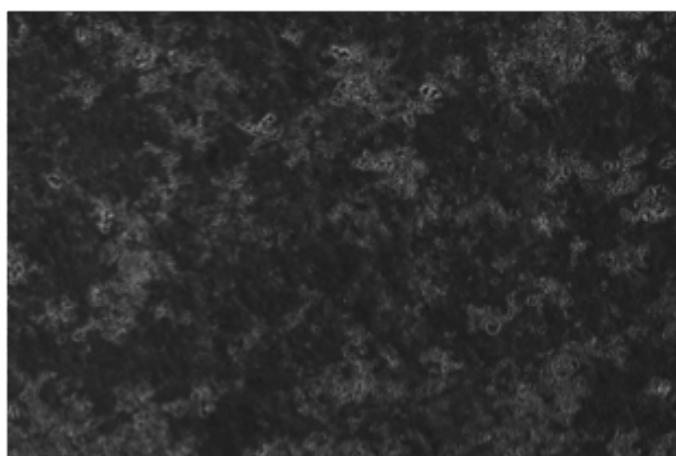
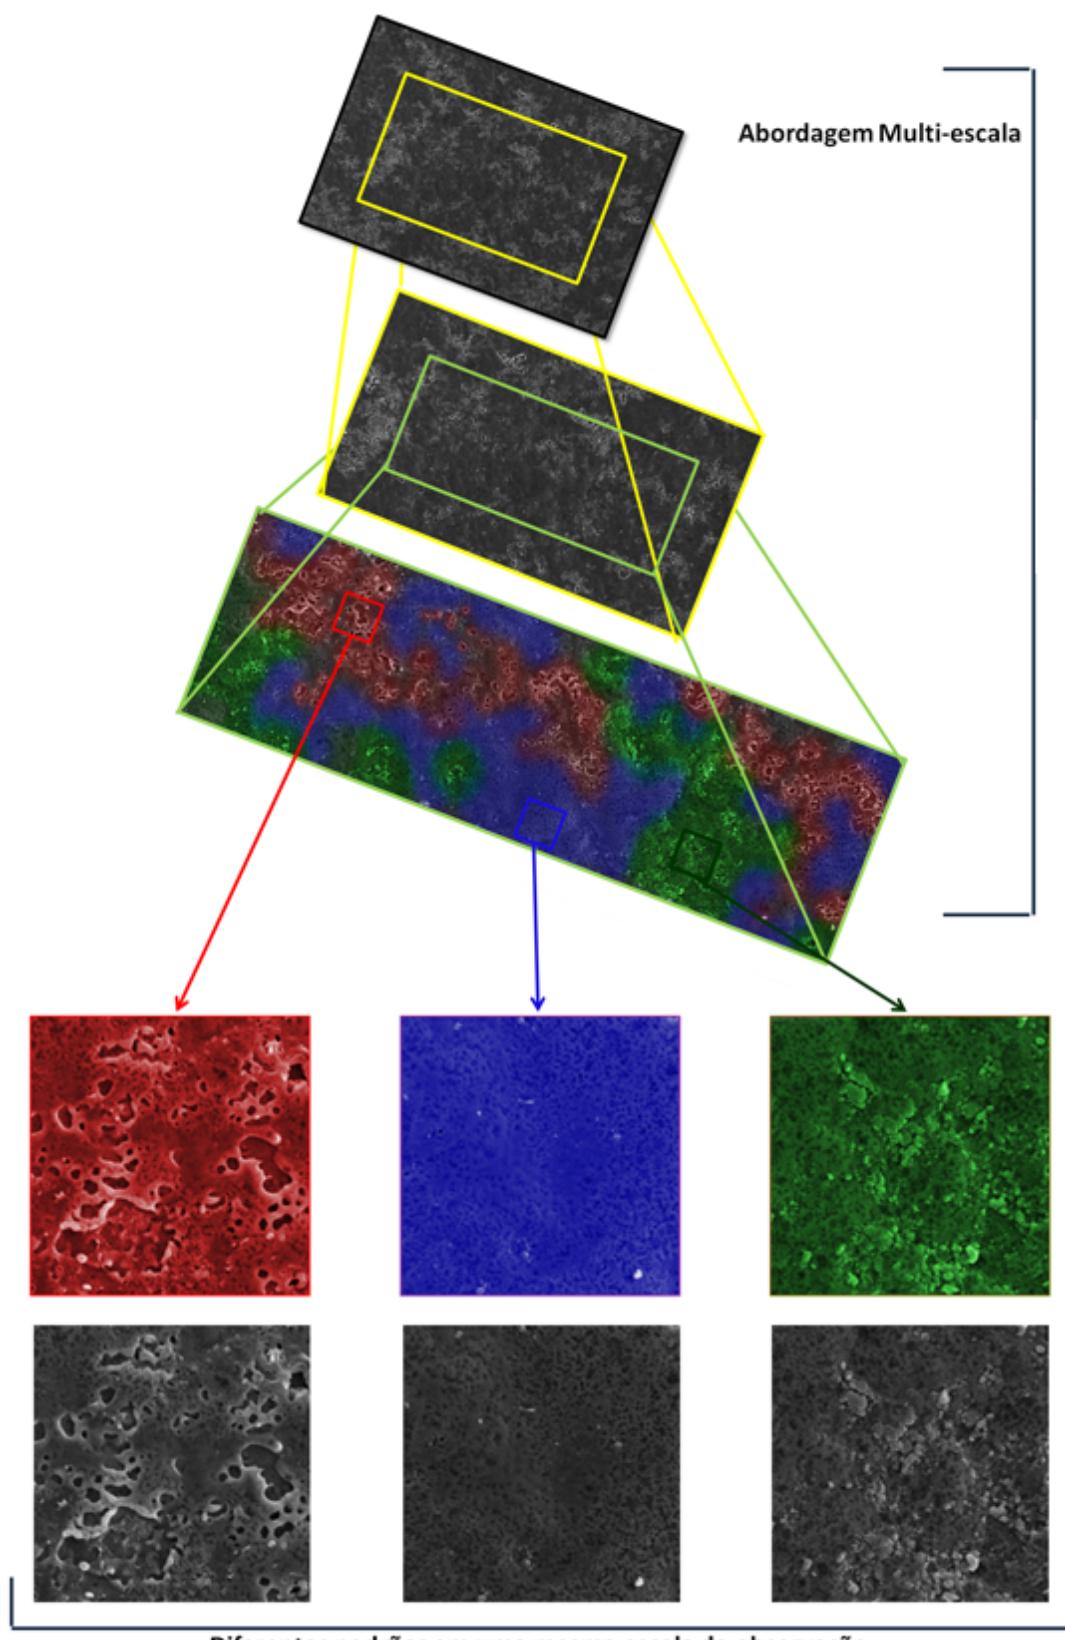


Figura 11 – Imagem padrão do ácido oxálico.



Diferentes padrões em uma mesma escala de observação

Figura 12 – Utilizando abordagem multi escala para analisar diferentes padrões em uma mesma imagem. A primeira parte da figura apresenta a abordagem multi-escala, onde são observadas diferentes escalas de uma mesma imagem e na segunda parte da figura é possível observar os padrões heterogêneos da imagem, identificando três diferentes padrões de textura.

Os dois exemplos anteriores apresentaram o padrão heterogêneo na análise espacial. Entretanto, ela pode estar presente também em outros espaços, como por exemplo, na análise temporal. A Figura 13 ilustra um padrão celular local, onde o tecido muda de forma durante o processo morfogênese/tubulogênese (formação de túbulos em células epiteliais ou endoteliais) na glândula salivar. Uma determinada região da imagem altera seu padrão estrutural ao longo do tempo, transformando-se em uma estrutura tubular. As regiões que participam desta dinâmica podem ser usadas para caracterizar as diferentes composições da sequência de imagens sendo considerados como padrões heterogêneos no tempo.

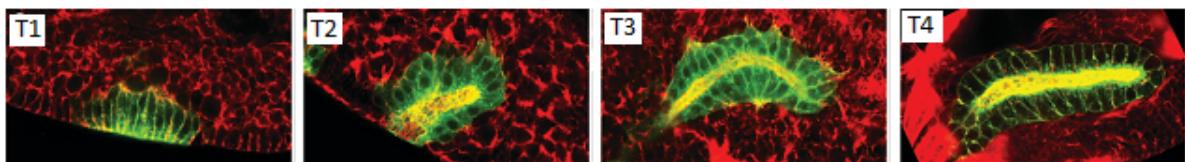


Figura 13 – *Morphogenesis* da glândula salivar em estágio embrionário nos tempos T1 a T4. Em vermelho tem-se a actina e em verde a formação dos microtúbulos, revelando a forma da célula. Adaptado de (MAYBECK; RÖPER, 2009).

Não somente nestes casos podem ser analisados padrões heterogêneos, mas esta representação pode ser aplicada em diversas áreas, como é o caso da nanotecnologia em que alguns padrões complexos são formados a partir de fenômenos de cristalização (RASTOGI, 2008). Outros exemplos podem ser citados em biologia, com o surgimento de novas estruturas durante o processo de desenvolvimento celular, denominado morfogênese, onde inicia-se a determinação e diferenciação daquela área específica (MEINHARDT, 1982), com o desenvolvimento de padrões, formas e estruturas encontradas na natureza (TURING, 1952; LEPPANEN *et al.*, 2004), na medicina, com a análise de atividades espontâneas do cérebro, em redes de computadores, com a classificação de tráfego em redes (ESTE; GRINGOLI; SALGARELLI, 2009), em visão computacional, com a classificação de movimento em vídeo, de formas e texturas, entre outros.

3.1 Modelagem do Problema

Em aplicações de reconhecimento de padrões, raramente existe um conhecimento completo sobre a estrutura probabilística do modelo, dada pelas probabilidades *a priori* $P(w_i)$ e densidade classe-condicional $p(\mathbf{x}|w_i)$ (DUDA; HART, 1973). Muitas vezes, há apenas a informação do problema e um conjunto de amostras para treinamento, também chamado de base de dados. Desta forma, é preciso extrair informações dessas amostras para chegar a um sistema de classificação satisfatório. Duas abordagens distinguem a forma como o problema será resolvido, sendo elas aprendizado supervisionado e não-supervisionado. Nos dois casos, uma amostra \mathbf{x} é atribuída a uma classe w_i de acordo com a densidade de probabilidade condicionada à classe w_i dada por $p(\mathbf{x}|w_i)$. Sendo assim, um vetor de características $\mathbf{x} = (x_1, x_2, \dots, x_n)$ de dimensão n , que representa uma amostra da base de dados, é classificado de acordo com as probabilidades a

posteriori de pertencerem à classe $w_i, i = 1, 2, \dots, c$, da seguinte forma:

$$P(w_i|\mathbf{x}) = \frac{p(\mathbf{x}|w_i)P(w_i)}{p(x)}, \quad (3.1)$$

onde $P(w_i)$ é a probabilidade *a priori* de w_i e $p(\mathbf{x})$ é a densidade de probabilidade misturada e $x \in \mathbf{R}$. O que diferencia essas duas abordagens é que no aprendizado supervisionado, a classe de cada amostra é conhecida, enquanto no aprendizado não-supervisionado não há nenhum conhecimento sobre as classes das amostras.

A solução por meio da análise de padrões heterogêneos para o problema de classificar imagens de textura utiliza as duas abordagens em diferentes fases. Primeiramente, o problema de classificar as amostras é dividido em subproblemas, de tal forma que, antes de realizar a classificação é necessário encontrar os padrões heterogêneos de textura em cada amostra. Como os padrões de textura, e até mesmo sua quantidade, não são conhecidos, utiliza-se o aprendizado não-supervisionado para identificação dos padrões. Posteriormente, a partir das características dos padrões heterogêneos, busca-se resolver o problema inicial de classificar as amostras por meio da abordagem supervisionada, uma vez que as classes de cada amostra são conhecidas.

A análise de padrões heterogêneos tem como objetivo partitionar as regiões da imagem de textura em diferentes grupos de tal forma que as regiões contidas em um mesmo grupo tenham mais semelhança do que aquelas em grupos diferentes. Uma das maneiras de resolver o problema de agrupamento é por meio de distribuição de misturas (HASTIE; TIBSHIRANI; FRIEDMAN, 2001). A modelagem de mistura supõe que o dado é uma amostra independente e identicamente distribuída (*i.i.d*) de uma população descrita por uma função de densidade de probabilidade (HASTIE; TIBSHIRANI; FRIEDMAN, 2001). Cada densidade que compõe a mistura descreve um dos grupos e portanto, descreve um padrão de textura na imagem. Dessa forma, o problema de análise dos padrões heterogêneos pode ser representado como uma mistura de distribuição normal multivariada, que é uma generalização da normal univariada quando se trabalha com duas ou mais variáveis aleatórias simultaneamente.

Uma mistura de distribuições é uma soma ponderada de distribuições. Ao considerar que a estrutura de probabilidade do problema é conhecida, mas sem conhecimento sobre os parâmetros do modelo, assume-se que as amostras pertencem a um número c de classes. Sendo as probabilidades *a priori* $P(w_i), i = 1, 2, \dots, c$, para cada classe e a densidade de probabilidade condicional à classe $p(x|w_i, \theta_i), i = 1, 2, \dots, c$, conhecidas, os vetores paramétricos $\theta_1, \theta_2, \dots, \theta_c$ e as classes de cada amostra desconhecidos. A função de mistura de densidade probabilidade para as amostras é dada por:

$$p(X|\theta) = \sum_{i=1}^c p(X|w_i, \theta_i)P(w_i), \quad (3.2)$$

onde $\theta = (\theta_1, \theta_2, \dots, \theta_c)^t$.

A densidade de probabilidade de uma distribuição normal univariada, com média μ e variância σ^2 , é dada por:

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-1/2((x-\mu)^2/\sigma^2)}, \quad (3.3)$$

onde $-\infty < x < \infty$, $\mu \in (-\infty, \infty)$ e $\sigma > 0$. De forma enfática, $p(x) \sim N(\mu, \sigma^2)$.

A função de densidade normal multivariada é dada por:

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right], \quad (3.4)$$

onde $-\infty < x_i < \infty$, $i = 1, 2, \dots, n$, sendo n o número de dimensões, Σ é a matriz de covariância e o determinante de Σ é o produto das variâncias. A densidade normal n -dimensional é denotada por $N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Dado um vetor aleatório X com distribuição normal multivariada, a combinação linear de seus componentes são normalmente distribuídos, todos os seus componentes tem uma distribuição normal (multivariada), zero covariância implica que os componentes correspondentes tem distribuição independente e as distribuições condicionais dos componentes são normais (multivariadas). Dessa forma, o modelo de mistura de distribuição normal multivariada é dada por $p(x|w_i, \theta_i) \sim N(\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$.

A verossimilhança baseada no modelo de misturas da densidade normal é aproximadamente o procedimento do método de agrupamento k -means (JOHNSON; WICHERN, 1988; HASTIE; TIBSHIRANI; FRIEDMAN, 2001). A principal dificuldade com o método de misturas diz respeito ao número de componentes, ou seja, o número de grupos. Normalmente, para lidar com esse problema, define-se uma faixa de valores para o número de grupos, verificando o erro do agrupamento, pois o erro irá diminuir consideravelmente ao encontrar a melhor separação, reduzindo suavemente até encontrar o número de grupos igual ao número de amostras (DUDA; HART, 1973).

O algoritmo k -means (HARTIGAN, 1975; HARTIGAN; WONG, 1979), descrito inicialmente por MacQueen (1967), tem como objetivo particionar os elementos de um conjunto de dados em k grupos de forma que o particionamento resulte em grupos coesos internamente e isolados em relação a outros grupos, ou seja, maximizando a semelhança entre elementos do mesmo grupo (homogeneidade) e a diferença entre elementos de grupos diferentes (heterogeneidade), minimizando sua função objetivo. Cada grupo é representado por um centróide, que é a média dos elementos do grupo. Como todas as variáveis são do tipo quantitativo, a medida de dissimilaridade comumente utilizada é distância euclidiana quadrática:

$$d(x_i, x'_i) = \sum_{i=1}^p (x_i - x'_i)^2 = \|x_i - x'_i\|^2. \quad (3.5)$$

Seja D uma base de dados com n elementos e C_1, C_2, \dots, C_k os k grupos disjuntos de D . O número k de grupos é equivalente ao número c de classes mencionado anteriormente. Uma

função erro é definida como função de parada do algoritmo, que ocorre quando a função erro não tem uma mudança significante ou os elementos dos grupos não são modificados, pois a cada iteração do algoritmo os elementos são reorganizados de acordo com suas distâncias aos centróides. A função erro é dada por:

$$Err = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} d(\mathbf{x}, \mu(C_i)), \quad (3.6)$$

onde $\mu(C_i)$ é o centróide do grupo C_i na iteração corrente, $d(\mathbf{x}, \mu(C_i))$ é a distância de \mathbf{x} a $\mu(C_i)$.

O algoritmo k -means pode ser dividido em duas fases principais: inicialização e iteração. Na fase de inicialização, k elementos de D são escolhidos aleatoriamente e definidos como os k centróides iniciais. Na fase de iteração a distância entre cada elemento de D a todos os centróides correntes é calculada, atribuindo cada elemento ao grupo com centróide mais próximo. Além disso, o erro é calculado em cada iteração. Sendo $D = \mathbf{x}_i, i = 1, 2, \dots, n$, uma atribuição de grupo ao elemento \mathbf{x}_i é dada por:

$$C(\mathbf{x}_i) = \operatorname{argmin}_{1 \leq i \leq k} \|\mathbf{x}_i - \mu(C_i)\|^2. \quad (3.7)$$

Após a atribuição de todos os elementos a um dado grupo, o centróide de cada grupo é recalculado, sendo a média dos elementos do grupo. A fase de iteração irá continuar até que não haja mudanças significativas no erro e nem mudanças entre os elementos dos grupos. Algumas otimizações de k -means verificam se o erro não irá aumentar caso ocorram modificações nos grupos. Além disso, o algoritmo deve ser executado com várias escolhas iniciais dos centróides, admitindo ser a melhor solução aquela com menor erro. Diferentes maneiras podem ser utilizadas para escolha dos centróides iniciais, como por exemplo, o uso de técnicas hierárquicas aglomerativas ([MINGOTI, 2005](#)).

Se k componentes da mistura são especificados, cada uma com uma densidade Gaussiana com matriz de covariância, a densidade relativa de cada componente da mistura é uma função monotônica da distância Euclidiana entre cada elemento e o centro da mistura ([HASTIE; TIBSHIRANI; FRIEDMAN, 2001](#)). O resultado do algoritmo k -means será a média de cada um dos grupos e por consequência tem-se um vetor de características representativo para cada região heterogênea da imagem de textura.

Como não existe uma sequência definida dos padrões, ou seja, o primeiro padrão de textura encontrado em uma imagem pode não ser o primeiro em outra, os padrões são organizados de acordo com o desvio padrão de cada vetor de características. O desvio padrão mostra o quanto dispersos os elementos do conjunto estão da média. Dessa forma, espera-se que as características de textura de padrões semelhantes possuam dispersão semelhante e que ela irá variar de acordo com as modificações nos padrões. Por outro lado, esse é um ponto negativo do método, pois não há garantia de que as características dos padrões de todas as imagens estejam ordenadas

da mesma forma. Outro ponto a ser considerado é que a largura ou amplitude do sino dado pela distribuição normal é proporcional ao desvio padrão σ , desta forma, padrões de textura semelhantes terão distribuições normais parecidas (DUDA; HART, 1973).

Assim, volta-se ao problema inicial de classificar as imagens do banco de imagens de textura. Neste caso, como as classes das imagens são conhecidas, um algoritmo de classificação supervisionada é utilizado. Sendo uma base de imagens contendo k classes, em que cada imagem está relacionada a uma classe $1, 2, \dots, k$, uma função discriminante é modelada para cada classe, classificando cada imagem de acordo com a classe que possui a maior função discriminante. Por outro lado, métodos que consideram a proximidade entre as amostras para realizar a predição, baseiam-se na hipótese de que dados similares tendem a se concentrar em uma mesma região e amostras não similares estarão distantes entre si.



ANÁLISE DE PADRÕES HETEROGÊNEOS

Este capítulo apresenta três metodologias para classificação de imagens com padrões de textura heterogêneos. A primeira está baseada em um sistema de janelamento da imagem, seguido da extração de características de texturas dessas janelas para identificação dos padrões heterogêneos e finalmente a classificação das amostras. A segunda abordagem tem seu foco na combinação das características de cada padrão de textura por meio de modelos gerados por *random forest* para realizar a classificação, independente de como essas características foram extraídas. Finalmente, a terceira abordagem utiliza uma metodologia baseada em autômatos celulares que enfatiza os padrões heterogêneos de textura e classifica as imagens de acordo com a evolução temporal das modificações causadas nas imagens devido a heterogeneidade de padrões. O ponto principal em analisar imagens com padrões de textura heterogêneo é distinguir os padrões dentro da imagem, posteriormente, extrair características de textura de cada padrão. A utilização da abordagem de padrões heterogêneos pode melhorar consideravelmente a taxa de classificação independente do método de extração de característica utilizado, uma vez que o importante é considerar a composição de padrões na imagem.

4.1 Lazy-Patch

A abordagem *lazy-patch*, uma das propostas desta tese, foi desenvolvida para análise de padrões heterogêneos em imagens de textura, sendo composta pelos seguintes passos: segmentação dos padrões heterogêneos em janelas (*patches*) da imagem e agrupamento das janelas com características de textura semelhantes; extração de características dos padrões de textura; correspondência desses padrões e finalmente; o reconhecimento de padrões por meio da classificação das imagens de textura, como mostra a Figura 14.

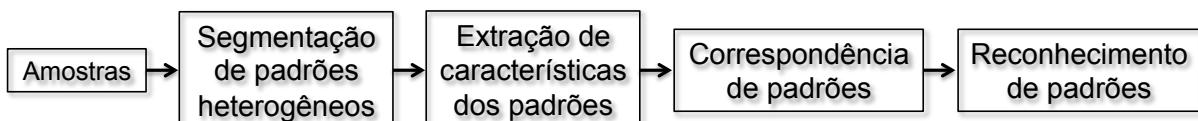


Figura 14 – Atividades para o reconhecimento de padrões por meio da análise de padrões heterogêneos em imagens utilizando abordagem *Lazy-Patch*.

4.1.1 Segmentação de Padrões Heterogêneos

Dado um conjunto de imagens com heterogeneidade de padrões de textura, o primeiro passo é realizar a segmentação para encontrar os padrões heterogêneos em uma imagem ou em uma sequência de imagens, no caso de texturas dinâmicas. Este passo é independente da análise que está sendo realizada, seja ela espacial ou temporal, encontrando um subconjunto de características de acordo com o problema de classificação de textura específico (ILEA; WHELAN, 2011). O objetivo deste passo é detectar os padrões heterogêneos em cada imagem, em alguns casos sendo necessário modificar a escala em análise. Uma importante particularidade dos padrões heterogêneos é que eles podem estar oclusos em determinadas escalas, sendo necessário analisar as características da imagem em diferentes escalas para verificar em qual delas os padrões heterogêneos podem ser identificados. Um exemplo é encontrado na Figura 12, em que a imagem do ácido oxálico é segmentada em três diferentes padrões.

Para segmentação das regiões heterogêneas utiliza-se uma abordagem de janelas de texturas, a qual modela a textura como uma distribuição de intensidades dos pixels em uma janela local. Dessa forma, toda a imagem é subdividida em janelas de tamanho $\sqrt{n} \times \sqrt{n}$, onde o tamanho da janela torna-se um parâmetro a ser analisado. Devido a natureza multi-escala dos padrões heterogêneos em imagens, ou seja, eles podem ser evidenciados em diferentes escalas, o tamanho da janela deve ser analisado de acordo com o conjunto de imagens em análise. Além disso, deve ser considerado que o tamanho da janela deve ser tão pequeno quanto possível para minimizar o risco de ter janelas com mais de um tipo de textura e, grande o suficiente para capturar as características de textura pela análise utilizada (PETROU; SEVILLA, 2006). De cada uma dessas janelas são extraídas características de textura para formar um vetor de característica que as represente.

Em seguida, as janelas são agrupadas com o algoritmo de agrupamento k -means (ver Seção 3.1) utilizando os vetores de características extraídos de cada janela. O vetor de característica pode ser extraído por diversos métodos globais de caracterização de textura homogênea, como por exemplo descritores de Haralick (HARALICK, 1979), descritores de Fourier (ZAHN; ROSKIES, 1972; AZENCOTT; WANG; YOUNES, 1997; GONZALEZ; WOODS, 2006), filtros de Gabor (MANJUNATH; MA, 1996; DAUGMAN; DOWNING, 1998; IDRISIA; ACHEROY, 2002), entre outros. O importante é que janelas com características semelhantes fiquem no mesmo grupo formando um subpadrão de textura dentro da imagem e desse agrupamento extrai-se um vetor de características que é a média dos vetores das janelas do grupo. O número de padrões é o mesmo número de grupos formados.

Como a imagem passou por um processo de janelamento pode ocorrer que não sejam obtidas janelas homogêneas, ou seja, que não representem bem o padrão de textura em que ela foi agrupada ou que possuam características de mais de um padrão de textura, por isso utiliza-se o teste de Grubbs (GRUBBS, 1969; STEFANSKY, 1972), uma técnica de análise multivariada para detecção de *outlier*. Um *outlier* corresponde a uma observação que parece desviar-se significativamente de outros membros da amostra em que ela ocorre (GRUBBS, 1969). Dessa forma, janelas com características distantes das demais são eliminadas. A seguir, uma breve descrição de como o teste de Grubbs é realizado:

4.1.1.1 Teste de Grubbs

O teste de Grubbs é realizado calculando-se o desvio d_i de cada janela x_i , representada por seu vetor de característica, em relação à média do grupo:

$$d_i = |x_i - \mu|. \quad (4.1)$$

Posteriormente d_i é dividido pelo desvio padrão s do grupo obtendo o coeficiente G (Equação 4.2). Se G estiver acima de um limiar estipulado, então essa janela é considerada um *outlier*. O limiar é dado por meio de uma tabela de níveis de significância de acordo com a confiabilidade que se quer das amostras.

$$G = \frac{d_i}{s} = \frac{|x_i - \mu|}{s} \quad (4.2)$$

4.1.2 Extração de Características dos Padrões Heterogêneos

Após encontrar os padrões heterogêneos é necessário caracterizar cada padrão, extraíndo suas informações para utilizá-las como objeto de comparação entre os diferentes padrões dentro da imagem e entre padrões de diferentes imagens. O vetor de característica de cada padrão é dado pela média dos vetores de características das janelas remanescentes que compõem cada um dos grupos encontrados por k -means. Dessa forma, um vetor de característica para cada padrão de textura é formado.

4.1.3 Correspondência de Padrões Heterogêneos

Com os padrões devidamente modelados, neste momento é necessário promover a correspondência entre os padrões heterogêneos nas diferentes imagens ou em diferentes sequências de imagens, como exemplificado na Figura 10. Ao fazer a correspondência entre os diferentes padrões, é possível verificar quais deles fazem a distinção entre imagens de grupos diferentes ao mesmo tempo que maximiza a semelhança entre imagens de um mesmo grupo. Todas as possibilidades de correspondência são testadas, para cada uma delas é calculada a distância χ -quadrado entre os pares de padrões que se correspondem, tendo como resultado o menor valor encontrado ao realizar todas as tentativas de correspondência.

As Figuras 15(a) e 15(b) mostram dois exemplos de correspondência de padrões. Nos dois casos ocorre uma correspondência ótima entre os padrões, sendo imagens da mesma classe. Ao encontrar o melhor encaixe entre todos os padrões de cada imagem, o grau de similaridade entre elas é obtido. Desta forma, é possível obter o grau de similaridade entre as imagens (ou sequências de imagens) a partir da porcentagem de correspondência entre os padrões heterogêneos das classes de imagens analisadas. Deste modo, pode-se realizar o reconhecimento de padrões em uma variedade de aplicações.

A Figura 16 mostra um exemplo em que não é possível realizar o encaixe de padrões devido as imagens pertencerem a classes distintas. Neste caso, obtém-se como similaridade entre as imagens o menor valor entre todas as tentativas de correspondência dos padrões.

Esta abordagem possui uma peculiaridade quando o mesmo padrão pode ser encontrado em diferentes classes de textura, como mostra a Figura 17. Este fato influencia a análise do grau de similaridade entre as classes que possuem um ou mais padrões semelhantes, isto porque classes diferentes podem obter uma alta taxa de similaridade mesmo possuindo padrões que as diferenciem.

4.1.4 Reconhecimento de Padrões

O reconhecimento dos padrões é realizado de forma direta, como cada grupo de padrões de uma imagem é comparado com todos os grupos de padrões do restante das imagens por meio de uma abordagem *lazy* (estratégia preguiçosa), a classificação ocorre ao encontrar a amostra mais próxima atribuindo a classe desta amostra a da imagem que está sendo analisada, seguindo a abordagem do vizinho mais próximo. Formalmente, o problema do vizinho mais próximo pode ser definido da seguinte forma: dado um conjunto D de amostras em um espaço n -dimensional e uma amostra de busca $q \in M$, encontrar a amostra mais próxima em D a q . Algoritmos *lazy* têm a vantagem de não ser necessário utilizar nenhum tipo de pré-processamento dos dados até que o elemento a ser classificado seja apresentado. Desta forma, são ótimos algoritmos para conjuntos de treinamento com dimensão elevada. No entanto, apresentam um alto custo computacional durante a fase de classificação.

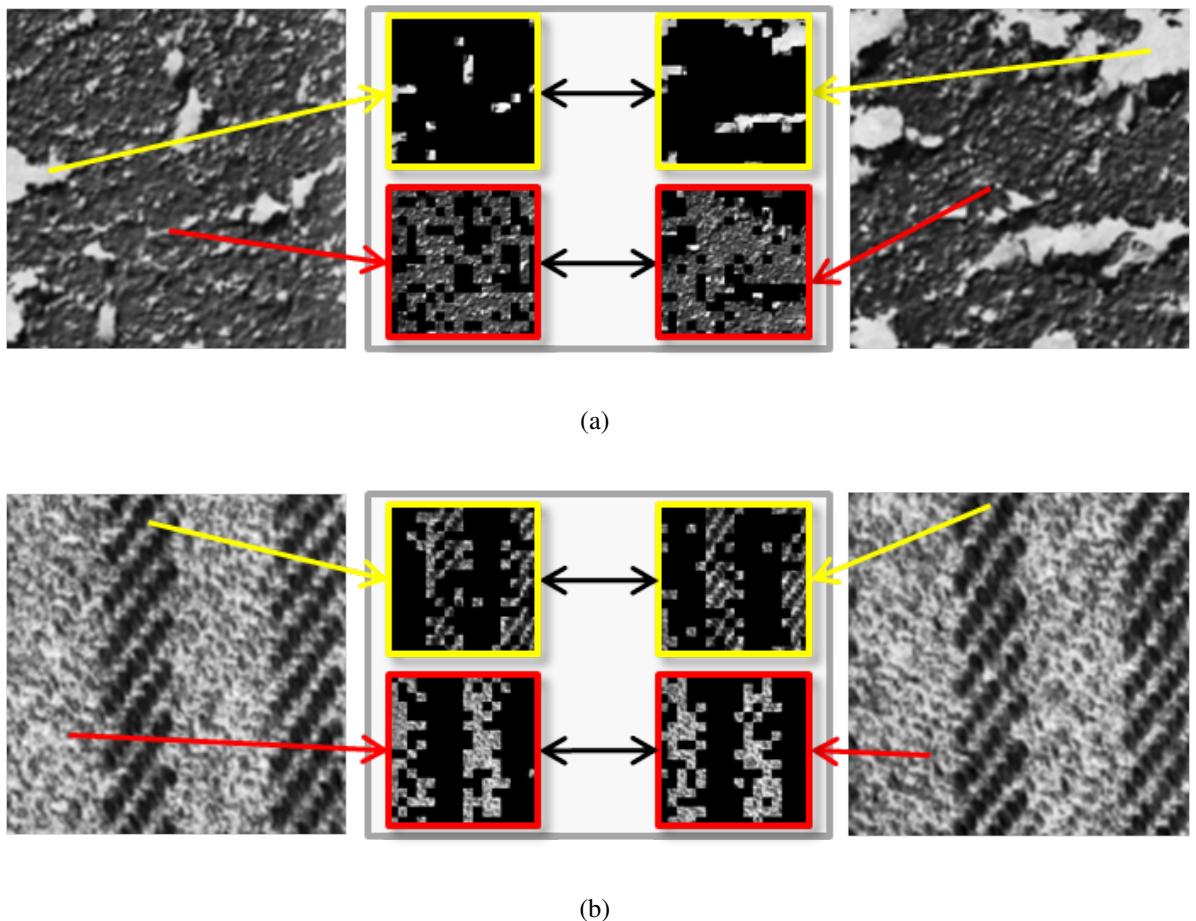


Figura 15 – Correspondência de padrões entre imagens da mesma classe. (a) e (b) mostram exemplos de diferentes classes de imagens.

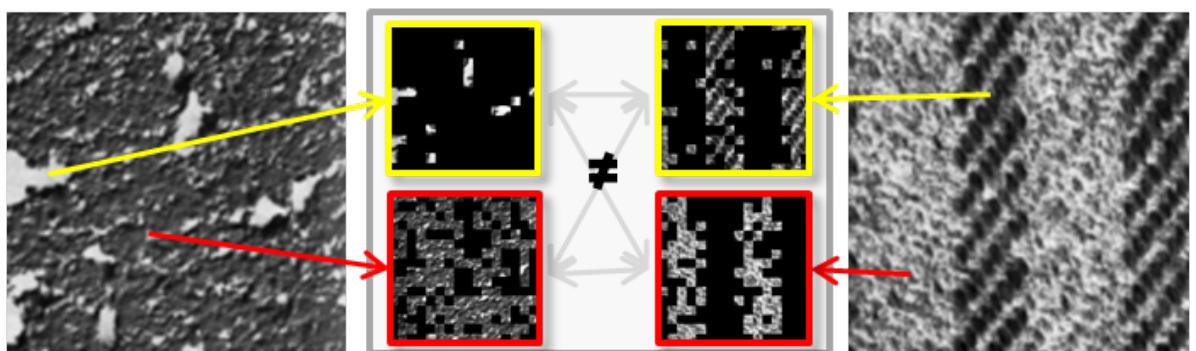


Figura 16 – Imagens de diferentes classes não possuem correspondência de padrões.

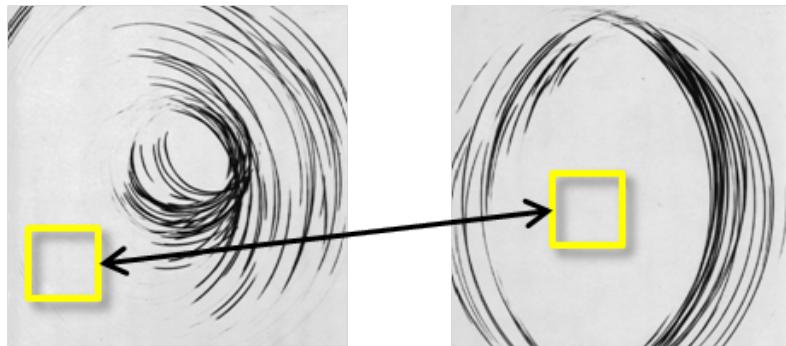
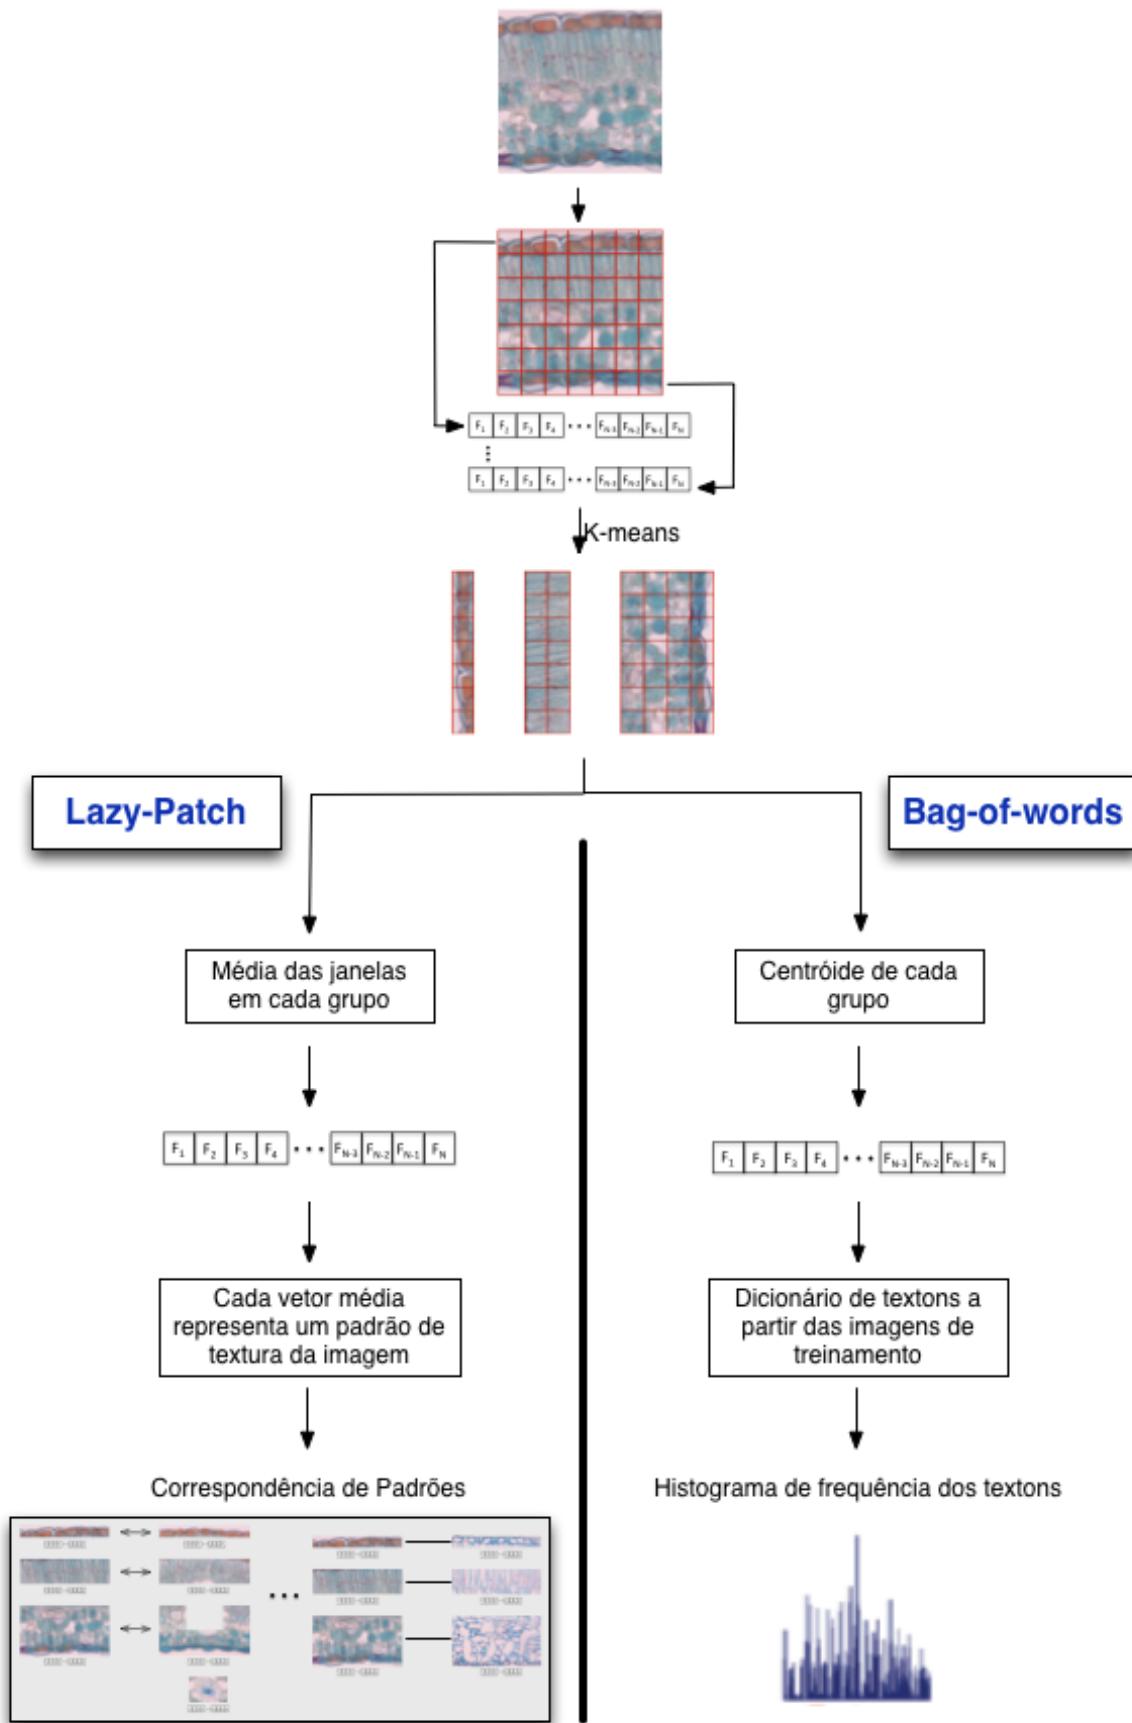


Figura 17 – Mesmo padrão em diferentes classes.

Algumas semelhanças podem ser encontradas ao contrapor esta abordagem com *bag-of-words*, no entanto, existem características marcantes que as diferenciam. A Figura 18 mostra uma comparação entre as duas abordagens. A fase inicial de ambas as abordagens consiste na divisão da imagem em janelas e posteriormente o agrupamento utilizando *k-means*. Neste momento os dois métodos seguem por metodologias diferentes, enquanto o *Lazy-Patch* faz a média de todas as janelas após a eliminação de janelas pelo teste de Grubb para obter um vetor de característica para representar cada padrão, o método *bag-of-words* utiliza o centróide de cada grupo para montar um dicionário de *textons*. É importante notar que são utilizadas todas as imagens de treino para montar o dicionário de *textons* e a partir deste dicionário calcular um histograma de *textons* para posterior classificação. No método proposto por este trabalho não é necessário que a classificação passe pela fase de treinamento conhecendo todo o conjunto de treinamento, pois utiliza a abordagem *lazy* para atribuir uma classe à imagem fazendo somente a comparação dos padrões de cada imagem para verificar a sua semelhança. A desvantagem desse método é o tempo gasto para classificar todas as amostras, sendo necessário percorrer todo o conjunto de amostras para cada amostra a ser classificada. Por outro lado, a maior vantagem deste método é não ter a necessidade de um conjunto de treinamento.

Figura 18 – Comparação entre o modelo *Lazy-Patch* e *Bag-of-words*.

4.2 Combinação de modelos

Métodos de classificação baseados em modelos têm como principal vantagem a característica de não precisarem de todo o conjunto de amostras para realizar a predição. Dada uma nova amostra a ser classificada, sua classe é predita baseando-se em um modelo gerado a partir de um conjunto de treinamento. A segunda proposta deste trabalho para a classificação de conjuntos de imagens com padrões de textura heterogêneo é o uso de um sistema de classificação que combina modelos de padrões de textura gerados por *Random Forest* para posterior classificação utilizando regressão logística (*Logistic Regression*). Essa proposta diz respeito a uma nova estratégia de classificação dos padrões heterogêneos considerando que as características de textura para cada padrão já foram extraídas. Para descrever esta metodologia, primeiramente, os métodos de classificação *Random Forest* e regressão logística são elucidados e posteriormente é realizada a descrição do modelo Random Forest combinado.

4.2.1 Random Forest

Breiman (2001) propôs em 2001 uma nova técnica de aprendizado de máquina denominada *Random Forests*, que é baseada em um sistema de votação para classificar as amostras. Seja N o número de instâncias de um conjunto de treinamento, para cada t iteração, m amostras são escolhidas aleatoriamente com substituição no conjunto de treinamento e um modelo de classificação é obtido utilizando árvores de decisão. Este modelo é armazenado e a classe de cada amostra do conjunto teste é predita de acordo com cada um dos t modelos, retornando a classe que ocorreu com maior frequência. Formalmente, um *Random Forest* é um classificador composto por uma coleção de classificadores $h(x, \theta_k), k = 1, \dots, K$ onde os θ_k são vetores aleatórios independentes identicamente distribuídos (iid) e cada árvore remete um único voto para a classe mais popular da entrada x .

Um classificador θ_k , no passo t , é gerado por um conjunto de amostras bootstrap de tamanho m escolhido de maneira aleatória do conjunto de treinamento, onde m é fixo e $m << p$ que o número de variáveis p . Para o problema de classificação, o valor padrão para m é $\lfloor \sqrt{p} \rfloor$. Uma árvore preditora $h(x, \theta_k)$ é então construída usando os dados escolhidos por θ_k determinados pela melhor divisão das amostras nas m características escolhidas aleatoriamente. Cada árvore é estendida ao máximo sem poda. Desta forma, um grande número de árvores são geradas, usualmente $K \geq 100$. Para este trabalho, 500 árvores foram utilizadas.

Aproximadamente um terço das amostras são deixadas fora do conjunto de treinamento. A classificação dessas amostras fornecerá uma estimativa *out-of-bag* do erro generalizado. Após um grande número de árvores terem sido geradas, todas votam por uma classe. A amostra x é classificada considerando a classe mais votada por todas as árvores preditoras na floresta:

$$(h(x, \theta_k), k = 1, \dots, K).$$

Random Forests são vantajosos porque são eficientes em grandes conjuntos de dados, podem lidar com um número muito grande de variáveis sem que seja necessário removê-las dando uma estimativa de quais variáveis são importantes para a classificação.

4.2.2 Regressão logística

Regressão logística modela as probabilidades *a posteriori* de K classes por meio de funções lineares em x , assegurando que a soma permaneça em $[0, 1]$, ou seja, a partir de um conjunto de observações, objetiva-se produzir um modelo que permita a predição de valores categóricos a partir de variáveis contínuas ou binárias (HASTIE; TIBSHIRANI; FRIEDMAN, 2001). A variável de resposta tem probabilidade binomial

$$Y_i \sim B(n_i, p_i); i = 1, 2, \dots, n, \quad (4.3)$$

onde os números de variáveis Bernoulli n_i são conhecidos e as probabilidades de sucesso p_i são desconhecidas (JOHNSON; WICHERN, 1988).

A medida de associação calculada a partir do modelo logístico é o *odds ratio* ou *chance*. A *chance* r de ocorrência de um evento é a probabilidade de ocorrência deste evento (p) dividida pela probabilidade da não ocorrência do mesmo evento, dada por:

$$r = \frac{p}{1-p}. \quad (4.4)$$

Os logaritmos dos *odds*, logits (logaritmos dos *odds*) das probabilidades binomiais desconhecidas, são modelados como uma função linear da amostra x_i :

$$\text{logit}(p_i) = \ln(\text{odds}) = \ln\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 x_{1,i} + \dots + \beta_K x_{K,i}. \quad (4.5)$$

O parâmetro β determina o quanto rápido p muda em relação a um preditor $z = 1, 2, \dots, K$.

4.2.3 Modelo Random Forest Combinado

O modelo Random Forest combinado é construído sobre um conjunto de amostras de treinamento e um conjunto de amostras de teste. Para suprir a necessidade destes conjuntos, os dados são divididos em k subconjuntos e $k - 1$ subconjuntos foram utilizados para treinamento, enquanto um subconjunto foi usado como teste. Esta estratégia, chamada *k-fold cross-validation*, é executada k vezes variando o subconjunto de teste, deste modo, de tal forma que todas as amostras sejam classificadas. Além disso, o conjunto de dados deve ter, pelo menos, k amostras da mesma classe, para garantir que cada *fold* tenha pelo menos uma amostra de cada classe, tornando a abordagem estratificada.

Os dados de entrada do modelo são obtidos a partir do conjunto de características de cada padrão de textura, resultando em c vetores de características $F_i = f_1, f_2, f_3, \dots, f_n, i = 1, 2, \dots, c$ para cada amostra, onde c é o número de padrões heterogêneos encontrados nas imagens, como mostra a Figura 19. Assim, cada amostra é representada por $\{F_1, F_2, \dots, F_c\}$.

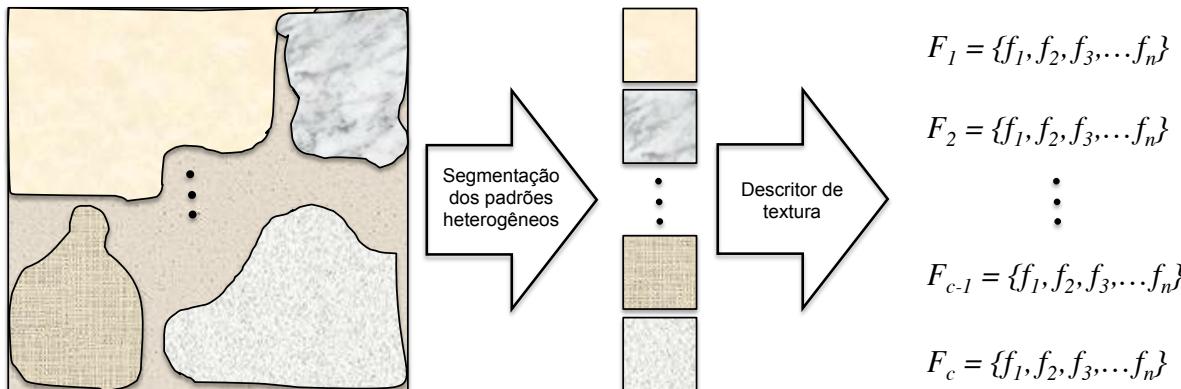


Figura 19 – Composição das características de uma imagem. Os vetores de características são obtidos a partir de um descritor de textura para cada uma das texturas que compõem a textura heterogênea da imagem.

Em um primeiro passo, o classificador Random Forest é empregado para gerar, baseado no conjunto de treinamento, c modelos Random Forest utilizando os c conjuntos de vetores de características dos padrões de textura. Os modelos gerados a partir do conjunto de treinamento são utilizados para obter as probabilidades *out-of-bag* (*oob*) para cada amostra separadamente para cada padrão de textura, ou seja, uma estimativa de probabilidade para cada classe em uma configuração um contra todos é calculada usando os modelos Random Forest (RF): *Modelo RF 1*, *Modelo RF 2*, ..., *Modelo RF c*. Neste momento, as características de textura do conjunto de treinamento são transformadas em características no espaço de probabilidades *oob*. Desta forma, as amostras são reformuladas pela concatenação das respectivas probabilidades baseada em cada padrão com a classe correspondente.

O *Modelo RF* é empregado novamente para obter as probabilidades *oob* do conjunto de teste. Similarmente, as probabilidades *oob* são geradas para cada padrão resultando em c conjuntos de probabilidades um contra todos para cada amostra de teste. Como as classes do conjunto de treinamento continuam desconhecidas, as características no espaço de probabilidades são utilizadas para predizer as classes das amostras do conjunto de teste. A técnica estatística de regressão logística é aplicada ao conjunto de treinamento no espaço de probabilidades *oob* para obter o modelo Logistic Regression (*LR Model*). A partir desse modelo, as classes do conjunto de teste são preditas analisando-se o impacto de cada variável que corresponde à probabilidade *oob* daquela amostra pertencer a cada uma das classes. Devido ao esquema de validação cruzada empregado, este procedimento é executado k vezes variando o conjunto de treinamento. Uma visão geral do modelo proposto pode ser visto na Figura 20.

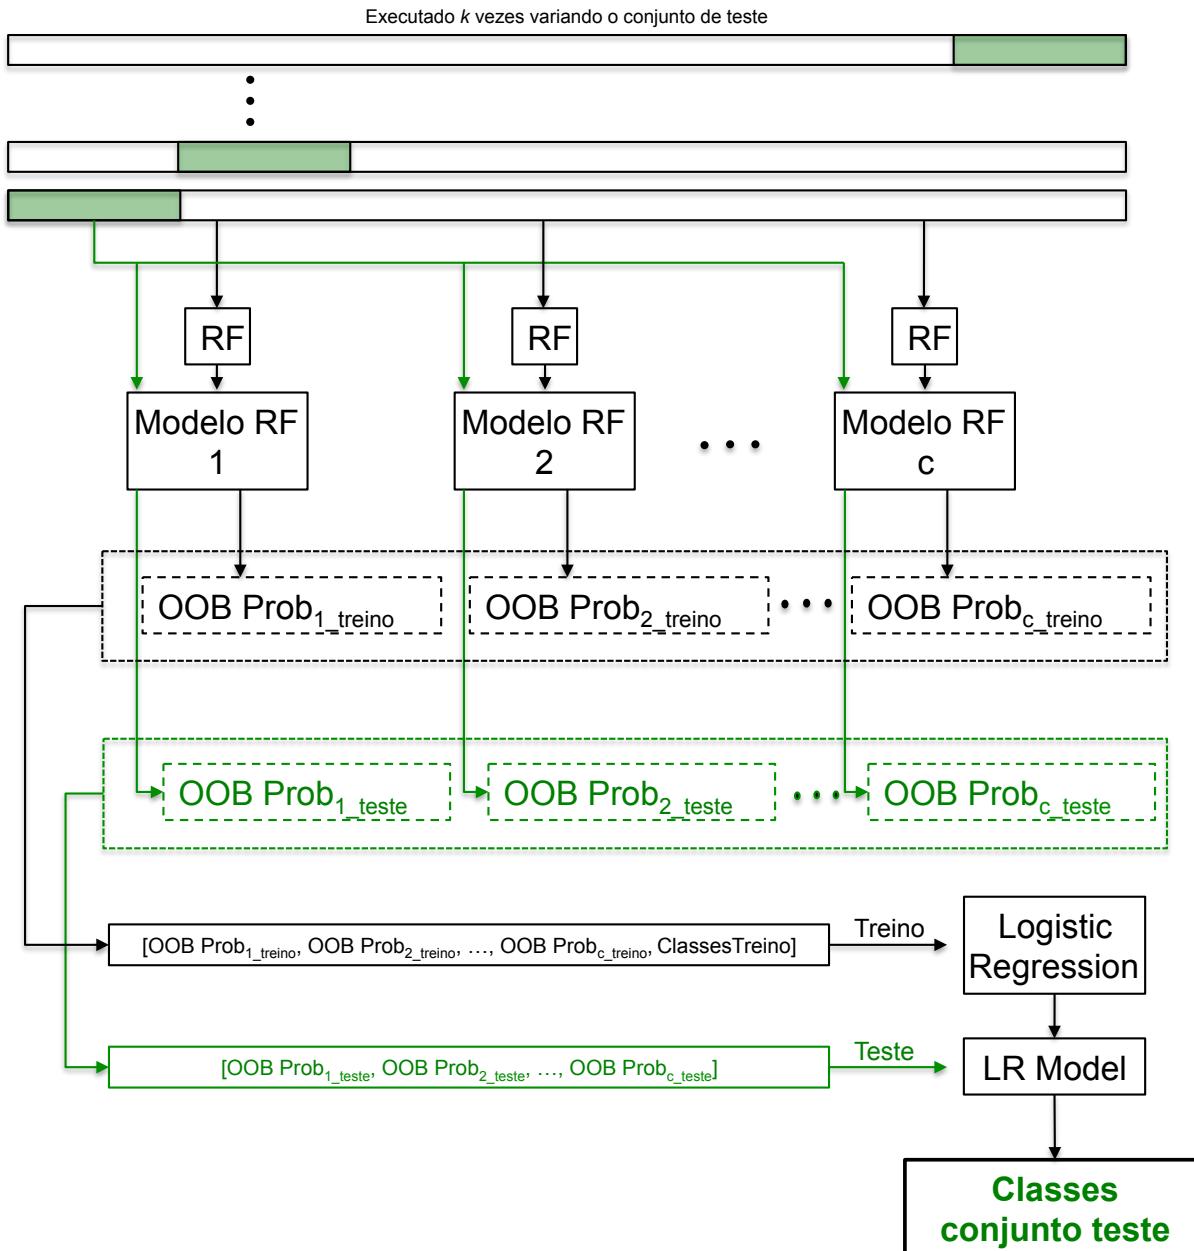


Figura 20 – Modelo random forest combinado. Características de textura de todos os padrões que compõem a textura heterogênea da imagem são utilizadas para gerar modelos random forest que combinados levam à classificação das amostras. Com estes modelos, as probabilidades *oob* para o conjunto de treinamento e teste são gerados. Desta forma, os padrões deixam de ser representados por características de textura passando à representação em um espaço de probabilidades. Finalmente, as classes do conjunto de treinamento são preditas utilizando regressão logística. Este procedimento é executado k vezes, variando o conjunto de teste, em um esquema de validação cruzada estratificada *k-fold*.

4.3 CITA: Autômatos celulares, corrosão e textura

Propriedades globais, tais como subjetividade e reversibilidade, tornam os autômatos celulares úteis para modelar propriedades físicas de fenômenos naturais (GOLES; MARTÍNEZ, 1998). Por esta razão, autômatos celulares têm sido utilizados com frequência para modelar vários processos biológicos (MILNE; FU, 2003; PICIOREANU; van Loosdrecht; HEIJNEN, 1998; PREZIOSI, 2003; SCHIFF, 2008; Van der Weeën *et al.*, 2012; VASILKOSKI; WEAVER, 2000) a partir de funções de transição relativamente simples, sendo possível modelar até mesmo padrões espaço-temporais complexos. Weeën *et al.* (2014) modelaram a corrosão alveolar ou corrosão por *pits* baseados nos principais mecanismos por trás deste fenômeno utilizando autômatos celulares. A corrosão é um processo de desintegração de metais em seus constituintes devido a reações com o ambiente (ROBERGE, 2008). A natureza complexa e o envolvimento de muitas variáveis, torna a modelagem de processos corrosivos uma tarefa difícil.

No entanto, a modelagem deste processo permite prever de forma mais acurada o processo corrosivo no tempo. Modelos baseados em autômatos celulares, sendo excelentes candidatos para modelagem de corrosão, estão aptos a capturarem a estocasticidade das reações eletroquímicas envolvidas em escala mesoscópica (LISHCHUK *et al.*, 2011). A corrosão alveolar é caracterizada pela formação de pequenas orifícios (alvéolos ou *pites*), como mostra a Figura 21, que iniciam na superfície metálica como resultado de impurezas ou irregularidades da superfície do metal ou do ambiente. A acidez dentro do orifício é mantida pela separação espacial das meias-reações catódicas e anódicas, o que cria um gradiente de migração de ânions agressivos para dentro do orifício (veja a Figura 21) e quanto mais profundo o orifício, menor é a sua taxa de crescimento (MALKI; BAROUX, 2005; PICKERING, 1989; WANG *et al.*, 2011).

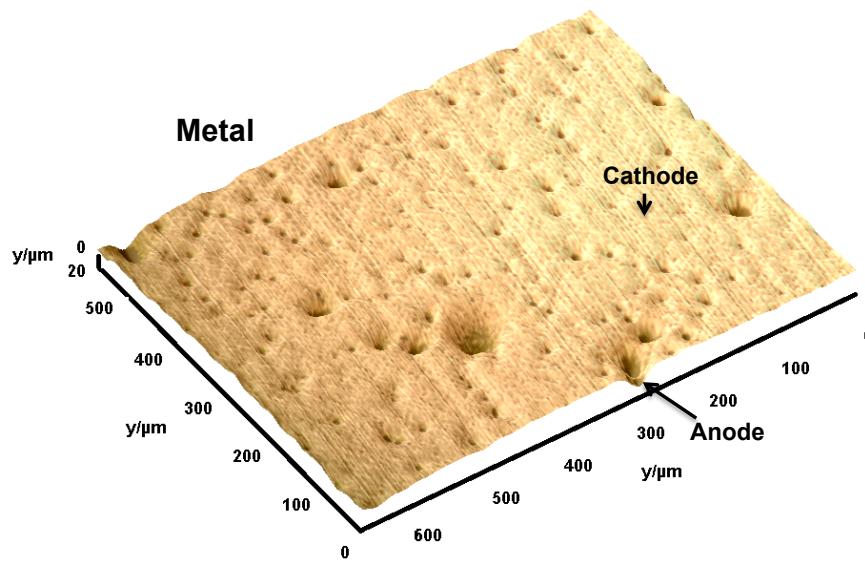


Figura 21 – Corrosão alveolar: representação esquemática em uma superfície metálica (SILVA *et al.*, 2015).

Indo além, nesta tese foi utilizada a modelagem de corrosão alveolar como uma forma de explorar os padrões heterogêneos em imagens de textura (SILVA *et al.*, 2015). Para realizar esta análise a imagem é considerada como uma superfície metálica onde os níveis de cinza definem a irregularidade da superfície. Este modelo de CA, assim como a corrosão alveolar, amplifica as diferenças existentes no material, neste caso os níveis de cinza, de modo que os maiores contrastes na imagem de textura original se tornarão mais marcantes e contrastes menores serão anulados. Utilizando essa modelagem para texturas heterogêneas, os padrões de textura são evidenciados ao longo das iterações da corrosão alveolar e é possível captar essas mudanças por meio da análise das modificações dos níveis de cinza. A seguir, é apresentada uma descrição de autômatos celulares e posteriormente os detalhes em sua aplicação para modelagem de corrosão alveolar na análise de imagens de texturas.

4.3.1 Autômatos celulares

Autômatos celulares (CA) são construções matemáticas em que o domínio do espaço, estado e tempo são discretos, em oposição as equações diferenciais parciais (PDE) em que esses três domínios são contínuos (BEREC, 2002; WOLFRAM, 1983). Modelos baseados em CAs podem ser vistos como uma alternativa a modelos baseados em PDEs, provendo aos pesquisadores uma ampla gama de ferramentas de modelagem e, em alguns casos complexos, uma solução para problemas encontrados em alguns dos métodos de modelagem clássicos (El Yacoubi; El Jai, 2002; TOFFOLI, 1984).

Para a modelagem de imagens, faz-se o uso de CA homogêneos, em que uma única função de transição governa a dinâmica de todas as células. Um autômato celular 2D homogêneo \mathcal{C} pode ser representado como

$$\mathcal{C} = \langle \mathcal{T}, S, s, N, \Phi \rangle ,$$

onde

- (i) \mathcal{T} é uma tesselação bidimensional de células c .
- (ii) S é um conjunto finito de T estados, com $S \subset \mathbb{N}$.
- (iii) A saída da função s produz o estado $s(c, t)$ de cada célula c no t -ésimo tempo de um espaço discreto.
- (iv) A função de vizinhança N determina as células vizinhas de cada célula c , incluindo a própria célula c .
- (v) A função de transição Φ gera o estado $s(c, t + 1)$ de cada célula c no tempo $(t + 1)$ baseando-se em seu estado e no estado dos vizinhos no espaço de tempo corrente.

Alguns conceitos dessa definição são esclarecidos a seguir.

4.3.1.1 Tesselação \mathcal{T}

É uma tesselação bidimensional finita formada por quadrados, sua implementação mais simples oferece uma maneira fácil de ligar as células de \mathcal{T} aos pixels da imagem de textura. Além disso, uma indexação das células de um CA 2D é introduzido, como mostrado na Figura 22. Para uma tesselação quadrada $i^* = j^* = \sqrt{|\mathcal{T}|}$.

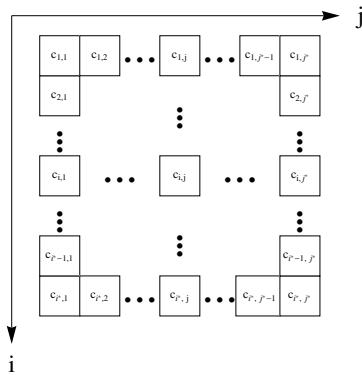


Figura 22 – Organizaçāo de um CA 2D.

4.3.1.2 Funçāo de vizinhança N

Diferentes vizinhanças podem ser definidas em 2D, sendo Moore e von Neumann, as duas vizinhanças mais utilizadas. A vizinhança Moore de uma célula $c_{i,j}$ compreende todas as células que compartilham pelo menos um vértice com $c_{i,j}$ (Figura 23(a)). A vizinhança von Neumann é mais restrita, somente aquelas células que compartilham uma aresta com $c_{i,j}$ fazem parte da vizinhança (Figura 23(b)).



Figura 23 – Vizinhança de uma célula $c_{i,j}$: (a) vizinhança Moore e (b) vizinhança von Neumann.

4.3.1.3 Estados discretos

Cada célula $c_{i,j}$ tem um dos T estados discretos compreendidos no conjunto S . Os estados das células $c_{i,j}$ do \mathcal{T} em $t = 0$, i.e. $s(c_{i,j}, 0)$, constituem a condição inicial de \mathcal{T} . Para a análise de imagens utilizando CA, a condição inicial de \mathcal{T} é determinada pelo nível de cinza dos pixels correspondentes na imagem de textura.

4.3.1.4 Função de transição Φ

A função de transição Φ determina o estado da célula $c_{i,j}$ no $(t + 1)$ -ésimo passo baseado no estado corrente das células e nos estados de seus vizinhos. A função de transição normalmente empregada em imagens é executada de maneira determinística e síncrona, em que Φ é usado para avaliar os estados de cada célula de \mathcal{T} em todos os passos e para todas as células ao mesmo tempo (BAETENS; Van der Weeën; De Baets, 2012).

4.3.2 Análise de textura

Uma imagem bidimensional em escala de cinza é tratada como uma objeto discreto e visto com uma tesselação \mathcal{T} . As dimensões de \mathcal{T} são definidas pelo tamanho da imagem, onde cada pixel da imagem é uma célula do CA. A imagem original é então utilizada para determinar um estado inicial das células do CA ao converter os níveis de cinza da imagem nos estados iniciais discretos de cada célula. Portanto, para a configuração inicial $s(c_{i,j}, 0)$ existem 256 estados possíveis, variando de 0 a 255. Esta conversão é descrita por:

$$s(c_{i,j}, 0) = I(i, j), \quad (4.6)$$

onde I é a imagem original e $I(i, j)$ representa o nível de cinza do pixel na i -ésima linha e j -ésima coluna da imagem I . Para introduzir as ideias da corrosão alveolar, a tesselação 2D é considerada como uma superfície de metal e o estado de cada célula irá representar a profundidade do orifício local no metal (ou seja, a terceira dimensão), onde o estado 0 significa que não há orifício e 255 sendo a maior profundidade de um orifício no metal no tempo $t = 0$. É importante observar que para $t > 0$ a profundidade máxima pode exceder 255 e a partir daí, é possível que a tesselação não possa ser representada como uma imagem em níveis de cinza.

Uma consideração significativa é a escolha das condições de borda para obter um comportamento apropriado para o modelo de CA. As duas condições de contorno mais populares são periódica e refletora. A primeira tenta simular uma tesselação infinita, onde as novas bordas superiores, inferiores, direita e esquerda são preenchidas com valores do lado oposto, formando um torus no espaço 3D. Esta condição de borda é útil para simular sistemas em que as bordas físicas não desempenham um papel importante. Entretanto, na abordagem proposta, bordas refletores serão utilizadas, pois elas fornecem melhores resultados para os bancos de dados estudados, como observado em resultados preliminares. Em primeiro lugar, quatro linhas imaginárias, sendo uma na parte superior, inferior, à esquerda e à direita da tesselação, são adicionadas. Em seguida, as condições de contorno refletores são aplicadas a cada passo de tempo como segue:

$$\begin{aligned}
s(c_{1,j}, t) &= s(c_{2,j}, t), \\
s(c_{n+2,j}, t) &= s(c_{n+1,j}, t), \\
s(c_{i,1}, t) &= s(c_{i,2}, t), \\
s(c_{i,n+2}, t) &= s(c_{i,n+1}, t),
\end{aligned} \tag{4.7}$$

em uma imagem de tamanho $n \times n$ pixels.

O estado atualizado de cada célula $c_{i,j}$ do \mathcal{T} no tempo $t + 1$ depende da análise dos estados das células na vizinhança de $c_{i,j}$ no tempo t . A vizinhança Moore (Figura 23(a)) é empregada. Além disso, o modelo de CA faz uso de uma função de transição Φ inspirada na corrosão alveolar. Em um primeiro passo, $d_{i,j}$ é calculada para cada célula $c_{i,j}$ como a diferença entre o estado desta célula e o valor mais baixo de estados dentro de sua vizinhança Moore, como mostra a Equação 4.8:

$$d_{i,j} = s(c_{i,j}, t) - \min(\tilde{s}(N(c_{i,j}), t)), \tag{4.8}$$

onde $\tilde{s}(N(c_{i,j}), t)$ é o conjunto de estados das células na vizinhança Moore de $c_{i,j}$.

Tendo em vista os princípios da corrosão alveolar, uma “impureza” local ou uma diferença de altura mínima é necessária em um determinado local, para iniciar ou propagar a corrosão. Para este propósito, um parâmetro de rugosidade da superfície v é introduzido. Todas as diferenças menores que este parâmetro são consideradas insignificantes, ou seja, não são impurezas reais, considerando o fato de que nem mesmo superfícies metálicas polidas são perfeitamente lisas. Isso significa que diferenças $d_{i,j}$ menores que v não levarão a uma corrosão alveolar. Por outro lado, à medida que a diferença aumenta, menor será a taxa de crescimento da corrosão, até que finalmente, a taxa de corrosão se torna zero. Assume-se que se a diferença $d_{i,j}$ é maior que 255, a maior diferença no estado $t = 0$, a taxa de crescimento da corrosão é zero. Dessa forma, somente estados cuja diferença $d_{i,j}$ seja maior ou igual a v e menor ou igual a 255 são atualizadas.

As Figuras 24(a)-24(c) mostram o processo de seleção para determinar se uma célula será avaliada ou não. Neste exemplo, v é igual a cinco significando que células $c_{i,j}$ com diferença menor que cinco em relação aos estados em sua vizinhança são considerados como pertencentes a superfície e não terão seu estado modificado. A Figura 24(a) mostra as células pertencentes a uma tesselação 5×5 e seus respectivos estados iniciais. A Figura 24(b) descreve a diferença $d_{i,j}$ para cada uma dessas células calculada de acordo com a Equação 4.8. Finalmente, na Figura 24(c), as células em cinza indicam as células a serem avaliadas naquela iteração, porque suas distâncias $d_{i,j}$ são maiores ou iguais a cinco e menores ou iguais a 255.

Sob estas premissas, a função de transição Φ estabelece o estado de uma célula $c_{i,j}$ na

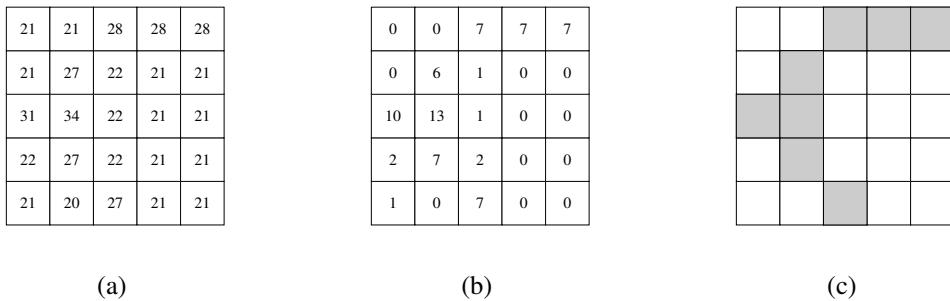


Figura 24 – Seleção de células a serem atualizadas, com $v = 5$: (a) tesselação 5×5 com o estado inicial de cada célula, (b) diferença $d_{i,j}$ para todas as células de acordo com a Equação 4.8 e (c) níveis de cinza indicando as células a serem atualizadas.

$(t + 1)$ -ésima iteração de acordo com a Equação 4.9:

$$s(c_{i,j}, t+1) = \begin{cases} s(c_{i,j}, t) + Q(d_{i,j}, \gamma) & , \text{if } 255 \geq d_{i,j} \geq v, \\ s(c_{i,j}, t) & , \text{if } d_{i,j} < v \text{ or } d_{i,j} > 255, \end{cases} \quad (4.9)$$

onde $\gamma \in [0, 1]$ é o poder de corrosão alveolar. O parâmetro γ representa a resistência específica do metal à corrosão sob condições ambientais dadas, onde $\gamma = 0$ significa um metal completamente resistente. Além disso, Q é uma função que emprega $d_{i,j}$ e γ para determinar o nível de corrosão a ser aplicado. Q é definido como:

$$Q(d_{i,j}, \gamma) = (255 - d_{i,j}) \gamma. \quad (4.10)$$

Da Equação 4.10, pode-se observar que a função Q fornece, dependendo do valor de γ , uma saída não inteira, tornando a estrutura do modelo um CA contínuo ou um mapa de grades acoplados (*Coupled Map Lattice*) (LEVINE; REYNOLDS, 1992), que modela o comportamento de sistemas não lineares. Entretanto, para continuar trabalhando com um modelo baseado em CA e para manter o modelo simples, a escolha foi limitar a saída de Q a valores inteiros, como na Equação 4.11:

$$Q(d_{i,j}, \gamma) = \lfloor (255 - d_{i,j}) \gamma \rfloor, \quad (4.11)$$

onde a em $\lfloor a \rfloor$ denota o piso de a .

A saída do modelo baseado em CA em cada iteração é a massa cumulativa da superfície corroída. Em cada iteração, após atualizar o estado das células, a massa que sofreu corrosão naquela iteração é adicionada à massa erodida da iteração anterior. Finalmente, esta massa corroída acumulada é expressa em relação ao número de pixels da imagem de textura de tal forma que imagens com tamanhos distintos possam ser comparadas. As séries temporais da massa corroída acumulada serão utilizadas como descritores de textura para cada imagem, sendo o número de características igual ao número de iterações do modelo baseado em CA. O

procedimento para obter as características de textura está descrito no Algoritmo 1 e a Figura 25 mostra o resultado da execução do algoritmo para algumas imagens. A primeira coluna da Figura 25 mostra algumas imagens originais, enquanto a segunda e terceira colunas mostram, respectivamente, o resultado da execução do modelo baseado em CA após 90 iterações em escala de cinza e mapa de cores.

Algoritmo 1: Pseudocódigo do modelo de CA para extração de características de textura baseado na corrosão alveolar.

Input: Imagem original ($n \times n$), rigidez da superfície v , poder de corrosão γ , número de iterações

Output: Classe da imagem

```

1  $s(c_{i,j}, 0) \leftarrow$  imagem original ( $I(i, j)$ )
2 Adicionar linha imaginária na parte superior e inferior
3 Adicionar linha imaginária à direita e à esquerda
4 for all iterações do
5   Aplicar borda refletida na tesselação  $\mathcal{T}$ :
6      $s(c_{1,j}, t) = s(c_{2,j}, t)$ 
7      $s(c_{n+2,j}, t) = s(c_{n+1,j}, t)$ 
8      $s(c_{i,1}, t) = s(c_{i,2}, t)$ 
9      $s(c_{i,n+2}, t) = s(c_{i,n+1}, t)$ 
10    for  $i = 2 \rightarrow n + 1$  do
11      for  $j = 2 \rightarrow n + 1$  do
12         $d_{i,j} \leftarrow s(c_{i,j}, t) - \min(\tilde{s}(N(c_{i,j}), t))$ 
13        if ( $d_{i,j} < v$  or  $d_{i,j} \geq 255$ ) then
14           $s(c_{i,j}, t + 1) \leftarrow s(c_{i,j}, t)$ 
15        else
16           $s(c_{i,j}, t + 1) \leftarrow s(c_{i,j}, t) + Q(d_{i,j}, \gamma)$ 
17    Calcular a massa corroída acumulada
18  Vetor de características  $\leftarrow$  massa corroída acumulada em relação ao número de pixels

```

Mesmo após um grande número de iterações do algoritmo, detalhes estruturais da imagem original podem ser observados. As regiões com valores de estado semelhantes são principalmente considerados pelo modelo como pertencendo à mesma superfície local e, por conseguinte, tendem a manter o mesmo valor de estado durante toda a simulação. Por outro lado, os demais padrões de textura encontrados na imagem tendem a ter um comportamento peculiar a cada padrão, evidenciando a heterogeneidade da textura. Esse extrator de características de textura foi denominado como *CITA descriptor*.

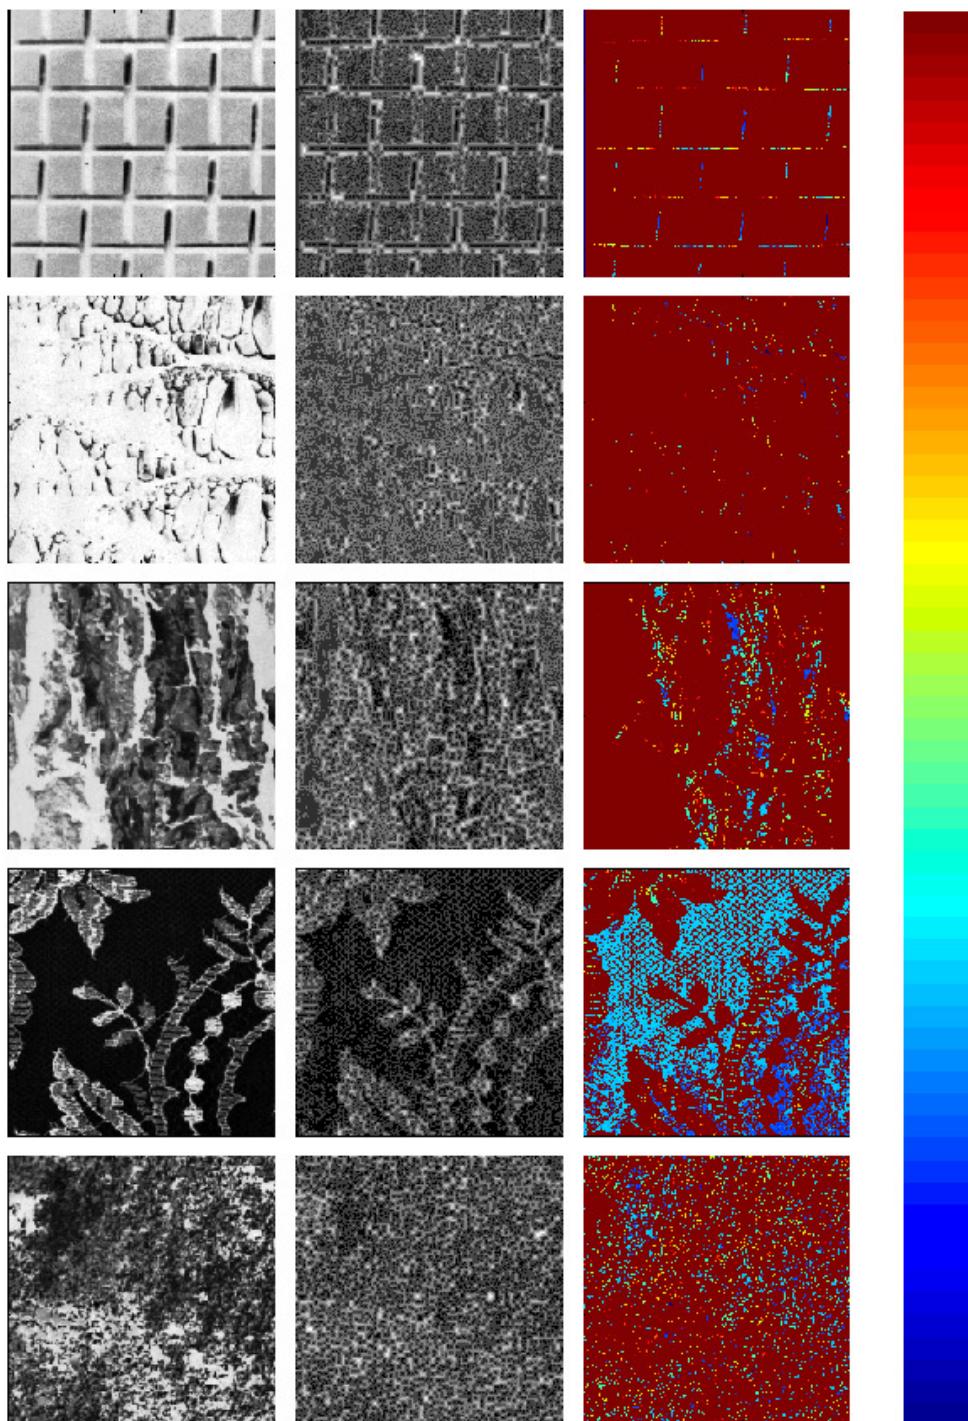


Figura 25 – Simulação dos resultados (SILVA *et al.*, 2015). Primeira coluna: imagens originais. Segunda coluna: resultado em escala de cinza da aplicação do modelo de corrosão alveolar em imagens de textura utilizando $\gamma = 0.05$, $v = 5$ e 90 iterações. Terceira coluna: mesmo que segunda coluna em escala azul-vermelho.



EXPERIMENTOS E RESULTADOS

No Capítulo 4 foram apresentadas três abordagens principais para análise de padrões heterogêneos. A primeira proposta diz respeito a segmentação dos padrões heterogêneos da textura para obter características concernentes a cada padrão. Dentro dessa proposta foram desenvolvidas duas vertentes para classificação das amostras. Sendo a primeira, a análise de um vetor de características que contenha as características de todos os padrões de textura da imagem e a segunda, a análise dos padrões de textura separadamente por meio de modelos Random Forest e posteriormente a combinação dos modelos gerados por meio de regressão logística. A terceira proposta para análise de padrões heterogêneos é dada pela modelagem do processo de corrosão alveolar por meio de autômatos celulares considerando a imagem de textura como uma superfície. Nesta proposta, os padrões heterogêneos de textura são evidenciados no decorrer das iterações do autômato celular devido à natureza inerente a cada padrão. Embora, as características de textura extraídas da imagem sejam obtidas de maneira global, elas são capazes de capturar a essência heterogênea da textura.

Para mostrar a robustez destas abordagens para análise de textura, este Capítulo apresenta os experimentos em bases de textura sintéticas, enquanto o Capítulo 6 exibe aplicações de análise de textura heterogênea em problemas reais.

5.1 Bases de Dados

Para validar o método de análise por padrões heterogêneos, esta abordagem foi aplicada em diferentes bases de dados de textura, cada uma com suas particularidades, sendo elas: Brodatz ([BRODATZ, 1966](#)), Outex ([OJALA et al., 2002](#)), Vistex ([VISION..., 2009](#)), Ustex ([BACKES; CASANOVA; BRUNO, 2012](#)) e a base de textura dinâmica Dyntex ([PÉTERI; FAZEKAS; HUISKES, 2010](#)), descritas a seguir:

Brodatz ([BRODATZ, 1966](#)) contém 111 imagens de textura naturais cada uma com tamanho 640×640 pixels e 256 níveis de cinza. Cada imagem foi dividida em 10 sub-imagens de 200×200 pixels resultando em um banco de dados com 1110 images. A Figura [26](#) mostra as imagens deste álbum.

Outex ([OJALA et al., 2002](#)), possui um conjunto de 68 imagens com 640×512 pixels. As imagens foram divididas em sub-imagens de tamanho 128×128 pixels para obter um banco de imagens com 1360 imagens divididas em 68 classes. Ver Figura [27](#).

Vistex ([VISION..., 2009](#)) A base de dados *The Vision Texture* é mantida pelo grupo *Vision and Modelling* do MIT Media Lab. Cada uma das 54 classes possui 16 amostras de tamanho 128×128 pixels. Essas imagens foram obtidas em diferentes condições reais, tais como variação de luz e perspectiva, como pode ser visto na Figura [28](#).

USPTex ([BACKES; CASANOVA; BRUNO, 2012](#)) possui 3984 imagens de texturas naturais divididas em 332 classes. Cada imagem possui 512×384 pixels. Para obter 12 imagens por classe, cada imagem foi dividida em sub-imagens de 128×128 pixels sem sobreposição. Ver Figura [29](#).

Dyntex ([PÉTERI; FAZEKAS; HUISKES, 2010](#)) consiste de 123 classes de textura dinâmica contendo 10 amostras de cada imagem retirados do banco de dados de textura dinâmica Dyntex. Todos os vídeos possuem 250 frames com dimensão de 400×300 pixels. Ver Figura [30](#).

A Tabela 1 traz um levantamento comparativo das características gerais de todas as bases de dados utilizadas.

Base de dados		# Classes	# Imagens	# Imagens/classe	Tamanho da imagem
Brodatz	Figura 26	111	1110	10	200×200 pixels
Outex	Figura 27	68	1360	20	128×128 pixels
Vistex	Figura 28	54	864	16	128×128 pixels
Usptex	Figura 29	191	2292	12	128×128 pixels
Dyntex	Figura 30	123	1230	10	250 frames $\times 400 \times 300$ pixels

Tabela 1 – Bases de dados de imagens de textura.

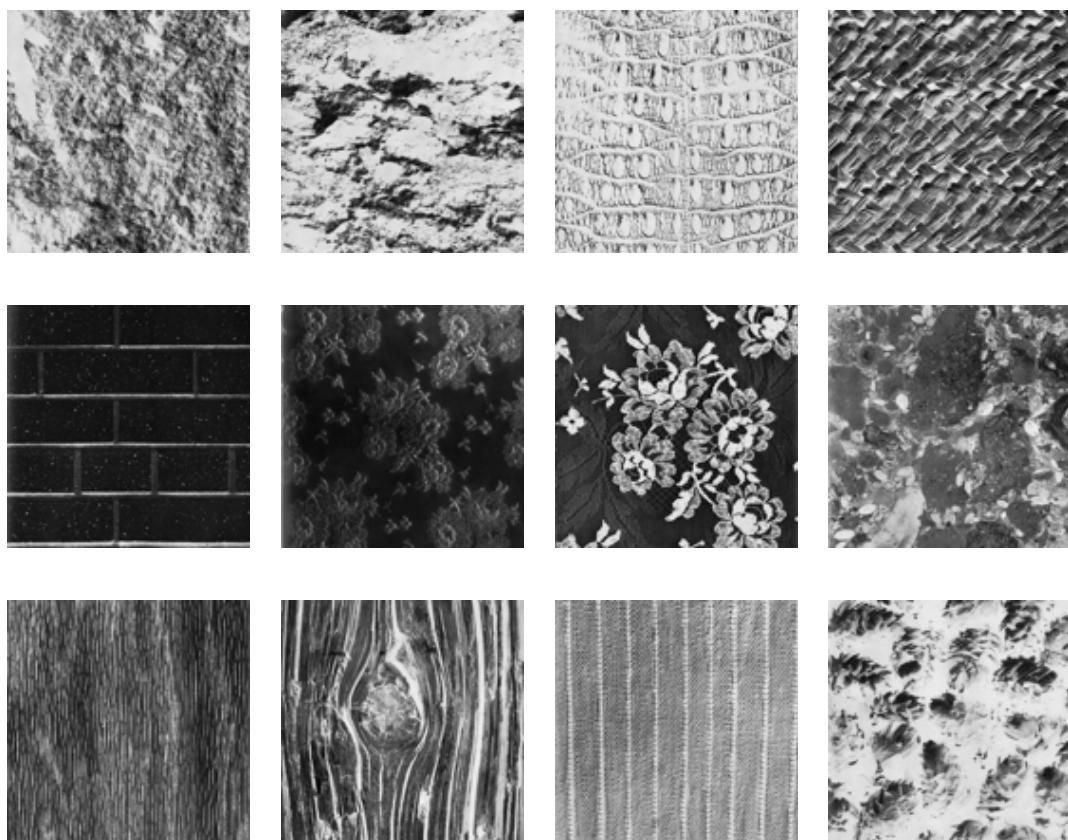


Figura 26 – Amostras da base de dados Brodatz ([BRODATZ, 1966](#)).

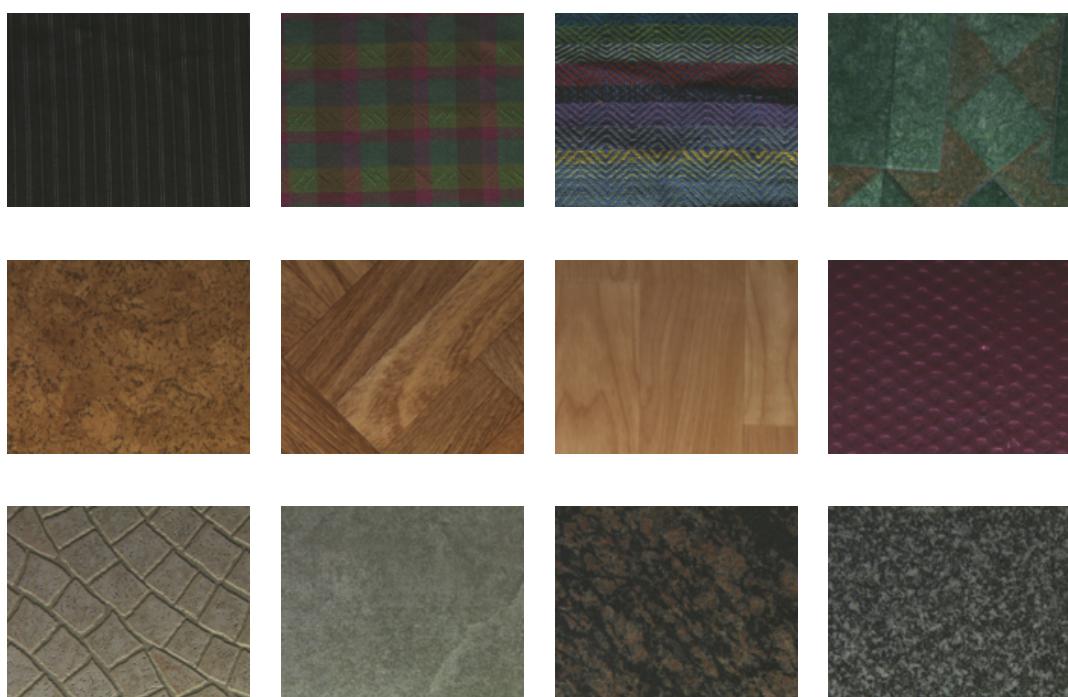


Figura 27 – Amostras da base de dados Outex ([OJALA et al., 2002](#)).

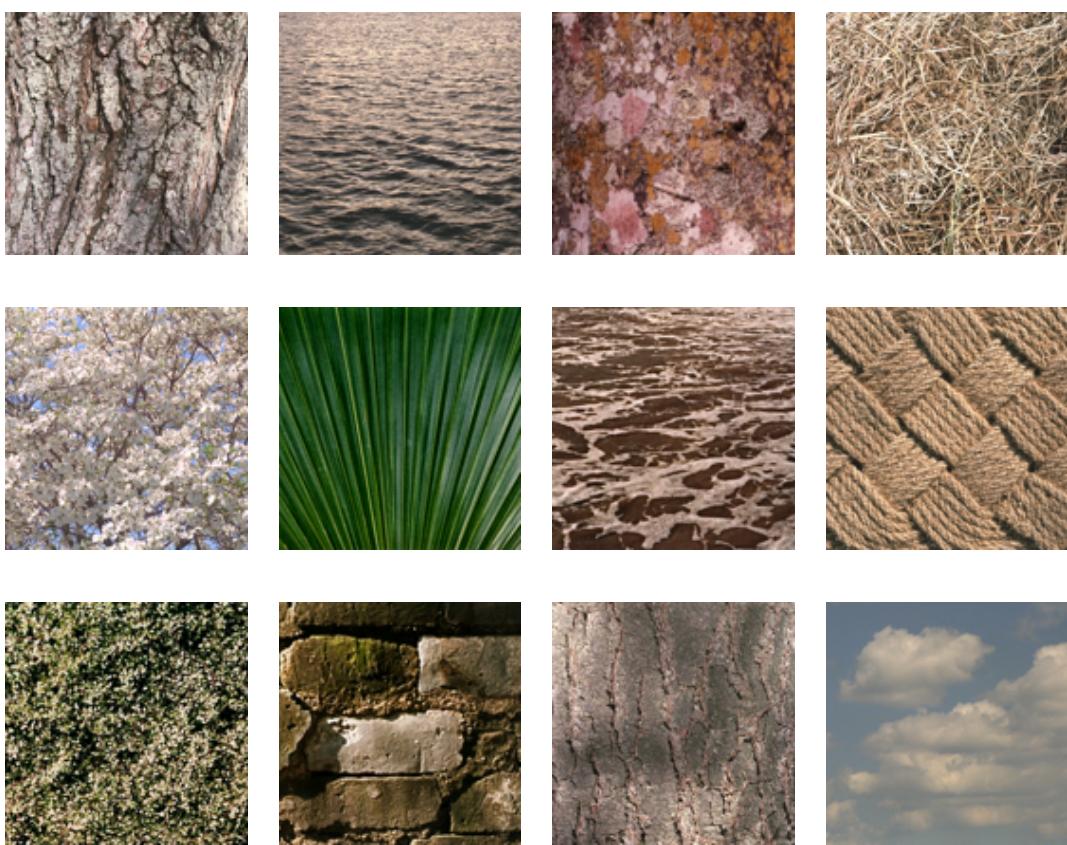


Figura 28 – Amostras da base de dados Vistex ([VISION...](#), 2009).

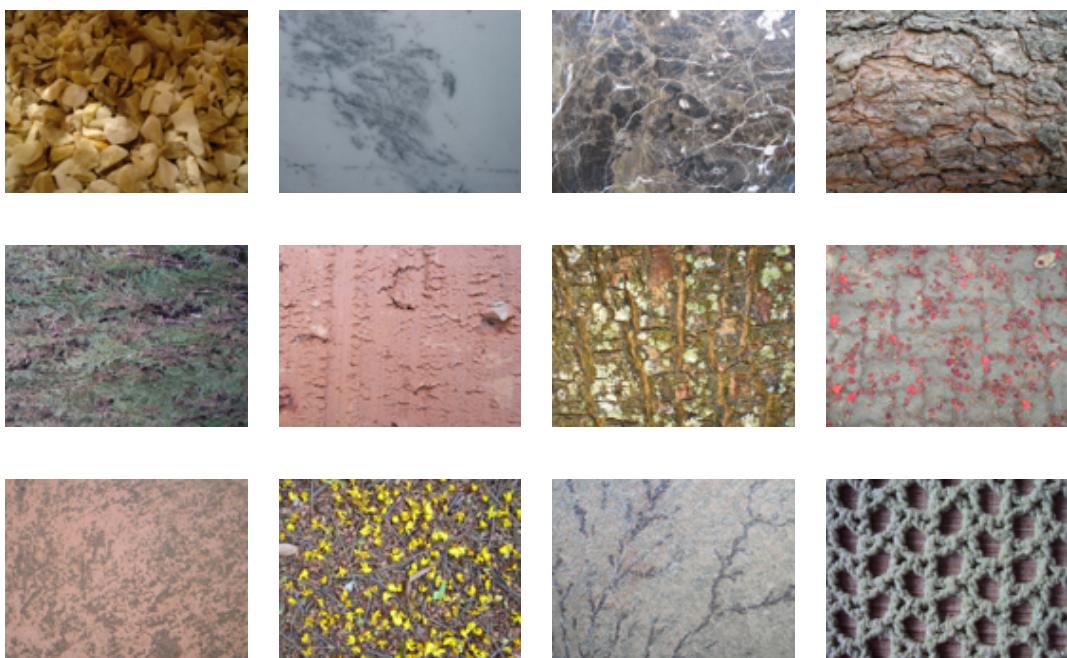


Figura 29 – Amostras da base de dados Usptex ([BACKES; CASANOVA; BRUNO, 2012](#)).



Figura 30 – Amostras de imagens do banco de texturas dinâmicas Dyntex ([PÉTERI; FAZEKAS; HUISKES, 2010](#)).

5.2 Descritores de Características de Textura

- **Descritores de Fourier** ([AZENCOTT; WANG; YOUNES, 1997; GONZALEZ; WOODS, 2006](#)) consideram os atributos em termos da densidade espectral considerando a textura como um campo aleatório gaussiano. A transformada de Fourier é calculada para cada imagem, sendo o espectro dividido em 64 setores com oito distâncias radiais e oito ângulos. A soma dos valores absolutos de espectro para cada setor é calculada, resultando em 64 descritores por imagem.
- **Descritores de Haralick (GLCM)** ([HARALICK, 1979](#)) é baseado nas matrizes de co-ocorrência dos níveis de cinza. Os descritores: contraste, correlação, energia e homogeneidade foram calculados a partir da matriz de co-correlação resultante ao utilizar os ângulos 0° , 45° , 90° e 135° , distâncias iguais a um ou dois pixels e 64 níveis de cinza a fim de obter um conjunto de 32 descritores para cada imagem.
- **Matrizes de diferença dos níveis de cinza (GLDM)** ([WESZKA; DYER; ROSENFELD, 1976; KIM; PARK, 1999](#)) representam a diferença absoluta dos níveis de cinza entre cada dois pixels com distância h . Aqui, 60 descritores foram obtidos utilizando $h = 1, 3$ e 5 e os atributos: contraste, segundo momento angular, entropia, média e momento da diferença inversa da função densidade de probabilidade estimada.
- **Filtros de Gabor** ([MANJUNATH; MA, 1996; DAUGMAN; DOWNING, 1998; IDRISIA; ACHEROY, 2002](#)) é uma função Gaussiana bi-dimensional modulada com uma senóide orientada numa frequência e direção determinada. Para realizar os testes, foram utilizados 64 filtros, sendo oito filtros de rotação e oito filtros de escala, com menor frequência igual a 0,01 e maior frequência igual a 0,4.

- **Variância de padrões binários locais (LBPV)** (GUO; ZHANG; ZHANG, 2010) é uma variante do LBP tradicional (OJALA; PIETIKÄINEN; MÄENPÄÄ, 2002) e é calculado a partir do valor de cada pixel binário na vizinhança do pixel central com raio 1, medindo a variação local.

5.3 Experimentos e Resultados

Esta seção contempla os experimentos realizados para validação dos métodos propostos.

5.3.1 Lazy-patch e Random Forest Combinado

Para a segmentação dos padrões, cada imagem foi dividida em janelas de tamanho 8×8 pixels com textura suficientemente homogênea, ou seja, onde somente um padrão seja encontrado. Janelas com características semelhantes permaneceram no mesmo padrão e aquelas com características distintas foram separadas em diferentes padrões. Para caracterizar cada janela foi utilizado o descritor de textura Haralick (HARALICK; SHANMUGAM; DINSTEIN, 1973). Para a base de textura dinâmica foi desenvolvida uma extensão das matrizes de co-ocorrência para três dimensões, sendo utilizada distância igual a 1 e 16 níveis de cinza.

Os vetores de característica de cada janela foram utilizados para realizar o agrupamento das janelas de acordo com seu respectivo padrão. Depois que as janelas foram divididas em tipos de padrões utilizando o método k -means de agrupamento, foi realizada uma análise de sobrevivência das janelas em cada padrão utilizando o teste de Grubbs, ou seja, 25% das janelas com características mais distantes em relação a média do grupo de janelas do padrão foram descartadas. Esta ação tornou a representação de cada padrão mais consistente. O resultado obtido do agrupamento das janelas de acordo com seu padrão de textura pode ser visto na Figura 31.

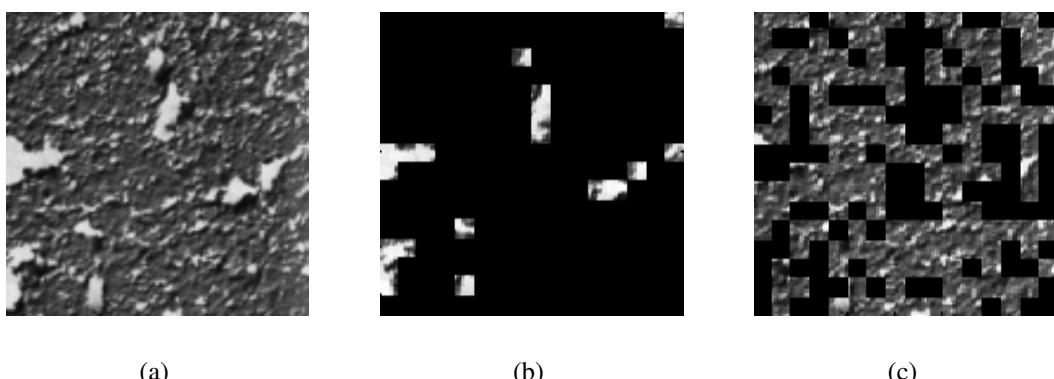


Figura 31 – (a) Imagem original. (b) e (c) Segmentação de textura de uma imagem em dois padrões por meio da divisão de todas as imagens em janelas e posteriormente o seu agrupamento de acordo com suas características obtidas por meio dos descritores de Haralick.

A Tabela 2 apresenta os resultados obtidos ao utilizar a metodologia clássica, ou de análise homogênea, em contraposição com os padrões heterogêneos, ambas com descritores obtidos a partir das matrizes de co-ocorrência. Os experimentos foram realizados utilizando o classificador *k-Nearest Neighbor* (*k* – *NN*) com *k* igual a 1 e validação cruzada utilizando 10-fold. Em todas as bases de dados testadas, o método de padrões heterogêneos melhorou a taxa de classificação. O que torna esta abordagem ainda mais interessante é que os resultados de reconhecimento de padrões podem ser melhorados independente do método de caracterização dos padrões, mas levando em consideração que pode ser encontrado mais de um padrão de textura em cada imagem. O que queremos mostrar com esta comparação é que ao utilizar o mesmo método para descrever a textura, mas assumindo que a imagem possui mais de um padrão de textura são encontradas melhores taxas de classificação para as imagens.

Método	Taxa de acerto (RMSE)				
	Brodatz	Vistex	Usptex	Outex	Dyntex
Matrizes de co-ocorrência	88.92 (\pm 0.043)	89.47 (\pm 0.061)	69.58 (\pm 0.041)	76.62 (\pm 0.081)	76.89 (\pm 0.219)
<i>Lazy-patch</i>	93.06 (\pm 0.035)	93.63 (\pm 0.048)	78.49 (\pm 0.035)	76.99 (\pm 0.082)	98.29 (\pm 0.018)

Tabela 2 – Resultados da abordagem clássica de análise de padrões de textura e a abordagem utilizando padrões heterogêneos utilizando *lazy-patch*.

A Tabela 3 mostra a análise comparativa entre o método de extração de características utilizando padrões heterogêneos com alguns outros métodos consagrados pela literatura, sendo eles: descritores de Fourier (ZAHN; ROSKIES, 1972; AZENCOTT; WANG; YOUNES, 1997; GONZALEZ; WOODS, 2006), GLDM (WESZKA; DYER; ROSENFIELD, 1976; KIM; PARK, 1999) ou matrizes de diferença, filtros de Gabor (MANJUNATH; MA, 1996; DAUGMAN; DOWNING, 1998; IDRISIA; ACHEROY, 2002) e LBPV (GUO; ZHANG; ZHANG, 2010). As bases de dados Brodatz e Vistex, que possuem perfil heterogêneo, apresentaram aumento na taxa de acerto ao utilizar a abordagem *lazy-patch*, obtendo uma taxa de acerto ainda melhor ao utilizar o modelo random forest combinado. Os resultados da análise de padrões heterogêneos na base de dados Usptex, que possui uma mistura de imagens com textura homogêneas e heterogêneas, mostrou-se comparável ao resultados dos métodos da literatura, alcançando taxa de acerto superior aos demais métodos ao utilizar a abordagem *lazy-patch*. Por outro lado, para a base de dados Outex, que apresenta grande parte de suas imagens com padrões homogêneos de textura, a abordagem de padrões heterogêneos resultou em taxas de acerto inferiores a alguns métodos da literatura, mas ainda assim alcançando o segundo melhor resultado ao utilizar a abordagem random forest combinado. Portanto, os resultados revelam que as texturas que possuem padrões heterogêneos em sua composição são melhor classificadas quando estes são analisados.

Método	Taxa de acerto (RMSE)			
	Brodatz	Vistex	Usptex	Outex
Descritores de Fourier	89.91 (± 0.042)	90.86 (± 0.057)	75.15 (± 0.037)	82.72 (± 0.070)
GLDM	91.80 (± 0.038)	89.47 (± 0.061)	73.59 (± 0.038)	77.57 (± 0.079)
Filtros de Gabor	90.45 (± 0.041)	90.16 (± 0.059)	77.11 (± 0.036)	76.76 (± 0.081)
LBPV	88.92 (± 0.043)	86.92 (± 0.068)	65.81 (± 0.044)	72.57 (± 0.088)
<i>Lazy-patch</i>	93.06 (± 0.035)	93.63 (± 0.048)	78.49 (± 0.035)	76.99 (± 0.082)
Random Forest Combinado	94.14 (± 0.020)	94.68 (± 0.022)	73.66 (± 0.034)	79.45 (± 0.021)

Tabela 3 – Comparação dos resultados entre os métodos propostos, *lazy-patch* e random forest combinado, e métodos tradicionais de análise de textura.

5.3.2 CITA

Esta seção mostra os experimentos ao utilizar o descriptor de textura CITA comparado a métodos tradicionais da literatura. Primeiramente, uma avaliação dos parâmetros utilizando a base de dados Usptex é realizada para averiguar qual a melhor configuração a ser utilizada. Posteriormente, os experimentos são executados utilizando as bases de dados Brodatz e Vistex.

5.3.2.1 Avaliação dos Parâmetros

A fim de definir os parâmetros utilizados pelo descriptor CITA, a base de dados Usptex, uma base de dados diferente das bases utilizadas para validação, é empregada. Isto é feito para assegurar que o descriptor CITA não é suscetível aos parâmetros e, portanto, a mesma configuração pode ser utilizada para a classificação de texturas de diferentes bases de dados. Os experimentos foram realizadas utilizando um esquema de validação cruzada estratificada 10-fold (HASTIE; TIBSHIRANI; FRIEDMAN, 2001) e LDA como classificador, tanto para o descriptor CITA, bem como para as características estabelecidas da literatura.

5.3.2.1.1 Número de iterações

Para descrever cada imagem, a massa acumulada de metal corroído depois de cada iteração do modelo de CA baseado em corrosão é utilizada. Estes valores constituem o vetor de característica que é usado para discriminar cada uma das imagens. No entanto, encontrar um único número de iterações que dá origem ao menor, vetor característica mais informativo para todas as imagens de ambas as bases de dados não é uma tarefa trivial, devido à variedade do tipo de imagens de textura e também porque este número é dependente dos valores de γ e v . A fim de não complicar o problema, a escolha é feita ao olhar para um único número ideal de repetições para todas as bases de dados que, em geral dá o melhor resultado para todas as imagens de textura nas bases de dados analisadas. Este número ideal de iterações é, no entanto, dependente de γ e v .

5.3.2.1.2 Rugosidade da superfície v

Um dos parâmetros que definem a resistência à corrosão é a rugosidade da superfície v . De acordo com o método baseado em corrosão proposto, pixels com uma diferença d inferior a v (Eqs. (4.8) e (4.9)) não sofrem a ação do processo de corrosão, tendo em conta que eles fazem parte da superfície local. No entanto, se a vizinhança tem uma diferença d maior do que a superfície limite permitida, o pixel central vai passar por um processo de corrosão tendo seu valor corroído de acordo com as equações Eqs. (4.9) e (4.10). A Figura 32(a) mostra uma superfície da taxa de sucesso, isto é, a percentagem de imagens de texturas corretamente classificadas para a base de dados Usptex para v variando entre 0 e 10 e γ variando entre 0,01 e 0,08. A figura mostra que os maiores valores de v levam a uma menor taxa de acerto. No entanto, quando v é igual a 0 a taxa de sucesso é menor do que o obtido para v igual a 1 para quase todos os valores de γ . Assim, o valor de 1 para v é escolhido como um valor ótimo.

5.3.2.1.3 Poder de corrosão γ

Outro parâmetro do modelo com um significado físico é o poder de corrosão γ . Este parâmetro é importante, porque determina o nível de corrosão de acordo com o material a ser erodido. No entanto, como não estamos lidando com superfícies de metais reais, este parâmetro não é conhecido pela análise de imagem da textura. A Figura 32(a) agora é analisada para γ variando de 0,01 a 0,08. Pode ser visto que a maior taxa de acerto é obtida com γ e v iguais a 0,05 e 1, respectivamente. Para valores de γ abaixo de 0,05 a taxa tende a ser reduzida, ao passo que para valores superiores a 0,05 a taxa também tende a decrescer. Ao olhar para altos valores combinados de γ e v as taxas de acerto caem acentuadamente. A Figura 32(b) mostra que o número de iterações para se obter a mais elevada taxa de acerto para cada uma das combinações de parâmetros. O gráfico mostra que o número ideal de iterações necessárias para γ igual a 0,05 e v igual a 1 é relativamente baixo em comparação com os outros resultados.

5.3.2.2 Experimentos

Três conjuntos de experimentos foram realizados: o primeiro com as bases de dados originais, e posteriormente, em versões modificadas dessas bases de dados para testar invariância à ruído e rotação. Todos os testes foram realizados utilizando os valores otimizados para v , γ e número de iterações apresentados na Tabela 4. Para todas os experimentos, a taxa de sucesso e o desvio padrão (std) estão baseados em dez repetições e são mostrados para comparação dos resultados.

5.3.2.2.1 Bases de Dados sem Modificações

A Tabela 5 lista os resultados obtidos para as bases de dados não modificadas. Como pode ser visto, uma excelente taxa de acerto pode ser obtida usando o descritor CITA, que é mais

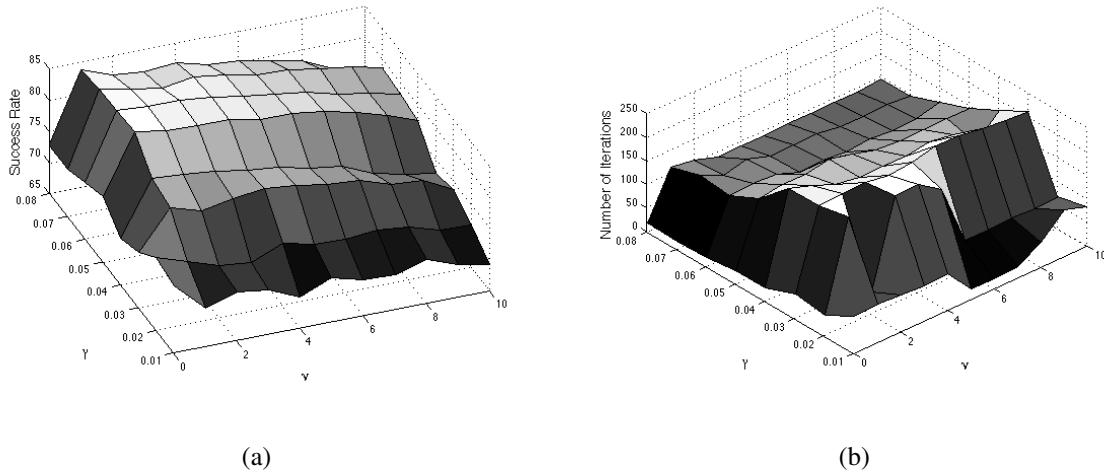


Figura 32 – (a) Análise dos parâmetros de poder de corrosão (γ) e rugosidade da superfície (v) para a base de dados Usptex com γ variando de 0,01 a 0,08 e v variando de 0 a 10. (b) Número de iterações para cada configuração de parâmetros em (a).

Parâmetro	Valor
Número de iterações	158
v	1
γ	0.05

Tabela 4 – Valores ótimos dos parâmetros.

elevada do que a taxa de acerto para todos os demais descritores da base de dados Brodatz e é da mesma qualidade que a taxa de acerto obtido com GLDM para a base de dados Vistex.

Feature	Taxa de acerto (\pm std)	
	Brodatz	Vistex
Fourier	94 (\pm 2,4)	94 (\pm 1,9)
GLCM	94 (\pm 3,3)	94 (\pm 3,5)
GLDM	98 (\pm 0,9)	97 (\pm 1,6)
Gabor filter	92 (\pm 3,7)	92 (\pm 1,7)
LBPV	88 (\pm 3,3)	82 (\pm 3,9)
CITA	99 (\pm 1,5)	97 (\pm 1,7)

Tabela 5 – Comparação em termos da taxa de acerto da classificação das bases de dados Brodatz e Vistex utilizando o descritor CITA e métodos da literatura.

5.3.2.2.2 Invariância a Ruído

A fim de demonstrar a tolerância do descritor de características CITA ao ruído, os experimentos foram realizados em versões modificadas das bases de dados Brodatz e Vistex com adição de ruído ‘Salt & Pepper’. Ao aplicar este tipo de ruído a uma imagem, pixels pretos e brancos são adicionados de forma aleatória à matriz de imagem com uma intensidade l , que

pode variar de 0 a 1 e representa a parte da imagem afetada pelo ruído. A robustez do método de classificação para a adição de ruído é demonstrada efetuando a classificação de textura em seis bases modificadas geradas a partir das bases de dados Brodatz e Vistex. As seis diferentes bases de dados foram geradas em ambos os casos, adicionando o ruído ‘Salt & Pepper’ com intensidades $l = 0,01, 0,05, 0,07, 0,1, 0,5$ e $0,7$. A Figura 33 exibe amostras da base de dados Vistex modificada, onde cada coluna mostra exemplos de uma intensidade l do ruído.

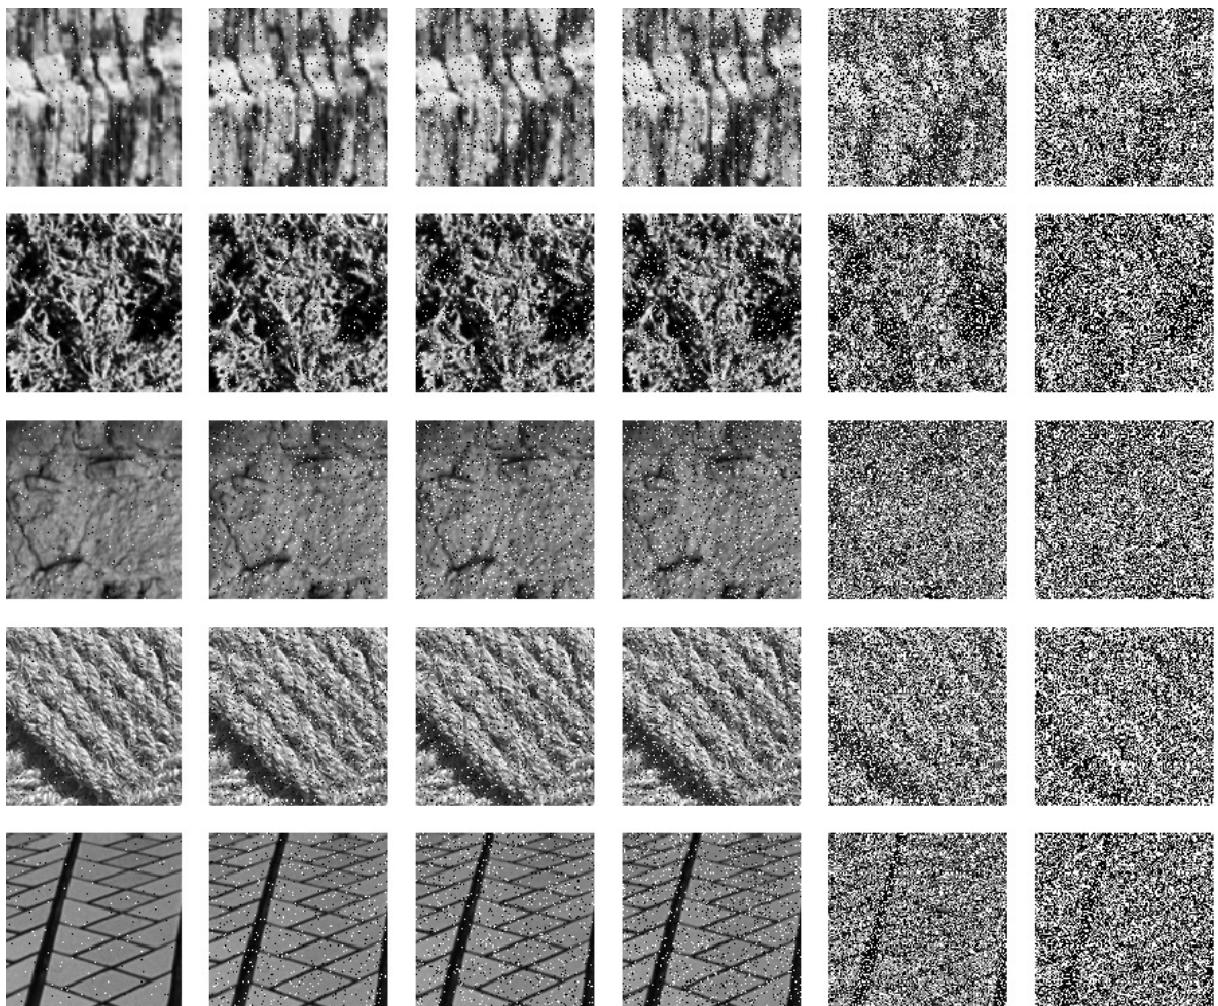


Figura 33 – Amostras de seis modificações da base de dados Vistex adicionando ruído ‘Salt & Pepper’. Cada coluna corresponde a uma intensidade do ruído, com $l = 0,01, 0,05, 0,07, 0,1, 0,5$ and $0,7$, da esquerda para a direita.

As taxas de acerto ao classificar as imagens das bases de dados Brodatz e Vistex modificadas usando diferentes características são indicadas nas Tabelas 6 e 7, respectivamente. Os resultados demonstram o bom desempenho do CITA mesmo com a adição de várias intensidades de ruído. Para todos os bancos de dados gerados a partir do banco de dados Brodatz, a classificação utilizando CITA obteve maior taxa de sucesso em comparação com os métodos tradicionais da literatura. É importante notar que, mesmo com o aumento dos níveis de ruído, a taxa de acerto ao utilizar CITA continuou alta, enquanto, a taxa de acerto ao utilizar os métodos da literatura decaem. Para os bancos de dados gerados a partir da base de dados Vistex, CITA dá origem à

segunda melhor taxa de acerto, precedida de classificação com GLDM, mas ainda demonstrando robustez ao ruído.

Descriptor de textura	Taxa de acerto (\pm std)					
	$l = 0.01$	$l = 0.05$	$l = 0.07$	$l = 0.1$	$l = 0.5$	$l = 0.7$
Fourier	93 (\pm 2.6)	93 (\pm 3.3)	91 (\pm 3.5)	90 (\pm 3.5)	82 (\pm 4.9)	67 (\pm 6.1)
GLCM	94 (\pm 3.4)	94 (\pm 2.7)	95 (\pm 2.7)	94 (\pm 3.0)	87 (\pm 4.8)	76 (\pm 6.3)
GLDM	98 (\pm 1.5)	98 (\pm 1.5)	98 (\pm 1.5)	98 (\pm 1.8)	95 (\pm 2.1)	91 (\pm 3.5)
Filtros de Gabor	91 (\pm 3.7)	90 (\pm 4.6)	90 (\pm 4.7)	90 (\pm 5.1)	82 (\pm 5.8)	67 (\pm 3.8)
LBPV	88 (\pm 3.1)	87 (\pm 3.8)	87 (\pm 4.5)	87 (\pm 4.8)	66 (\pm 5.2)	46 (\pm 6.4)
CITA	99 (\pm 1.6)	98 (\pm 1.3)	98 (\pm 1.4)	98 (\pm 1.2)	97 (\pm 2.3)	97 (\pm 1.7)

Tabela 6 – Taxa de acerto para classificação de seis modificações da base Brodatz, obtidas através da adição de ruído ‘Salt & Pepper’ com diferentes intensidades l .

Descriptor de textura	Taxa de acerto (\pm std)					
	$l = 0.01$	$l = 0.05$	$l = 0.07$	$l = 0.1$	$l = 0.5$	$l = 0.7$
Fourier	93 (\pm 2.4)	91 (\pm 2.4)	89 (\pm 1.6)	89 (\pm 2.1)	67 (\pm 3.3)	35 (\pm 5.9)
GLCM	94 (\pm 2.9)	95 (\pm 1.6)	95 (\pm 2.8)	94 (\pm 1.8)	84 (\pm 3.8)	66 (\pm 4.3)
GLDM	98 (\pm 1.1)	97 (\pm 1.5)	97 (\pm 1.8)	97 (\pm 1.3)	94 (\pm 1.4)	86 (\pm 3.1)
Filtros de Gabor	91 (\pm 2.2)	89 (\pm 1.7)	89 (\pm 3.2)	86 (\pm 3.2)	56 (\pm 5.9)	34 (\pm 3.9)
LBPV	83 (\pm 3.9)	83 (\pm 2.5)	82 (\pm 3.9)	81 (\pm 3.8)	54 (\pm 3.1)	39 (\pm 7.8)
CITA	96 (\pm 2.4)	94 (\pm 1.6)	94 (\pm 1.3)	94 (\pm 1.5)	94 (\pm 4.7)	81 (\pm 4.5)

Tabela 7 – Taxa de acerto para classificação de seis modificações da base Vistex, obtidas através da adição de ruído ‘Salt & Pepper’ com diferentes intensidades l .

Outra abordagem de experimentos foi realizada ao utilizar imagens de textura não-perturbados para treinamento e imagens com adição de ruído para o teste. Estes resultados são exibidos nas Tabelas 8 e 9, sendo os melhores alcançados ao utilizar os métodos da literatura. No entanto, a taxa de acerto obtida com CITA é comparável às taxas de acerto obtidas ao utilizar os métodos da literatura, tanto para Brodatz quanto para Vistex.

Descriptor de textura	Taxa de acerto (\pm std)					
	$l = 0.01$	$l = 0.05$	$l = 0.07$	$l = 0.1$	$l = 0.5$	$l = 0.7$
Fourier	90 (\pm 2.6)	62 (\pm 3.5)	50 (\pm 4.0)	36 (\pm 2.6)	4 (\pm 0.9)	1 (\pm 1.2)
GLCM	49 (\pm 2.1)	6 (\pm 0.9)	4 (\pm 0.5)	3 (\pm 0.7)	1 (\pm 0.0)	1 (\pm 0.0)
GLDM	84 (\pm 5.2)	42 (\pm 3.0)	16 (\pm 1.6)	9 (\pm 0.6)	1 (\pm 0.0)	1 (\pm 0.0)
Filtros de Gabor	73 (\pm 4.9)	57 (\pm 1.9)	32 (\pm 1.5)	26 (\pm 2.2)	7 (\pm 1.1)	4 (\pm 0.8)
LBPV	57 (\pm 3.3)	14 (\pm 1.3)	10 (\pm 1.4)	9 (\pm 0.7)	1 (\pm 0.0)	1 (\pm 0.0)
CITA	97 (\pm 2.8)	37 (\pm 3.4)	20 (\pm 1.7)	11 (\pm 1.4)	6 (\pm 1.9)	4 (\pm 0.8)

Tabela 8 – Taxa de acerto para classificação da base de dados Brodatz, sendo o conjunto de treinamento formado por imagens originais e o conjunto de teste com adição de diferentes intensidades l do ruído ‘Salt & Pepper’.

5.3.2.2.3 Invariância à Rotação

O descriptor de CITA é intrinsecamente invariante à rotação, e, portanto, bons resultados são esperados quando os testes são realizados com bancos de dados modificados com imagens

Descriptor de textura	$l = 0.01$	$l = 0.05$	Taxa de acerto (\pm std)			
			$l = 0.07$	$l = 0.1$	$l = 0.5$	$l = 0.7$
Fourier	58 (\pm 4.3)	10 (\pm 2.1)	8 (\pm 2.1)	6 (\pm 2.1)	3 (\pm 1.1)	2.1 (\pm 1.1)
GLCM	64 (\pm 3.6)	33 (\pm 1.4)	5 (\pm 0.6)	2 (\pm 0.6)	2 (\pm 0.6)	2 (\pm 0.6)
GLDM	90 (\pm 2.6)	13 (\pm 1.4)	13 (\pm 1.1)	9 (\pm 1.3)	2 (\pm 0.6)	2.3 (\pm 1.1)
Filtros de Gabor	58 (\pm 2.8)	14 (\pm 3.4)	10 (\pm 2.2)	5. (\pm 1.6)	2 (\pm 0.6)	2 (\pm 0.6)
LBPV	52 (\pm 2.7)	14 (\pm 2.7)	7 (\pm 1.6)	5.6 (\pm 1.6)	2 (\pm 0.6)	2 (\pm 0.6)
CITA	83 (\pm 3.4)	23 (\pm 4.3)	17 (\pm 2.6)	11 (\pm 1.7)	6 (\pm 3.3)	5 (\pm 2.9)

Tabela 9 – Taxa de acerto para classificação da base de dados Vistex, sendo o conjunto de treinamento formado por imagens originais e o conjunto de teste com adição de diferentes intensidades l do ruído ‘Salt & Pepper’.

rotacionadas. Para demonstrar a invariância à rotação, versões adicionais das bases de dados Brodatz e Vistex são criados. Cada imagem das bases de dados é rotacionada com os seguintes ângulos: 0° , 45° , 90° , 135° , 180° , 225° e 270° . Desta forma, sete imagens são obtidas de cada imagem original. Portanto, a nova base de dados com imagens Brodatz rotacionados possui 70 imagens por classe e a nova base de dados com imagens Vistex rotacionados possui 112 imagens por classe. A Figura 34 mostra algumas imagens de textura da base de dados Brodatz rotacionada com as sete imagens obtidas nos diferentes ângulos de rotação, sendo todas as imagens na mesma linha obtidas da mesma imagem original.

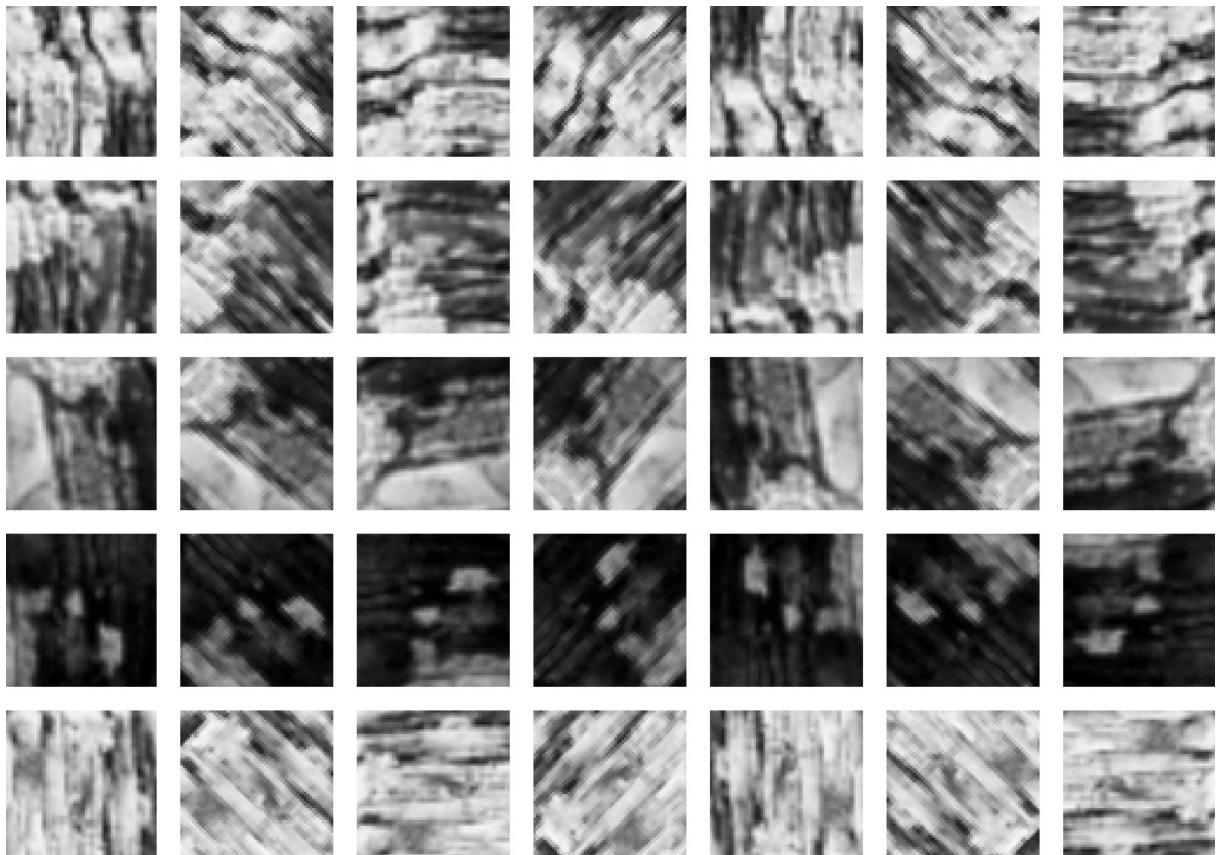


Figura 34 – Amostras da base de dados Brodatz rotacionada. Cada coluna corresponde a um diferente ângulo de rotação. Da esquerda para a direita: 0° , 45° , 90° , 135° , 180° , 225° e 270° .

A Tabela 10 mostra as taxas de acerto para a classificação das imagens de textura das bases de dados Brodatz e Vistex com imagens rotacionadas. As taxas de acerto obtidas com o descriptor CITA são melhores do que as taxas de acerto obtidas com qualquer um dos outros descriptores e são comparáveis com os resultados obtidos nas bases de dados não modificadas. Estes resultados experimentais indicam que o descriptor CITA tem uma boa capacidade de generalização, mostrando seu alto desempenho também para a classificação de textura rotacionada.

Descriptores de textura	Taxa de acerto (\pm std)	
	Rotated Brodatz	Rotated Vistex
Fourier	83 (\pm 1.1)	77 (\pm 1.3)
GLCM	71 (\pm 0.6)	74 (\pm 1.3)
GLDM	84 (\pm 0.5)	83 (\pm 0.7)
Filtros de Gabor	78 (\pm 0.9)	71 (\pm 1.3)
LBPV	63 (\pm 1.0)	62 (\pm 1.7)
CITA	98 (\pm 0.4)	97 (\pm 0.7)

Tabela 10 – Comparação em termos da taxa de acerto utilizando as bases de dados Brodatz e Vistex rotacionadas.



APLICAÇÕES EM BIOLOGIA E NANOTECNOLOGIA

Este Capítulo tem como objetivo mostrar diferentes aplicações em bases de dados reais para análise de imagens com padrões de textura heterogêneo. As análises realizadas decorrem de problemas práticos do mundo real ainda em aberto, desta forma, as imagens a serem utilizadas são de texturas naturais. Dois importantes problemas serão abordados, sendo o primeiro relacionado à nanotecnologia e o segundo à identificação de espécies de plantas. No primeiro problema, é realizada a classificação de experimentos de óxido de titânio anódico galvanostático em diferentes concentrações por meio da análise de imagens de FEG-SEM (Microscópio Eletrônico de Varredura de Emissão de Campo - *Field Emission Gun-Scanning Electron Microscopy*). O segundo problema, que diz respeito à identificação de espécies de plantas, engloba duas bases de imagens microscópicas: a primeira consistem em imagens de cortes transversal, tangencial e radial de madeira para identificação de 77 espécies lenhosas da República Democrática do Congo e a segunda base consiste em imagens de cortes paradérmicos da epiderme de folhas para identificar 32 espécies de plantas do cerrado brasileiro.

Tendo em vista a importância desses problemas e o fato de que as soluções existentes para tais problemas ainda possuem limitações, a análise de textura aparece como uma importante ferramenta para sua resolução, e indo mais adiante, para os problemas específicos abordados aqui, a análise de texturas com padrões heterogêneos. As soluções para análise de padrões heterogêneos de textura apresentadas no Capítulo 3 são utilizadas de forma peculiar a cada aplicação.

6.1 Óxido de Titânio Anódico Galvanostático

Técnicas de análise de imagens têm sido empregadas em importantes aplicações de Ciências dos Materiais ([MASUDA; FUKUDA, 1995](#); [MASUDA et al., 1999](#); [YANAGISHITA et](#)

al., 2002; KIM *et al.*, 2008). Os dados obtidos através de diferentes técnicas de microscopia, tais como FEG-SEM (Microscópio Eletrônico de Varredura de Emissão de Campo - *Field Emission Gun-Scanning Electron Microscopy*), AFM (Microscópido de Força Atômica - *Atomic Force Microscopy*), STM (Microscópio de Corrente de Tunelamento - *Scanning Tunneling Microscopy*) e TEM (Microscópio Eletrônico de Transmissão - *Transmission Electron Microscopy*) consistem de uma matriz de valores e podem ser tratados como uma imagem convencional.

Usualmente, a análise de tais tipos de imagens é conduzida utilizando metodologias simples, como por exemplo, contagem de poros através de ferramentas de pacotes de software como o ImageJ (ABRAMOFF; MAGALHAES; RAM, 2004) e Gwyddion (NECAS; Klapetek, 2012). Embora estes métodos sejam suficientes para uma análise simplista, eles consideram, na maioria das vezes, somente propriedades geométricas básicas e não são capazes de modelar relações complexas entre estruturas que podem ser distinguidas por uma análise estatística complexa. Desta forma, tais abordagens falham ao analisar morfologias mais complexas, tais como aquelas encontradas no óxido de titânio anódico e películas de zircônia. A literatura demonstra a eficiência de métodos de análise de textura em tais aplicações e, particularmente FLORINDO *et al.* (2013a) e FLORINDO *et al.* (2013b) apresentam uma análise dos experimentos com amostras de óxido de titânio anódico galvanostático preparado em solução de ácido oxálico com diferentes concentrações, em que um esquema de validação cruzada foi utilizado, alcançando ótimos resultados a partir de descritores fractais.

Descritores fractais são uma extensão do conceito de dimensão fractal. Enquanto a dimensão fractal mede a complexidade global de um objeto, descritores fractais são obtidos de uma relação de lei de potência entre uma medida de auto-similaridade e escala. Desta forma, ao invés de apenas um valor escalar, um vetor de características é gerado para representar o grau de complexidade em diferentes escalas. Aspectos morfológicos enfatizados por estes descritores também expressam importantes atributos estruturais do material, tais como aspereza, reactividade, área superficial, defeitos morfológicos, entre outros. A respeito de sua eficiência, descritores fractais tem demonstrado ser menos precisos quando o material é heterogêneo, bem como quando temos um conjunto de treinamento e teste com diferenças morfológicas marcantes. Esta é uma situação comum na prática, principalmente quando é necessário analisar diferentes replicatas de um material sob diferentes condições. Tais condições podem afetar severamente a estrutura morfológica e tornar inviável a análise do material por meio de características globais. Metodologias computacionais devem ser capazes de identificar amostras em uma condição específica, baseando-se nas características encontradas em amostras sob diferentes condições.

Com o intuito de contornar tais casos, a análise por meio de padrões heterogêneos de textura é realizada descrevendo os padrões utilizando diferentes métodos de extração de características de textura. A imagem original é dividida em janelas quadradas de tamanho arbitrário, extraíndo-se características de textura de cada janela para agrupá-las de acordo com o respectivo padrão de textura para identificação dos padrões heterogêneos da imagem, como

descrito na abordagem *Lazy-Patch* no Capítulo 4. Ao fazer isso, diferentes padrões de textura da mesma imagem são encontrados, permitindo comparar esses padrões em diferentes imagens.

6.1.1 Aquisição de Imagens

A proposta deste experimento é classificar um banco de imagens de FEG-SEM de óxido de titânio anódico galvanostático, composto por duas replicatas sob oito diferentes condições, sendo geradas 4 imagens por condição. Dessa forma, 32 imagens de tamanho 3072×2060 pixels provenientes de uma replicata são utilizadas para treinamento e as 32 imagens de mesmo tamanho da segunda replicata são utilizadas para teste. A Figura 35 mostra um exemplo de imagem para cada experimento.

6.1.2 Análise de Padrões Heterogêneos

Primeiramente, as imagens de óxido de titânio são divididas em janelas de tamanho 16×16 pixels. Embora os testes tenham sido realizados com janelas de tamanho 8×8 , 16×16 , 32×32 , 64×64 , 128×128 e 256×256 pixels, os melhores resultados foram gerados ao utilizar janelas 16×16 . Os descritores de textura (matrizes de co-ocorrência dos níveis de cinza - *Gray Level Co-occurrence Matrix* - GLCM (HARALICK, 1979), filtros de Gabor (MANJUNATH; MA, 1996; DAUGMAN; DOWNING, 1998; IDRISIA; ACHEROY, 2002), matrizes de diferença dos níveis de cinza - *Gray-Level Difference Matrix* - GLDM (WESZKA; DYER; ROSENFELD, 1976; KIM; PARK, 1999) e descritores Fractais (FLORINDO *et al.*, 2013a; FLORINDO *et al.*, 2013b)) foram computados para cada janela, resultando em um vetor de características para cada uma delas. O próximo passo é agrupar esses vetores de características para encontrar os padrões heterogêneos de textura na imagem. Os vetores de características extraídos são agrupados utilizando o algoritmo de agrupamento *k-means* (DUDA; HART, 1973). Nesta análise foram identificados dois grupos ou padrões para cada imagem, como mostram as Figuras 36 e 37. A Figura 36 exibe a segmentação dos padrões para três imagens, sendo as duas primeiras do mesmo experimento, enquanto a Figura 37 mostra a correspondência de padrões entre diferentes imagens. Na Figura 37(a), pode-se observar que há correspondência entre os padrões, ou seja, os mesmos padrões de textura foram encontrados em imagens pertencentes ao mesmo experimento. Por outro lado, diferentes padrões foram encontrados em imagens pertencentes a diferentes experimentos, como mostra a Figura 37(b).

Como janelas com características similares pertencem ao mesmo grupo, é necessário obter um vetor de características que represente o grupo de janelas que compõem o padrão. Portanto, a média de todos os vetores de característica de um mesmo grupo é calculada, obtendo um vetor média que representa o respectivo padrão. Desta forma, dois vetores representativos foram obtidos e concatenados para representar cada imagem. A ordem de concatenação foi definida de acordo com o desvio padrão de cada vetor, de forma ascendente.

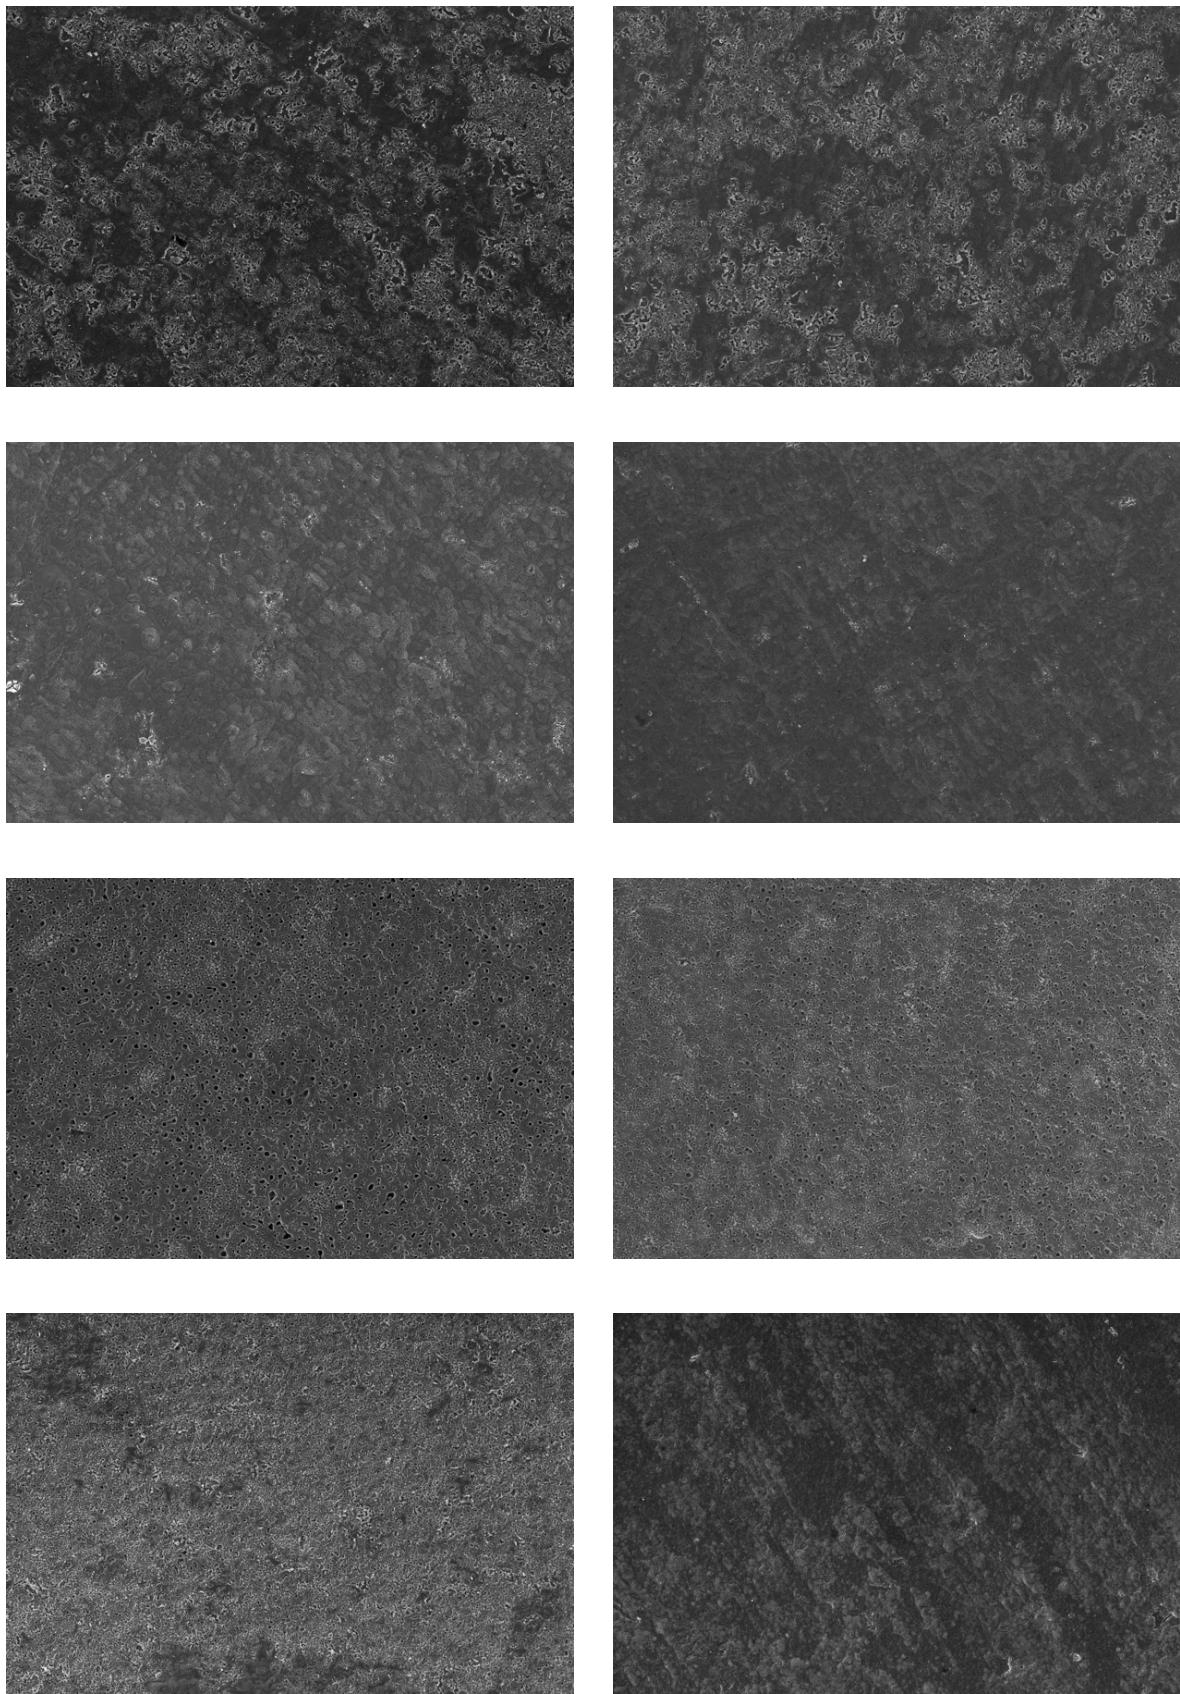


Figura 35 – Imagens de FEG-SEM de óxido de titânio anódico galvanostático preparado em solução de ácido oxálico em oito condições diferentes.

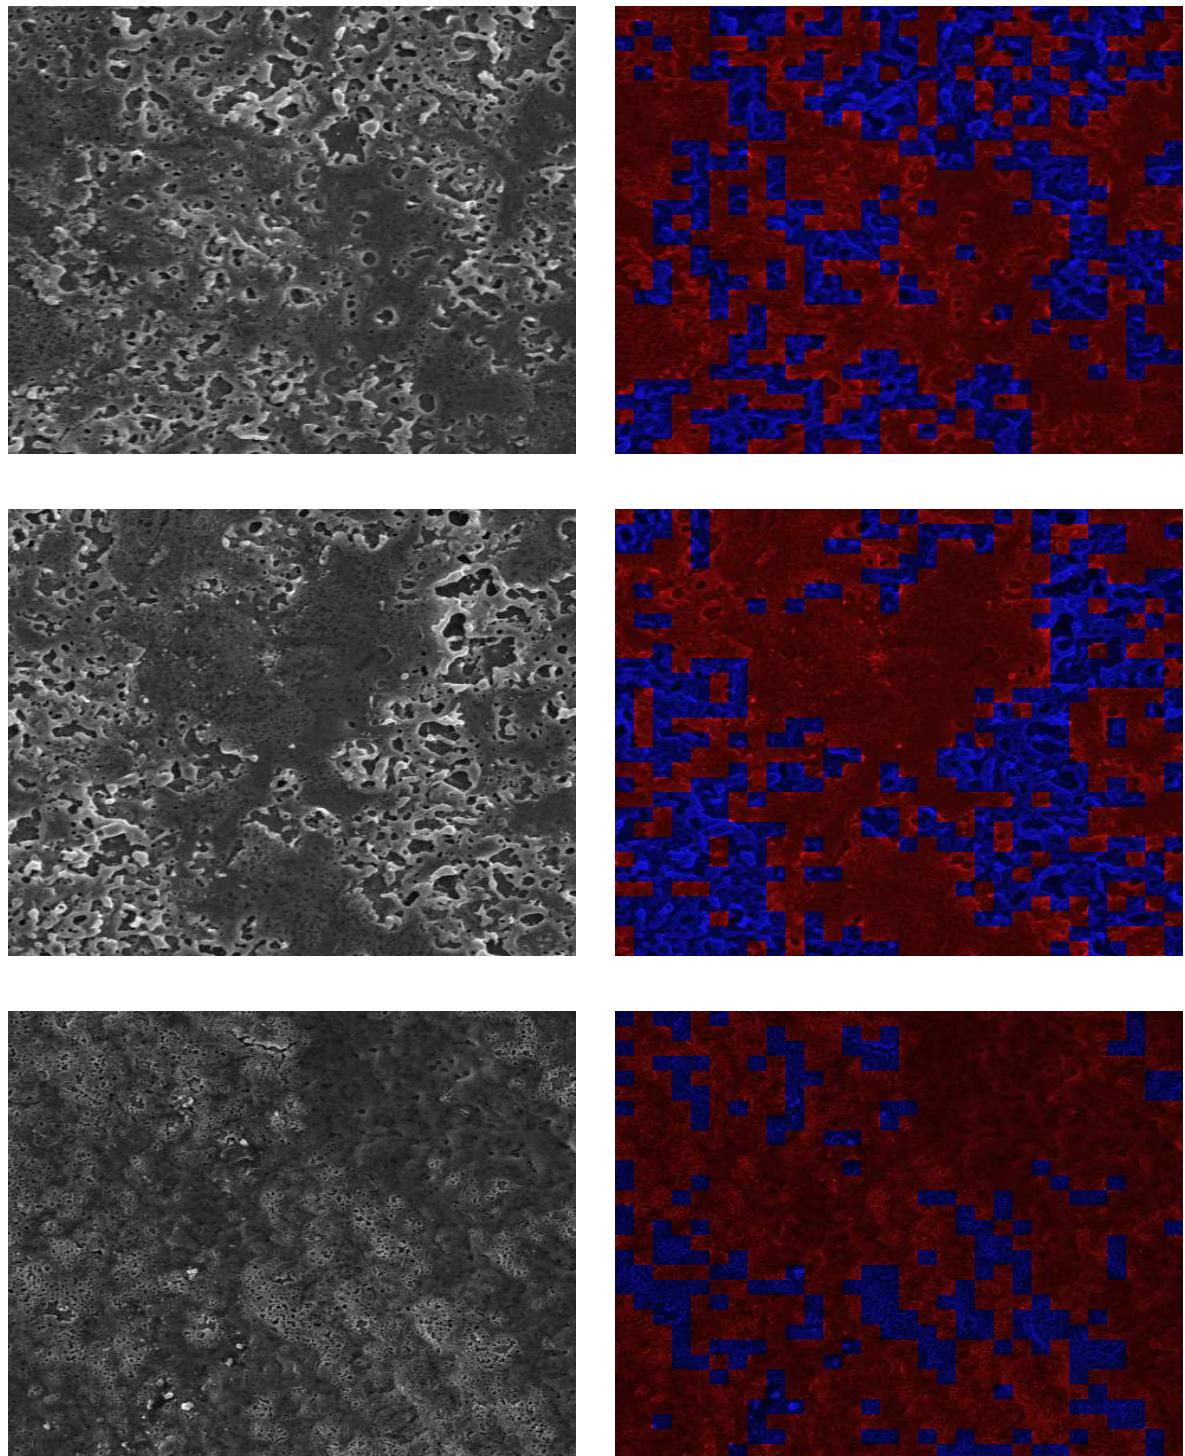
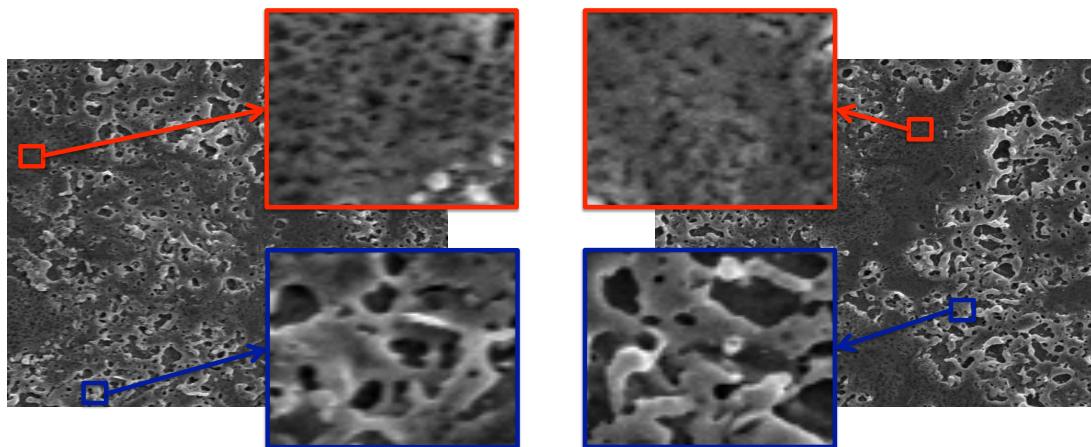
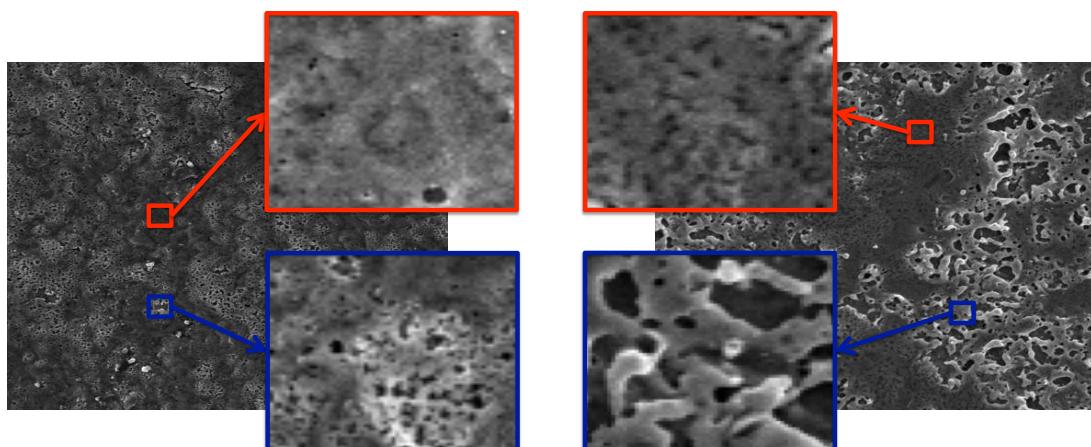


Figura 36 – Segmentação de padrões. Primeira coluna: imagens originais. Segunda coluna: segmentação dos padrões heterogêneos de textura das imagens da primeira coluna.



(a) Imagens do mesmo experimento.



(b) Imagens de experimentos diferentes.

Figura 37 – Matching de padrões heterogêneos. As janelas com bordas coloridas indicam zoom das janelas menores dentro das imagens.

Para mostrar o potencial discriminatório da metodologia proposta, a Figura 38 mostra os vetores de características sem seleção de atributos para as classes 4 e 8 que correspondem a dois diferentes experimentos. Como pode ser observado nesta Figura, os vetores de características pertencentes ao mesmo experimento são similares, mantendo o mesmo padrão de curva. Entretanto, os vetores de características provenientes de experimentos diferentes mostram padrões discriminatórios. Os vetores de características obtidos através da análise de padrões heterogêneos em imagens, após serem sujeitos a uma seleção de atributos, foram classificados utilizando *Linear Discriminant Analysis* (LDA) (DUDA; HART, 1973) em um sistema de validação externa e comparados em termos da taxa de acerto e número de descritores (Figura 39).

Os resultados exibidos no gráfico da Figura 39 mostram dois importantes pontos. O primeiro diz respeito a alta taxa de acerto ao classificar os oito experimentos utilizando LBPV,

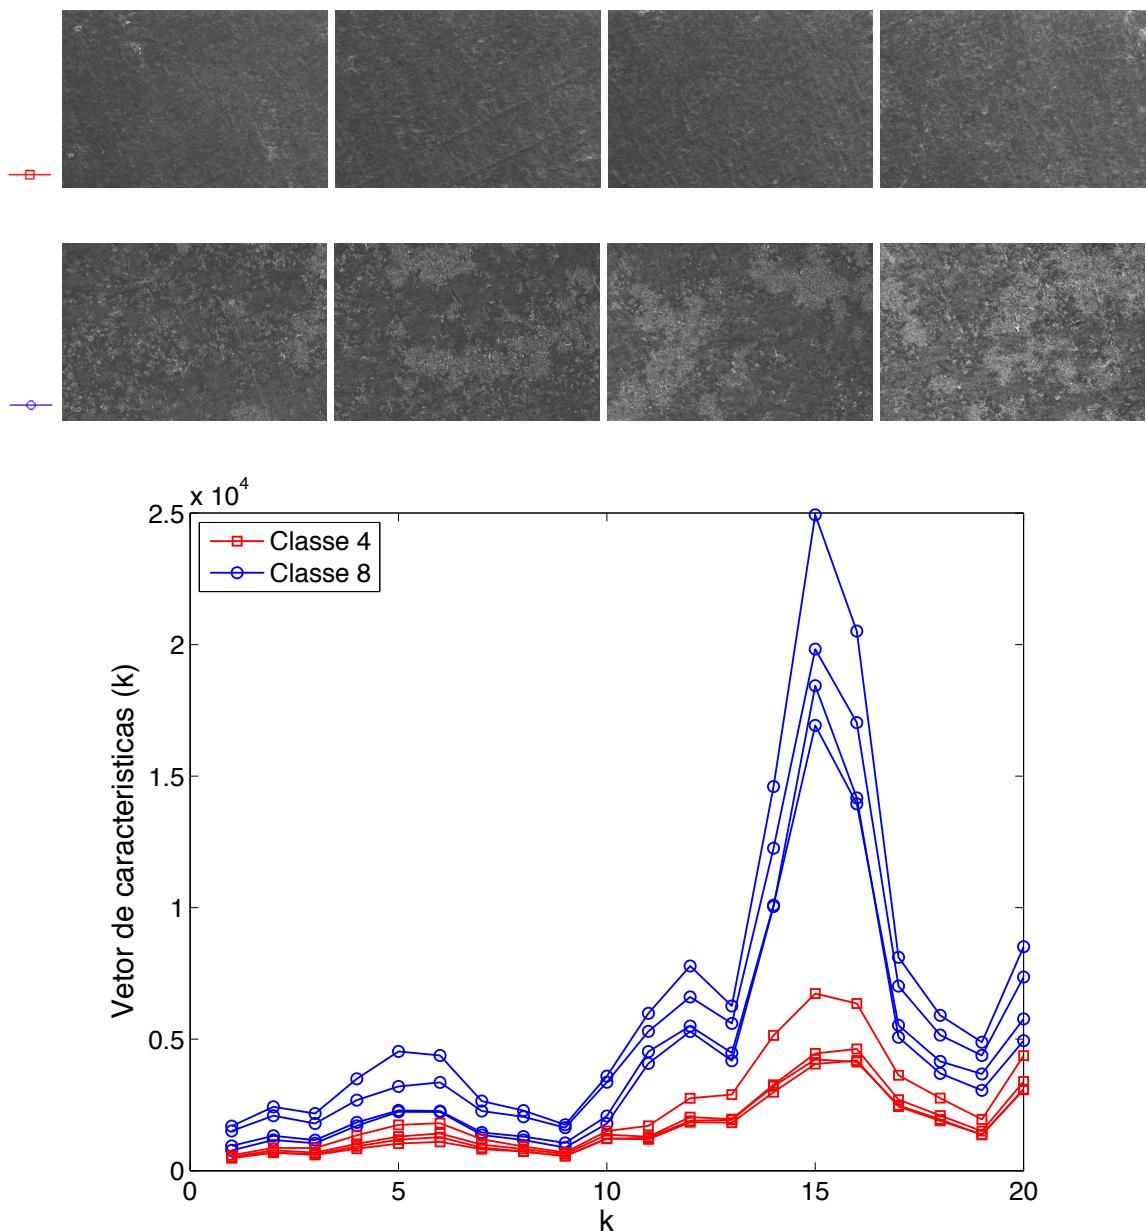


Figura 38 – Vetores de características de dois experimentos.

cujos resultados são colocados em evidência na matriz de confusão da Figura 40, tendo taxa de acerto igual a 84,38%. O segundo ponto está relacionado ao uso do mesmo descritor para descrever a textura assumindo que as imagens possuem apenas um padrão de textura, ou seja, homogêneas e ao considerar mais de um padrão de textura, heterogêneas. Para todos os métodos utilizados, somente usando a abordagem de padrões heterogêneos foi possível obter uma boa taxa de classificação dos experimentos analisados. Este fato é explicado pela heterogeneidade do material, formando diferentes padrões em um período de reações químicas em cada condição do experimento.

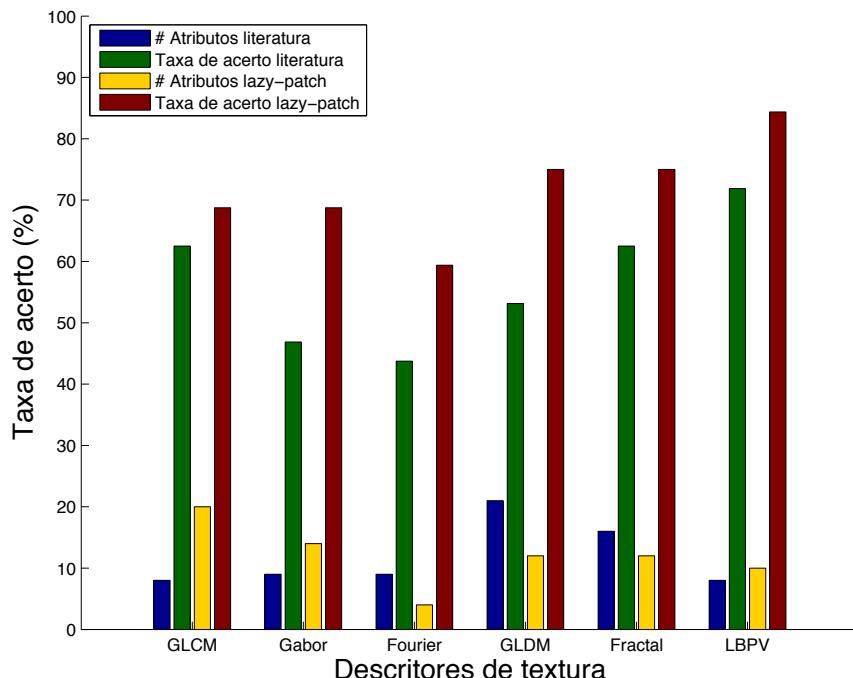


Figura 39 – Comparação dos resultados utilizando métodos da literatura com abordagem homogênea (barras verdes), considerando que exista apenas um padrão de textura na imagem, e a abordagem com padrões heterogêneos de textura (barras vermelhas). As barras em azul e amarelo mostram o número de descritores para cada abordagem, respectivamente.

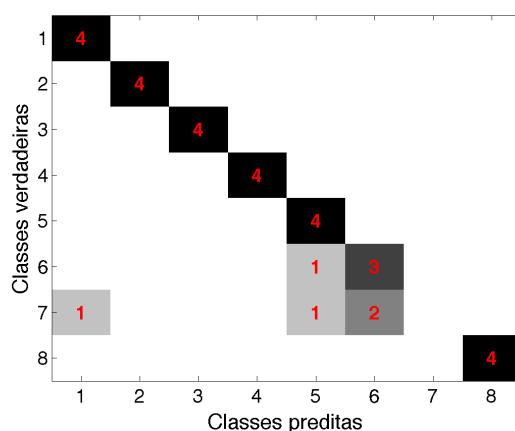


Figura 40 – Matriz de confusão para o método LBPV com análise de padrões heterogêneos de textura com taxa de acerto igual a 84,38%.

6.2 Identificação de Espécies de Madeira

Contrário a outros materiais como o aço, concreto ou ferro, a madeira é caracterizada por uma estrutura heterogênea explícita. Três planos (transversal, tangencial e radial) são usados para identificar e descrever espécies de madeira. Além disso, a diversidade de espécies é enorme. Apenas 5% das espécies de madeira do mundo têm uma descrição anatômica/botânica, coincidindo principalmente com o pequeno grupo de espécies comerciais (WHEELER, 2011). Um outro problema é a identificação das amostras de madeira e plantas em geral. Devido a cortes em orçamento e reorganização de estratégias de pesquisa, vários herbários em todo o mundo sofrem de uma grave falta de pessoal qualificado para realizar a identificação e catalogação de espécies (VA, 2014; B, 2015).

Anatomistas especializados em madeira são necessários para descrever espécies alternativas para o comércio, mas uma boa descrição requer seções transversais bem finas, equipamentos de laboratório apropriados (micrótomo, microscópio, programas para análise de imagens) e replicatas das descrições por pelo menos dois especialistas para assegurar a objetividade e validade das características anatômicas da madeira (STEPPE *et al.*, 2004; WHEELER, 2011). Cada descrição é baseada na lista IAWA onde 164 características são verificadas para cada amostra de madeira. Todos estes pontos tornam a identificação de cortes anatômicos de madeira custosa, em relação a tempo, trabalho e equipamentos.

Finalmente, algumas espécies de madeira, como é o caso das espécies pertencentes ao gênero *Entandrophragma*, são tão parecidas que não podem ser distinguidas baseando-se em suas descrições anatômicas. Neste contexto, o uso de reconhecimento de padrões para identificação automatizada de espécies de madeira aparece como uma solução plausível e atraente, especialmente porque é menos dependente do conhecimento especializado de anatomia da madeira e pode fazer uso das bases de dados existentes que contenham imagens microscópicas de alta qualidade.

Recentes pesquisas têm sido feitas para analisar computacionalmente imagens de madeira para identificar as suas espécies (CUI; ZHAI; WANG, 2013), utilizando imagens macroscópicas (BREMANANTH; NITHYA; SAIPRIYA, 2009; YU *et al.*, 2009; KHAIRUDDIN; KHALID; YUSOF, 2011; KHALID; RUBIYAHYUSOF; ANISSALWAMOHDKHAIRUDDIN, 2011; YUSOF; KHALID; KHAIRUDDIN, 2013b; YUSOF; KHALID; KHAIRUDDIN, 2013a; ZHAO, 2013; ZHAO; DOU; CHEN, 2014b; ZHAO; DOU; CHEN, 2014a; FILHO *et al.*, 2014) e microscópicas (MALLIK *et al.*, 2011; GURAU *et al.*, 2013; GUANG-SHENG; PENG, 2013; MARTINS *et al.*, 2013; MARTINS; OLIVEIRA; SABOURIN, 2012; CAVALIN *et al.*, 2013). No entanto, apesar de alguns estudos mostrarem resultados satisfatórios com uma boa taxa de sucesso, eles são baseados em experimentos utilizando poucas espécies, em alguns casos até 10 espécies (BREMANANTH; NITHYA; SAIPRIYA, 2009; ZHAO, 2013; ZHAO; DOU; CHEN, 2014b; ZHAO; DOU; CHEN, 2014a; MALLIK *et al.*, 2011). Por outro lado, algumas pesquisas fazem uso de características morfológicas (KHAIRUDDIN; KHALID; YUSOF, 2011;

KHALID; RUBIYAH YUSOF; ANISSALWA MOHD KHAIRUDDIN, 2011; YUSOF; KHALID; KHAIRUDDIN, 2013b; YUSOF; KHALID; KHAIRUDDIN, 2013a; GURAU *et al.*, 2013; GUANG-SHENG; PENG, 2013), tais como propriedades estatísticas de distribuição de poros, que são dependentes da segmentação (GUANG-SHENG; PENG, 2013), obtendo resultados instáveis, uma vez que a segmentação ainda é um campo aberto de investigação (WANG; HUANG; XU, 2010; WANG; ZHANG; QI, 2013). Devido à limitação para segmentar imagens, a textura tem se mostrado um campo promissor para a identificação de espécies de madeira (FILHO *et al.*, 2014; WANG; ZHANG; QI, 2013; WANG; QI; WANG, 2013; MARTINS *et al.*, 2013; MARTINS; OLIVEIRA; SABOURIN, 2012; CAVALIN *et al.*, 2013; ZHAO; DOU; CHEN, 2014a; ZHAO; DOU; CHEN, 2014b). Em Martins *et al.* (2013), Martins, Oliveira e Sabourin (2012) e Cavalin *et al.* (2013) foram utilizadas características de textura para identificar 112 espécies de madeira da flora brasileira, utilizando somente seções transversais microscópicas. No entanto, poucos estudos têm relatado a análise de textura de imagens de seção microscópicas transversais para a identificação de madeira.

Neste contexto, a segunda aplicação da análise de texturas com padrões heterogêneos consiste em utilizar cortes microscópicos transversais, tangenciais e radiais para identificação de 77 espécies de madeira da República Democrática do Congo (DRC), o que inclui todas as espécies comerciais deste país. A floresta tropical do Congo é a segunda maior floresta tropical do mundo, sendo a primeira a Amazônia. Mas, por várias razões, por exemplo inacessibilidade de florestas pantanosas, esta região não é documentada. Como três tipos de cortes de madeira estão disponíveis para análise, a abordagem que melhor se encaixa para identificação de espécies de madeira é o uso do modelo random forest combinado, onde cada seção microscópica é representada por um conjunto de características de textura. Nesta aplicação, as características de textura foram obtidas por Quantização de Fase Local (*Local Phase Quantization - LPQ*) (OJANSIVU; RAHTU; HEIKKIL’^a, 2008; OJANSIVU; HEIKKIL’^a, 2008).

6.2.1 Aquisição de imagens

Cada amostra de madeira é composta por três imagens, sendo uma imagem de cada seção, transversal, tangencial e radial, como mostra a Figura 41. Desta forma, 805 imagens de tamanho 1000×1000 pixels foram obtidas para cada seção, totalizando 2415 imagens sendo analisadas. Foram analisadas 77 espécies pertencentes a 58 gêneros e 25 famílias (Tabela 11). Todas as amostras foram coletadas na DRC e as imagens foram obtidas com a ajuda de um microscópio com resolução de $2.5\times$. As Figuras 42–44 mostram exemplos de quatro imagens para seis espécies de cada seção, evidenciando as diferenças dentro de uma mesma espécie.

Família	Gênero	Espécie
Anacardiaceae	<i>Antrocaryon</i>	<i>Antrocaryon nannanii</i>
Continua na próxima página		

Tabela 11 – continuação da página anterior

Família	Gênero	Espécie
Apocynaceae	<i>Alstonia</i>	<i>Alstonia boonei</i>
	<i>Funtumia</i>	<i>Funtumia africana</i>
Bombacaceae	<i>Ceiba</i>	<i>Ceiba pentandra</i>
Boraginaceae	<i>Cordia</i>	<i>Cordia platythyrsa</i>
Burseraceae	<i>Canarium</i>	<i>Canarium schweinfurthii</i>
Clusiaceae	<i>Mammea</i>	<i>Mammea africana</i>
Combretaceae	<i>Terminalia</i>	<i>Terminalia superba</i>
Ebenaceae	<i>Diospyros</i>	<i>Diospyros crassiflora</i>
Euphorbiaceae	<i>Drypetes</i>	<i>Drypetes gossweileri</i>
Fabaceae-Caesalpiniaceae	<i>Afzelia</i>	<i>Afzelia africana</i> <i>Afzelia bella</i> <i>Afzelia bipindensis</i> <i>Afzelia cuanzensis</i> <i>Afzelia pachyloba</i>
	<i>Amphimas</i>	<i>Amphimas ferrugineus</i> <i>Amphimas pterocarpoides</i>
	<i>Anthonotha</i>	<i>Anthonotha macrophylla</i>
	<i>Antiaris</i>	<i>Antiaris toxicaria</i>
	<i>Brachystegia</i>	<i>Brachystegia laurentii</i>
Fabaceae-Mimosaceae	<i>Copaifera</i>	<i>Copaifera mildbraedii</i>
	<i>Cynometra</i>	<i>Cynometra alexandri</i> <i>Cynometra hankei</i>
	<i>Erythrophleum</i>	<i>Erythrophleum suaveolens</i>
	<i>Gilbertiodendron</i>	<i>Gilbertiodendron dewevrei</i>
	<i>Guibourtia</i>	<i>Guibourtia arnoldiana</i> <i>Guibourtia demeusei</i>
	<i>Prioria</i>	<i>Prioria balsamifera</i> <i>Prioria oxyphylla</i>
	<i>Scorodophloeus</i>	<i>Scorodophleus zenkeri</i>
	<i>Tessmannia</i>	<i>Tessmannia africana</i>
	<i>Albizia</i>	<i>Albizia adianthifolia</i> <i>Albizia antunesiana</i> <i>Albizia ferruginea</i>
	<i>Newtonia</i>	<i>Newtonia leucocarpa</i>
Fabaceae-Papilionaceae	<i>Pentaclethra</i>	<i>Pentaclethra eetveldeana</i> <i>Pentaclethra macrophylla</i>
	<i>Piptadeniastrum</i>	<i>Piptadeniastrum africanum</i>
	<i>Millettia</i>	<i>Millettia laurentii</i>
<i>Pericopsis</i>	<i>Pericopsis</i>	<i>Pericopsis elata</i>
	<i>Pterocarpus</i>	<i>Pterocarpus soyauxii</i> <i>Pterocarpus tinctorius</i>

Continua na próxima página

Tabela 11 – continuação da página anterior

Família	Gênero	Espécie
Irvingiaceae	<i>Irvingia</i>	<i>Irvingia grandifolia</i>
	<i>Klainedoxa</i>	<i>Klainedoxa gabonensis</i>
Lauraceae	<i>Beilschmiedia</i>	<i>Beilschmiedia congolana</i>
Lecythidaceae	<i>Petersianthus</i>	<i>Petersianthus macrocarpus</i>
	<i>Ekebergia</i>	<i>Ekebergia capensis</i>
Meliaceae	<i>Entandrophragma</i>	<i>Entandrophragma angolense</i> <i>Entandrophragma candollei</i> <i>Entandrophragma cylindricum</i> <i>Entandrophragma utile</i>
	<i>Khaya</i>	<i>Khaya anthotheca</i>
	<i>Leplaea</i>	<i>Leplaea cedrata</i> <i>Leplaea laurentii</i> <i>Leplaea thompsonii</i>
	<i>Lovoa</i>	<i>Lovoa trichilioides</i>
	<i>Ficus</i>	<i>Ficus mucoso</i>
Moraceae	<i>Milicia</i>	<i>Milicia excelsa</i>
	<i>Morus</i>	<i>Morus mesozygia</i>
	<i>Musanga</i>	<i>Musanga cecropioides</i>
Myristicaceae	<i>Pycnanthus</i>	<i>Pycnanthus angolensis</i>
	<i>Staudtia</i>	<i>Staudtia kamerunensis</i>
Ochnaceae	<i>Lophira</i>	<i>Lophira alata</i>
Olacaceae	<i>Ongokea</i>	<i>Ongokea gore</i>
Rubiaceae	<i>Hallea</i>	<i>Hallea stipulosa</i>
	<i>Nauclea</i>	<i>Nauclea diderrichii</i>
Rutaceae	<i>Zanthoxylum</i>	<i>Zanthoxylum gilletii</i> <i>Zanthoxylum lemairei</i>
	<i>Autranella</i>	<i>Autranella congolensis</i>
Sapotaceae	<i>Chrysophyllum</i>	<i>Chrysophyllum africanum</i> <i>Chrysophyllum lacourtianum</i>
	<i>Pouteria</i>	<i>Pouteria aningeri</i>
	<i>Tieghemella</i>	<i>Tieghemella heckelii</i>
	<i>Nesogordonia</i>	<i>Nesogordonia kabingensis</i>
Sterculiaceae	<i>Triplochiton</i>	<i>Triplochiton scleroxylon</i>
	<i>Celtis</i>	<i>Celtis gomphophylla</i>
Ulmaceae	<i>Holoptelea</i>	<i>Holoptelea grandis</i>

Tabela 11 – Família, gênero e espécies utilizadas para os experimentos de identificação de espécies de madeira.

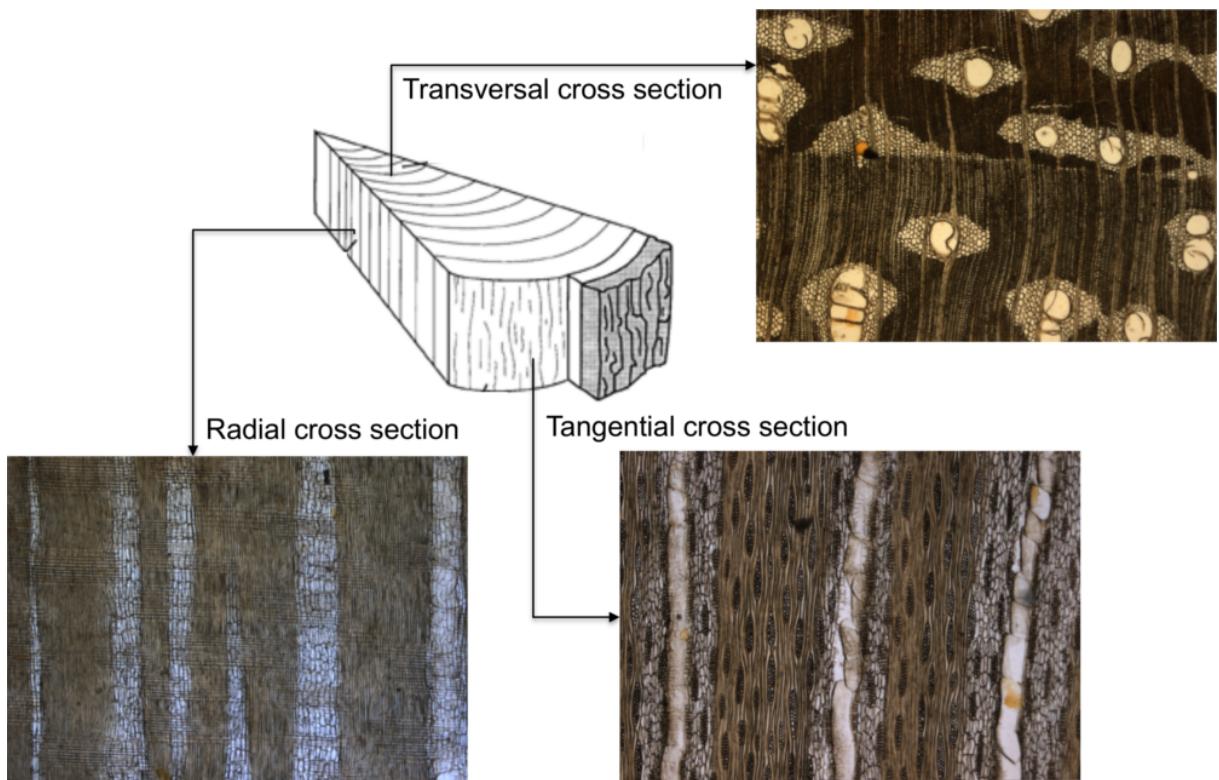


Figura 41 – Cortes microscópicos transversal, tangencial e radial.

6.2.2 Metodologia para Identificação de Espécies

A identificação das 77 espécies de madeira foi realizada seguindo o modelo random forest combinado. Características de textura de cada seção foram extraídas representando os diferentes padrões de textura que compõem o modelo. Para mostrar a vantagem em utilizar a combinação das seções, as amostras foram classificadas primeiramente de acordo com cada seção utilizando diferentes classificadores, sendo: *k*-Nearest Neighbor, Decision Tree e Random Forest. Sendo este último, o mesmo classificador utilizado para construção do modelo random forest combinado. Todos os experimentos foram executados usando *k-fold cross-validation* estratificado, com exceção do classificador Random Forest que faz uso da estimativa *oob* que é tão acurada quanto o esquema *k-fold cross-validation* (BREIMAN, 1996; HASTIE; TIBSHIRANI; FRIEDMAN, 2008). O número de *folds* foi definido de acordo com o número mínimo de amostras por espécie de madeira, que é quatro neste caso. Os resultados correspondentes estão relatados na Tabela 12.

Modelo random forest combinado, onde cada seção microscópica é representada por um conjunto de características de textura.

Os resultados obtidos ao analisar os cortes separadamente vão de encontro com a perspectiva biológica de cada corte. Do ponto de vista anatômico da madeira, as estruturas celulares mais importantes, como vasos, fibras, raios e parênquima são mais discriminativas na seção transversal. Assim, uma série de características anatômicas da madeira a partir da lista IAWA pode ser

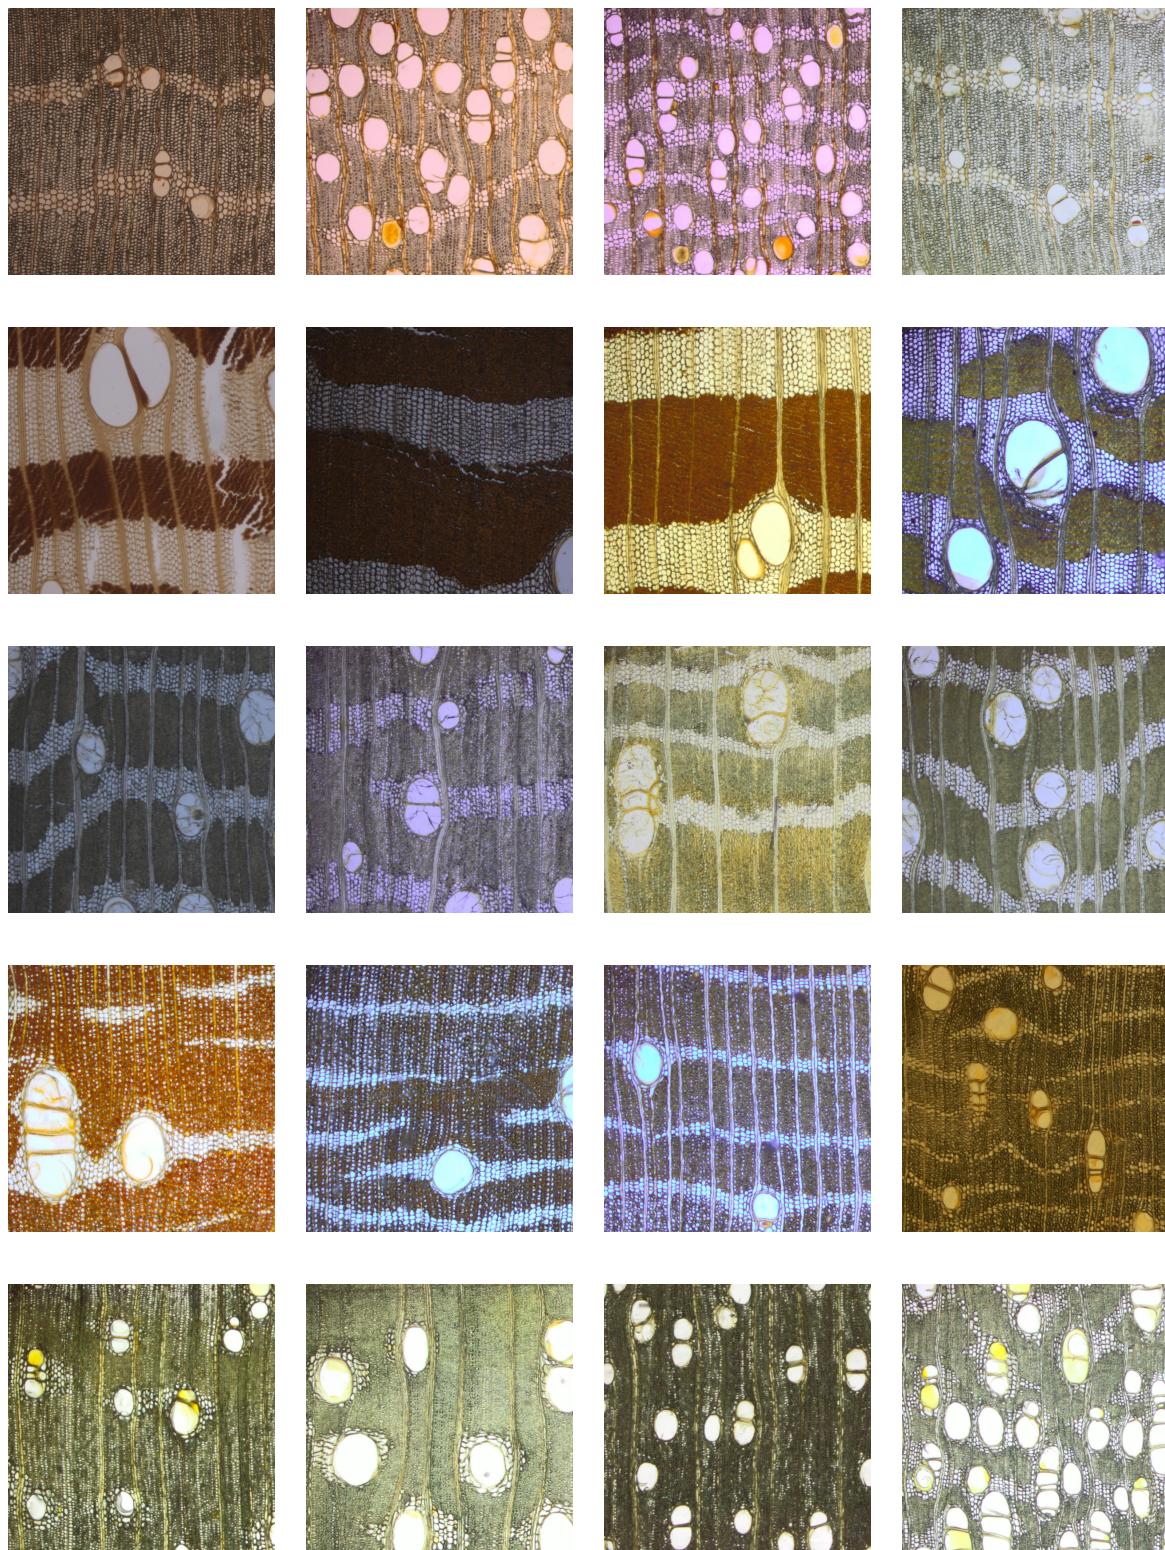


Figura 42 – Seções transversais de madeira. Cada linha mostra imagens da mesma espécie, de cima para baixo: *Leplaea cedrata*, *Millettia laurentii*, *Morus mesozygia*, *Pterocarpus soyauxii* and *Zanthoxylum gilletii*.

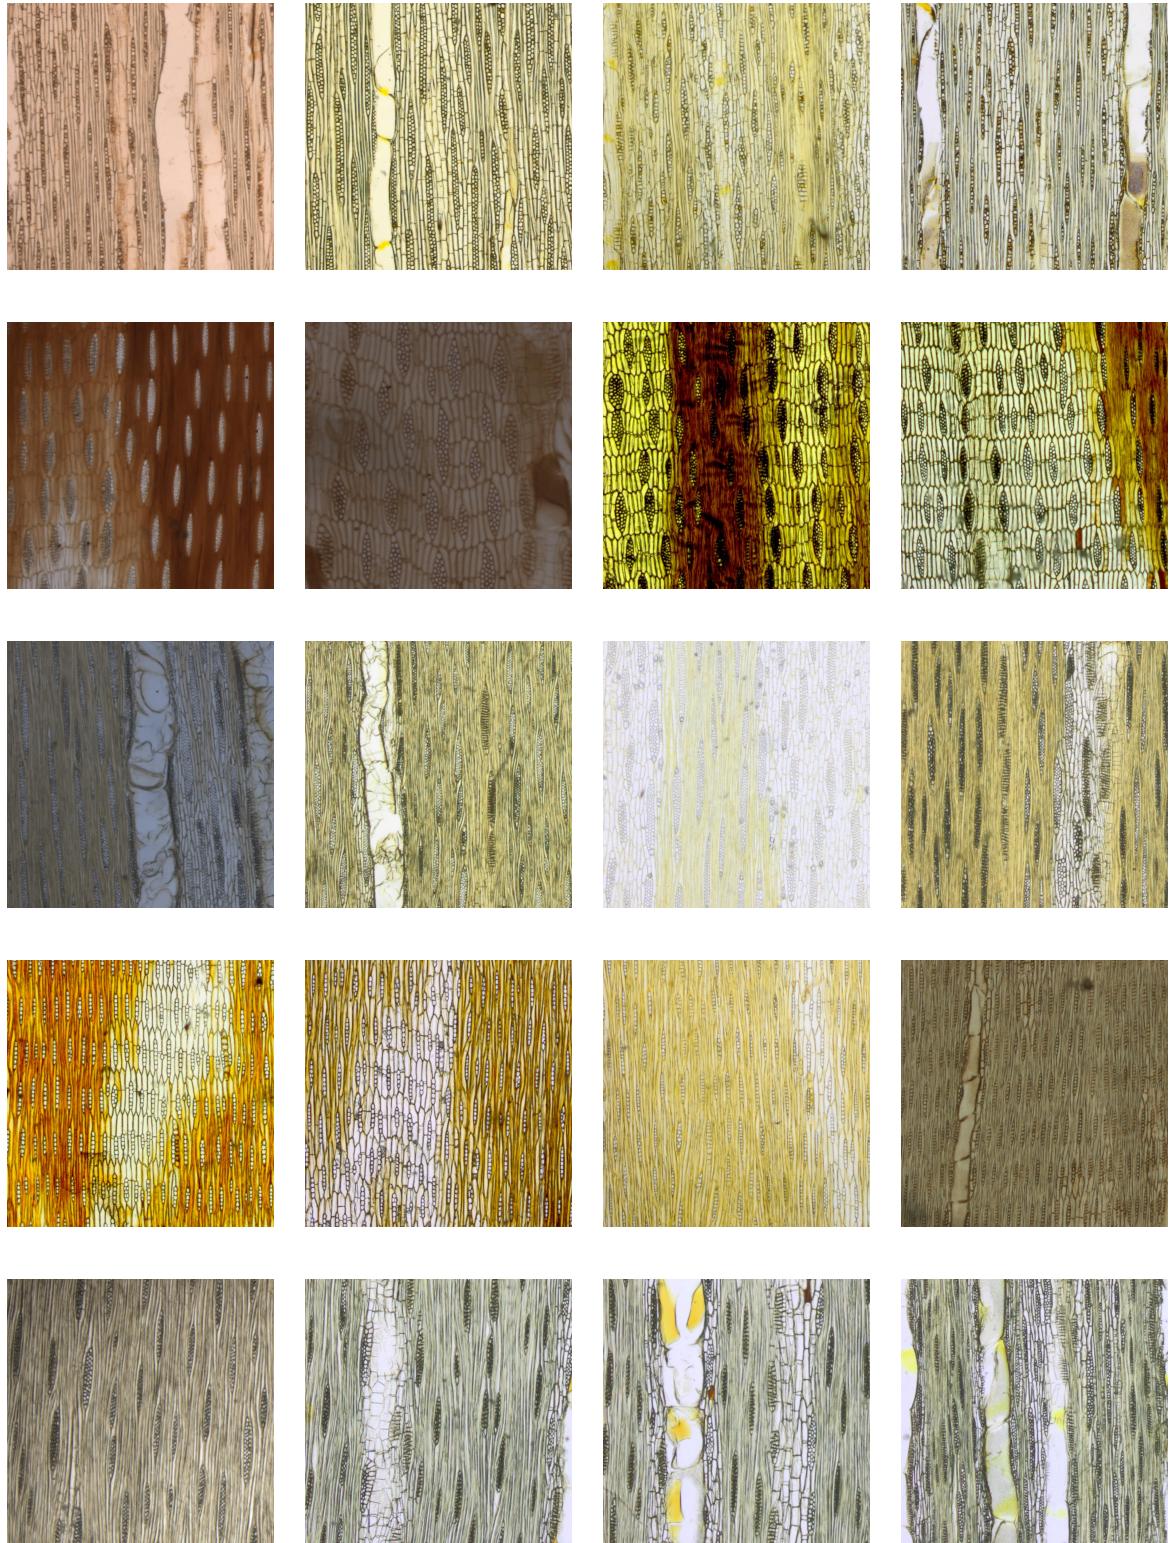


Figura 43 – Seções tangenciais de madeira. Cada linha mostra imagens da mesma espécie, de cima para baixo: *Leplaea cedrata*, *Millettia laurentii*, *Morus mesozygia*, *Pterocarpus soyauxii* e *Zanthoxylum gilletii*.

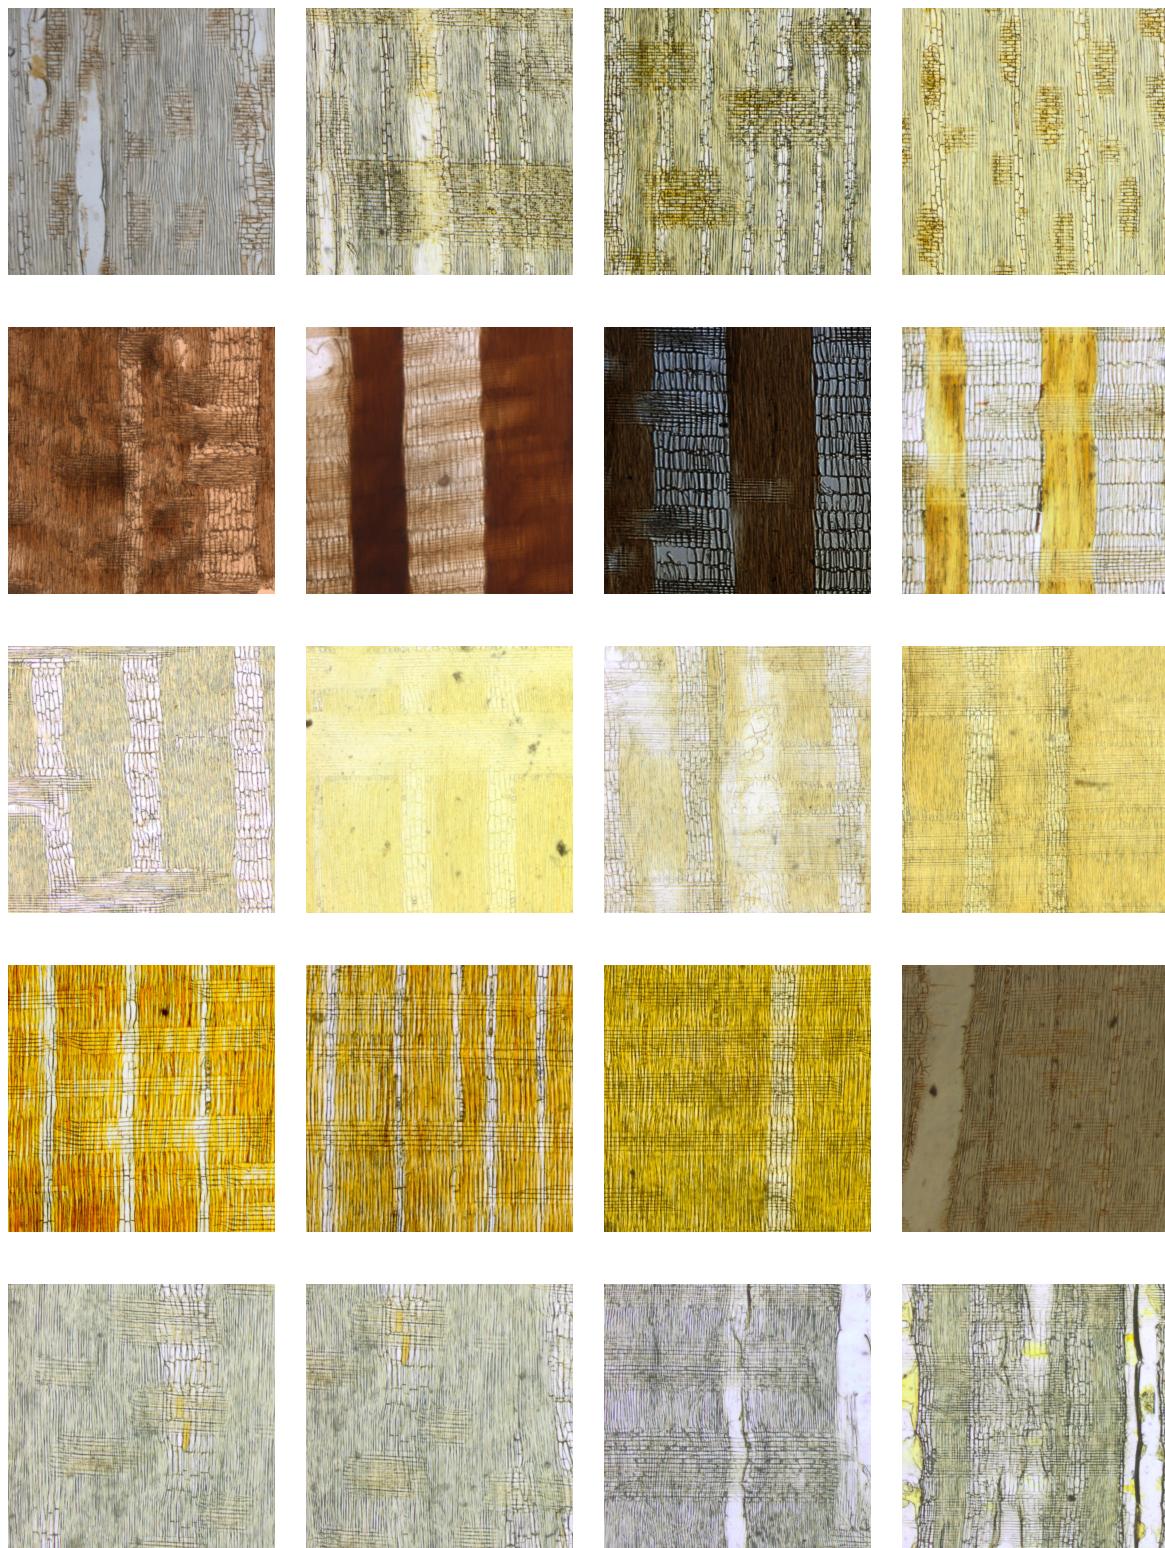


Figura 44 – Seções radiais de madeira. Cada linha mostra imagens da mesma espécie, de cima para baixo: *Leplaea cedrata*, *Millettia laurentii*, *Morus mesozygia*, *Pterocarpus soyauxii* and *Zanthoxylum gilletii*.

	Taxa de acerto (\pm std)		
	Transversal	Tangencial	Radial
Random Forest	57,02 (\pm 0,61)	43,74 (\pm 0,74)	40,32 (\pm 0,79)
<i>k</i> -NN	58,64 (\pm 1,83)	42,98 (\pm 2,01)	38,39 (\pm 4,20)
Descision Tree	15,53 (\pm 2,28)	12,30 (\pm 2,29)	11,93 (\pm 1,42)
Random Forest Combinado		65,20 (\pm 1,60)	

Tabela 12 – Taxa de acerto ao utilizar cada seção separadamente para identificar as espécies de madeira e ao utilizar o modelo Random Forest Combinado.

documentada usando a seção transversal. As características mais importantes da seção transversal muitas vezes podem ser visualizadas usando uma lente de mão, enquanto as informações contidas nos cortes tangencial e radial só são visualizadas de forma suficiente usando microscopia de luz. Seções transversais também são usadas mais que as tangenciais e radiais porque essas seções podem mostrar anéis de crescimento (se houver) ou variações nos parâmetros de vaso que podem estar relacionados com a ecologia florestal, manejo ou reações à mudança climática. Ao utilizar textura para identificação das espécies, o corte transversal foi responsável pelo melhor resultado quando os cortes foram utilizados separadamente. No entanto, a melhor taxa de acerto, 65.2% (\pm 1.6), somente foi alcançada ao utilizar o modelo random forest combinado, integrando as três seções. Dessa forma, demonstrando o potencial desta metodologia.

6.3 Identificação de Espécies de Plantas

As plantas verdes (**Viridiplantae** em Latin) estão entre os seres vivos mais importantes do mundo natural. Elas são organismos fotossintéticos eucariotos multicelulares que formam um clado que inclui as plantas com flores, coníferas e outras gimnospermas, samambaias, musgos, antóceros, hepáticas, musgos e algas verdes (KEDDY, 2006), produzindo a maioria do carbono fotossintético do mundo (FIELD *et al.*, 1998), sendo a base da vida na terra. De acordo com Archibald *et al.* (1995) existem 11 tipos principais de ecossistemas: florestas tropicais, florestas temperadas, regiões áridas (deserto), ecossistema mediterrâneo, savanas tropicais, florestas de coníferas, tundra, os ecossistemas de água doce e sistemas marinhos.

Na América do Sul, florestas e savanas predominam (RATTER; RIBEIRO; BRIDGEWATER, 1997), e no território brasileiro, o Cerrado está incluído como uma das savanas tropicais mais importantes (LEHMANN *et al.*, 2014). Seu alcance geográfico é responsável por 22% da área de terra do país, estendendo-se marginalmente no Paraguai e Bolívia, sendo o segundo ecossistema mais importante da América do Sul, depois da Floresta Amazônica. O Fundo Mundial para a Natureza nomeou-a savana biologicamente mais rica do mundo, com cerca de 12.000 espécies de plantas, sendo 44% endêmicas (que só ocorrem naquele local), de acordo com Mendonça *et al.* (2008) e Walter (2006). Além disso, o Cerrado tem sido considerado um

*hotspot*¹, que sofre com o desmatamento grave e uso agrícola (MYERS, 1990).

Devido à diversidade de plantas, o que se reflete em uma grande diversidade de estruturas morfológicas (GOTTSBERGER; SILBERBAUER-GOTTSBERGER, 2006; BIERAS; SAJO, 2009), o ecossistema Cerrado apresenta-se como uma grande oportunidade para testar métodos e abordagens para fornecer novas ferramentas para a identificação de plantas. Até à data a principal abordagem utilizada para identificar qualquer espécie de planta é o uso de caracteres morfológicos (BRIDSON; FORMAN; GARDENS, 1998). Esta abordagem é amplamente baseada em caracteres morfológicos de órgãos reprodutivos que nem sempre estão presentes na planta, tais como flores e frutos (STACE, 1991). Alternativamente, nos últimos anos, algumas abordagens computacionais foram propostas para identificar espécies com base em imagens de folhas que são frequentemente disponíveis durante todo o ano em regiões tropicais e subtropicais do mundo. Tais métodos são capazes de diferenciar as espécies com base nas propriedades de imagem da folha, onde a textura é a principal característica analisada. A aplicação destes métodos tem sido utilizada em seções transversais de folhas (análise de estruturas internas) ou na superfície da folha (onde subamostras de toda a folha digitalizada são analisadas) (LIU; ZHANG; DENG, 2009; CASANOVA; JUNIOR; BRUNO, 2009; BACKES; CASANOVA; BRUNO, 2009; ROSSATTO *et al.*, 2011; JUNIOR *et al.*, 2011; FLORINDO *et al.*, 2014).

Nesta aplicação de identificação de espécies de plantas, são utilizadas imagens microscópicas da epiderme dissociada de folhas (EVERT; EICHHORN, 2006). O processo de dissociação é normalmente utilizado para inferir padrões estruturais como o tamanho, posição e densidade de estômatos, bem como a distribuição e forma das células epidérmicas e as características da cutícula, como padrões de estrias (EVERT; EICHHORN, 2006; METCALFE; CHALK, 1979). Na análise da superfície da epiderme, os procedimentos anatômicos são relativamente simples em comparação com a preparação de cortes transversais (JOHANSEN, 1940). No entanto, poucos estudos avaliaram a morfometria, estrutura anatômica e a textura da epiderme da folha com fins de identificação. Em Ramos e Fernández (2009), amostras de epiderme dissociada foram utilizadas, sendo que, apenas uma espécie foi analisada.

6.3.1 Aquisição de Imagens

As folhas foram coletadas de espécies representativas do cerrado, na Reserva Ecológica do IBGE e na Reserva Ecológica Águas Emendadas, ambas em Brasília, Distrito Federal, Brasil. As superfícies abaxiais da epiderme foram obtidas a partir de quatro ou cinco folhas (uma por indivíduo) de cada espécie. Para cada folha coletada, uma amostra de aproximadamente 1cm^2 foi removida da região mediana da folha, entre a borda e a nervura principal. A dissociação da folha foi realizada com uma solução de 1:1 de ácido acético glacial e de peróxido de hidrogênio a 60°C por 12 horas, ou o tempo necessário para a dissociação total de epiderme (modificado

¹ Hotspot é toda área prioritária para conservação, isto é, de alta biodiversidade e ameaçada no mais alto grau. É considerada *hotspot* uma área com pelo menos 1.500 espécies endêmicas de plantas e que tenha perdido mais de 3/4 de sua vegetação original.

de (FRANKLIN, 1945)). Após esse procedimento, a epiderme foi lavada com água destilada, corada com safranina e montada em glicerina. As imagens foram capturadas com lentes de $20\times$ utilizando um microscópio óptico modelo *Zeiss Axio Scope A1* acoplado a uma câmera digital modelo *Zeiss AxioCam MRc*. Três imagens por folha foram utilizadas para o procedimento de classificação. Para as experiências utilizando medições manuais, a densidade de estômatos, bem como o comprimento das células guarda e a largura do complexo estomático, foram obtidos com a ajuda do software *AxioVision Zeiss*. Contagens dos estômatos foram feitas em três campos (definidos aleatoriamente) por indivíduo amostrado, em uma lente objetiva de $10\times$. Seguindo este procedimento, 300 amostras de tamanho 2080×1540 pixels distribuídas sobre 32 espécies foram obtidas (Tabela 13). A Figura 45 mostra, por linha, duas amostras de imagens de epiderme da mesma espécie.

6.3.2 Metodologia para Identificação de Espécies

As imagens de epiderme obtidas para este experimento passaram por um procedimento de coloração, que levou a obtenção de imagens com modificações das cores originais das folhas. Por esta razão, as imagens foram convertidas para níveis de cinza e passaram por uma rotina para melhoramento de contraste antes de realizar a extração de características. A operação utilizada, *Stretching*, ou espalhamento de contraste, visa uniformizar a distribuição dos níveis de cinza da imagem. Seja uma imagem $f(x,y)$, a imagem melhorada $g(x,y)$ é dada por:

$$g(x,y) = \frac{f(x,y) - \min(f(x,y))}{\max(f(x,y)) - \min(f(x,y))} 2^{bpp}, \quad (6.1)$$

onde bpp é o número de bits por pixel da imagem $f(x,y)$. Para esta aplicação, a imagem tem 256 níveis de cinza e $bpp = 8$. Na imagem melhorada $g(x,y)$, 1% dos dados é saturado nas intensidades baixas e altas da imagem original.

Foram utilizados três descritores de textura para caracterizar cada imagem de epiderme, que são: Fourier (COSGRIFF, 1960; AZENCOTT; WANG; YOUNES, 1997; GONZALEZ; WOODS, 2006), análise de textura baseada na modelagem da textura como autômatos celulares inspirados no processo de corrosão alveolar (SILVA *et al.*, 2015) (método CITA proposto nesta tese) e Padrões Binários Locais (OJALA; PIETIKÄINEN; MÄENPÄÄ, 2002). Para os descritores de Fourier, duas abordagens para representação das características foram utilizadas: circular angular e circular. A primeira utiliza somente os descritores circulares de Fourier e a segunda utiliza os vetores concatenados de Fourier circular e Fourier circular-angular. O número de descritores varia de 200 a 833, portanto, a técnica de redução da dimensionalidade Análise de Componentes Principais (PCA) foi utilizada para obter um número reduzido de descritores. PCA é uma transformação que converte um número de variáveis possivelmente correlatas em um conjunto de valores de variáveis não correlacionadas denominadas componentes principais (JOLLIFFE, 2002). A primeira componente principal possui a maior variância dos dados, a segunda componente possui a segunda maior variância e componentes sucessivos têm a

Família	Espécie
Anacardiaceae	<i>Tapirira guianensis</i> Aubl.
Annonaceae	<i>Duguetia furfuracea</i> (A.St.-Hill.) Saff. <i>Xylopia sericea</i> A. St.-Hil.
Aquifoliaceae	<i>Ilex affinis</i> Gardner
Asteraceae	<i>Baccharis linearifolia</i> (Lam.) Pers.
Bignoniaceae	<i>Tabebuia impetiginosa</i> (Mart. ex DC.) Standl.
Celastraceae	<i>Maytenus floribunda</i> Reissek <i>Plenckia populnea</i> Reissek <i>Salacia crassifolia</i> (Mart. ex Schult.) G. Don
Clusiaceae	<i>Calophyllum brasiliense</i> Cambess. <i>Clusia criuva</i> Cambess.
Connaraceae	<i>Rourea induta</i> Planch.
Ericaceae	<i>Gaylussacia brasiliensis</i> (Spreng.) Meisn.
Fabaceae	<i>Copaifera langsdorffii</i> Desf. <i>Hymenaea stigonocarpa</i> Mart. ex Hayne
Malpighiaceae	<i>Byrsonima laxiflora</i> Griseb.
Malvaceae	<i>Eriotheca candolleana</i> (K. Schum.) A. Robyns <i>Pseudobombax longiflorum</i> (Mart.) A. Robyns
Melastomataceae	<i>Miconia cuspidata</i> Mart. ex Naudin <i>Miconia chamaissoides</i> Naudin
Myristicaceae	<i>Virola sebifera</i> Aubl.
Myrsinaceae	<i>Myrsine guianensis</i> (Aubl.) Kuntze <i>Myrsine ferruginea</i> (Ruiz & Pav.) Spreng.
Myrtaceae	<i>Campomanesia velutina</i> (Cambess.) O. Berg
Nyctaginaceae	<i>Guapira noxia</i> (Netto) Lundell
Ochnaceae	<i>Ouratea hexasperma</i> (A.St.-Hill.) Baill.
Proteaceae	<i>Roupala montana</i> Aubl.
Rutaceae	<i>Esenbeckia pumila</i> Pohl.
Sapindaceae	<i>Cupania vernalis</i> Cambess. <i>Matayba guianensis</i> Aubl.
Symplocaceae	<i>Symplocos mosenii</i> Brand <i>Symplocos nitens</i> (Pohl) Benth.

Tabela 13 – Famílias e espécies utilizadas para os experimentos de identificação de espécies utilizando epiderme foliar.

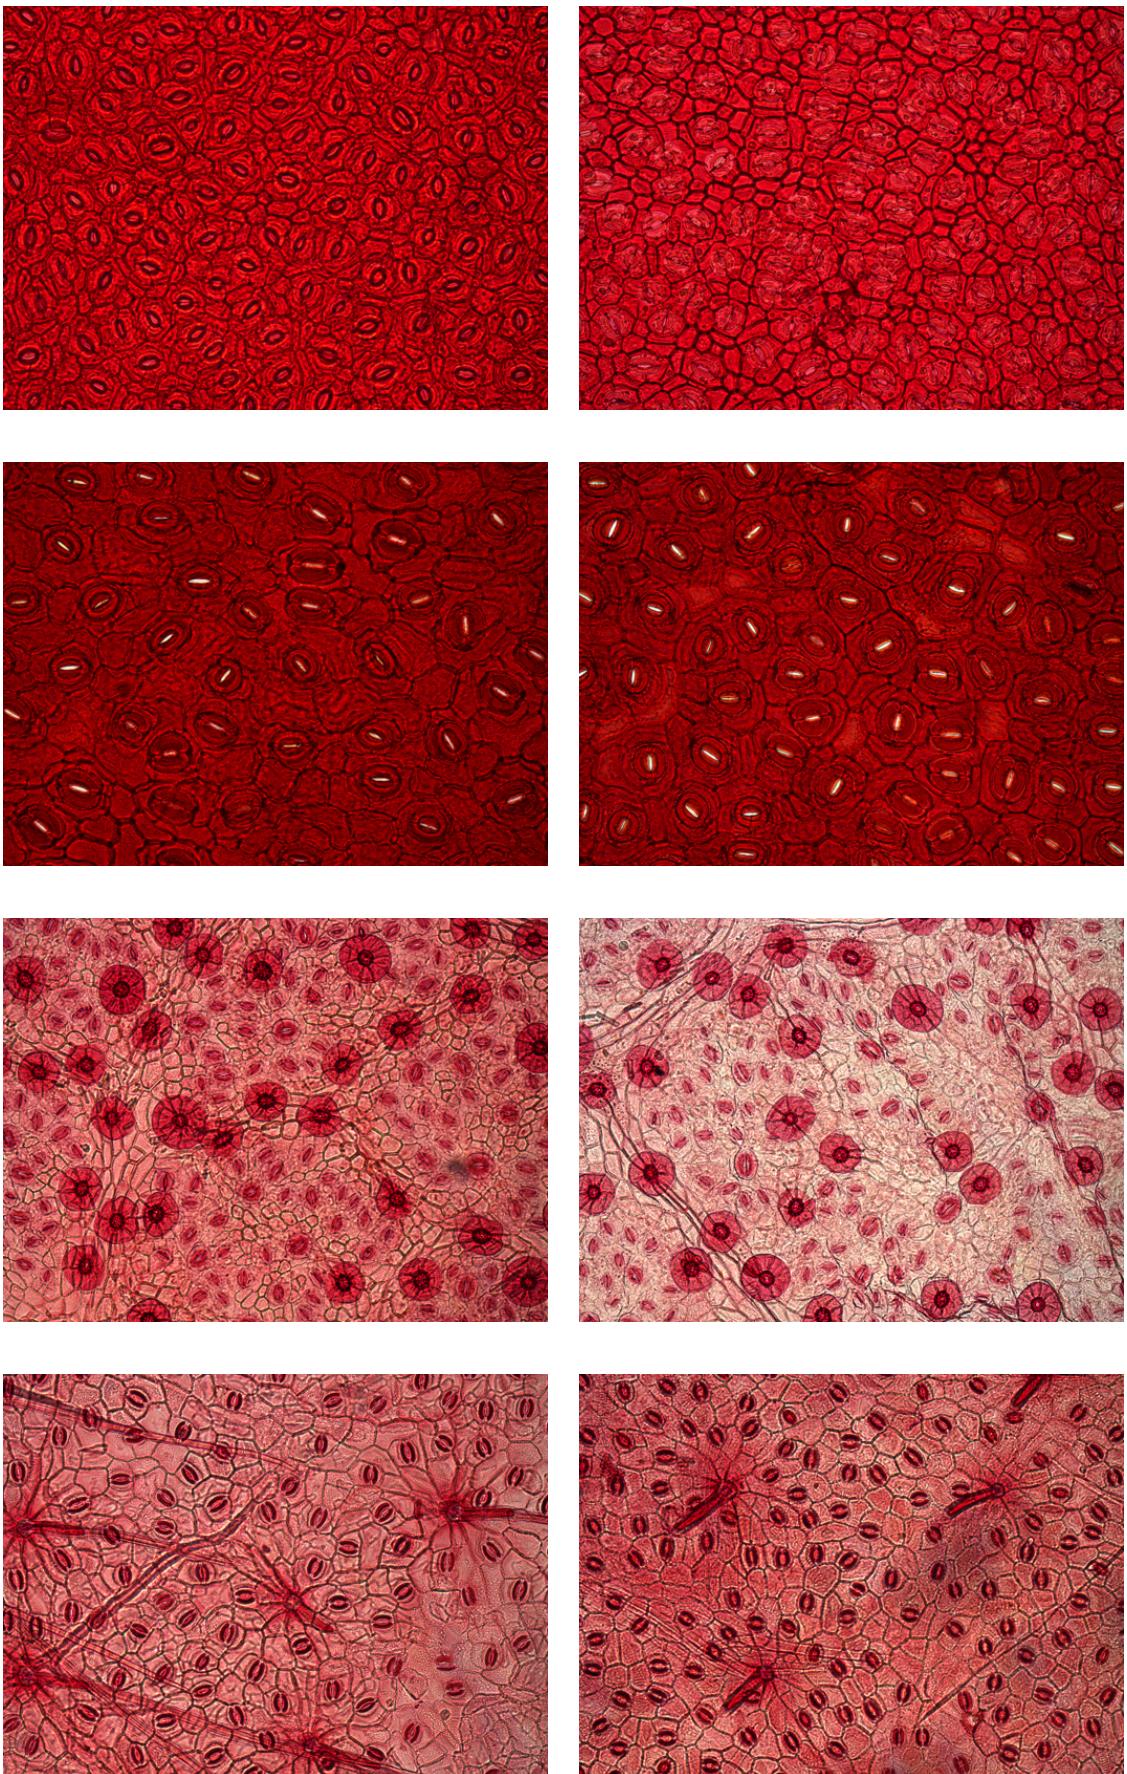


Figura 45 – Imagens de epiderme cujas imagens intra espécies se assemelham. As linhas contém imagens da mesma espécie, de cima para baixo: *Ilex affinis*, *Myrsine guianensis*, *Tabebuia impetiginosa* and *Xylopia sericea*.

maior variabilidade em ordem decrescente. A identificação das amostras foi realizada utilizando o sistema de validação cruzada estratificada 6-fold ([HASTIE; TIBSHIRANI; FRIEDMAN, 2001](#)), pois existem pelo menos 6 amostras por espécie, e a classificação das amostras foi realizada utilizando *k-Nearest Neighbor* (*k*-NN) ([AHA; KIBLER; ALBERT, 1991](#)), com *k*=1. Todos os resultados são apresentados na Tabela 14.

6.3.2.1 Medidas quantitativas manuais

Para enfatizar a importância de métodos computacionais no auxílio da identificação de espécies de plantas, medidas quantitativas manuais foram obtidas para fazer uma comparação entre as duas abordagens. As seguintes medidas foram consideradas: densidade dos estômatos, comprimento e largura das células guarda. As mesmas 300 amostras das 32 espécies utilizadas para os experimentos computacionais também foram utilizadas para os experimentos utilizando morfologia. O resultado utilizando as medidas quantitativas é de 61,33%. Essas medidas foram adicionadas aos descritores de textura para verificar o impacto de usar os dois descritores em conjunto. Observa-se na Tabela 14 que características morfológicas podem aumentar até 10% a taxa de acerto ao combinar os descritores, mas sozinhos não são suficientes para realizar a identificação das espécies.

6.3.2.2 Efeito da plasticidade na identificação

O conjunto de imagens utilizado para os experimentos contém 300 imagens de 32 espécies, em que seis amostras de plantas da espécie *Tapirira guianensis* cresceram no ambiente mata de galeria. Para verificar a invariância à plasticidade, nove imagens de *Tapirira guianensis* crescidas no ambiente vereda foram adicionadas ao conjunto de imagens totalizando 309 imagens. A invariância à plasticidade é uma característica importante para identificação de espécies porque indivíduos que cresceram em diferentes formações vegetacionais sob diferentes fatores ambientais podem apresentar características morfológicas distintas sendo um problema para a identificação convencional de espécies. Os resultados apresentados na Tabela 14, colunas ‘% *T. g.*’ mostram a taxa de acerto para *Tapirira guianensis* considerando 300 e 309 imagens. No primeiro caso, considerando amostras de *Tapirira guianensis* da mata de galeria, a taxa de acerto para esta espécie foi de 100% para a maioria dos descritores, inclusive os morfológicos. Entretanto, ao adicionar amostras de *Tapirira guianensis* do ambiente vereda, a taxa de acerto ao utilizar a metodologia tradicional com medidas morfológicas cai drasticamente enquanto os descritores de textura são robustos mantendo uma alta taxa de identificação.

A habilidade dos descritores de Fourier em concentrar componentes de baixas frequências separadamente das altas frequências permite a análise do tecido epidermial (células regulares com função de revestimento) separadamente das células especializadas (estômatos) e apêndices epidérmicos (tricomas). Portanto, atributos de baixa e alta frequências podem ser comparados separadamente entre as amostras levando a uma alta taxa de acerto, maior que 96%. Por outro

Descriptor	#	300 imagens		309 imagens	
		% (\pm std)	% T. g.	#	% (\pm std)
Fourier Circular + Circular-Angular	20	96.00 (\pm 0.05)	100	20	94.17 (\pm 0.06)
Fourier Circular + Circular-Angular + Quantitativo	23	98.67 (\pm 0.03)	100	23	96.76 (\pm 0.05)
Fourier Circular	19	95.00 (\pm 0.06)	83	19	93.20 (\pm 0.06)
Fourier Circular + Quantitativo	22	97.33 (\pm 0.04)	100	22	95.79 (\pm 0.05)
CITA	19	74.33 (\pm 0.12)	100	21	74.11 (\pm 0.12)
CITA + Quantitativo	22	84.67 (\pm 0.09)	100	24	84.14 (\pm 0.09)
LBP	29	70.00 (\pm 0.13)	67	33	72.49 (\pm 0.13)
LBP + Quantitativo	32	80.67 (\pm 0.11)	100	36	81.88 (\pm 0.10)
Quantitativo (Densidade + Comprimento + Largura)	3	61.33 (\pm 0.15)	100	3	57.61 (\pm 0.15)

Tabela 14 – Taxa de acerto para classificação de 32 espécies de plantas. Os resultados são descritos por meio do número de componentes PCA (#), taxa de acerto e desvio padrão (std) utilizando Fourier, CITA e LBP como descritores de textura e k-NN como classificador. A primeira parte dos resultados mostra a taxa de acerto para as 300 imagens, em que as amostras de *Tapirira guianensis* são provenientes somente de mata de galeria. A segunda parte mostra os resultados para 309 imagens, com nove amostras de *Tapirira guianensis* provenientes de vereda. Estes dois resultados fazem uma comparação da taxa de acerto com amostras de uma espécie que cresceu em diferentes ambientes. A taxa de acerto para identificação da espécie *Tapirira guianensis* é mostrada na coluna '% T. g.' para 300 e 309 imagens.

lado, com a análise de padrões heterogêneos utilizando o método CITA, uma taxa de acerto superior a 74% foi atingida. CITA considera as regiões, tais como tecido da epiderme e regiões dentro da estrutura do estômato, cujos valores são similares, como pertencentes a uma superfície local e tenta manter estas regiões ao longo das iterações. Ao mesmo tempo, tenta erodir regiões com diferenças abruptas permitindo a análise da estrutura da epiderme. Assim, CITA atinge um resultado razoável na identificação de espécies de plantas. LBP considera o comportamento da vizinhança de um pixel central verificando se os valores são maiores ou menores do que o pixel central, alcançando uma taxa de 70% de acerto.

Diferenças notáveis podem ser observadas ao comparar metodologias computacionais baseadas na textura e na abordagem convencional usando medições manuais. Os métodos baseados em diferentes características de textura foram mais eficientes em identificar as espécies que apenas os dados quantitativos, os quais são mais laboriosos para obtê-los. Descritores de textura são capazes de identificar espécies de plantas, mesmo quando há plasticidade nas medições quantitativas das estruturas epidérmicas. Estes valores quantitativos podem mudar de acordo com o ambiente, no entanto, a informação de textura se mantém concisa. A análise usando medições manuais considera apenas a forma e a densidade dos estômatos, enquanto que a análise de textura considera orientação espacial e arranjo geométrico de estômatos, além de suas características quantitativas. Além disso, como o método de identificação baseado em textura utiliza toda a imagem da epiderme, os estômatos não são segmentados, padrões de tecidos da epiderme e, assim, também outras estruturas que podem ocorrer em algumas espécies, tais como os tricomas, também são consideradas. A combinação de todas estas características permite uma

análise rica, capaz de fornecer uma identidade forte e única para diferentes espécies de plantas.



CONCLUSÕES

Neste trabalho, padrões heterogêneos de textura foram investigados com o intuito de melhorar a análise de conjuntos de imagens que apresentam padrões heterogêneos de textura em sua composição. Como resultado três abordagens foram desenvolvidas: (i) *lazy-patch*, (ii) combinação de modelos e (iii) modelagem da textura por meio de autômatos celulares inspirados em corrosão alveolar. As comparações das abordagens homogênea e heterogênea, utilizando o mesmo descritor de textura, mostraram que para bases de textura heterogêneas, os resultados podem melhorar significativamente. Ou seja, dado um conjunto de imagens que apresente padrões heterogêneos de textura em sua composição e, dado um descritor de características de textura, se esse descritor for utilizado seguindo a abordagem de padrões heterogêneos, os resultados serão melhores do que utilizar esse descritor de maneira global.

Três problemas foram apresentados como forma de aplicação das metodologias propostas: análise de imagens de FEG-SEM de óxido de titânio anódico galvanostático para classificação de oito experimentos; imagens de cortes transversal, tangencial e radial de madeira para identificação de 77 espécies de madeira da República Democrática do Congo e imagens da epiderme dissociada de folhas para identificar 32 espécies de plantas do cerrado brasileiro. Em todas essas aplicações a análise de padrões heterogêneos de textura pôde dar sua contribuição para a área. Nos dois primeiros casos, tornando possível uma melhor classificação das amostras e no último caso, não foi possível atingir o melhor resultado, no entanto, permitiu uma taxa maior do que 70% de identificação das amostras.

Portanto, a análise de padrões heterogêneos em imagens de textura é capaz de classificar, com melhor acurácia que a abordagem homogênea, clássica na literatura, conjuntos de imagens que apresentam diferentes padrões de textura em sua composição. Entretanto, este método apresenta uma lacuna, para os casos em que em um conjunto de imagens, uma ou mais imagens possuem diferente número de padrões de textura. Até o momento as metodologias desenvolvidas contemplam apenas conjuntos de imagens que possuem o mesmo número de padrões. Acredita-se

que se o número de padrões a ser considerado em cada imagem puder ser variável e independente por imagem, as taxas de acerto seriam ainda maiores.

7.1 Artigos gerados durante o doutorado

A elaboração de artigos científicos foi realizada de forma contínua durante todo o doutorado. A seguir são apresentadas as publicações geradas até o presente momento e os artigos em fase de submissão.

7.1.1 Publicações

- Silva, N. R., Florindo, J. B., Gómez, M. C., Rossatto, D. R., Kolb, R. M. and Bruno, O. M. Plant identification based on leaf midrib cross-section images using fractal descriptors. *PLoS One*. 2015; 10(6): e0130014
- Oliveira, M. W. S., Silva, N. R., Manzanera, A. and Bruno, O. M. Feature extraction on local jet space for texture classification. *Physica A: Statistical Mechanics and its Applications*, (In Press) 2015.
- Silva, N. R., Der Ween, P. V., Baets, B. D. and Bruno, O. M. Improved texture image classification through the use of a corrosion-inspired cellular automaton. *Neurocomputing* 149, Part C 1560–1572, 2015.
- Florindo, J. B., Silva, N. R.; Romualdo, L. M., Silva, F. F.; Luz, P. H. C., Herling, V. R. and Bruno, O. M. Brachiaria species identification using imaging techniques based on fractal descriptors. *Computers and Electronics in Agriculture*, v. 103, p. 48–54, 2014.
- Silva, N. R., Florindo, J. B., Gómez, M. C., Kolb, R. M., and Bruno, O. M., Fractal descriptors for discrimination of microscopy images of plant leaves, *Journal of Physics. Conference Series (Online)*, vol. 490, no. 1, p. 012085, 2014.
- Assirati, L., Silva, N. R., Berton, L., Lopes, A. A., and Bruno, O. M., Performing edge detection by difference of gaussians using q -gaussian kernels, *Journal of Physics. Conference Series (Online)*, vol. 490, no. 1, p. 012020, 2014.
- Assirati, L., Silva, N. R., and Bruno, O. M., Improving texture classification with nonextensive statistical mechanics, in *Anais do X Workshop de Visão Computacional*, 2014.
- Oliveira, M. W. S., Silva, N. R., Casanova, D., Pinheiro, L. F. S., Kolb, R. M., and Bruno, O. M., Automatic counting of stomata in epidermis microscopic images, in *Anais do X Workshop de Visão Computacional*, 2014.

- Silva, N. R. and Bruno, O. M., Heterogeneous patterns enhancing static and dynamic texture classification, *Journal of Physics. Conference Series (Online)*, vol. 410, no. 1, p. 012033, 2013.
- Silva, N. R. and Bruno, O. M., Analysis of multi-scale fractal dimension to classify human motion, in *Anais do VIII Workshop de Visão Computacional*, 2012.

7.1.2 Artigos Submetidos

- Wesley N Gonçalves, Núbia R Silva, Luciano F Costa and Odemir M Bruno, Texture recognition based on diffusion in networks. *Information Sciences*.
Data da submissão: 29/07/2015.
- Silva, N. R., Florindo, J. B., Oliveira, M. W. S., Almeida Filho, H. A., Pinheiro, L. F. S., Rossatto, D. R., Kolb, R. M. and Bruno, O. M. Leaf epidermal images for robust identification of plants. *Scientific Reports*.
Data da submissão: 30/09/2015.
- Silva, N. R., Oliveira, M. W. S., Baetens, J. M., Baets, B. D. and Bruno, O. M. Classification of cellular automata through texture analysis. *Information Sciences*.
Data da submissão: 09/10/2015.

7.1.3 Artigos em Fase de Submissão

- Silva, N. R., Ridder, M. D., Baetens, J., den Bulcke, J. V., Rousseau, M., Bruno, O. M., Beeckman, H., Acker, J. V., and Baets, B. D., Automated identification of commercial wood species based on transversal cross section imagery, *Annals of Botany*.
- Silva, N. R., Verwaeren, J. , Baetens, J., den Bulcke, J. V., Ridder, M. D., Rousseau, M., Bruno, O. M., Beeckman, H., Acker, J. V., and Baets, B. D., Wood species identification using a combined random forests model based on transversal, tangential and radial cross sections imagery, *Pattern Recognition*.
- Silva, N. R., Florindo, J. B., Pereira, E. C., and Bruno, O. M., Analysis of complex morphology characteristics by texture heterogeneous patterns for classification of nanostructured material images.

REFERÊNCIAS

- ABRAMOFF, M. D.; MAGALHAES, P. J.; RAM, S. J. R. Image processing with imagej. **Biophotonics International**, v. 11, p. 36–42, 2004. Citado na página [84](#).
- AHA, D. W.; KIBLER, D.; ALBERT, M. K. Instance-based learning algorithms. **Mach. Learn.**, Kluwer Academic Publishers, Hingham, MA, USA, v. 6, n. 1, p. 37–66, jan. 1991. ISSN 0885-6125. Citado na página [104](#).
- ALVAREZ, S.; SALVATELLA, A.; VANRELL, M.; OTAZU, X. 3d texton spaces for color-texture retrieval. In: CAMPILHO, A.; KAMEL, M. (Ed.). **Image Analysis and Recognition**. [S.I.]: Springer Berlin / Heidelberg, 2010, (Lecture Notes in Computer Science, v. 6111). p. 354–363. ISBN 978-3-642-13771-6. Citado na página [32](#).
- ALVAREZ, S.; VANRELL, M. Texton theory revisited: A bag-of-words approach to combine textons. **Pattern Recognition**, v. 45, n. 12, p. 4312–4325, 2012. ISSN 0031-3203. Citado 3 vezes nas páginas [32](#), [33](#) e [34](#).
- ANNAMPEDU, V.; WAGH, M. D. Reconfigurable approximate pattern matching architectures for nanotechnology. **Microelectronics Journal**, v. 38, n. 3, p. 430 – 438, 2007. ISSN 0026-2692. Citado na página [21](#).
- ARCHIBOLD, O. W. *et al.* **Ecology of world vegetation**. [S.I.]: Chapman & Hall Ltd, 1995. Citado na página [99](#).
- AZENCOTT, R.; WANG, J.-P.; YOUNES, L. Texture classification using windowed fourier filters. **Pattern Analysis and Machine Intelligence, IEEE Transactions on**, v. 19, n. 2, p. 148 –153, feb 1997. ISSN 0162-8828. Citado 4 vezes nas páginas [51](#), [73](#), [75](#) e [101](#).
- B, D. Plant collections get pruned back: North america's herbaria wilt under budget pressure. **Nature**, v. 523, p. 16, 2015. Citado na página [91](#).
- BACKES, A. R.; CASANOVA, D.; BRUNO, O. M. Plant leaf identification based on volumetric fractal dimension. **International Journal of Pattern Recognition and Artificial Intelligence**, v. 23, n. 6, p. 1145–1160, 2009. Citado na página [100](#).
- BACKES, A. R.; CASANOVA, D.; BRUNO, O. M.. Color texture analysis based on fractal descriptors. **Pattern Recognition**, v. 45, n. 5, p. 1984–1992, 2012. ISSN 0031-3203. Citado 4 vezes nas páginas [15](#), [69](#), [70](#) e [72](#).
- BAETENS, J. M.; Van der Weeën, P.; De Baets, B. Effects of asynchronous updating in cellular automata. **Chaos, Solitons & Fractals**, v. 45, p. 383–394, 2012. Citado na página [63](#).
- BATTIATO, S.; FARINELLA, G.; GALLO, G.; RAVI, D. Scene categorization using bag of textons on spatial hierarchy. In: **Image Processing, 2008. ICIP 2008. 15th IEEE International Conference on**. [S.I.: s.n.], 2008. p. 2536 –2539. ISSN 1522-4880. Citado 2 vezes nas páginas [32](#) e [34](#).

BATTIATO, S.; FARINELLA, G. M.; GUARNERA, G. C.; MECCIO, T.; PUGLISI, G.; RAVÌ, D.; RIZZO, R. Bags of phrases with codebooks alignment for near duplicate image detection. In: **Proceedings of the 2nd ACM workshop on Multimedia in forensics, security and intelligence**. New York, NY, USA: ACM, 2010. (MiFor '10), p. 65–70. ISBN 978-1-4503-0157-2. Citado na página 34.

BENARY, W. **The Influence of form on Brightness Contrast**. [S.l.]: W. D. Ellis (Ed.), A Sourcebook of Gestalt Psychology, 1938. 104-108 p. Citado na página 27.

BEREC, L. Techniques of spatially explicit individual-based models: construction, simulation and mean-field analysis. **Ecological Modelling**, v. 150, p. 55–81, 2002. Citado na página 61.

BIERAS, A. C.; SAJO, M. das G. Leaf structure of the cerrado (Brazilian savanna) woody plants. **Trees-structure and Function**, v. 23, p. 451–471, 2009. Citado na página 100.

BOVIK, A. Analysis of multichannel narrow-band filters for image texture segmentation. **Signal Processing, IEEE Transactions on**, v. 39, n. 9, p. 2025–2043, Sep 1991. ISSN 1053-587X. Citado 2 vezes nas páginas 21 e 25.

BOVIK, A.; CLARK, M.; GEISLER, W. Multichannel texture analysis using localized spatial filters. **Pattern Analysis and Machine Intelligence, IEEE Transactions on**, v. 12, n. 1, p. 55–73, Jan 1990. ISSN 0162-8828. Citado 2 vezes nas páginas 21 e 25.

BREIMAN, L. **Out-of-bag estimation**. <https://www.stat.berkeley.edu/~breiman/OOBestimation.pdf>: [s.n.], 1996. Citado na página 95.

BREIMAN, L. Random forests. **Machine Learning**, Kluwer Academic Publishers, v. 45, n. 1, p. 5–32, 2001. ISSN 0885-6125. Citado na página 56.

BREMANANTH, R.; NITHYA, B.; SAIPRIYA, R. Wood species recognition system. **World Academy of Science Engineering and Technology**, v. 52, n. 128, p. 873–879, 2009. Citado na página 91.

BRIDSON, D.; FORMAN, L.; GARDENS, K. R. B. **The Herbarium Handbook**. [S.l.]: Royal Botanic Gardens, 1998. ISBN 9781900347433. Citado na página 100.

BRODATZ, P. Book. **Textures; a photographic album for artists and designers**. [S.l.]: Dover Publications New York,, 1966. xiv, 112 p. (chiefly illus.) p. ISBN 0486216691. Citado 4 vezes nas páginas 15, 69, 70 e 71.

BURGHOUTS, G. J.; GEUSEBROEK, J. M. Color textons for texture recognition. In: **British Machine Vision Conference**. [S.l.: s.n.], 2006. v. 3, p. 1099–1108. Citado na página 32.

BURGHOUTS, G. J.; GEUSEBROEK, J. M. Material-specific adaptation of color invariant features. **Pattern Recognition Letters**, v. 30, p. 306–313, 2009. Citado na página 32.

CAICEDO, J.; CRUZ, A.; GONZALEZ, F. Histopathology image classification using bag of features and kernel functions. In: COMBI, C.; SHAHAR, Y.; ABU-HANNA, A. (Ed.). **Artificial Intelligence in Medicine**. [S.l.]: Springer Berlin / Heidelberg, 2009, (Lecture Notes in Computer Science, v. 5651). p. 126–135. ISBN 978-3-642-02975-2. Citado na página 33.

CANALS, V.; MORRO, A.; ROSSELLÓ, J. L. Stochastic-based pattern-recognition analysis. **Pattern Recognition Letters**, v. 31, n. 15, p. 2353–2356, 2010. ISSN 0167-8655. Citado na página 21.

- CASANOVA, D.; JUNIOR, J. J. de M. S.; BRUNO, O. M. Plant leaf identification using gabor wavelets. **International Journal of Imaging Systems and Technology**, v. 19, n. 3, p. 236–243, 2009. Citado na página [100](#).
- CAVALIN, P. R.; KAPP, M. N.; MARTINS, J.; OLIVEIRA, L. E. S. A multiple feature vector framework for forest species recognition. In: **Proceedings of the 28th Annual ACM Symposium on Applied Computing**. New York, NY, USA: ACM, 2013. (SAC '13), p. 16–20. ISBN 978-1-4503-1656-9. Citado 2 vezes nas páginas [91](#) e [92](#).
- C.J.D.M.; VERHAGEN. Some general remarks about pattern recognition; its definition; its relation with other disciplines; a literature survey. **Pattern Recognition**, v. 7, n. 3, p. 109–116, 1975. ISSN 0031-3203. Citado na página [21](#).
- COGGINS, J. M.; JAIN, A. K. A spatial filtering approach to texture analysis. **Pattern Recognition Letters**, v. 3, n. 3, p. 195 – 203, 1985. ISSN 0167-8655. Citado 2 vezes nas páginas [21](#) e [25](#).
- COSGRIFF, R. L. **Identification of Shape**. 1960. Ohio State University Research Foundation, Columbus, Rep. 820-11,. ASTIA AD 254 792. Citado na página [101](#).
- CROSIER, M.; GRIFFIN, L. Using basic image features for texture classification. **International Journal of Computer Vision**, Springer Netherlands, v. 88, p. 447–460, 2010. ISSN 0920-5691. Citado 2 vezes nas páginas [33](#) e [34](#).
- CRUZ-ROA, A.; CAICEDO, J. C.; GONZÁLEZ, F. A. Visual pattern mining in histology image collections using bag of features. **Artificial Intelligence in Medicine**, v. 52, n. 2, p. 91–106, 2011. ISSN 0933-3657. Citado na página [34](#).
- CSURKA, G.; DANCE, C. R.; FAN, L.; WILLAMOWSKI, J.; BRAY, C. Visual categorization with bags of keypoints. In: **In Workshop on Statistical Learning in Computer Vision, ECCV**. [S.l.: s.n.], 2004. p. 1–22. Citado na página [34](#).
- CUI, K. peng; ZHAI, X. rui; WANG, H. jun. A survey on wood recognition using machine vision. **Advances in Forestry Letters**, v. 2, n. 4, December 2013. Citado na página [91](#).
- DAGBERT, M.; PERTSOWSKY, R.; DAVID, M.; PERRAULT, G. Agpaicity revisited: pattern recognition in the chemistry of nepheline syenite rocks. **Geochimica et Cosmochimica Acta**, v. 39, n. 11, p. 1499 – 1504, 1975. ISSN 0016-7037. Citado na página [21](#).
- DAHME, G.; RIBEIRO, E.; BUSH, M. Spatial statistics of textons. In: **International Conference of Computer Vision Theory and Applications - VISAPP**. Setubal, Portugal: [s.n.], 2006. Citado na página [31](#).
- DAUGMAN, J.; DOWNING, C. Gabor wavelets and statistical pattern recognition. In: ARBIB, M. A. (Ed.). **The handbook of brain theory and neural networks**. Cambridge, MA, USA: MIT Press, 1998. cap. Gabor wavelets for statistical pattern recognition, p. 414–420. ISBN 0-262-51102-9. Citado 4 vezes nas páginas [51](#), [73](#), [75](#) e [85](#).
- DUDA, R. O.; HART, P. E. **Pattern Classification and Scene Analysis**. 1. ed. [S.l.]: John Wiley & Sons Inc, 1973. Hardcover. ISBN 0471223611. Citado 6 vezes nas páginas [31](#), [44](#), [46](#), [48](#), [85](#) e [88](#).

DUNN, M. M.; WOOLLISCROFT, J. O. Assessment of a surgical pattern recognition examination. **The American Journal of Surgery**, v. 169, n. 3, p. 341 – 343, 1995. ISSN 0002-9610. Citado na página [21](#).

EFROS, A. A.; LEUNG, T. K. Texture synthesis by non-parametric sampling. In: **Proceedings of the International Conference on Computer Vision-Volume 2 - Volume 2**. Washington, DC, USA: IEEE Computer Society, 1999. (ICCV '99), p. 1033–. ISBN 0-7695-0164-8. Citado na página [37](#).

El Yacoubi, S.; El Jai, A. Cellular automata and spreadability. **Mathematical and Computer Modelling**, v. 36, p. 1059–1074, 2002. Citado na página [61](#).

ESTE, A.; GRINGOLI, F.; SALGARELLI, L. Support vector machines for tcp traffic classification. **Comput. Netw.**, Elsevier North-Holland, Inc., New York, NY, USA, v. 53, p. 2476–2490, September 2009. ISSN 1389-1286. Citado 2 vezes nas páginas [21](#) e [44](#).

EVERT, R.; EICHHORN, S. **Esau's Plant Anatomy: Meristems, Cells, and Tissues of the Plant Body: Their Structure, Function, and Development**. [S.l.]: Wiley, 2006. ISBN 9780471738435. Citado na página [100](#).

FAUGERAS, O. D.; PRATT, W. K. Decorrelation methods of texture feature extraction. **Pattern Analysis and Machine Intelligence, IEEE Transactions on**, PAMI-2, n. 4, p. 323–332, July 1980. ISSN 0162-8828. Citado 2 vezes nas páginas [21](#) e [25](#).

FEI-FEI, L.; PERONA, P. A bayesian hierarchical model for learning natural scene categories. In: **IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2005**. [S.l.: s.n.], 2005. v. 2, p. 524–531. ISSN 1063-6919. Citado na página [32](#).

FERNÁNDEZ, A.; ÁLVAREZ, M.; BIANCONI, F. Texture description through histograms of equivalent patterns. **Journal of Mathematical Imaging and Vision**, Springer US, v. 45, n. 1, p. 76–102, 2013. ISSN 0924-9907. Citado na página [35](#).

FIELD, C. B.; BEHRENFELD, M. J.; RANDERSON, J. T.; FALKOWSKI, P. Primary production of the biosphere: integrating terrestrial and oceanic components. **Science**, American Association for the Advancement of Science, v. 281, n. 5374, p. 237–240, 1998. Citado na página [99](#).

FILHO, P. L. P.; OLIVEIRA, L. S.; NISGOSKI, S.; BRITTO ALCEU S., J. Forest species recognition using macroscopic images. **Machine Vision and Applications**, Springer Berlin Heidelberg, v. 25, n. 4, p. 1019–1031, 2014. ISSN 0932-8092. Citado 2 vezes nas páginas [91](#) e [92](#).

FLORINDO, J.; SIKORA, M.; PEREIRA, E.; BRUNO, O. Multiscale fractal descriptors applied to nanoscale images. **Journal of Superconductivity and Novel Magnetism**, Springer US, v. 26, n. 7, p. 2479–2484, 2013. ISSN 1557-1939. Citado 2 vezes nas páginas [84](#) e [85](#).

FLORINDO, J. B.; SIKORA, M. S.; PEREIRA, E. C.; BRUNO, O. M. Characterization of nanostructured material images using fractal descriptors. **Physica A: Statistical Mechanics and its Applications**, v. 392, n. 7, p. 1694 – 1701, 2013. ISSN 0378-4371. Citado 2 vezes nas páginas [84](#) e [85](#).

FLORINDO, J. B.; SILVA, N. R. da; ROMUALDO, L. M.; SILVA, F. de Fátima da; LUZ, P. H. de C.; HERLING, V. R.; BRUNO, O. M. *Brachiaria* species identification using imaging techniques based on fractal descriptors. **Computers and Electronics in Agriculture**, v. 103, n. 0, p. 48 – 54, 2014. ISSN 0168-1699. Citado na página [100](#).

- FRANKLIN, G. L. Preparation of thin sections of synthetic resins and wood-resin composites, and a new macerating method for wood [10]. **Nature**, v. 155, n. 3924, p. 51, 1945. Citado na página 101.
- GABOR, D. Theory of communication. **J. IEE**, v. 93, n. 26, p. 429–457, nov. 1946. Citado 2 vezes nas páginas 21 e 25.
- GALARO, J.; JUDKINS, A.; ELLISON, D.; BACCON, J.; MADABHUSHI, A. An integrated texton and bag of words classifier for identifying anaplastic medulloblastomas. In: **IEEE International Conference of Engineering in Medicine and Biology Society (EMBS)**. [S.l.: s.n.], 2011. p. 3443 –3446. ISSN 1557-170X. Citado na página 34.
- GALAS, D. J.; EGGERT, M.; WATERMAN, M. S. Rigorous pattern-recognition methods for dna sequences: Analysis of promoter sequences from escherichia coli. **Journal of Molecular Biology**, v. 186, n. 1, p. 117 – 128, 1985. ISSN 0022-2836. Citado na página 21.
- GARNER, W. R.; LEE, W. An analysis of redundancy in perceptual discrimination monograph supplement 4-v15. **Perceptual and Motor Skills**, Ammons Scientific, v. 15, n. 2, p. 367–388, 2015/07/29 1962. Citado na página 26.
- GOLES, E.; MARTÍNEZ, S. **Cellular Automata and Complex Systems**. [S.l.]: Springer Netherlands, 1998. (Nonlinear Phenomena and Complex Systems). ISBN 9780792355120. Citado na página 60.
- GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. 3rd. ed. [S.l.]: Addison-Wesley, 1992. Citado na página 28.
- GONZALEZ, R. C.; WOODS, R. E. 2nd edition. ed. [S.l.]: Tom Robbins, 2002. Hardcover. ISBN 0201180758. Citado 3 vezes nas páginas 21, 25 e 30.
- GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing (3rd Edition)**. Upper Saddle River, NJ, USA: Prentice-Hall, Inc., 2006. ISBN 013168728X. Citado 4 vezes nas páginas 51, 73, 75 e 101.
- GOTTSBERGER, G.; SILBERBAUER-GOTTSBERGER, I. **Life in the Cerrado: Origin, structure, dynamics and plant use**. [S.l.]: Reta Verlag, 2006. (Life in the Cerrado). ISBN 9783000179280. Citado na página 100.
- GRUBBS, F. E. Procedures for detecting outlying observations in samples. **Technometrics**, v. 11, p. 1–21, 1969. Citado na página 51.
- GUANG-SHENG, C.; PENG, Z. Wood cell recognition using geodesic active contour and principal component analysis. **Optik - International Journal for Light and Electron Optics**, v. 124, n. 10, p. 949 – 952, 2013. ISSN 0030-4026. Citado 2 vezes nas páginas 91 e 92.
- GUO, Z.; LI, Q.; ZHANG, L.; YOU, J.; LIU, W.; WANG, J. Texture image classification using complex texton. In: **Proceedings of the 7th international conference on Advanced Intelligent Computing Theories and Applications: with aspects of artificial intelligence**. Berlin, Heidelberg: Springer-Verlag, 2012. (ICIC'11), p. 98–104. ISBN 978-3-642-25943-2. Citado na página 31.
- GUO, Z.; ZHANG, L.; ZHANG, D. Rotation invariant texture classification using lbp variance (lbpv) with global matching. **Pattern Recognition**, Elsevier Science Inc., New York, NY, USA, v. 43, n. 3, p. 706–719, mar. 2010. ISSN 0031-3203. Citado 2 vezes nas páginas 74 e 75.

GURAU, L.; TIMAR, M. C.; POROJAN, M.; IORAS, F. Image processing method as a supporting tool for wood species identification. **Wood and fiber science**, v. 45, n. 3, p. 303–313, July 2013. Citado 2 vezes nas páginas [91](#) e [92](#).

HÁJEK, M.; BENOIT-CATTIN, H. **Texture Analysis for Magnetic Resonance Imaging**. [S.l.]: Med4publishing, 2006. ISBN 9788090366008. Citado na página [26](#).

HALL, E. L.; KRUGER, R.; DWYER, S.; HALL, D.; MCLAREN, R.; LODWICK, G. A survey of preprocessing and feature extraction techniques for radiographic images. **Computers, IEEE Transactions on**, C-20, n. 9, p. 1032–1044, Sept 1971. ISSN 0018-9340. Citado 2 vezes nas páginas [21](#) e [25](#).

HARALICK, R. M. Statistical and structural approaches to texture. **Proceedings of the IEEE**, IEEE, v. 67, n. 5, p. 786–804, maio 1979. ISSN 0018-9219. Citado 7 vezes nas páginas [21](#), [25](#), [26](#), [28](#), [51](#), [73](#) e [85](#).

HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. **Systems, Man and Cybernetics, IEEE Transactions on**, v. 3, n. 6, p. 610–621, nov. 1973. ISSN 0018-9472. Citado 4 vezes nas páginas [21](#), [25](#), [28](#) e [74](#).

HARMS, H.; GUNZER, U.; AUS, H. Combined local color and texture analysis of stained cells. **Computer Vision, Graphics, and Image Processing**, v. 33, n. 3, p. 364–376, 1986. ISSN 0734-189X. Citado na página [32](#).

HARTIGAN, J. **Clustering Algorithms**. New York: John Wiley & Sons Inc., 1975. Citado na página [46](#).

HARTIGAN, J. A.; WONG, M. A. Algorithm AS 136: A k-means clustering algorithm. **Applied Statistics**, Blackwell Publishing for the Royal Statistical Society, v. 28, n. 1, p. 100–108, 1979. ISSN 00359254. Citado na página [46](#).

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning**. New York, NY, USA: Springer New York Inc., 2001. (Springer Series in Statistics). Citado 6 vezes nas páginas [45](#), [46](#), [47](#), [57](#), [76](#) e [104](#).

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The elements of statistical learning. [S.l.]: Hastie, Tibshirani & Friedman, 2008. cap. Random Forests, p. 601–621. Citado na página [95](#).

HAWKINS, J. Picture processing and psychopictorics psychopictorics. [S.l.]: Academic Press, New York, 1969. cap. Textural properties for pattern recognition. Citado na página [25](#).

IDRISSA, M.; ACHEROY, M. Texture classification using gabor filters. **Pattern Recognition Letters**, v. 23, n. 9, p. 1095–1102, 2002. ISSN 0167-8655. Citado 4 vezes nas páginas [51](#), [73](#), [75](#) e [85](#).

ILEA, D. E.; WHELAN, P. F. Image segmentation based on the integration of colour-texture descriptors-a review. **Pattern Recogn.**, Elsevier Science Inc., New York, NY, USA, v. 44, p. 2479–2501, October 2011. ISSN 0031-3203. Citado na página [50](#).

ISASI, A. G.; ZAPIRAIN, B. G.; ZORRILLA, A. M. Melanomas non-invasive diagnosis application based on the abcd rule and pattern recognition image processing algorithms. **Computers in Biology and Medicine**, v. 41, n. 9, p. 742 – 755, 2011. ISSN 0010-4825. Citado na página [21](#).

- IVANCECIĆ, S. N. Stereometric pattern recognition by artificial touch. **Pattern Recognition**, v. 6, n. 2, p. 77 – 83, 1974. ISSN 0031-3203. Citado na página 21.
- J.; MANTAS. Methodologies in pattern recognition and image analysis - a brief survey. **Pattern Recognition**, v. 20, n. 1, p. 1–6, 1987. ISSN 0031-3203. Citado na página 21.
- JÄHNE, B.; HAUSSECKER, H.; GEISSLER, P. **Handbook of Computer Vision and Applications: Signal processing and pattern recognition**. [S.l.]: Academic Press, 1999. (Handbook of Computer Vision and Applications, v. 2). ISBN 9780123797728. Citado 2 vezes nas páginas 21 e 25.
- JOHANSEN, D. **Plant Microtechnique**. [S.l.]: McGraw-Hill, 1940. (McGraw-Hill publications in the botanical sciences). Citado na página 100.
- JOHNSON, R. A.; WICHERN, D. W. (Ed.). **Applied Multivariate Statistical Analysis**. Upper Saddle River, NJ, USA: Prentice-Hall, Inc., 1988. ISBN 0-130-41146-9. Citado 2 vezes nas páginas 46 e 57.
- JOLLIFFE, I. T. **Principal component analysis**. New York: Springer, 2002. ISBN 0387224408 9780387224404. Citado na página 101.
- JULESZ, B. Visual pattern discrimination. **Information Theory, IRE Transactions on**, v. 8, n. 2, p. 84–92, February 1962. ISSN 0096-1000. Citado na página 21.
- JULESZ, B. Textons, the elements of texture perception, and their interactions. **Nature**, v. 290, n. 5802, p. 91–97, 03 1981. Citado na página 30.
- JULESZ, B. Texton gradients: The texton theory revisited. **Biological Cybernetics**, Springer-Verlag, v. 54, n. 4-5, p. 245–251, 1986. ISSN 0340-1200. Citado 3 vezes nas páginas 26, 27 e 29.
- JUNIOR, J. J. d. M. S. **Identificação de espécies vegetais por meio de análise de imagens microscópicas de folhas**. Dissertação (Mestrado) — Universidade de São Paulo - Instituto de Ciências Matemáticas e de Computação, 2008. Citado 3 vezes nas páginas 13, 40 e 41.
- JUNIOR, J. J. d. M. S.; BACKES, A. R.; ROSSATTO, D. R.; KOLB, R. M.; BRUNO, O. M. Measuring and analyzing color and texture information in anatomical leaf cross sections: an approach using computer vision to aid plant species identification. **Botany**, v. 89, n. 7, p. 467–479, 2011. Citado 2 vezes nas páginas 41 e 100.
- K.; VARMUZA. Pattern recognition in analytical chemistry. **Analytica Chimica Acta**, v. 122, n. 3, p. 227 – 240, 1980. ISSN 0003-2670. Citado na página 21.
- KEDDY, P. A. **Plants and vegetation**. [S.l.]: Cambridge University Press, 2006. Citado na página 99.
- KHAIRUDDIN, A. S. M.; KHALID, M.; YUSOF, R. Using two stage classification for improved tropical wood species recognition system. In: TSIHRINTZIS, G.; VIRVOU, M.; JAIN, L.; HOWLETT, R. (Ed.). **Intelligent Interactive Multimedia Systems and Services**. [S.l.]: Springer Berlin Heidelberg, 2011, (Smart Innovation, Systems and Technologies, v. 11). p. 305–314. ISBN 978-3-642-22157-6. Citado 2 vezes nas páginas 91 e 92.

KHALID, M.; RUBIYAH YUSOF; ANISSALWAMOHDKHAIRUDDIN. Improved tropical wood species recognition system based on multi-feature extractor and classifier. *World Academy of Science, Engineering and Technology*, v. 5, n. 11, p. 1082 – 1088, 2011. ISSN 1307-6892. Citado 2 vezes nas páginas [91](#) e [92](#).

KHAN, F.; WEIJER, J. van de; VANRELL, M. Modulating shape features by color attention for object recognition. **International Journal of Computer Vision**, Springer Netherlands, v. 98, p. 49–64, 2012. ISSN 0920-5691. Citado na página [34](#).

KIM, D.; GHICOV, A.; ALBU, S. P.; SCHMUKI, P. Bamboo-type tio₂ nanotubes: Improved conversion efficiency in dye-sensitized solar cells. **Journal of American Chemical Society**, American Chemical Society, v. 130, n. 49, p. 16454–16455, 2008. Citado na página [83](#).

KIM, J. K.; PARK, H. W. Statistical textural features for detection of microcalcifications in digitized mammograms. **Medical Imaging, IEEE Transactions on**, v. 18, n. 3, p. 231–238, march 1999. ISSN 0278-0062. Citado 3 vezes nas páginas [73](#), [75](#) e [85](#).

KOFFKA, K. Perception: an introduction to the gestalt-theorie. **Psychological Bulletin**, v. 19, n. 10, p. 531–585, Oct 1922. Citado na página [26](#).

KOLTSOV, P. Comparative study of texture detection and classification algorithms. **Computational Mathematics and Mathematical Physics**, MAIK Nauka/Interperiodica distributed exclusively by Springer Science+Business Media LLC., v. 51, p. 1460–1466, 2011. ISSN 0965-5425. Citado 2 vezes nas páginas [21](#) e [25](#).

LANDEWEERD, G.; GELSEMA, E.; BINS, M.; HALIE, M. Interactive pattern recognition of blood cells in malignant lymphomas. **Pattern Recognition**, v. 14, n. 1-6, p. 239 – 244, 1981. ISSN 0031-3203. Citado na página [21](#).

LAVINE, B.; JURS, P.; HENRY, D.; MEER, R.; PINO, J.; MCMURRY, J. Pattern recognition studies of complex chromatographic data sets: Design and analysis of pattern recognition experiments. **Chemometrics and Intelligent Laboratory Systems**, v. 3, n. 1-2, p. 79 – 89, 1988. ISSN 0169-7439. Citado na página [21](#).

LAZEBNIK, S.; SCHMID, C.; PONCE, J. Beyond bags of features: Spatial pyramid matching for recognizing natural scene categories. In: **Proceedings of the 2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition**. Washington, DC, USA: IEEE Computer Society, 2006. (CVPR '06, v. 2), p. 2169–2178. ISBN 0-7695-2597-0. Citado na página [34](#).

LEE, D.-S.; JUNG, J.-K.; LIM, J.-W.; HUH, J.-S.; LEE, D.-D. Recognition of volatile organic compounds using sno₂ sensor array and pattern recognition analysis. **Sensors and Actuators B: Chemical**, v. 77, n. 1-2, p. 228 – 236, 2001. ISSN 0925-4005. Citado na página [21](#).

LEHMANN, C. E. R.; ANDERSON, T. M.; SANKARAN, M.; HIGGINS, S. I.; ARCHIBALD, S.; HOFFMANN, W. A.; HANAN, N. P.; WILLIAMS, R. J.; FENSHAM, R. J.; FELFILI, J.; HUTLEY, L. B.; RATNAM, J.; JOSE, J. S.; MONTES, R.; FRANKLIN, D.; RUSSELL-SMITH, J.; RYAN, C. M.; DURIGAN, G.; HIERNaux, P.; HAIDAR, R.; BOWMAN, D. M. J. S.; BOND, W. J. Savanna vegetation-fire-climate relationships differ among continents. **Science**, v. 343, n. 6170, p. 548–552, 2014. Citado na página [99](#).

- LENDARIS, G.; STANLEY, G. Diffraction-pattern sampling for automatic pattern recognition. **Proceedings of the IEEE**, v. 58, n. 2, p. 198–216, Feb 1970. ISSN 0018-9219. Citado 2 vezes nas páginas [21](#) e [25](#).
- LEPPANEN, T.; KARTTUNEN, M.; BARRIO, R.; KASKI, K. Turing systems as models of complex pattern formation. **Brazilian Journal of Physics**, scielo, v. 34, p. 368–372, 06 2004. ISSN 0103-9733. Citado na página [44](#).
- LEUNG, T. Texton correlation for recognition. In: PAJDLA, T.; MATAS, J. (Ed.). **Computer Vision - ECCV 2004**. [S.l.]: Springer Berlin / Heidelberg, 2004, (Lecture Notes in Computer Science, v. 3021). p. 203–214. ISBN 978-3-540-21984-2. Citado na página [31](#).
- LEUNG, T.; MALIK, J. Recognizing surfaces using three-dimensional textons. In: **Computer Vision, 1999. The Proceedings of the Seventh IEEE International Conference on**. [S.l.: s.n.], 1999. v. 2, p. 1010–1017. Citado 2 vezes nas páginas [30](#) e [31](#).
- LEUNG, T.; MALIK, J. Representing and recognizing the visual appearance of materials using three-dimensional textons. **International Journal of Computer Vision**, Kluwer Academic Publishers, Hingham, MA, USA, v. 43, n. 1, p. 29–44, jun. 2001. ISSN 0920-5691. Citado 3 vezes nas páginas [13](#), [30](#) e [32](#).
- LEVINE, H.; REYNOLDS, W. N. Coupled map lattice techniques for simulating interfacial phenomena in reaction-diffusion systems. **Chaos**, v. 2, p. 337–342, 1992. Citado na página [65](#).
- LISHCHUK, S. V.; AKID, R.; WORDEN, K.; MICHALSKI, J. A cellular automaton model for predicting intergranular corrosion. **Corrosion Science**, v. 53, p. 2518–2526, 2011. Citado na página [60](#).
- LIU, G.-H.; YANG, J.-Y. Image retrieval based on the texton co-occurrence matrix. **Pattern Recognition**, v. 41, n. 12, p. 3521–3527, 2008. ISSN 0031-3203. Citado na página [32](#).
- LIU, G.-H.; ZHANG, L.; HOU, Y.-K.; LI, Z.-Y.; YANG, J.-Y. Image retrieval based on multi-texton histogram. **Pattern Recognition**, v. 43, n. 7, p. 2380 – 2389, 2010. ISSN 0031-3203. Citado na página [32](#).
- LIU, J.; ZHANG, S.; DENG, S. A method of plant classification based on wavelet transforms and support vector machines. In: HUANG, D.-S.; JO, K.-H.; LEE, H.-H.; KANG, H.-J.; BEVILACQUA, V. (Ed.). **Emerging Intelligent Computing Technology and Applications**. [S.l.]: Springer Berlin Heidelberg, 2009, (Lecture Notes in Computer Science, v. 5754). p. 253–260. ISBN 978-3-642-04069-6. Citado na página [100](#).
- LIU, L.; FIEGUTH, P. Texture classification from random features. **Pattern Analysis and Machine Intelligence, IEEE Transactions on**, v. 34, n. 3, p. 574–586, March 2012. ISSN 0162-8828. Citado na página [29](#).
- LUZZATI, V.; TARDIEU, A.; TAUPIN, D. A pattern-recognition approach to the phase problem: Application to the x-ray diffraction study of biological membranes and model systems. **Journal of Molecular Biology**, v. 64, n. 1, p. 269 – 286, 1972. ISSN 0022-2836. Citado na página [21](#).
- MACQUEEN, J. Some methods for classification and analysis of multivariate observations. In: **Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, Volume 1: Statistics**. Berkeley, Calif.: University of California Press, 1967. p. 281–297. Citado na página [46](#).

- MALIK, J.; PERONA, P. Preattentive texture discrimination with early vision mechanism. **Journal of the Optical Society of America**, v. 7, n. 5, p. 923–932, 1990. Citado na página 27.
- MALKI, B.; BAROUX, B. Computer simulation of the corrosion pit growth. **Corrosion Science**, v. 47, p. 171–182, 2005. Citado na página 60.
- MALLIK, A.; TARRÍO-SAAVEDRA, J.; FRANCISCO-FERNÁNDEZ, M.; NAYA, S. Classification of wood micrographs by image segmentation. **Chemometrics and Intelligent Laboratory Systems**, v. 107, n. 2, p. 351 – 362, 2011. ISSN 0169-7439. Citado na página 91.
- MANDELBROT, B. B. **The Fractal Geometry of Nature**. [S.l.]: W. H. Freeman and Company, 1977. Citado na página 25.
- MANJUNATH, B.; MA, W. Texture features for browsing and retrieval of image data. **Pattern Analysis and Machine Intelligence, IEEE Transactions on**, v. 18, n. 8, p. 837–842, aug 1996. ISSN 0162-8828. Citado 4 vezes nas páginas 51, 73, 75 e 85.
- MARTINS, J.; OLIVEIRA, L.; NISGOSKI, S.; SABOURIN, R. A database for automatic classification of forest species. **Machine Vision and Applications**, Springer-Verlag, v. 24, n. 3, p. 567–578, 2013. ISSN 0932-8092. Citado 2 vezes nas páginas 91 e 92.
- MARTINS, J.; OLIVEIRA, L.; SABOURIN, R. Combining textural descriptors for forest species recognition. In: **IECON 2012 - 38th Annual Conference on IEEE Industrial Electronics Society**. [S.l.: s.n.], 2012. p. 1483–1488. ISSN 1553-572X. Citado 2 vezes nas páginas 91 e 92.
- MASUDA, H.; FUKUDA, K. Ordered Metal Nanohole Arrays Made by a Two-Step Replication of Honeycomb Structures of Anodic Alumina. **Science**, American Association for the Advancement of Science, v. 268, n. 5216, p. 1466–1468, 1995. Citado na página 83.
- MASUDA, H.; OHYA, M.; ASOH, H.; NAKAO, M.; NOHTOMI, M.; TAMAMURA, T. Photonic crystal using anodic porous alumina. **Japanese Journal of Applied Physics**, The Japan Society of Applied Physics, v. 38, n. Part 2, No. 12A, p. L1403–L1405, 1999. Citado na página 83.
- MATERKA, A.; STRZELECKI, M. **Texture Analysis Methods, A Review**. Brussels, 1998. Citado 2 vezes nas páginas 21 e 25.
- MAYBECK, V.; RÖPER, K. A targeted gain-of-function screen identifies genes affecting salivary gland morphogenesis/tubulogenesis in drosophila. **Genetics**, v. 181, n. 2, p. 543–565, 2009. Citado 2 vezes nas páginas 14 e 44.
- MEINHARDT, H. **Models of Biological Pattern Formation**. [S.l.]: Academic Press, 1982. v. 6. 1-211 p. Citado na página 44.
- MENDONÇA, R. C. *et al.* Flora vascular do cerrado: checklist com 12.356 espécies. In: SANO, S. M.; ALMEIDA, S. P.; RIBEIRO, J. F. (Ed.). **Cerrado: ecologia e flora**. [S.l.], 2008. p. 422–442. Citado na página 99.
- METCALFE, C. R.; CHALK, L. **Anatomy of the dicotyledons: volume 1. Systematic anatomy of leaf and stem, with a brief history of the subject**. [S.l.]: Oxford, Clarendon Press, 1979. Citado na página 100.
- MILNE, J.; FU, S. C. Epidemic modelling using cellular automata. In: **Proceedings of the 1st Australian Conference on Artificial Life**. [S.l.: s.n.], 2003. p. 43–57. Citado na página 60.

- MINGOTI, S. **Análise de dados através de métodos de estatística multivariada: uma abordagem aplicada.** [S.l.]: Editora UFMG, 2005. ISBN 9788570414519. Citado na página 47.
- MYERS, N. The biodiversity challenge: Expanded hot-spots analysis. **Environmentalist**, Kluwer Academic Publishers, v. 10, n. 4, p. 243–256, 1990. ISSN 0251-1088. Citado na página 100.
- NANNI, L.; BRAHNAM, S.; LUMINI, A. Random interest regions for object recognition based on texture descriptors and bag of features. **Expert Systems with Applications**, v. 39, n. 1, p. 973–977, 2012. ISSN 0957-4174. Citado na página 34.
- NATALE, C. D.; DAVIDE, F.; D'AMICO, A. Pattern recognition in gas sensing: well-stated techniques and advances. **Sensors and Actuators B: Chemical**, v. 23, n. 2-3, p. 111 – 118, 1995. ISSN 0925-4005. Citado na página 21.
- NECAS, D.; Klapetek, P. Gwyddion: an open-source software for SPM data analysis. **Central European Journal of Physics**, Versita, co-published with Springer-Verlag GmbH, v. 10, p. 181–188, 2012. ISSN 1895-1082. Citado na página 84.
- NETEA, M. G.; VEERDONK, F. L. van de; DEUREN, M. van; MEER, J. W. van der. Defects of pattern recognition: primary immunodeficiencies of the innate immune system. **Current Opinion in Pharmacology**, v. 11, n. 4, p. 412 – 422, 2011. ISSN 1471-4892. Citado na página 21.
- NOWAK, E.; JURIE, F.; TRIGGS, B. Sampling strategies for bag-of-features image classification. In: LEONARDIS, A.; BISCHOF, H.; PINZ, A. (Ed.). **European Conference on Computer Vision - ECCV 2006**. Graz, Austria: Springer, 2006. (Lecture Notes in Computer Science (LNCS), v. 3954), p. 490–503. Citado na página 34.
- OH, E. H.; SONG, H. S.; PARK, T. H. Recent advances in electronic and bioelectronic noses and their biomedical applications. **Enzyme and Microbial Technology**, v. 48, n. 6-7, p. 427 – 437, 2011. ISSN 0141-0229. Citado na página 21.
- OJALA, T.; MÄENPÄÄ, T.; PIETIKÄINEN, M.; VIERTOLA, J.; KYLLÖNEN, J.; HUOVINEN, S. Outex - new framework for empirical evaluation of texture analysis algorithms. In: **Proceedings of the 16 th International Conference on Pattern Recognition (ICPR'02) Volume 1 - Volume 1**. Washington, DC, USA: IEEE Computer Society, 2002. (ICPR '02), p. 10701. ISBN 0-7695-1695-X. Citado 4 vezes nas páginas 15, 69, 70 e 71.
- OJALA, T.; PIETIKÄINEN, M.; MÄENPÄÄ, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. **IEEE Transactions Pattern Analysis and Machine Intelligence**, IEEE Computer Society, Washington, DC, USA, v. 24, n. 7, p. 971–987, jul 2002. ISSN 0162-8828. Citado 3 vezes nas páginas 34, 74 e 101.
- OJANSIVU, V.; HEIKKIL'A, J. Blur insensitive texture classification using local phase quantization. In: ELMOATAZ, A.; LEZORAY, O.; NOUBOUD, F.; MAMMASS, D. (Ed.). **Image and Signal Processing**. [S.l.]: Springer Berlin Heidelberg, 2008, (Lecture Notes in Computer Science, v. 5099). p. 236–243. ISBN 978-3-540-69904-0. Citado na página 92.
- OJANSIVU, V.; RAHTU, E.; HEIKKIL'A, J. Rotation invariant local phase quantization for blur insensitive texture analysis. In: **Pattern Recognition, 2008. ICPR 2008. 19th International Conference on**. [S.l.: s.n.], 2008. p. 1–4. ISSN 1051-4651. Citado na página 92.

PAGET, R. Texture modelling and synthesis. **Handbook of Texture Analysis**. [S.l.: s.n.], 2008. cap. 2, p. 33–60. Citado 2 vezes nas páginas [25](#) e [36](#).

PARK, H.; BYUN, H.; KIM, C. Multi-exemplar inhomogeneous texture synthesis. **Computers & Graphics**, v. 37, n. 1-2, p. 54–64, 2013. ISSN 0097-8493. Citado na página [37](#).

PÉTERI, R.; FAZEKAS, S.; HUISKES, M. J. Dyntex: a comprehensive database of dynamic textures. **Pattern Recognition Letters**, v. 31, n. 12, p. 1627–1632, 2010. <Http://projects.cwi.nl/dyntex/>. Citado 4 vezes nas páginas [15](#), [69](#), [70](#) e [73](#).

PETROU, M.; SEVILLA, P. **Image processing: dealing with texture**. [S.l.]: John Wiley & Sons Inc., 2006. ISBN 9780470026281. Citado 4 vezes nas páginas [34](#), [36](#), [37](#) e [50](#).

PICIOREANU, C.; van Loosdrecht, M.; HEIJNEN, J. Mathematical modelling of biofilm structure with a hybrid differential-discrete cellular automaton approach. **Biotechnology and Bioengineering**, v. 58, p. 101–116, 1998. Citado na página [60](#).

PICKERING, H. W. The significance of the local electrode potential within pits, crevices and cracks. **Corrosion Science**, v. 29, p. 325–341, 1989. Citado na página [60](#).

PREZIOSI, L. **Modelling and Simulation**. [S.l.]: Chapman & Hall, Boca Raton, United States, 2003. Citado na página [60](#).

RAMIREZ, G.; DINIO, R. C.; PRIBOR, H. C. Pattern recognition of multiple tests values as a diagnostic tool. **Computers in Biology and Medicine**, v. 2, n. 1, p. 39 – 44, 1972. ISSN 0010-4825. Citado na página [21](#).

RAMOS, E.; FERNÁNDEZ, D. S. Classification of leaf epidermis microphotographs using texture features. **Ecological Informatics**, v. 4, n. 3, p. 177 – 181, 2009. ISSN 1574-9541. Citado na página [100](#).

RANDEN, T.; HUSØY, J. H. Filtering for texture classification: A comparative study. **IEEE Trans. Pattern Anal. Mach. Intell.**, IEEE Computer Society, Washington, DC, USA, v. 21, n. 4, p. 291–310, abr. 1999. ISSN 0162-8828. Citado 2 vezes nas páginas [21](#) e [25](#).

RASTOGI, R. Chapter 13 - complex pattern formation. In: **Introduction to Non-equilibrium Physical Chemistry**. Amsterdam: Elsevier, 2008. p. 235–V. ISBN 978-0-444-52188-0. Citado na página [44](#).

RATTER, J. A.; RIBEIRO, J. F.; BRIDGEWATER, S. The Brazilian Cerrado vegetation and threats to its biodiversity. **Annals of Botany**, v. 80, n. 3, p. 223–230, 1997. Citado na página [99](#).

REED, T.; DUBUF, J. A review of recent texture segmentation and feature extraction techniques. **CVGIP: Image Understanding**, v. 57, n. 3, p. 359 – 372, 1993. ISSN 1049-9660. Citado 2 vezes nas páginas [21](#) e [25](#).

ROBERGE, P. R. **Corrosion Engineering: Principles and Practice**. [S.l.]: McGraw-Hill Professional, 2008. Citado na página [60](#).

ROSENBERGER, A.; COHEN-OR, D.; LISCHINSKI, D. Layered shape synthesis: Automatic generation of control maps for non-stationary textures. **ACM Trans. Graph.**, ACM, New York, NY, USA, v. 28, n. 5, p. 107:1–107:9, dez. 2009. ISSN 0730-0301. Citado na página [36](#).

- ROSENFIELD, A. Automatic recognition of basic terrain types from aerial photographs. **PhEng**, v. 28, p. 639–646, March 1962. Citado 2 vezes nas páginas [21](#) e [25](#).
- ROSSATTO, D.; CASANOVA, D.; KOLB, R.; BRUNO, O. M. Fractal analysis of leaf-texture properties as a tool for taxonomic and identification purposes: a case study with species from neotropical Melastomataceae (Miconieae tribe). **Plant Systematics and Evolution**, v. 291, n. 1-2, p. 103–116, 2011. Citado na página [100](#).
- SCHIFF, J. **Cellular Automata: A Discrete View of the World**. [S.l.]: John Wiley & Sons Ltd., Chichester, United Kingdom, 2008. Citado na página [60](#).
- SHI, J.; MALIK, J. Normalized cuts and image segmentation. **IEEE Trans. Pattern Anal. Mach. Intell.**, v. 22, n. 8, p. 888–905, 2000. Citado na página [32](#).
- SHOTTON, J.; JOHNSON, M.; CIPOLLA, R. Semantic texton forests for image categorization and segmentation. In: **Computer Vision and Pattern Recognition, 2008. CVPR 2008. IEEE Conference on**. [S.l.: s.n.], 2008. p. 1 –8. ISSN 1063-6919. Citado 2 vezes nas páginas [32](#) e [33](#).
- SILVA, N. R. da; WEEËN, P. V. der; BAETS, B. D.; BRUNO, O. M. Improved texture image classification through the use of a corrosion-inspired cellular automaton. **Neurocomputing**, v. 149, Part C, n. 0, p. 1560 – 1572, 2015. ISSN 0925-2312. Citado 6 vezes nas páginas [14](#), [15](#), [60](#), [61](#), [67](#) e [101](#).
- SKLANSKY, J. Image segmentation and feature extraction. **Systems, Man and Cybernetics, IEEE Transactions on**, v. 8, n. 4, p. 237–247, April 1978. ISSN 0018-9472. Citado na página [26](#).
- SOUZA, F.; ALLEN, D.; KIM, Y.-R. Multiscale model for predicting damage evolution in composites due to impact loading. **Composites Science and Technology**, v. 68, n. 13, p. 2624–2634, 2008. ISSN 0266-3538. Citado na página [39](#).
- SOUZA, F. V.; ALLEN, D. H. Modeling the transition of microcracks into macrocracks in heterogeneous viscoelastic media using a two-way coupled multiscale model. **International Journal of Solids and Structures**, v. 48, n. 22-23, p. 3160–3175, 2011. ISSN 0020-7683. Citado 2 vezes nas páginas [13](#) e [39](#).
- SRINIVASAN, G.; SHOBHA, G. Statistical texture analysis. **Proceedings of world academy of science, engineering and technology**, v. 36, p. 1264–1269, 2008. Citado na página [26](#).
- STACE, C. A. **Plant taxonomy and biosystematics**. [S.l.]: Cambridge University Press, 1991. Citado na página [100](#).
- STALEY, D. D.; MATTA, M. S.; WATERMAN, E. L. **Chemistry**. [S.l.]: Pearson Prentice Hall, 2004. Citado na página [39](#).
- STEFANSKY, W. Rejecting outliers in factorial designs. **Technometrics**, v. 14, n. 2, p. 469–479, 1972. Citado na página [51](#).
- STEPPE, K.; CNUDDE, V.; GIRARD, C.; LEMEURA, R.; CNUDDE, J.; JACOBS, P. Use of x-ray computed microtomography for non-invasive determination of wood anatomical characteristics. **Journal of Structural Biology**, v. 148, n. 1, p. 11–21, 2004. Citado na página [91](#).

TAMURA, H.; MORI, S.; YAMAWAKI, T. Textural features corresponding to visual perception. **Systems, Man and Cybernetics, IEEE Transactions on**, v. 8, n. 6, p. 460–473, June 1978. ISSN 0018-9472. Citado 2 vezes nas páginas [25](#) e [35](#).

TOFFOLI, T. Cellular automata as an alternative to (rather than an approximation of) differential equations in modeling physics. **Physica D**, v. 10, p. 117–127, 1984. Citado na página [61](#).

TOMMASI, T.; ORABONA, F.; CAPUTO, B. Clef2007 image annotation task: an svm-based cue integration approach. In: **In Working Notes of the 2007 CLEF Workshop**. [S.l.: s.n.], 2007. Citado na página [34](#).

TROY, E.; ROSENFIELD, A.; DEUTSCH, E.; MARYLAND, C. P. C. V. L. University of; MARYLAND, C. P. C. S. C. University of. **Visual Texture Analysis**. [S.l.]: University of Maryland, Computer Science Center, 1970. (Report (University of Maryland, College Park. Computer Vision Laboratory), v. 3). Citado 2 vezes nas páginas [21](#) e [25](#).

TUCERYAN, M.; JAIN, A. K. The handbook of pattern recognition and computer vision. 2nd edition. ed. [S.l.]: World Scientific Publishing Company, 1998. cap. Texture Analysis, p. 207–248. Citado na página [25](#).

TURING, A. M. The chemical basis of morphogenesis. **Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences**, v. 237, n. 641, p. 37–72, 1952. Citado na página [44](#).

UNSER, M. Texture classification and segmentation using wavelet frames. **Image Processing, IEEE Transactions on**, v. 4, n. 11, p. 1549–1560, Nov 1995. ISSN 1057-7149. Citado 2 vezes nas páginas [21](#) e [25](#).

VA, F. A curator's perspective: The erosion of collections-based science: Alarming trend or coincidence? **The Plant Press**, v. 17, n. 4, p. 13–15, October 2014. Citado na página [91](#).

VALOIS, R. L. D.; ALBRECHT, D. G.; THORELL, L. G. Spatial frequency selectivity of cells in macaque visual cortex. **Vision Research**, v. 22, n. 5, p. 545 – 559, 1982. ISSN 0042-6989. Citado na página [27](#).

VAN DER WEEËN, P.; BAETENS, J. M.; VERWAEREN, J.; Van Doorslaer, X.; HEYN-DERICKX, P. M.; DEWULF, J.; De Baets, B. Modeling the photocatalytic degradation of moxifloxacin by means of a stochastic cellular automaton. **Chemical Engineering Journal**, v. 188, p. 181–190, 2012. Citado na página [60](#).

VAN DER WEEËN, P.; ZIMER, A. M.; PEREIRA, E. C.; MASCARO, L. H.; BRUNO, O. M.; BAETS, B. D. Modeling pitting corrosion by means of a 3d discrete stochastic model. **Corrosion Science**, v. 82, p. 133 – 144, 2014. ISSN 0010-938X. Citado na página [60](#).

VARMA, M.; ZISSERMAN, A. Texture classification: are filter banks necessary? In: **Computer Vision and Pattern Recognition, 2003. Proceedings. 2003 IEEE Computer Society Conference on**. [S.l.: s.n.], 2003. v. 2, p. II – 691–8. ISSN 1063-6919. Citado na página [32](#).

VARMA, M.; ZISSERMAN, A. A statistical approach to texture classification from single images. **Int. J. Comput. Vision**, Kluwer Academic Publishers, Hingham, MA, USA, v. 62, n. 1-2, p. 61–81, apr 2005. ISSN 0920-5691. Citado 2 vezes nas páginas [31](#) e [32](#).

- VARMA, M.; ZISSERMAN, A. A statistical approach to material classification using image patch exemplars. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 31, n. 11, p. 2032–2047, nov 2009. ISSN 0162-8828. Citado 4 vezes nas páginas 13, 31, 32 e 33.
- VASILKOSKI, Z.; WEAVER, C. D. A generator of protein folding kinetics states for the diffusion-collision model. **Journal of Computational Chemistry**, v. 21, p. 923–932, 2000. Citado na página 60.
- VISION Texture Database. 2009. Disponível em: <<http://vismod.media.mit.edu/vismod/imagery/VisionTexture/vistex.html>>. Citado 4 vezes nas páginas 15, 69, 70 e 72.
- WALTER, B. M. T. **Fitofisionomias do bioma Cerrado: síntese terminológica e relações florísticas**. Tese (Doutorado) — Universidade de Brasília, Brasilia, 2006. Citado na página 99.
- WANG, H.; SONG, B.; WANG, L.; LV, G. Three dimensional cellular automaton for simulation of the multi-pi corrosion damage evolution. **Advanced Science Letters**, v. 4, p. 2980–2985, 2011. Citado na página 60.
- WANG, H.; ZHANG, G.; QI, H. Wood recognition using image texture features. **PLoS ONE**, Public Library of Science, v. 8, n. 10, p. e76101, 10 2013. Citado na página 92.
- WANG, H.; QI, H.; WANG, X. A new gabor based approach for wood recognition. **Neurocomputing**, v. 116, n. 0, p. 192 – 200, 2013. ISSN 0925-2312. Advanced Theory and Methodology in Intelligent Computing Selected Papers from the Seventh International Conference on Intelligent Computing (ICIC 2011). Citado na página 92.
- WANG, X.-F.; HUANG, D.-S.; XU, H. An efficient local chan-vese model for image segmentation. **Pattern Recognition**, v. 43, n. 3, p. 603 – 618, 2010. ISSN 0031-3203. Citado na página 92.
- WECHSLER, H. Texture analysis – a survey. **Signal Processing**, v. 2, n. 3, p. 271–282, 1980. ISSN 0165-1684. Citado 3 vezes nas páginas 21, 25 e 26.
- WEI, L.-Y.; HAN, J.; ZHOU, K.; BAO, H.; GUO, B.; SHUM, H.-Y. Inverse texture synthesis. **ACM Trans. Graph.**, ACM, New York, NY, USA, v. 27, n. 3, p. 52:1–52:9, ago. 2008. ISSN 0730-0301. Citado na página 37.
- WEI, L.-Y.; LEVOY, M. Fast texture synthesis using tree-structured vector quantization. In: **Proceedings of the 27th Annual Conference on Computer Graphics and Interactive Techniques**. New York, NY, USA: ACM Press/Addison-Wesley Publishing Co., 2000. (SIGGRAPH '00), p. 479–488. ISBN 1-58113-208-5. Citado na página 37.
- WERTHEIMER, M. **Laws of organization in perceptual forms**. [S.l.]: W. D. Ellis (Ed.), A Sourcebook of Gestalt Psychology, 1938. 71-88 p. Citado na página 26.
- WESZKA, J. S.; DYER, C. R.; ROSENFIELD, A. A comparative study of texture measures for terrain classification. **IEEE Transactions on Systems, Man and Cybernetics**, SMC-6, n. 4, p. 269–285, april 1976. ISSN 0018-9472. Citado 3 vezes nas páginas 73, 75 e 85.
- WHEELER, E. A. Inside wood – a web resource for hardwood anatomy. **IAWA Journal**, v. 32, n. 2, p. 199–211, 2011. Citado na página 91.
- WILSON, R. A.; KEIL, F. C. (Ed.). **The MIT Encyclopedia of the Cognitive Sciences**. [S.l.]: The MIT Press, 1999. Citado na página 26.

WINN, J.; CRIMINISI, A.; MINKA, T. Object categorization by learned universal visual dictionary. In: **Computer Vision, 2005. ICCV 2005. Tenth IEEE International Conference on.** [S.l.: s.n.], 2005. v. 2, p. 1800–1807. ISSN 1550-5499. Citado na página [34](#).

WOLFRAM, S. Statistical mechanics of cellular automata. **Reviews of Modern Physics**, v. 55, p. 601–644, 1983. Citado na página [61](#).

YANAGISHITA, T.; NISHIO, K.; NAKAO, M.; FUJISHIMA, A.; MASUDA, H. Synthesis of diamond cylinders with triangular and square cross sections using anodic porous alumina templates. **Chemistry Letters**, v. 31, n. 10, p. 976–977, 2002. Citado na página [83](#).

YU, H.; CAO, J.; LUO, W.; LIU, Y. Image retrieval of wood species by color, texture, and spatial information. In: **Information and Automation, 2009. ICIA '09. International Conference on.** [S.l.: s.n.], 2009. p. 1116–1119. Citado na página [91](#).

YUSOF, R.; KHALID, M.; KHAIRUDDIN, A. M. Fuzzy logic-based pre-classifier for tropical wood species recognition system. **Machine Vision and Applications**, Springer Berlin Heidelberg, v. 24, n. 8, p. 1589–1604, 2013. ISSN 0932-8092. Citado 2 vezes nas páginas [91](#) e [92](#).

YUSOF, R.; KHALID, M.; KHAIRUDDIN, A. S. M. Application of kernel-genetic algorithm as nonlinear feature selection in tropical wood species recognition system. **Computers and Electronics in Agriculture**, v. 93, n. 0, p. 68 – 77, 2013. ISSN 0168-1699. Citado 2 vezes nas páginas [91](#) e [92](#).

ZAHN, C. T.; ROSKIES, R. Z. Fourier descriptors for plane closed curves. **Transactions on Computers, IEEE**, c-21, n. 3, p. 269–281, mar. 1972. Citado 2 vezes nas páginas [51](#) e [75](#).

ZHANG, Q.; XIE, C.; ZHANG, S.; WANG, A.; ZHU, B.; WANG, L.; YANG, Z. Identification and pattern recognition analysis of chinese liquors by doped nano zno gas sensor array. **Sensors and Actuators B: Chemical**, v. 110, n. 2, p. 370 – 376, 2005. ISSN 0925-4005. Citado na página [21](#).

ZHAO, P. Robust wood species recognition using variable color information. **Optik - International Journal for Light and Electron Optics**, v. 124, n. 17, p. 2833 – 2836, 2013. ISSN 0030-4026. Citado na página [91](#).

ZHAO, P.; DOU, G.; CHEN, G.-S. Wood species identification using feature-level fusion scheme. **Optik - International Journal for Light and Electron Optics**, v. 125, n. 3, p. 1144 – 1148, 2014. ISSN 0030-4026. Citado 2 vezes nas páginas [91](#) e [92](#).

ZHAO, P.; DOU, G.; CHEN, G.-S. Wood species identification using improved active shape model. **Optik - International Journal for Light and Electron Optics**, v. 125, n. 18, p. 5212 – 5217, 2014. ISSN 0030-4026. Citado 2 vezes nas páginas [91](#) e [92](#).

ZHOU, L.; ZHOU, Z.; HU, D. Scene classification using a multi-resolution bag-of-features model. **Pattern Recognition**, v. 0, n. 0, p. 1–28, 2012. ISSN 0031-3203. Citado 2 vezes nas páginas [33](#) e [34](#).

ZHU, S. C.; LIU, X.; WU, Y. N. Exploring texture ensembles by efficient markov chain monte carlo-toward a 'trichromacy' theory of texture. **IEEE Trans. Pattern Anal. Mach. Intell.**, v. 22, n. 6, p. 554–569, 2000. Citado na página [35](#).